


# Cálculo Numérico

Um Livro Colaborativo

Versão Scilab

5 de janeiro de 2017



# Organizadores

Dagoberto Adriano Rizzotto Justo - UFRGS

Esequia Sauter - UFRGS

Fabio Souto de Azevedo - UFRGS

Leonardo Fernandes Guidi - UFRGS

Matheus Correia dos Santos - UFRGS

Pedro Henrique de Almeida Konzen - UFRGS

# Licença

Este trabalho está licenciado sob a Licença Creative Commons Atribuição-CompartilhaIgual 3.0 Não Adaptada. Para ver uma cópia desta licença, visite <http://creativecommons.org/licenses/by-sa/3.0/> ou envie uma carta para Creative Commons, PO Box 1866, Mountain View, CA 94042, USA.

# Nota dos organizadores

Estamos escrevendo este livro de forma colaborativa desde 2011 e, recentemente, decidimos por abrir à colaborações externas. Nosso objetivo é produzir um material didático no nível de graduação de excelente qualidade e de acesso livre pela colaboração entre professores e alunos de universidades, institutos de educação e demais interessados na análise, estudo e aplicação de métodos numéricos nos mais diversos ramos da ciência e da tecnologia.

O sucesso do projeto depende da colaboração! Edite você mesmo o livro, dê sugestões ou nos avise de erros e imprecisões. Toda a colaboração é bem vinda. Saiba mais visitando o site oficial do projeto:

<http://www.ufrgs.br/numerico>

Nós preparamos uma série de ações para ajudá-lo a participar. Em primeiro lugar, o acesso irrestrito ao livro pode se dar através do [site oficial do projeto](#). Disponibilizamos o livro na versão original em [PDF](#) e versões adaptadas em [HTML](#), [EPUB](#) e [Slides](#). Além disso, o livro está escrito em código  $\text{\LaTeX}$  disponível em [repositório GitHub público](#).

Nada disso estaria completo sem uma licença apropriada à colaboração. Por isso, escolhemos disponibilizar o material do livro sob licença [Creative Commons Atribuição-CompartilhaIgual 3.0 Não Adaptada \(CC-BY-SA 3.0\)](#). Ou seja, você pode copiar, redistribuir, alterar e construir um novo material para qualquer uso, inclusive comercial. Leia a [licença](#) para maiores informações.

Desejamos-lhe ótimas colaborações!

# Prefácio

Este livro busca abordar os tópicos de um curso de introdução ao cálculo numérico moderno oferecido a estudantes de matemática, física, engenharias e outros. A ênfase é colocada na formulação de problemas, implementação em computador da resolução e interpretação de resultados. Pressupõe-se que o estudante domine conhecimentos e habilidades típicas desenvolvidas em cursos de graduação de cálculo, álgebra linear e equações diferenciais. Conhecimentos prévios em linguagem de computadores é fortemente recomendável, embora apenas técnicas elementares de programação sejam realmente necessárias.

Nesta versão do livro, fazemos ênfase na utilização do **software** livre **Scilab** para a implementação dos métodos numéricos abordados. Recomendamos ao leitor ter à sua disposição um computador com o **Scilab** instalado. Não é necessário estar familiarizado com esta linguagem, mas recomendamos a leitura do Apêndice A, no qual apresentamos uma rápida introdução a este pacote computacional. Alternativamente, existem algumas soluções em nuvem que fornecem acesso ao **Scilab** via internet. Por exemplo, a plataforma virtual rollApp (<https://www.rollapp.com/app/scilab>) ou o Scilab on Cloud (<http://cloud.scilab.in/>).

Os códigos computacionais dos métodos numéricos apresentados no livro são implementados em uma abordagem didática. Isto é, temos o objetivo de que a implementação em linguagem computacional venha a auxiliar o leitor no aprendizado das técnicas numéricas que são apresentadas no livro. Implementações computacionais eficientes de técnicas de cálculo numérico podem ser obtidas na série de livros “Numerical Recipes”, veja [10].

# Sumário

# Capítulo 1

## Introdução

Cálculo numérico é a disciplina que estuda as técnicas para a solução aproximada de problemas matemáticos. Estas técnicas são de natureza analítica e computacional. As principais preocupações normalmente envolvem exatidão e desempenho.

Aliado ao aumento contínuo da capacidade de computação disponível, o desenvolvimento de métodos numéricos tornou a simulação computacional de modelos matemáticos uma prática usual nas mais diversas áreas científicas e tecnológicas. As então chamadas simulações numéricas são constituídas de um arranjo de vários esquemas numéricos dedicados a resolver problemas específicos como, por exemplo: resolver equações algébricas, resolver sistemas lineares, interpolar e ajustar pontos, calcular derivadas e integrais, resolver equações diferenciais ordinárias etc. Neste livro, abordamos o desenvolvimento, a implementação, a utilização e os aspectos teóricos de métodos numéricos para a resolução desses problemas.

Trabalharemos com problemas que abordam aspectos teóricos e de utilização dos métodos estudados, bem como com problemas de interesse na engenharia, na física e na matemática aplicada.

A necessidade de aplicar aproximações numéricas decorre do fato de que esses problemas podem se mostrar intratáveis se dispomos apenas de meios puramente analíticos, como aqueles estudados nos cursos de cálculo e álgebra linear. Por exemplo, o teorema de Abel-Ruffini nos garante que não existe uma fórmula algébrica, isto é, envolvendo apenas operações aritméticas e radicais, para calcular as raízes de uma equação polinomial de qualquer grau, mas apenas casos particulares:

- Simplesmente isolar a incógnita para encontrar a raiz de uma equação do primeiro grau;
- Fórmula de Bhaskara para encontrar raízes de uma equação do segundo grau;
- Fórmula de Cardano para encontrar raízes de uma equação do terceiro grau;

- Existe expressão para equações de quarto grau;
- Casos simplificados de equações de grau maior que 4 onde alguns coeficientes são nulos também podem ser resolvidos.

Equações não polinomiais podem ser ainda mais complicadas de resolver exatamente, por exemplo:

$$\cos(x) = x \quad \text{e} \quad xe^x = 10$$

Para resolver o problema de valor inicial

$$y' + xy = x,$$

$$y(0) = 2,$$

podemos usar o método de fator integrante e obtemos  $y = 1 + e^{-x^2/2}$ . Já o cálculo da solução exata para o problema

$$y' + xy = e^{-y},$$

$$y(0) = 2,$$

não é possível.

Da mesma forma, resolvemos a integral

$$\int_1^2 xe^{-x^2} dx$$

pelo método da substituição e obtemos  $\frac{1}{2}(e^{-1} - e^{-2})$ . Porém a integral

$$\int_1^2 e^{-x^2} dx$$

não pode ser resolvida analiticamente.

A maioria dos modelos de fenômenos reais chegam em problemas matemáticos onde a solução analítica é difícil (ou impossível) de ser encontrada, mesmo quando provamos que ela existe. Nesse curso propomos calcular aproximações numéricas para esses problemas, que apesar de, em geral, serem diferentes da solução exata, mostraremos que elas podem ser bem próximas.

Para entender a construção de aproximações é necessário estudar um pouco como funciona a aritmética de computador e erros de arredondamento. Como computadores, em geral, usam uma base binária para representar números, começaremos falando em mudança de base.



# Capítulo 2

## Representação de números e aritmética de máquina

Neste capítulo, discutiremos sobre formas de representação de números em computadores. Iniciamos com uma discussão sobre representação posicional e mudança de base. Então, discutimos sobre representação com número de dígitos finitos e, mais especificamente, as representações de números inteiros, ponto fixo e ponto flutuante em computadores.

A representação de números e a aritmética em computadores levam aos chamados erros de arredondamento e de truncamento. Ao final deste capítulo, discutiremos sobre os efeitos do erro de arredondamento na computação científica.

### 2.1 Sistema de numeração e mudança de base

Usualmente, utilizamos o sistema de numeração decimal para representar números. Esse é um sistema de numeração posicional onde a posição do dígito indica a potência de 10 que o dígito está representando.

**Exemplo 2.1.1.** O número 293 é decomposto como

$$\begin{aligned} 293 &= 2 \text{ centenas} + 9 \text{ dezenas} + 3 \text{ unidades} \\ &= 2 \times 10^2 + 9 \times 10^1 + 3 \times 10^0. \end{aligned}$$

O sistema de numeração posicional também pode ser usado com outras bases. Vejamos a seguinte definição.

**Definição 2.1.1** (Sistema de numeração de base  $b$ ). *Dado um número natural  $b > 1$  e o conjunto de símbolos  $\{, -, \mathbf{0}, \mathbf{1}, \mathbf{2}, \dots, \mathbf{b-1}\}$ <sup>1</sup>, a sequência de símbolos*

$$(d_n d_{n-1} \cdots d_1 d_0, d_{-1} d_{-2} \cdots)_b$$

---

<sup>1</sup>Para  $b > 10$ , veja a observação 2.1.1

representa o número positivo

$$d_n \cdot b^n + d_{n-1} \cdot b^{n-1} + \dots + d_0 \cdot b^0 + d_{-1} \cdot b^{-1} + d_{-2} \cdot b^{-2} + \dots$$

Para representar números negativos usamos o símbolo  $-$  a esquerda do numeral.

**Observação 2.1.1** ( $b \geq 10$ ). Para sistemas de numeração com base  $b \geq 10$  é usual utilizar as seguintes notações:

- No sistema de numeração decimal ( $b = 10$ ), costumamos representar o número sem os parênteses e o subíndice, ou seja,

$$\pm d_n d_{n-1} \dots d_1 d_0, d_{-1} d_{-2} \dots := \pm (d_n d_{n-1} \dots d_1 d_0, d_{-1} d_{-2} \dots)_{10}$$

- Se  $b > 10$ , usamos as letras  $A, B, C, \dots$  para completar os símbolos:  $A = 10$ ,  $B = 11$ ,  $C = 12$ ,  $D = 13$ ,  $E = 14$ ,  $F = 15$ .

**Exemplo 2.1.2** (Sistema binário). O sistema de numeração em base dois é chamado de binário e os algarismos binários são conhecidos como *bits*, do inglês **binary digits**. Um *bit* pode assumir dois valores distintos: 0 ou 1. Por exemplo:

$$\begin{aligned} x &= (1001,101)_2 \\ &= 1 \cdot 2^3 + 0 \cdot 2^2 + 0 \cdot 2^1 + 1 \cdot 2^0 + 1 \cdot 2^{-1} + 0 \cdot 2^{-2} + 1 \cdot 2^{-3} \\ &= 8 + 0 + 0 + 1 + 0,5 + 0 + 0,125 = 9,625 \end{aligned}$$

Ou seja,  $(1001,101)_2$  é igual a 9,625 no sistema decimal.

**Exemplo 2.1.3** (Sistema quaternário). No sistema quaternário a base  $b$  é igual a 4. Por exemplo:

$$(301,2)_4 = 3 \cdot 4^2 + 0 \cdot 4^1 + 1 \cdot 4^0 + 2 \cdot 4^{-1} = 49,5$$

**Exemplo 2.1.4** (Sistema octal). No sistema octal a base é  $b = 8$  e utilizamos os símbolos em  $\{0, 1, 2, 3, 4, 5, 6, 7\}$ . Por exemplo:

$$\begin{aligned} (1357,24)_8 &= 1 \cdot 8^3 + 3 \cdot 8^2 + 5 \cdot 8^1 + 7 \cdot 8^0 + 2 \cdot 8^{-1} + 4 \cdot 8^{-2} \\ &= 512 + 192 + 40 + 7 + 0,25 + 0,0625 = 751,3125 \end{aligned}$$

**Exemplo 2.1.5** (Sistema hexadecimal). O sistema de numeração cuja a base é  $b = 16$  é chamado de sistema hexadecimal. O conjunto de símbolos necessários é  $S = \{“, ”, -, 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, A, B, C, D, E, F\}$ . Convertendo o número  $(E2AC)_{16}$  para a base 10 temos

$$\begin{aligned} (E2AC)_{16} &= 14 \cdot 16^3 + 2 \cdot 16^2 + 10 \cdot 16^1 + 12 \cdot 16^0 \\ &= 57344 + 512 + 160 + 12 = 58028 \end{aligned}$$

**Observação 2.1.2.** O Scilab oferece algumas funções para a conversão de números inteiros em dada base para a base decimal. Por exemplo, temos:

```
-->bin2dec('1001')
ans =
    9.
-->hex2dec('451')
ans =
   1105.
-->oct2dec('157')
ans =
   111.
-->base2dec('BEBA',16)
ans =
  48826.
```

A partir da definição 2.1.1, acabamos de mostrar vários exemplos de conversão de números de uma sistema de numeração de base  $b$  para o sistema decimal. Agora, vamos estudar como fazer o processo inverso. Isto é, dado um número decimal  $(X)_{10}$  queremos escrevê-lo em uma outra base  $b$ , isto é, queremos obter a seguinte representação:

$$\begin{aligned}(X)_{10} &= (d_n d_{n-1} \cdots d_0, d_{-1} \cdots)_b \\ &= d_n \cdot b^n + d_{n-1} \cdot b^{n-1} + \cdots + d_0 \cdot b^0 + d_{-1} \cdot b^{-1} + d_{-2} \cdot b^{-2} + \cdots\end{aligned}$$

Separando as partes inteira e fracionária de  $X$ , isto é,  $X = X^i + X^f$ , temos:

$$X^i = d_n \cdot b^n + \cdots + d_{n-1} b^{n-1} + d_1 \cdot b^1 + d_0 \cdot b^0$$

e

$$X^f = \frac{d_{-1}}{b^1} + \frac{d_{-2}}{b^2} + \cdots$$

Nosso objetivo é determinar os algarismos  $\{d_n, d_{n-1}, \dots\}$ .

Primeiramente, vejamos como tratar a parte inteira  $X^i$ . Calculando sua divisão por  $b$ , temos:

$$\frac{X^i}{b} = \frac{d_0}{b} + d_1 + d_2 b^1 + \cdots + d_{n-1} \cdot b^{n-2} + d_n \cdot b^{n-1}.$$

Observe que  $d_0$  é o resto da divisão de  $X^i$  por  $b$ , pois  $d_1 + d_2 b^1 + \cdots + d_{n-1} \cdot b^{n-2} + d_n \cdot b^{n-1}$  é inteiro e  $\frac{d_0}{b}$  é uma fração (lembramos que  $d_0 < b$ ). Da mesma forma, o resto da divisão de  $d_1 + d_2 b^1 + \cdots + d_{n-1} \cdot b^{n-2} + d_n \cdot b^{n-1}$  por  $b$  é  $d_1$ . Repetimos o processo até encontrar os símbolos  $d_0, d_1, d_2, \dots$

**Exemplo 2.1.6** (Conversão da parte inteira). Vamos escrever o número 125 na base 6. Para tanto, fazemos sucessivas divisões por 6 como segue:

$$\begin{aligned} 125 &= 20 \cdot 6 + 5 \quad (125 \text{ dividido por } 6 \text{ é igual a } 20 \text{ e resta } 5) \\ &= (3 \cdot 6 + 2) \cdot 6 + 5 = 3 \cdot 6^2 + 2 \cdot 6 + 5, \end{aligned}$$

logo  $125 = (325)_6$ .

Estes cálculos podem ser feitos no **Scilab** com o auxílio das funções **modulo** e **int**. A primeira calcula o resto da divisão entre dois números, enquanto que a segunda retorna a parte inteira de um número dado. No nosso exemplo, temos:

```
-->q = 125, d0 = modulo(q,6)
-->q = int(q/6), d1 = modulo(q,6)
-->q = int(q/6), d2 = modulo(q,6)
```

Verifique!

**Observação 2.1.3.** O **Scilab** oferece algumas funções para a conversão de números inteiros em base decimal para uma dada base. Por exemplo, temos:

```
-->dec2base(9,2)
ans =
1001
-->dec2base(111,8)
ans =
157
-->dec2base(48826,16)
ans =
BEBA
```

Vamos converter a parte fracionária de um número decimal em uma dada base  $b$ . Usando a notação  $X = X^i + X^f$  para as partes inteira e fracionária, respectivamente, temos:

$$bX^f = d_{-1} + \frac{d_{-2}}{b} + \frac{d_{-3}}{b^2} + \dots$$

Observe que a parte inteira desse produto é  $d_{-1}$  e  $\frac{d_{-2}}{b} + \frac{d_{-3}}{b^2} + \dots$  é a parte fracionária. Quando multiplicamos  $\frac{d_{-2}}{b} + \frac{d_{-3}}{b^2} + \dots$  por  $b$  novamente, encontramos  $d_{-2}$ . Repetimos o processo até encontrar todos os símbolos.

**Exemplo 2.1.7** (Conversão da parte fracionária). Escrever o número  $125,58\bar{3}$  na base 6. Do exemplo anterior temos que  $125 = (325)_6$ . Assim, nos resta converter a

parte fracionária. Para tanto, fazemos sucessivas multiplicações por 6 como segue:

$$\begin{aligned} 0,58\bar{3} &= 3,5 \cdot 6^{-1} \quad (0,58\bar{3} \text{ multiplicado por } 6 \text{ é igual a } 3,5) \\ &= 3 \cdot 6^{-1} + 0,5 \cdot 6^{-1} \\ &= 3 \cdot 6^{-1} + (3 \cdot 6^{-1}) \cdot 6^{-1} \\ &= 3 \cdot 6^{-1} + 3 \cdot 6^{-2}, \end{aligned}$$

logo  $0,58\bar{3} = (0,33)_6$ . As contas feitas aqui, também podem ser computadas no **Scilab**. Você sabe como?

Uma maneira de converter um número dado em uma base  $b_1$  para uma base  $b_2$  é fazer em duas partes: primeiro converter o número dado na base  $b_2$  para base decimal e depois converter para a base  $b_1$ .

## Exercícios

**E 2.1.1.** Converta para base decimal cada um dos seguintes números:

- |              |              |                |               |
|--------------|--------------|----------------|---------------|
| a) $(100)_2$ | c) $(100)_b$ | e) $(AA)_{16}$ | g) $(3,12)_5$ |
| b) $(100)_3$ | d) $(12)_5$  | f) $(7,1)_8$   |               |

**E 2.1.2.** Escreva os números abaixo na base decimal.

- a)  $(25,13)_8$
- b)  $(101,1)_2$
- c)  $(12F,4)_{16}$
- d)  $(11,2)_3$

**E 2.1.3.** Escreva cada número decimal na base  $b$ .

- a)  $7,\bar{6}$  na base  $b = 5$
- b)  $29,1\bar{6}$  na base  $b = 6$

**E 2.1.4.** Escreva cada número dado para a base  $b$ .

- a)  $(45,1)_8$  para a base  $b = 2$

- b)  $(21,2)_8$  para a base  $b = 16$
- c)  $(1001,101)_2$  para a base  $b = 8$
- d)  $(1001,101)_2$  para a base  $b = 16$

**E 2.1.5.** Escreva o número  $x = 5,5$  em base binária.

**E 2.1.6.** Escreva o número  $x = 17,109375$  em base hexadecimal (16).

**E 2.1.7.** Quantos algarismos são necessários para representar o número 937163832173947 em base binária? E em base 7? Dica: Qual é o menor e o maior inteiro que pode ser escrito em dada base com  $N$  algarismos?

**E 2.1.8.** Escreva  $x = (12,4)_8$  em base decimal e binária.

## 2.2 Notação científica e notação normalizada

Como vimos, no sistema posicional usual um número  $x$  na base  $b$  é representado por

$$x = \pm(d_n d_{n-1} \cdots d_0, d_{-1} d_{-2} d_{-3} \cdots)_b,$$

onde  $d_n \neq 0$  e  $d_i \in \{0, 1, \dots, b-1\}$  é o dígito da  $i$ -ésima posição. Alternativamente, é costumeiro usarmos a chamada notação científica. Nesta, o número  $x$  é representado como

$$x = \pm(M)_b \times b^e,$$

onde  $(M)_b = (d_m d_{m-1} \cdots d_0, d_{-1} d_{-2} d_{-3} \cdots)_b$  é chamada de mantissa e  $e \in \mathbb{Z}$  é chamado de expoente de  $x$ .

**Exemplo 2.2.1.** a) O número 602,2141 em notação científica pode ser escrito como

$$602,2141 \times 10^0 = 60,22141 \times 10^1 = 0,6022141 \times 10^3.$$

- b) O número  $(1010,10)_2$  pode ser escrito em notação científica como  $(10,1010)_2 \times 2^2$ .

Observamos que um número pode ser representado de várias formas equivalentes em notação científica. Para termos uma representação única introduzimos o conceito de notação normalizada.

**Definição 2.2.1.** Um número  $x$  na base  $b$  é dito estar representado em notação (científica) normalizada quando está escrito na forma

$$x = (-1)^s (M)_b \times b^E,$$

onde  $(M)_b = (d_1, d_{-1}d_{-2}d_{-3}\dots)_b$ , com  $d_1 \neq 0$ <sup>23</sup>,  $s$  é 0 para positivo e 1 para negativo,  $E$  é o expoente.

**Exemplo 2.2.2.** Vejamos os seguintes casos:

- a) O número 602,2141 em notação (científica) normalizada é representado por  $6,022141 \times 10^2$ .
- b) O número  $(1010,10)_2$  escrito em notação normalizada é  $(1,01010)_2 \times 2^3$ .

**Observação 2.2.1.** No Scilab, A representação em ponto flutuante decimal com 8 dígitos é a padrão, por exemplo:

```
-->-%pi
ans =
- 3.14159D+00
```

Podemos controlar a impressão de números com o comando `format`. Por exemplo:

```
-->format('v',12); -%pi
ans =
- 3.141592654
-->format('e',12); -%pi
ans =
- 3.14159D+00
```

Observamos que, no primeiro caso, obtemos a representação em ponto flutuante decimal com 10 dígitos (2 posições são reservadas para o sinal e o ponto), enquanto que na segunda obtemos a representação em notação científica normalizada com 6 dígitos (6 posições são reservadas para o sinal, ponto, símbolo  $D := 10$  e expoente). Alternativamente, podemos usar o comando `printf`, por exemplo:

```
-->printf('%1.5f',-%pi)
-3.14159
-->printf('%1.5e',-%pi)
-3.14159e+00
```

<sup>2</sup>Em algumas referências é usado  $M_b = (0, d_{-1}d_{-2}d_{-3}\dots)_b$ .

<sup>3</sup>No caso de  $x = 0$ ,  $M_b = (0,00\dots)_b$ .

### 2.2.1 Exercícios

**E 2.2.1.** Represente os seguintes números em notação científica normalizada:

$$\begin{array}{ll} a) 299792,458 & b) 66,2607 \times 10^{-35} \\ c) 0,6674 \times 10^{-7} & d) 9806,65 \times 10^1 \end{array}$$

**E 2.2.2.** Use o computador para verificar as respostas do Exercício 2.2.1.

## 2.3 Representação decimal finita

Em computadores, é usual representarmos números usando uma quantidade de dígitos finita. A quantidade a ser usada normalmente depende da precisão com que as computações estão sendo feitas. Ocorre, que quando restringimos a representação a um número finito de dígitos, muitos números não podem ser representado de forma exata. Por exemplo, dízimas infinitas e números irracionais não são usualmente representados de forma exata em computadores. Esta questão nos leva aos conceitos de número de dígitos significativos e arredondamento.

**Definição 2.3.1** (Número de dígitos significativos). *Um número decimal  $x = \pm d_1 d_{-1} \cdots d_{-i} d_{-i-1} \cdots d_{-i-n} d_{-i-n-1} \cdots \times 10^E$  é dito ter  $n$  dígitos significativos quando  $d_j = 0$  para  $j \geq -i$  e  $j \leq -i - n - 1$ .*

**Exemplo 2.3.1.** O número  $0,0602100 \times 10^{-3}$  tem 4 dígitos significativos.

### 2.3.1 Arredondamento de números

Quando representamos um número  $x$  com uma quantidade de dígitos menor que a de dígitos significativos acabamos com uma aproximação deste. Este procedimento é chamado arredondamento de um número. Mais precisamente, seja dado

$$x = \pm d_0 d_1 d_2 \cdots d_{k-1} d_k d_{k+1} \cdots d_n \times 10^e$$

em notação normalizada, i.e.  $d_0 \neq 0$ . Podemos representar  $x$  com  $k$  dígitos fazendo:

1. **Arredondamento por truncamento** (ou corte): aproximamos  $x$  por

$$\bar{x} = \pm d_0 d_1 d_2 \cdots d_k \times 10^e$$

simplesmente descartando os dígitos  $d_j$  com  $j > k$ .



2. **Arredondamento por proximidade:** se  $d_{k+1} < 5$  aproximamos  $x$  por

$$\bar{x} = \pm d_0, d_1 d_2 \dots d_k \times 10^e$$

senão aproximamos  $x$  por<sup>4</sup>

$$\bar{x} = \pm (d_0, d_1 d_2 \dots d_k + 10^{-k}) \times 10^e$$

**Exemplo 2.3.2.** Represente os números  $x_1 = 0,567$ ,  $x_2 = 0,233$ ,  $x_3 = -0,675$  e  $x_4 = 0,314159265 \dots \times 10^1$  com dois dígitos significativos por truncamento e arredondamento.

**Solução.** Vejamos cada caso:

- Por truncamento:

$$x_1 = 0,56, \quad x_2 = 0,23, \quad x_3 = -0,67 \quad \text{e} \quad x_4 = 3,1.$$

No Scilab, podemos obter a representação de  $x_3 = -0,675$  fazendo:

```
-->format('v',5)
-->-int(0.675*1e2)/1e2
ans =
- 0.67
```

e, em notação normalizada, temos:

```
-->format('e',8)
-->-int(0.675*1e2)/1e2
ans =
- 6.7D-01
```

- Por arredondamento:

$$x_1 = 0,57; \quad x_2 = 0,23; \quad x_3 = -0,68 \quad \text{e} \quad x_4 = 3,1.$$

No Scilab, a representação de números por arredondamento é o padrão. Assim, para obtermos a representação desejada de  $x_3 = 0,675$  fazemos:

---

<sup>4</sup>Note que essas duas opções são equivalentes a somar 5 no dígito a direita do corte e depois arredondar por corte, ou seja, arredondar por corte

$$\pm (d_0, d_1 d_2 \dots d_k d_{k+1} + 5 \times 10^{-(k+1)}) \times 10^e$$

```
-->format('v',5)
-->-0.675
ans  =
- 0.68
```

e, em notação normalizada, temos:

```
-->format('e',8)
-->-0.675
ans  =
- 6.8D-01
```

◇

**Observação 2.3.1.** Observe que o arredondamento pode mudar todos os dígitos e o expoente da representação em ponto flutuante de um número dado. Por exemplo, o arredondamento de  $0,9999 \times 10^{-1}$  com 3 dígitos significativos é  $0,1 \times 10^0$ .

## 2.4 Representação de números em máquina

Os computadores, em geral, usam a base binária para representar os números, onde as posições, chamadas de bits, assume as condições “verdadeiro” ou “falso”, ou seja, 0 ou 1. Os computadores representam os números com uma quantidade fixa de bits, o que se traduz em um conjunto finito de números representáveis. Os demais números são tomados por proximidade àqueles conhecidos, gerando erros de arredondamento. Por exemplo, em aritmética de computador, o número 2 tem representação exata, logo  $2^2 = 4$ , mas  $\sqrt{3}$  não tem representação finita, logo  $(\sqrt{3})^2 \neq 3$ .

Veja isso no Scilab:

```
-->2^2 == 4
ans  =
T
-->sqrt(3)^2 == 3
ans  =
F
```

### 2.4.1 Números inteiros

Tipicamente, um número inteiro é armazenado em um computador como uma sequência de dígitos binários de comprimento fixo denominado **registro**.

### Representação sem sinal

Um registro com  $n$  bits da forma

$d_{n-1}$	$d_{n-2}$	$\cdots$	$d_1$	$d_0$
-----------	-----------	----------	-------	-------

representa o número  $(d_{n-1}d_{n-2}\dots d_1d_0)_2$ .

Assim, é possível representar números inteiros entre

$$(111\dots 111)_2 = 2^{n-1} + 2^{n-2} + \cdots + 2^1 + 2^0 = 2^n - 1.$$

$$\vdots$$

$$(000\dots 011)_2 = 3$$

$$(000\dots 010)_2 = 2$$

$$(000\dots 001)_2 = 1$$

$$(000\dots 000)_2 = 0$$

**Exemplo 2.4.1.** No Scilab,

```
-->uint8( bin2dec('00000011') )
ans = 3
-->uint8( bin2dec('11111110') )
ans = 254
```

### Representação com bit de sinal

O bit mais significativo (o primeiro à esquerda) representa o sinal: por convenção, 0 significa positivo e 1 significa negativo. Um registro com  $n$  bits da forma

$s$	$d_{n-2}$	$\cdots$	$d_1$	$d_0$
-----	-----------	----------	-------	-------

representa o número  $(-1)^s(d_{n-2}\dots d_1d_0)_2$ . Assim, é possível representar números inteiros entre  $-2^{n-1}$  e  $2^{n-1}$ , com duas representações para o zero:  $(1000\dots 000)_2$  e  $(00000\dots 000)_2$ .

**Exemplo 2.4.2.** Em um registro com 8 bits, teremos os números

$$(11111111)_2 = -(2^6 + \dots + 2 + 1) = -127$$

$$\vdots$$

$$(10000001)_2 = -1$$

$$(10000000)_2 = -0$$

$$(01111111)_2 = 2^6 + \dots + 2 + 1 = 127$$

$$\vdots$$

$$(00000010)_2 = 2$$

$$(00000001)_2 = 1$$

$$(00000000)_2 = 0$$

### Representação complemento de dois

O bit mais significativo (o primeiro à esquerda) representa o coeficiente de  $-2^{n-1}$ . Um registro com  $n$  bits da forma:

$d_{n-1}$	$d_{n-2}$	$\dots$	$d_1$	$d_0$
-----------	-----------	---------	-------	-------

representa o número  $-d_{n-1}2^{n-1} + (d_{n-2}\dots d_1d_0)_2$ .

Note que todo registro começando com 1 será um número negativo.

**Exemplo 2.4.3.** O registro com 8 bits  $[01000011]$  representa o número:

$$-0(2^7) + (1000011)_2 = 64 + 2 + 1 = 67.$$

O registro com 8 bits  $[10111101]$  representa o número:

$$-1(2^7) + (0111101)_2 = -128 + 32 + 16 + 8 + 4 + 1 = -67.$$

Note que podemos obter a representação de  $-67$  invertendo os dígitos de 67 em binário e somando 1.

**Exemplo 2.4.4.** Em um registro com 8 bits, teremos os números

$$\begin{aligned}
 (11111111)_2 &= -2^7 + 2^6 + \cdots + 2 + 1 = -1 \\
 &\vdots \\
 (10000001)_2 &= -2^7 + 1 = -127 \\
 (10000000)_2 &= -2^7 = -128 \\
 (01111111)_2 &= 2^6 + \cdots + 2 + 1 = 127 \\
 &\vdots \\
 (00000010)_2 &= 2 \\
 (00000001)_2 &= 1 \\
 (00000000)_2 &= 0
 \end{aligned}$$

**Exemplo 2.4.5.** No Scilab,

```
-->int8( bin2dec('00000011') )
ans = 3
-->int8( bin2dec('11111110') )
ans = -2
```

## 2.4.2 Sistema de ponto fixo

O sistema de ponto fixo representa as partes inteira e fracionária do número com uma quantidade fixas de dígitos.

**Exemplo 2.4.6.** Em um computador de 32 bits que usa o sistema de ponto fixo, o registro

$d_{31}$	$d_{30}$	$d_{29}$	$\cdots$	$d_1$	$d_0$
----------	----------	----------	----------	-------	-------

pode representar o número

- $(-1)^{d_{31}}(d_{30}d_{29}\cdots d_{17}d_{16}, d_{15}d_{14}\cdots d_1d_0)_2$  se o sinal for representado por um dígito. Observe que nesse caso o zero possui duas representações possíveis:

10000000000000000000000000000000

e

00000000000000000000000000000000

- $(d_{30}d_{29} \cdots d_{17}d_{16})_2 - d_{31}(2^{15} - 2^{-16}) + (0, d_{15}d_{14} \cdots d_1d_0)_2$  se o sinal do número estiver representado por uma implementação em complemento de um. Observe que o zero também possui duas representações possíveis:

11111111111111111111111111111111

e

00000000000000000000000000000000

- $(d_{30}d_{29} \cdots d_{17}d_{16})_2 - d_{31}2^{15} + (0, d_{15}d_{14} \cdots d_1d_0)_2$  se o sinal do número estiver representado por uma implementação em complemento de dois. Nesse caso o zero é unicamente representado por

00000000000000000000000000000000

Observe que 16 dígitos são usados para representar a parte fracionária, 15 são para representar a parte inteira e um dígito, o  $d_{31}$ , está relacionado ao sinal do número.

### 2.4.3 Sistema de ponto flutuante

O sistema de ponto flutuante não possui quantidade fixa de dígitos para as partes inteira e fracionária do número.

Podemos definir uma máquina  $F$  em ponto flutuante de dois modos:

$$F(\beta, |M|, |E|, BIAS) \text{ ou } F(\beta, |M|, E_{MIN}, E_{MAX})$$

onde

- $\beta$  é a base (em geral 2 ou 10),
- $|M|$  é o número de dígitos da mantissa,
- $|E|$  é o número de dígitos do expoente,
- $BIAS$  é um valor de deslocamento do expoente (veja a seguir),
- $E_{MIN}$  é o menor expoente,
- $E_{MAX}$  é o maior expoente.

Considere uma máquina com um registro de 64 bits e base  $\beta = 2$ . Pelo padrão IEEE754, 1 bit é usado para o sinal, 11 bits para o expoente e 52 bits são usados para o significando tal que

$s$	$c_{10}$	$c_9$	$\cdots$	$c_0$	$m_1$	$m_2$	$\cdots$	$m_{51}$	$m_{52}$
-----	----------	-------	----------	-------	-------	-------	----------	----------	----------

represente o número (o  $BIAS = 1023$  por definição)

$$x = (-1)^s M \times 2^{c-BIAS},$$

onde a **característica** é representada por

$$c = (c_{10}c_9 \cdots c_1c_0)_2 = c_{10}2^{10} + \cdots + c_12^1 + c_02^0$$

e o significando por

$$M = (1.m_1m_2 \cdots m_{51}m_{52})_2.$$

Em base 2 não é necessário armazenar o primeiro dígito (por quê?).

Por exemplo, o registro

$$[0|100\ 0000\ 0000|1010\ 0000\ 0000\ldots 0000\ 0000]$$

representa o número

$$(-1)^0(1 + 2^{-1} + 2^{-3}) \times 2^{1024-1023} = (1 + 0.5 + 0.125)2 = 3.25.$$

### O expoente deslocado

Uma maneira de representar os expoentes inteiros é deslocar todos eles uma mesma quantidade. Desta forma permitimos a representação de números negativos e a ordem deles continua crescente. O expoente é representado por um inteiro sem sinal do qual é deslocado o **BIAS**.

Tendo  $|E|$  dígitos para representar o expoente, geralmente o  $BIAS$  é predefinido de tal forma a dividir a tabela ao meio de tal forma que o expoente *um* seja representado pela sequência  $[100\ldots 000]$ .

**Exemplo 2.4.7.** Com 64 bits, pelo padrão *IEEE754*, temos que  $|E| := 11$ . Assim,  $(100\ 0000\ 0000)_2 = 2^{10} = 1024$ . Como queremos que esta sequência represente o 1, definimos  $BIAS := 1023$ , pois

$$1024 - BIAS = 1.$$

Com 32 bits, temos  $|E| := 8$  e  $BIAS := 127$ . E com 128 bits, temos  $|E| := 15$  e  $BIAS := 16383$ .

Com 11 bits temos

$$\begin{aligned}
 [111\ 1111\ 1111] &= \textit{reservado} \\
 [111\ 1111\ 1110] &= 2046 - BIAS = 1023_{10} = E_{MAX} \\
 &\vdots = \\
 [100\ 0000\ 0001] &= 2^{10} + 1 - BIAS = 2_{10} \\
 [100\ 0000\ 0000] &= 2^{10} - BIAS = 1_{10} \\
 [011\ 1111\ 1111] &= 1023 - BIAS = 0_{10} \\
 [011\ 1111\ 1110] &= 1022 - BIAS = -1_{10} \\
 &\vdots = \\
 [000\ 0000\ 0001] &= 1 - BIAS = -1022 = E_{MIN} \\
 [000\ 0000\ 0000] &= \textit{reservado}
 \end{aligned}$$

O maior expoente é dado por  $E_{MAX} = 1023$  e o menor expoente é dado por  $E_{MIN} = -1022$ .

O menor número representável positivo é dado pelo registro

$$[0|000\ 0000\ 000\textcolor{red}{1}|\textcolor{blue}{0000\ 0000\ 0000\dots0000\ 0000}]$$

quando  $s = 0$ ,  $c = \textcolor{red}{1}$  e  $M = (1.\textcolor{blue}{000\dots000})_2$ , ou seja,

$$MINR = (1 + \textcolor{blue}{0})_2 \times 2^{\textcolor{red}{1}-1023} \approx 0.2225 \times 10^{-307}.$$

O maior número representável é dado por

$$[0|\textcolor{red}{111\ 1111\ 1110}|\textcolor{blue}{1111\ 1111\ \dots1111\ 1111}]$$

quando  $s = 0$ ,  $c = 2046$  e  $M = (1.1111\ 1111\dots1111)_2 = 2 - 2^{-52}$ , ou seja,

$$MAXR = (2 - 2^{-52}) \times 2^{2046-1023} \approx 2^{1024} \approx 0.17977 \times 10^{309}.$$

### Casos especiais

O **zero** é um caso especial representado pelo registro

$$[0|\textcolor{red}{000\ 0000\ 0000}|\textcolor{blue}{0000\ 0000\ 0000\dots0000\ 0000}]$$

Os expoentes **reservados** são usados para casos especiais:

- $c = [0000\dots0000]$  é usado para representar o zero (se  $m = 0$ ) e os números subnormais (se  $m \neq 0$ ).



- $c = [1111...1111]$  é usado para representar o infinito (se  $m = 0$ ) e NaN (se  $m \neq 0$ ).

Os números subnormais<sup>5</sup> tem a forma

$$x = (-1)^s (0.m_1 m_2 \cdots m_{51} m_{52})_2 \times 2^{1-BIAS}.$$

**Observação 2.4.1.** O menor número positivo, o maior número e o menor número subnormal representáveis no Scilab são:

```
-->MINR=number_properties('tiny')
-->MAXR=number_properties('huge')
-->number_properties('tiniest')
```

Outras informações sobre a representação em ponto flutuante podem ser obtidas com `help number_properties`.

### 2.4.4 Precisão e épsilon de máquina

A **precisão**  $p$  de uma máquina é o número de dígitos significativos usado para representar um número. Note que  $p = |M| + 1$  em binário e  $p = |M|$  para outras bases.

O **épsilon de máquina**,  $\epsilon_{mach} = \epsilon$ , é definido de forma que  $1 + \epsilon$  seja o menor número representável maior que 1, isto é,  $1 + \epsilon$  é representável, mas não existem números representáveis em  $(1, 1 + \epsilon)$ .

**Exemplo 2.4.8.** Com 64 bits, temos que o epsilon será dado por

$$\begin{aligned} 1 &\rightarrow (1.0000\ 0000...0000)_2 \times 2^0 \\ \epsilon &\rightarrow +(0.0000\ 0000...0001)_2 \times 2^0 = 2^{-52} \\ &\quad (1.0000\ 0000...0001)_2 \times 2^0 \neq 1 \end{aligned}$$

Assim,  $\epsilon = 2^{-52}$ .

### 2.4.5 Distribuição dos números

Utilizando uma máquina em ponto flutuante, temos um número finito de números que podemos representar.

Um número muito pequeno geralmente é aproximado por zero (underflow) e um número muito grande (overflow) geralmente faz o cálculo parar. Além disso, os números não estão uniformemente espaçados no eixo real. Números pequenos estão bem próximos enquanto que números com expoentes grandes estão bem distantes.

<sup>5</sup>Note que poderíamos definir números um pouco menores que o  $MINR$ .

Se tentarmos armazenar um número que não é representável, devemos utilizar o número mais próximo, gerando os erros de arredondamento.

Por simplicidade, a partir daqui, nós adotaremos  $b = 10$ .

**Observação 2.4.2.** O chamado modo de exceção de ponto flutuante é controlado pela função `ieee`. O padrão do Scilab é `ieee(0)`. Estude os seguintes resultados das seguintes operações usando os diferentes modos de exceção:

```
-->2*number_properties('huge'), 1/2^999, 1/0, 1/-0
```

## Exercícios

**E 2.4.1.** Explique a diferença entre o sistema de ponto fixo e ponto flutuante.

**E 2.4.2.** Considere a seguinte rotina escrita para ser usada no Scilab:

```
x=1
while x+1>x
    x=x+1
end
```

Explique se esta rotina finaliza em tempo finito, em caso afirmativo calcule a ordem de grandeza do tempo de execução supondo que cada passo do laço demore  $10^{-7}s$ . Justifique sua resposta.

## 2.5 Tipos de Erros

Em geral, os números não são representados de forma exata nos computadores. Isto nos leva ao chamado erro de arredondamento. Quando resolvemos problemas com técnicas numéricas estamos sujeitos a este e outros tipos de erros. Nesta seção, veremos quais são estes erros e como controlá-los, quando possível.

Quando fazemos aproximações numéricas, os erros são gerados de várias formas, sendo as principais delas as seguintes:

1. **Incerteza dos dados:** equipamentos de medição possuem precisão finita, acarretando erros nas medidas físicas.
2. **Erros de Arredondamento:** são aqueles relacionados com as limitações que existem na forma representar números de máquina.

3. **Erros de Truncamento:** surgem quando aproximamos um procedimento formado por uma sequência infinita de passos através de um procedimento finito. Por exemplo, a definição de integral é dada por uma soma infinita e a aproximamos por uma soma finita. O erro de truncamento deve ser analisado para cada método empregado.

Uma questão fundamental é a quantificação dos erros que estamos sujeitos ao computar a solução de um dado problema. Para tanto, precisamos definir medidas de erros (ou de exatidão). As medidas de erro mais utilizadas são o **erro absoluto** e o **erro relativo**.

**Definição 2.5.1** (Erro absoluto e relativo). *Seja  $x$  um número real e  $\bar{x}$  sua aproximação. O erro absoluto da aproximação  $\bar{x}$  é definido como*

$$|x - \bar{x}|.$$

*O erro relativo da aproximação  $\bar{x}$  é definido como*

$$\frac{|x - \bar{x}|}{|x|}, \quad x \neq 0.$$

**Observação 2.5.1.** Observe que o erro relativo é adimensional e, muitas vezes, é dado em porcentagem. Mais precisamente, o erro relativo em porcentagem da aproximação  $\bar{x}$  é dado por

$$\frac{|x - \bar{x}|}{|x|} \times 100\%.$$

**Exemplo 2.5.1.** Sejam  $x = 123456,789$  e sua aproximação  $\bar{x} = 123000$ . O erro absoluto é

$$|x - \bar{x}| = |123456,789 - 123000| = 456,789$$

e o erro relativo é

$$\frac{|x - \bar{x}|}{|x|} = \frac{456,789}{123456,789} \approx 0,00369999 \text{ ou } 0,36\%$$

**Exemplo 2.5.2.** Sejam  $y = 1,23456789$  e  $\bar{y} = 1,13$ . O erro absoluto é

$$|y - \bar{y}| = |1,23456789 - 1,13| = 0,10456789$$

que parece pequeno se compararmos com o exemplo anterior. Entretanto o erro relativo é

$$\frac{|y - \bar{y}|}{|y|} = \frac{0,10456789}{1,23456789} \approx 0,08469999 \text{ ou } 8,4\%$$

Note que o erro relativo leva em consideração a escala do problema.

**Exemplo 2.5.3.** Observe os erros absolutos e relativos em cada caso

$x$	$\bar{x}$	Erro absoluto	Erro relativo
$0,\bar{3} \times 10^{-2}$	$0,3 \times 10^{-2}$	$0,\bar{3} \times 10^{-3}$	10%
$0,\bar{3}$	$0,3$	$0,\bar{3} \times 10^{-2}$	10%
$0,\bar{3} \times 10^2$	$0,3 \times 10^2$	$0,\bar{3} \times 10^1$	10%

Outra forma de medir a exatidão de uma aproximação numérica é contar o **número de dígitos significativos corretos** em relação ao valor exato.

**Definição 2.5.2** (Número de dígitos significativos corretos). *A aproximação  $\bar{x}$  de um número  $x$  tem  $s$  **dígitos significativos corretos** quando<sup>6</sup>*

$$\frac{|x - \bar{x}|}{|x|} < 5 \times 10^{-s}.$$

**Exemplo 2.5.4.** Vejamos os seguintes casos:

- a) A aproximação de  $x = 0,333333$  por  $\bar{x} = 0,333$  tem 3 dígitos significativos corretos, pois

$$\frac{|x - \bar{x}|}{|x|} = \frac{0,000333}{0,333333} \approx 0,000999 \leq 5 \times 10^{-3}.$$

- b) Considere as aproximações  $\bar{x}_1 = 0,666$  e  $\bar{x}_2 = 0,667$  de  $x = 0,666888$ . Os erros relativos são

$$\frac{|x - \bar{x}_1|}{|x|} = \frac{|0,666888 - 0,666|}{0,666888} \approx 0,00133... < 5 \times 10^{-3}.$$

$$\frac{|x - \bar{x}_2|}{|x|} = \frac{|0,666888 - 0,667|}{0,666888} \approx 0,000167... < 5 \times 10^{-4}.$$

Note que  $\bar{x}_1$  possui 3 dígitos significativos corretos e  $\bar{x}_2$  possui 4 dígitos significativos (o quarto dígito é o dígito 0 que não aparece a direita, i.e.,  $\bar{x}_2 = 0.\textcolor{red}{6670}$ ). Isto também leva a conclusão que  $x_2$  aproxima melhor o valor de  $x$  do que  $x_1$  pois está mais próximo de  $x$ .

<sup>6</sup>Esta definição é apresentada em [3]. Não existe uma definição única na literatura para o conceito de dígitos significativos corretos, embora não precisamente equivalentes, elas transmitem o mesmo conceito. Uma maneira de interpretar essa regra é: calcula-se o erro relativo na forma normalizada e a partir da ordem do expoente temos o número de dígitos significativos corretos. Como queremos o expoente, podemos estimar  $s$  por

$$DIGSE(x, \bar{x}) = s \approx \text{int} \left\lceil \log_{10} \frac{|x - \bar{x}|}{|x|} \right\rceil.$$

c)  $\bar{x} = 9,999$  aproxima  $x = 10$  com 4 dígitos significativos corretos, pois

$$\frac{|x - \bar{x}|}{|x|} = \frac{|10 - 9,999|}{10} \approx 0,0000999... < 5 \times 10^{-4}.$$

d) Considere as aproximações  $\bar{x}_1 = 1,49$  e  $\bar{x}_2 = 1,5$  de  $x = 1$ . Da definição, temos que 1,49 aproxima 1 com um dígito significativo correto (verifique), enquanto 1,5 tem zero dígito significativo correto, pois:

$$\frac{|1 - 1,5|}{|1|} = 5 \times 10^{-1} < 5 \times 10^0.$$

## Exercícios

**E 2.5.1.** Calcule os erros absoluto e relativo das aproximações  $\bar{x}$  para  $x$ .

a)  $x = \pi = 3,14159265358979 \dots$  e  $\bar{x} = 3,141$

b)  $x = 1,00001$  e  $\bar{x} = 1$

c)  $x = 100001$  e  $\bar{x} = 100000$

**E 2.5.2.** Arredonde os seguintes números para cinco algarismos significativos corretos:

a) 1,7888544

c) 0,0017888544

e)  $2,1754999 \times 10^{-10}$

b) 1788,8544

d) 0,004596632

f)  $2,1754999 \times 10^{10}$

**E 2.5.3.** Verifique quantos são os dígitos significativos corretos em cada aproximação  $\bar{x}$  para  $x$ .

a)  $x = 2,5834$  e  $\bar{x} = 2,6$

b)  $x = 100$  e  $\bar{x} = 99$

**E 2.5.4.** Represente os números 3276; 42,55 e 0,00003331 com três dígitos significativos por truncamento e arredondamento.

**E 2.5.5.** Resolva a equação  $0,1x - 0,01 = 12$  usando arredondamento com três dígitos significativos em cada passo e compare com o resultado analítico

**E 2.5.6.** Calcule o erro relativo e absoluto envolvido nas seguintes aproximações e expresse as respostas com três algarismos significativos corretos.

a)  $x = 3,1415926535898$  e  $\tilde{x} = 3,141593$

b)  $x = \frac{1}{7}$  e  $\tilde{x} = 1,43 \times 10^{-1}$

## 2.6 Erros nas operações elementares

O erro relativo presente nas operações elementares de adição, subtração, multiplicação e divisão é da ordem do epsilon de máquina. Se estivermos usando uma máquina com 64 bits, temos que  $\epsilon = 2^{-52} \approx 2,22E16$ .

Este erro é bem pequeno! Assumindo que  $x$  e  $y$  são representados com todos dígitos corretos, temos aproximadamente 15 dígitos significativos corretos quando fazemos uma das operações  $x + y$ ,  $x - y$ ,  $x \times y$  ou  $x/y$ .

Mesmo que fizéssemos, por exemplo, 1000 operações elementares em ponto flutuante sucessivas, teríamos, no pior dos casos, acumulado todos esses erros e perdido 3 casas decimais ( $1000 \times 10^{-15} \approx 10^{-12}$ ).

Entretanto, quando subtraímos números muito próximos, os problemas aumentam.

## 2.7 Cancelamento catastrófico

Quando fazemos subtrações com números muito próximos entre si ocorre o cancelamento catastrófico, onde podemos perder vários dígitos de precisão em uma única subtração.

**Exemplo 2.7.1.** Efetue a operação

$$0,987624687925 - 0,987624 = 0,687925 \times 10^{-6}$$

usando arredondamento com seis dígitos significativos e observe a diferença se comparado com resultado sem arredondamento.

**Solução.** Os números arredondados com seis dígitos para a mantissa resultam na seguinte diferença

$$0,987625 - 0,987624 = 0,100000 \times 10^{-5}$$

Observe que os erros relativos entre os números exatos e aproximados no lado esquerdo são bem pequenos,

$$\frac{|0,987624687925 - 0,987625|}{|0,987624687925|} = 0,00003159$$

e

$$\frac{|0,987624 - 0,987624|}{|0,987624|} = 0\%,$$

enquanto no lado direito o erro relativo é enorme:

$$\frac{|0,100000 \times 10^{-5} - 0,687925 \times 10^{-6}|}{0,687925 \times 10^{-6}} = 45,36\%.$$

◇

**Exemplo 2.7.2.** Considere o problema de encontrar as raízes da equação de segundo grau

$$x^2 + 300x - 0,014 = 0,$$

usando seis dígitos significativos.

Aplicando a fórmula de Bhaskara com  $a = 0,100000 \times 10^1$ ,  $b = 0,300000 \times 10^3$  e  $c = 0,140000 \times 10^{-1}$ , temos o discriminante:

$$\begin{aligned} \Delta &= b^2 - 4 \cdot a \cdot c \\ &= 0,300000 \times 10^3 \times 0,300000 \times 10^3 \\ &\quad + 0,400000 \times 10^1 \times 0,100000 \times 10^1 \times 0,140000 \times 10^{-1} \\ &= 0,900000 \times 10^5 + 0,560000 \times 10^{-1} \\ &= 0,900001 \times 10^5 \end{aligned}$$

e as raízes:

$$\begin{aligned} x_1, x_2 &= \frac{-0,300000 \times 10^3 \pm \sqrt{\Delta}}{0,200000 \times 10^1} \\ &= \frac{-0,300000 \times 10^3 \pm \sqrt{0,900001 \times 10^5}}{0,200000 \times 10^1} \\ &= \frac{-0,300000 \times 10^3 \pm 0,300000 \times 10^3}{0,200000 \times 10^1} \end{aligned}$$

Então, as duas raízes obtidas com erros de arredondamento, são:

$$\begin{aligned} \tilde{x}_1 &= \frac{-0,300000 \times 10^3 - 0,300000 \times 10^3}{0,200000 \times 10^1} \\ &= -\frac{0,600000 \times 10^3}{0,200000 \times 10^1} = -0,300000 \times 10^3 \end{aligned}$$

e

$$\tilde{x}_2 = \frac{-0,300000 \times 10^3 + 0,300000 \times 10^3}{0,200000 \times 10^1} = 0,000000 \times 10^0$$

No entanto, os valores das raízes com seis dígitos significativos livres de erros de arredondamento, são:

$$x_1 = -0,300000 \times 10^3 \quad \text{e} \quad x_2 = 0,466667 \times 10^{-4}.$$

Observe que a primeira raiz apresenta seis dígitos significativos corretos, mas a segunda não possui nenhum dígito significativo correto.

Observe que isto acontece porque  $b^2$  é muito maior que  $4ac$ , ou seja,  $b \approx \sqrt{b^2 - 4ac}$ , logo a diferença

$$-b + \sqrt{b^2 - 4ac}$$

estará próxima de zero. Uma maneira de evitar o cancelamento catastrófico é aplicar procedimentos analíticos na expressão para eliminar essa diferença. Um técnica padrão consiste usar uma expansão em série de Taylor em torno da origem, tal como:

$$\sqrt{1-x} = 1 - \frac{1}{2}x + O(x^2).$$

Substituindo esta aproximação na fórmula de Bhaskara, temos:

$$\begin{aligned} x &= \frac{-b \pm \sqrt{b^2 - 4ac}}{2a} \\ &= \frac{-b \pm b\sqrt{1 - \frac{4ac}{b^2}}}{2a} \\ &\approx \frac{-b \pm b\left(1 - \frac{4ac}{2b^2}\right)}{2a} \end{aligned}$$

Observe que  $\frac{4ac}{b^2}$  é um número pequeno e por isso a expansão faz sentido. Voltamos no exemplo anterior e calculamos as duas raízes com a nova expressão

$$\begin{aligned} \tilde{x}_1 &= \frac{-b - b + \frac{4ac}{2b}}{2a} = -\frac{b}{a} + \frac{c}{b} \\ &= -\frac{0,300000 \times 10^3}{0,100000 \times 10^1} - \frac{0,140000 \times 10^{-1}}{0,300000 \times 10^3} \\ &= -0,300000 \times 10^3 - 0,466667 \times 10^{-4} \\ &= -0,300000 \times 10^3 \\ \tilde{x}_2 &= \frac{-b + b - \frac{4ac}{2b}}{2a} \\ &= -\frac{4ac}{4ab} \\ &= -\frac{c}{b} = -\frac{-0,140000 \times 10^{-1}}{0,300000 \times 10^3} = 0,466667 \times 10^{-4} \end{aligned}$$



Observe que o efeito catastrófico foi eliminado.

**Observação 2.7.1.** O cancelamento catastrófico também poderia ter sido evitado através do seguinte truque analítico:

$$\begin{aligned} x_2 &= \frac{-b + \sqrt{b^2 - 4ac}}{2a} = \frac{-b + \sqrt{b^2 - 4ac}}{2a} \cdot \frac{-b - \sqrt{b^2 - 4ac}}{-b - \sqrt{b^2 - 4ac}} \\ &= \frac{b^2 - (b^2 - 4ac)}{2a(-b - \sqrt{b^2 - 4ac})} = \frac{4ac}{2a(-b - \sqrt{b^2 - 4ac})} \\ &= -\frac{2c}{(b + \sqrt{b^2 - 4ac})} \end{aligned}$$

## 2.8 Condicionamento de um problema

Nesta seção, utilizaremos a seguinte descrição abstrata para o conceito de “resolver um problema”: dado um conjunto de dados de entrada, encontrar os dados de saída. Se denotamos pela variável  $x$  os dados de entrada e pela variável  $y$  os dados de saída, resolver o problema significa encontrar  $y$  dado  $x$ . Em termos matemáticos, a resolução de um problema é realizada pelo mapeamento  $f : x \rightarrow y$ , ou simplesmente  $y = f(x)$ .

É certo que, na maioria das aplicações, os dados de entrada do problema — isto é,  $x$  — não são conhecidos com total exatidão, devido a diversas fontes de erros, como incertezas na coleta dos dados e erros de arredondamento. O conceito de condicionamento está relacionado à forma como os erros nos dados de entrada influenciam os dados de saída.

Para fins de análise, denotaremos por  $x$ , os dados de entrada com precisão absoluta e por  $x^*$ , os dados com erro. Definiremos também a solução  $y^*$ , do problema com dados de entrada  $x^*$ , ou seja,  $y^* = f(x^*)$ .

Estamos interessados em saber se os erros cometidos na entrada  $\Delta x = x - x^*$  influenciaram na saída do problema  $\Delta y = y - y^*$ . No caso mais simples, temos que  $x \in \mathbb{R}$  e  $y \in \mathbb{R}$ . Assumindo que  $f$  seja diferenciável, a partir da série de Taylor

$$f(x + \Delta x) \approx f(x) + f'(x)\Delta x$$

obtemos (subtraindo  $f(x)$  dos dois lados)

$$\Delta y = f(x + \Delta x) - f(x) \approx f'(x)\Delta x$$

Para relacionarmos os erros relativos, dividimos o lado esquerdo por  $y$ , o lado direito por  $f(x) = y$  e obtemos

$$\frac{\Delta y}{y} \approx \frac{f'(x)}{f(x)} \frac{x \Delta x}{x}$$

sugerindo a definição de número de condicionamento de um problema.

**Definição 2.8.1.** *Seja  $f$  uma função diferenciável. O **número de condicionamento** de um problema é definido como*

$$\kappa_f(x) := \left| \frac{xf'(x)}{f(x)} \right|$$

e fornece uma estimativa de quanto os erros relativos na entrada  $\left| \frac{\Delta x}{x} \right|$  serão amplificados na saída  $\left| \frac{\Delta y}{y} \right|$ .

De modo geral, quando  $f$  depende de várias variáveis, podemos obter

$$\delta_f = |f(x_1, x_2, \dots, x_n) - f(\bar{x}_1, \bar{x}_2, \dots, \bar{x}_n)| \approx \sum_{i=1}^n \left| \frac{\partial f}{\partial x_i}(x_1, x_2, \dots, x_n) \right| \delta_{x_i}$$

Uma matriz de números de condicionamento também poderia ser obtida como em [5].

**Exemplo 2.8.1.** Considere o problema de calcular  $\sqrt{x}$  em  $x = 2$ . Se usarmos  $x^* = 1,999$ , quanto será o erro relativo na saída? O erro relativo na entrada é

$$\left| \frac{\Delta x}{x} \right| = \left| \frac{2 - 1,999}{2} \right| = 0,0005$$

O número de condicionamento do problema calcular a raiz é

$$\kappa_f(x) := \left| \frac{xf'(x)}{f(x)} \right| = \left| \frac{x \frac{1}{2\sqrt{x}}}{\sqrt{x}} \right| = \frac{1}{2}$$

Ou seja, os erros na entrada serão diminuídos pela metade. De fato, usando  $y = \sqrt{2} = 1,4142136\dots$  e  $y^* = \sqrt{1,999} = 1,41386\dots$ , obtemos

$$\frac{\Delta y}{y} = \frac{\sqrt{2} - \sqrt{1,999}}{\sqrt{2}} \approx 0,000250031\dots$$

**Exemplo 2.8.2.** Considere a função  $f(x) = \frac{10}{1-x^2}$  e  $x^* = 0,9995$  com um erro absoluto na entrada de 0,0001.

Calculando  $y^* = f(x^*)$  temos

$$y^* = \frac{10}{1 - (0,9995)^2} \approx 10002,500625157739705173$$

Mas qual é a estimativa de erro nessa resposta? Quantos dígitos significativos temos nessa resposta?

Sabendo que  $f'(x) = -10/(1-x^2)^2$ , o número de condicionamento é

$$\kappa_f(x) := \left| \frac{xf'(x)}{f(x)} \right| = \left| \frac{2x^2}{1-x^2} \right|$$

o que nos fornece para  $x^* = 0,9995$ ,

$$\kappa_f(0,9995) \approx 1998,5$$

Como o erro relativo na entrada é

$$\left| \frac{\Delta x}{x} \right| = \left| \frac{0,0001}{0,9995} \right| \approx 0,00010005...$$

temos que o erro na saída será aproximadamente

$$\left| \frac{\Delta y}{y} \right| \approx \kappa_f(x) \left| \frac{\Delta x}{x} \right| \approx 1998,5 \times 0,00010005... \approx 0,1999$$

ou seja um erro relativo de aproximadamente 19,99%.

Note que se usarmos  $x_1 = 0,9994$  e  $x_2 = 0,9996$  (ambos no intervalo do erro absoluto da entrada) encontramos

$$\begin{aligned} y_1^* &\approx 8335,83 \\ y_2^* &\approx 12520,50 \end{aligned}$$

confirmando a estimativa de 19,99%.

**Exemplo 2.8.3.** Seja  $f(x) = x \exp(x)$ . Calcule o erro absoluto ao calcular  $f(x)$  sabendo que  $x = 2 \pm 0,05$ .

**Solução.** Temos que  $x \approx 2$  com erro absoluto de  $\delta_x = 0,05$ . Neste caso, calculamos  $\delta_f$ , isto é, o erro absoluto ao calcular  $f(x)$ , por:

$$\delta_f = |f'(x)|\delta_x.$$

Como  $f'(x) = (1+x)e^x$ , temos:

$$\begin{aligned} \delta_f &= |(1+x)e^x| \cdot \delta_x \\ &= |3e^2| \cdot 0,05 = 1,1084. \end{aligned}$$

Portanto, o erro absoluto ao calcular  $f(x)$  quando  $x = 2 \pm 0,05$  é de 1,084.  $\diamond$

**Exemplo 2.8.4.** Calcule o erro relativo ao medir  $f(x,y) = \frac{x^2+1}{x^2}e^{2y}$  sabendo que  $x \approx 3$  é conhecido com 10% de erro e  $y \approx 2$  é conhecido com 3% de erro.

**Solução.** Calculamos as derivadas parciais de  $f$ :

$$\frac{\partial f}{\partial x} = \frac{2x^3 - (2x^3 + 2x)}{x^4} e^{2y} = -\frac{2e^{2y}}{x^3}$$

e

$$\frac{\partial f}{\partial y} = 2 \frac{x^2 + 1}{x^2} e^{2y}$$

Calculamos o erro absoluto em termos do erro relativo:

$$\frac{\delta_x}{|x|} = 0,1 \Rightarrow \delta_x = 3 \cdot 0,1 = 0,3$$

$$\frac{\delta_y}{|y|} = 0,03 \Rightarrow \delta_y = 2 \cdot 0,03 = 0,06$$

Aplicando a expressão para estimar o erro em  $f$  temos

$$\begin{aligned} \delta_f &= \left| \frac{\partial f}{\partial x} \right| \delta_x + \left| \frac{\partial f}{\partial y} \right| \delta_y \\ &= \frac{2e^4}{27} \cdot 0,3 + 2 \frac{9+1}{9} e^4 \cdot 0,06 = 8,493045557 \end{aligned}$$

Portanto, o erro relativo ao calcular  $f$  é estimado por

$$\frac{\delta f}{|f|} = \frac{8,493045557}{\frac{9+1}{9} e^4} = 14\%$$

◇

**Exemplo 2.8.5.** No exemplo anterior, reduza o erro relativo em  $x$  pela metade e calcule o erro relativo em  $f$ . Depois, repita o processo reduzindo o erro relativo em  $y$  pela metade.

**Solução.** Na primeira situação temos  $x = 3$  com erro relativo de 5% e  $\delta_x = 0,05 \cdot 3 = 0,15$ . Calculamos  $\delta_f = 7,886399450$  e o erro relativo em  $f$  de 13%. Na segunda situação, temos  $y = 2$  com erro de 1,5% e  $\delta_y = 2 \cdot 0,015 = 0,03$ . Calculamos  $\delta_f = 4,853168892$  e o erro relativo em  $f$  de 8%. Observe que mesma o erro relativo em  $x$  sendo maior, o erro em  $y$  é mais significante na função. ◇

**Exemplo 2.8.6.** Considere um triângulo retângulo onde a hipotenusa e um dos catetos são conhecidos a menos de um erro: hipotenusa  $a = 3 \pm 0,01$  metros e cateto  $b = 2 \pm 0,01$  metros. Calcule o erro absoluto ao calcular a área dessa triângulo.

**Solução.** Primeiro vamos encontrar a expressão para a área em função da hipotenusa  $a$  e um cateto  $b$ . A tamanho de segundo cateto  $c$  é dado pelo teorema de Pitágoras,  $a^2 = b^2 + c^2$ , ou seja,  $c = \sqrt{a^2 - b^2}$ . Portanto a área é

$$A = \frac{bc}{2} = \frac{b\sqrt{a^2 - b^2}}{2}.$$

Agora calculamos as derivadas

$$\frac{\partial A}{\partial a} = \frac{ab}{2\sqrt{a^2 - b^2}},$$

$$\frac{\partial A}{\partial b} = \frac{\sqrt{a^2 - b^2}}{2} - \frac{b^2}{2\sqrt{a^2 - b^2}},$$

e substituindo na estimativa para o erro  $\delta_A$  em termos de  $\delta_a = 0,01$  e  $\delta_b = 0,01$ :

$$\begin{aligned}\delta_A &\approx \left| \frac{\partial A}{\partial a} \right| \delta_a + \left| \frac{\partial A}{\partial b} \right| \delta_b \\ &\approx \frac{3\sqrt{5}}{5} \cdot 0,01 + \frac{\sqrt{5}}{10} \cdot 0,01 = 0,01565247584\end{aligned}$$

Em termos do erro relativo temos erro na hipotenusa de  $\frac{0,01}{3} \approx 0,333\%$ , erro no cateto de  $\frac{0,01}{2} = 0,5\%$  e erro na área de

$$\frac{0,01565247584}{\frac{2\sqrt{3^2 - 2^2}}{2}} = 0,7\%$$

◇

## Exercícios

**E 2.8.1.** Considere que a variável  $x \approx 2$  é conhecida com um erro relativo de 1% e a variável  $y \approx 10$  com um erro relativo de 10%. Calcule o erro relativo associado a  $z$  quando:

$$z = \frac{y^4}{1 + y^4} e^x.$$

Suponha que você precise conhecer o valor de  $z$  com um erro de 0,5%. Você propõe uma melhoria na medição da variável  $x$  ou  $y$ ? Explique.

**E 2.8.2.** A corrente  $I$  em ampères e a tensão  $V$  em volts em uma lâmpada se relacionam conforme a seguinte expressão:

$$I = \left( \frac{V}{V_0} \right)^\alpha,$$

onde  $\alpha$  é um número entre 0 e 1 e  $V_0$  é tensão nominal em volts. Sabendo que  $V_0 = 220 \pm 3\%$  e  $\alpha = -0,8 \pm 4\%$ , calcule a corrente e o erro relativo associado quando a tensão vale  $220 \pm 1\%$ .

**Obs.:** Este problema pode ser resolvido de duas formas distintas: usando a expressão aproximada para a propagação de erro e inspecionando os valores máximos e mínimos que a expressão pode assumir. Pratique os dois métodos.

**E 2.8.3.** A corrente  $I$  em ampères e a tensão  $V$  em volts em uma lâmpada se relacionam conforme a seguinte expressão:

$$I = \left( \frac{V}{V_0} \right)^\alpha$$

Onde  $\alpha$  é um número entre 0 e 1 e  $V_0$  é a tensão nominal em volts. Sabendo que  $V_0 = 220 \pm 3\%$  e  $\alpha = 0,8 \pm 4\%$  Calcule a corrente e o erro relativo associado quando a tensão vale  $220 \pm 1\%$ . **Dica:** lembre que  $x^\alpha = e^{\alpha \ln(x)}$

## 2.9 Mais exemplos de cancelamento catastrófico

**Exemplo 2.9.1.** Considere o seguinte processo iterativo:

$$\begin{aligned} x_0 &= \frac{1}{3} \\ x_{n+1} &= 4x_n - 1, \quad n \in \mathbb{N}. \end{aligned}$$

Observe que  $x_0 = \frac{1}{3}$ ,  $x_1 = 4 \cdot \frac{1}{3} - 1 = \frac{1}{3}$ ,  $x_2 = \frac{1}{3}$ , ou seja, temos uma sequência constante igual a  $\frac{1}{3}$ . No entanto, ao calcularmos no computador, usando o sistema de numeração 'double', a sequência obtida não é constante e, de fato, diverge. Faça o teste no **Scilab**, colocando:

```
-->x = 1/3
```

e itere algumas vezes a linha de comando:

```
-->x = 4*x-1
```

Para compreender o que acontece, devemos levar em consideração que o número  $\frac{1}{3} = 0,\overline{3}$  possui uma representação infinita tanto na base decimal quanto na base binária. Logo, sua representação de máquina inclui um erro de arredondamento. Seja  $\epsilon$  a diferença entre o valor exato de  $\frac{1}{3}$  e sua representação de máquina, isto é,  $\tilde{x}_0 = \frac{1}{3} + \epsilon$ . A sequência efetivamente calculada no computador é:

$$\begin{aligned} \tilde{x}_0 &= \frac{1}{3} + \epsilon \\ \tilde{x}_1 &= 4x_0 - 1 = 4 \left( \frac{1}{3} + \epsilon \right) - 1 = \frac{1}{3} + 4\epsilon \\ \tilde{x}_2 &= 4x_1 - 1 = 4 \left( \frac{1}{3} + 4\epsilon \right) - 1 = \frac{1}{3} + 4^2\epsilon \\ &\vdots \\ \tilde{x}_n &= \frac{1}{3} + 4^n\epsilon \end{aligned}$$




Figura 2.1: Gráfico na função do exemplo 2.9.2.

Portanto o limite da sequência diverge,

$$\lim_{x \rightarrow \infty} |\tilde{x}_n| = \infty$$

Qual o número de condicionamento desse problema?

**Exemplo 2.9.2.** Observe a seguinte identidade

$$f(x) = \frac{(1+x) - 1}{x} = 1$$

Calcule o valor da expressão à esquerda para  $x = 10^{-12}$ ,  $x = 10^{-13}$ ,  $x = 10^{-14}$ ,  $x = 10^{-15}$ ,  $x = 10^{-16}$  e  $x = 10^{-17}$ . Observe que quando  $x$  se aproxima do  $\epsilon$  de máquina a expressão perde o significado. Veja a figura 2.1 com o gráfico de  $f(x)$  em escala logarítmica.

**Exemplo 2.9.3.** Neste exemplo, estamos interessados em compreender mais detalhadamente o comportamento da expressão

$$\left(1 + \frac{1}{n}\right)^n$$




Figura 2.2: Gráfico de  $\left(1 + \frac{1}{n}\right)^n$  em função de  $n$  em escala linear-logarítmica variando de  $10^0$  até  $10^{18}$ . Veja o exemplo 2.9.3.

quando  $n$  é um número grande ao computá-la em sistemas de numeral de ponto flutuante com acurácia finita. Um resultado bem conhecido do cálculo nos diz que o limite de (2.9.3) quando  $n$  tende a infinito é o número de Euler:

$$\lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^n = e = 2,718281828459\dots$$

Sabemos também que a sequência produzida por (2.9.3) é crescente, isto é:

$$\left(1 + \frac{1}{1}\right)^1 < \left(1 + \frac{1}{2}\right)^2 < \left(1 + \frac{1}{3}\right)^3 < \dots$$

No entanto, quando calculamos essa expressão no **Scilab**, nos defrontamos com o seguinte resultado:



$n$	$\left(1 + \frac{1}{n}\right)^n$		$n$	$\left(1 + \frac{1}{n}\right)^n$
1	2,000000000000000		$10^2$	2,7048138294215
2	2,250000000000000		$10^4$	2,7181459268249
3	2,3703703703704		$10^6$	2,7182804690957
4	2,4414062500000		$10^8$	2,7182817983391
5	2,4883200000000		$10^{10}$	2,7182820532348
6	2,5216263717421		$10^{12}$	2,7185234960372
7	2,5464996970407		$10^{14}$	2,7161100340870
8	2,5657845139503		$10^{16}$	1,000000000000000
9	2,5811747917132		$10^{18}$	1,000000000000000
10	2,5937424601000		$10^{20}$	1,000000000000000

Podemos resumir esses dados no gráfico de  $\left(1 + \frac{1}{n}\right)^n$  em função de  $n$ , veja a figura 2.2.

Observe que quando  $n$  se torna grande, da ordem de  $10^{15}$ , o gráfico da função deixa de se crescente e apresenta oscilações. Observe também que a expressão se torna identicamente igual a 1 depois de um certo limiar. Tais fenômenos não são intrínsecos da função  $f(n) = \left(1 + \frac{1}{n}\right)^n$ , mas **oriundas de erros de arredondamento**, isto é, são resultados numéricos espúrios. A fim de pôr o comportamento numérico de tal expressão, apresentamos abaixo o gráfico da mesma função, porém restrito à região entre  $10^{14}$  e  $10^{16}$ .

Para compreendermos melhor por que existe um limiar  $N$  que, quando atingido torna a expressão do exemplo acima identicamente igual a 1, observamos a sequência de operações realizadas pelo computador:

$$n \rightarrow 1/n \rightarrow 1 + 1/n \rightarrow \left(1 + 1/n\right)^n \quad (2.1)$$

Devido ao limite de precisão da representação de números em ponto flutuante, existe um menor número representável que é maior do que 1. Este número é  $1+\text{eps}$ , onde **eps** é chamado de **épsilon de máquina** e é o menor número que somado a 1 produz um resultado superior a 1 no sistema de numeração usado. O épsilon de máquina no sistema de numeração **double** vale aproximadamente  $2,22 \times 10^{-16}$ . No **Scilab**, o epsilon de máquina é a constante **eps**. Observe que:

```
-->1+%eps
ans =
1.00000000000000002220446
```

Quando somamos a 1 um número positivo inferior ao épsilon de máquina, obtemos o número 1. Dessa forma, o resultado obtido pela operação de ponto flutuante  $1 + n$  para  $0 < n < 2,22 \times 10^{-16}$  é 1.

Portanto, quando realizamos a sequência de operações dada em (2.1), toda informação contida no número  $n$  é perdida na soma com 1 quando  $1/n$  é menor que o épsilon de máquina, o que ocorre quando  $n > 5 \times 10^{15}$ . Assim,  $(1 + 1/n)$  é aproximado para 1 e a última operação se resume a  $1^n$ , o que é igual a 1 mesmo quando  $n$  é grande.

Um erro comum é acreditar que o perda de significância se deve ao fato de  $1/n$  ser muito pequeno para ser representado e é aproximando para 0. Isto é falso, o sistema de ponto de flutuante permite representar números de magnitude muito inferior ao épsilon de máquina. O problema surge da limitação no tamanho da mantissa. Observe como a seguinte sequência de operações não perde significância para números positivos  $x$  muito menores que o épsilon de máquina:

$$n \rightarrow 1/n \rightarrow 1/(1/n) \quad (2.2)$$

compare o desempenho numérico desta sequência de operações para valores pequenos de  $n$  com o da seguinte sequência:

$$n \rightarrow 1 + n \rightarrow (1 + n) - 1. \quad (2.3)$$

Finalmente, notamos que quando tentamos calcular  $\left(1 + \frac{1}{n}\right)^n$  para  $n$  grande, existe perda de significância no cálculo de  $1 + 1/n$ . Para entendermos isso melhor, vejamos o que acontece no Scilab quando  $n = 7 \times 10^{13}$ :

```
-->n=7e13
n =
7.0000000000000000000000D+13
-->1/n
ans =
1.428571428571428435D-14
-->y=1+1/n
y =
1.00000000000000014211D+00
```

Observe a perda de informação ao deslocar a mantissa de  $1/n$ . Para evidenciar o fenômeno, observamos o que acontece quando tentamos recalcular  $n$  subtraindo 1 de  $1 + 1/n$  e invertendo o resultado:

```
-->y-1
ans =
    1.421085471520200372D-14
-->1/(y-1)
ans =
    7.036874417766400000D+13
```

Para entendermos isso melhor, vejamos o que acontece no **Scilab** quando  $n = 7 \times 10^{13}$ :

```
>>> n=7e13; print("%1.15e" % n)
7.000000000000000e+13
>>> n=7e13; print("%1.20e" % n)
7.000000000000000000e+13
>>> print("%1.20e" % (1/n))
1.42857142857142843451e-14
>>> y=1+1/n; print("%1.20e" % y)
1.000000000000001421085e+00
```

Observe a perda de informação ao deslocar a mantissa de  $1/n$ . Para evidenciar o fenômeno, observamos o que acontece quando tentamos recalcular  $n$  subtraindo 1 de  $1 + 1/n$  e invertendo o resultado:

```
>>> print("%1.20e" % (y-1))
1.42108547152020037174e-14
>>> print("%1.20e" % (1/(y-1)))
7.0368744177664000000e+13
```

**Exemplo 2.9.4** (Analogia da balança). Observe a seguinte comparação interessante que pode ser feita para ilustrar os sistemas de numeração com ponto fixo e flutuante: o sistema de ponto fixo é como uma balança cujas marcas estão igualmente espaçadas; o sistema de ponto flutuante é como uma balança cuja distância entre as marcas é proporcional à massa medida. Assim, podemos ter uma balança de ponto fixo cujas marcas estão sempre distanciadas de 100g (100g, 200g, 300g, ..., 1Kg, 1,1Kg,...) e outra balança de ponto flutuante cujas marcas estão distanciadas sempre de aproximadamente um décimo do valor lido (100g, 110g, 121g, 133g, ..., 1Kg, 1,1Kg, 1,21Kg, ...) A balança de ponto fixo apresenta uma resolução baixa para pequenas medidas, porém uma resolução alta para grandes medidas. A balança de ponto flutuante distribui a resolução de forma proporcional ao longo da escala.

Seguindo nesta analogia, o fenômeno de perda de significância pode ser interpretado como a seguir: imagine que você deseje obter o peso de um gato (aproximadamente 4Kg). Dois processos estão disponíveis: colocar o gato diretamente

na balança ou medir seu peso com o gato e, depois, sem o gato. Na balança de ponto flutuante, a incerteza associada na medida do peso do gato (sozinho) é aproximadamente 10% de 4Kg, isto é, 400g. Já a incerteza associada à medida da uma pessoa (aproximadamente 70Kg) com o gato é de 10% do peso total, isto é, aproximadamente 7Kg. Esta incerteza é da mesma ordem de grandeza da medida a ser realizada, tornando o processo impossível de ser realizado, já que teríamos uma incerteza da ordem de 14Kg (devido à dupla medição) sobre uma grandeza de 4Kg.

## Exercícios

**E 2.9.1.** Considere as expressões:

$$\frac{\exp(1/\mu)}{1 + \exp(1/\mu)}$$

e

$$\frac{1}{\exp(-1/\mu) + 1}$$

com  $\mu > 0$ . Verifique que elas são idênticas como funções reais. Teste no computador cada uma delas para  $\mu = 0,1$ ,  $\mu = 0,01$  e  $\mu = 0,001$ . Qual dessas expressões é mais adequada quando  $\mu$  é um número pequeno? Por quê?

**E 2.9.2.** Encontre expressões alternativas para calcular o valor das seguintes funções quando  $x$  é próximo de zero.

a)  $f(x) = \frac{1 - \cos(x)}{x^2}$

b)  $g(x) = \sqrt{1+x} - 1$

c)  $h(x) = \sqrt{x + 10^6} - 10^3$

d)  $i(x) = \sqrt{1+e^x} - \sqrt{2}$       Dica: Faça  $y = e^x - 1$

**E 2.9.3.** Use uma identidade trigonométrica adequada para mostrar que:

$$\frac{1 - \cos(x)}{x^2} = \frac{1}{2} \left( \frac{\sin(x/2)}{x/2} \right)^2.$$

Análise o desempenho destas duas expressões no computador quando  $x$  vale  $10^{-5}$ ,  $10^{-6}$ ,  $10^{-7}$ ,  $10^{-8}$ ,  $10^{-9}$ ,  $10^{-200}$  e 0. Discuta o resultado. **Dica:** Para  $|x| < 10^{-5}$ ,  $f(x)$  pode ser aproximada por  $1/2 - x^2/24$  com erro de truncamento inferior a  $10^{-22}$ .

**E 2.9.4.** Reescreva as expressões:

$$\sqrt{e^{2x} + 1} - e^x \quad \text{e} \quad \sqrt{e^{2x} + x^2} - e^x$$

de modo que seja possível calcular seus valores para  $x = 100$  utilizando a aritmética de ponto flutuante ("Double") no computador.

**E 2.9.5.** Na teoria da relatividade restrita, a energia cinética de uma partícula e sua velocidade se relacionam pela seguinte fórmula:

$$E = mc^2 \left( \frac{1}{\sqrt{1 - (v/c)^2}} - 1 \right),$$

onde  $E$  é a energia cinética da partícula,  $m$  é a massa de repouso,  $v$  o módulo da velocidade e  $c$  a velocidade da luz no vácuo dada por  $c = 299792458 \text{ m/s}$ . Considere que a massa de repouso  $m = 9,10938291 \times 10^{-31} \text{ Kg}$  do elétron seja conhecida com erro relativo de  $10^{-9}$ . Qual é o valor da energia e o erro relativo associado a essa grandeza quando  $v = 0,1c$ ,  $v = 0,5c$ ,  $v = 0,99c$  e  $v = 0,999c$  sendo que a incerteza relativa na medida da velocidade é  $10^{-5}$ ?

**E 2.9.6.** Deseja-se medir a concentração de dois diferentes oxidantes no ar. Três sensores eletroquímicos estão disponíveis para a medida e apresentam as seguintes respostas:

$$v_1 = 270[A] + 30[B], \quad v_2 = 140[A] + 20[B] \quad \text{e} \quad v_3 = 15[A] + 200[B]$$

as tensões  $v_1$ ,  $v_2$  e  $v_3$  são dadas em  $mV$  e as concentrações em  $\text{milimol/l}$ .

- a) Encontre uma expressão para os valores de  $[A]$  e  $[B]$  em termos de  $v_1$  e  $v_2$  e, depois, em termos de  $v_1$  e  $v_3$ . Dica: Se  $ad \neq bc$ , então a matriz  $A$  dada por

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

é inversível e sua inversa é dada por

$$A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

- b) Sabendo que incerteza relativa associada às sensibilidades dos sensores 1 e 2 é de 2% e que a incerteza relativa associada às sensibilidades do sensor 3 é 10%, verifique a incerteza associada à medida feita com o par 1 – 2 e o par 1 – 3. Use  $[A] = [B] = 10 \text{ milimol/l}$ . Dica: Você deve diferenciar as grandezas  $[A]$  e  $[B]$  em relação aos valores das tensões.

## Capítulo 3

# Solução de equações de uma variável

Neste capítulo, buscaremos aproximações numéricas para a solução de **equações de uma variável real**. Observamos que obter uma solução para uma tal dada equação é equivalente a encontrar um **zero de uma função** apropriada. Com isso, iniciamos este capítulo discutindo sobre condições de existência e unicidade de raízes de funções de uma variável real. Então, apresentamos o **método da bisseção** como uma primeira abordagem numérica para a solução de tais equações.

Em seguida, exploramos uma outra abordagem via **iteração do ponto fixo**. Desta, obtemos o **método de Newton**<sup>1</sup>, para o qual discutimos sua aplicação e convergência. Por fim, apresentamos o **método das secantes** como uma das possíveis variações do método de Newton.

### 3.1 Existência e unicidade

O **teorema de Bolzano**<sup>2</sup> nos fornece condições suficientes para a existência do zero de uma função. Este é uma aplicação direta do **teorema do valor intermediário**.

**Teorema 3.1.1** (Teorema de Bolzano). *Se  $f : [a, b] \rightarrow \mathbb{R}$ ,  $y = f(x)$ , é uma função contínua tal que  $f(a) \cdot f(b) < 0$ , então existe  $x^* \in (a, b)$  tal que  $f(x^*) = 0$ .*

*Demonstração.* O resultado é uma consequência imediata do teorema do valor intermediário que estabelece que dada uma função contínua  $f : [a, b] \rightarrow \mathbb{R}$ ,  $y = f(x)$ , tal que  $f(a) < f(b)$  (ou  $f(b) < f(a)$ ), então para qualquer  $d \in (f(a), f(b))$

---

<sup>1</sup>Sir Isaac Newton, 1642 - 1727, matemático e físico inglês.

<sup>2</sup>Bernhard Placidus Johann Gonzal Nepomuk Bolzano, 1781 - 1848, matemático do Reino da Boêmia.




Figura 3.1: Teorema de Bolzano.

(ou  $k \in (f(b), f(a))$ ) existe  $x^* \in (a, b)$  tal que  $f(x^*) = k$ . Ou seja, nestas notações, se  $f(a) \cdot f(b) < 0$ , então  $f(a) < 0 < f(b)$  (ou  $f(b) < 0 < f(a)$ ). Logo, tomando  $k = 0$ , temos que existe  $x^* \in (a, b)$  tal que  $f(x^*) = k = 0$ .  $\square$

Em outras palavras, se  $f(x)$  é uma função contínua em um dado intervalo no qual ela troca de sinal, então ela tem pelo menos um zero neste intervalo (veja a figura 3.1).

**Exemplo 3.1.1.** Mostre que existe pelo menos uma solução da equação  $e^x = x + 2$  no intervalo  $(-2, 0)$ .

**Solução.** Primeiramente, observamos que resolver a equação  $e^x = x + 2$  é equivalente a resolver  $f(x) = 0$  com  $f(x) = e^x - x - 2$ . Agora, como  $f(-2) = e^{-2} > 0$  e  $f(0) = -2 < 0$ , temos do teorema de Bolzano que existe pelo menos um zero de  $f(x)$  no intervalo  $(-2, 0)$ . E, portanto, existe pelo menos uma solução da equação dada no intervalo  $(-2, 0)$ .

Podemos usar o **Scilab** para estudarmos esta função. Por exemplo, podemos definir a função  $f(x)$  e computá-la nos extremos do intervalo dado com os seguintes comandos:

```
-->deff('y=f(x)', 'y=exp(x)-x-2')
-->f(-2), f(0)
ans =
    0.1353353
ans =
   - 1.
```

Alternativamente (e com maior precisão), podemos verificar diretamente o sinal da função nos pontos desejados com comando `sign`:

```
-->sign(f(-2)),sign(f(0))
ans =
    1.
ans =
   -1.
```

◇

Quando procuramos aproximações para zeros de funções, é aconselhável isolar cada raiz em um intervalo. Desta forma, gostaríamos de poder garantir a existência e a unicidade da raiz dentro de um dado intervalo. A seguinte proposição nos fornece condições suficientes para tanto.

**Proposição 3.1.1.** *Se  $f : [a, b] \rightarrow \mathbb{R}$  é uma função diferenciável,  $f(a) \cdot f(b) < 0$  e  $f'(x) > 0$  (ou  $f'(x) < 0$ ) para todo  $x \in (a, b)$ , então existe um único  $x^* \in (a, b)$  tal que  $f(x^*) = 0$ .*

Em outras palavras, para garantirmos que exista um único zero de uma dada função diferenciável em um intervalo, é suficiente que ela troque de sinal e seja monótona neste intervalo.

**Exemplo 3.1.2.** No exemplo 3.1.1, mostramos que existe pelo menos um zero de  $f(x) = e^x - x - 2$  no intervalo  $(-2, 0)$ , pois  $f(x)$  é contínua e  $f(-2) \cdot f(0) < 0$ . Agora, observamos que, além disso,  $f'(x) = e^x - 1$  e, portanto,  $f'(x) < 0$  para todo  $x \in (-2, 0)$ . Logo, da proposição 3.1.1, temos garantida a existência de um único zero no intervalo dado.

Podemos inspecionar o comportamento da função  $f(x) = e^x - x - 2$  e de sua derivada fazendo seus gráficos no Scilab. Para tanto, podemos fazer o seguinte teste:

```
-->x = linspace(-2,0,50);
-->deff('y = f(x)', 'y=exp(x)-x-2') // define f
-->plot(x,f(x));xgrid // grafico de f
-->deff('y = fl(x)', 'y=exp(x)-1') // a derivada
-->plot(x,fl(x));xgrid // grafico de f'
```

A discussão feita nesta seção, especialmente o teorema de Bolzano, nos fornece os fundamentos para o método da bisseção, o qual discutimos na próxima seção.



## Exercícios

**E 3.1.1.** Mostre que  $\cos x = x$  tem solução no intervalo  $[0, \pi/2]$ .

**E 3.1.2.** Mostre que  $\cos x = x$  tem uma única solução no intervalo  $[0, \pi/2]$ .

**E 3.1.3.** Interprete a equação  $\cos(x) = kx$  como o problema de encontrar a intersecção da curva  $y = \cos(x)$  com  $y = kx$ . Encontre o valor positivo  $k$  para o qual essa equação admite exatamente duas raízes positivas distintas.

**E 3.1.4.** Mostre que a equação:

$$\ln(x) + x^3 - \frac{1}{x} = 10$$

possui uma única solução positiva.

**E 3.1.5.** Use o teorema de Bolzano para mostrar que o erro absoluto ao aproximar o zero da função  $f(x) = e^x - x - 2$  por  $\bar{x} = -1,841$  é menor que  $10^{-3}$ .

**E 3.1.6.** Mostre que o erro absoluto associado à aproximação  $\bar{x} = 1,962$  para a solução exata  $x^*$  de:

$$e^x + \sin(x) + x = 10$$

é menor que  $10^{-4}$ .

**E 3.1.7.** Mostre que a equação

$$\ln(x) + x - \frac{1}{x} = v$$

possui uma solução para cada  $v$  real e que esta solução é única.

## 3.2 Método da bisseção

O **método da bisseção** explora o fato de que uma função contínua  $f : [a, b] \rightarrow \mathbb{R}$  com  $f(a) \cdot f(b) < 0$  tem um zero no intervalo  $(a, b)$  (veja o teorema de Bolzano 3.1.1). Assim, a ideia para aproximar o zero de uma tal função  $f(x)$  é tomar, como primeira aproximação, o ponto médio do intervalo  $[a, b]$ , isto é:

$$x^{(0)} = \frac{(a + b)}{2}.$$

Pode ocorrer de  $f(x^{(0)}) = 0$  e, neste caso, o zero de  $f(x)$  é  $x^* = x^{(0)}$ . Caso contrário, se  $f(a) \cdot f(x^{(0)}) < 0$ , então  $x^* \in (a, x^{(0)})$ . Neste caso, tomamos como




Figura 3.2: Método da bisseção.

segunda aproximação do zero de  $f(x)$  o ponto médio do intervalo  $[a, x^{(0)}]$ , isto é,  $x^{(1)} = (a + x^{(0)})/2$ . Noutro caso, temos  $f(x^{(0)}) \cdot f(b) < 0$  e, então, tomamos  $x^{(1)} = (x^{(0)} + b)/2$ . Repetimos este procedimento até obtermos a aproximação desejada (veja figura 3.2).

De forma mais precisa, suponha que queiramos calcular uma aproximação com uma certa precisão  $TOL$  para um zero  $x^*$  de uma dada função contínua  $f : [a, b] \rightarrow \mathbb{R}$  tal que  $f(a) \cdot f(b) < 0$ . Iniciamos, tomando  $n = 0$  e:

$$a^{(n)} = a, \quad b^{(n)} = b \quad \text{e} \quad x^{(n)} = \frac{a^{(n)} + b^{(n)}}{2}.$$

Verificamos o **critério de parada**, isto é, se  $f(x^{(n)}) = 0$  ou:

$$\frac{|b^{(n)} - a^{(n)}|}{2} < TOL,$$

então  $x^{(n)}$  é a aproximação desejada. Caso contrário, preparamos a próxima iteração  $n + 1$  da seguinte forma: se  $f(a^{(n)}) \cdot f(x^{(n)}) < 0$ , então setamos  $a^{(n+1)} = a^{(n)}$  e  $b^{(n+1)} = x^{(n)}$ ; noutro caso, se  $f(x^{(n)}) \cdot f(b^{(n)}) < 0$ , então setamos  $a^{(n+1)} = x^{(n)}$  e  $b^{(n+1)} = b^{(n)}$ . Trocando  $n$  por  $n + 1$ , temos a nova aproximação do zero de  $f(x)$  dada por:

$$x^{(n+1)} = \frac{a^{(n+1)} + b^{(n+1)}}{2}.$$

Voltamos a verificar o critério de parada acima e, caso não satisfeito, iteramos novamente. Iteramos até obtermos a aproximação desejada ou o número máximo de iterações ter sido atingido.

Tabela 3.1: Iteração do método da bisseção para o exemplo 3.2.1.

$n$	$a^{(n)}$	$b^{(n)}$	$x^{(n)}$	$f(a^{(n)})f(x^{(n)})$	$\frac{ b^{(n)} - a^{(n)} }{2}$
0	-2	0	-1	$< 0$	1
1	-2	-1	-1,5	$< 0$	0,5
2	-2	-1,5	-1,75	$< 0$	0,25
3	-2	-1,75	-1,875	$> 0$	0,125
4	-1,875	-1,75	-1,8125	$< 0$	0,0625

**Exemplo 3.2.1.** Use o método da bisseção para calcular uma solução de  $e^x = x+2$  no intervalo  $[-2, 0]$  com precisão  $TOL = 10^{-1}$ .

**Solução.** Primeiramente, observamos que resolver a equação dada é equivalente a calcular o zero de  $f(x) = e^x - x - 2$ . Além disso, temos  $f(-2) \cdot f(0) < 0$ . Desta forma, podemos iniciar o método da bisseção tomando o intervalo inicial  $[a^{(0)}, b^{(0)}] = [-2, 0]$  e:

$$x^{(0)} = \frac{a^{(0)} + b^{(0)}}{2} = -1.$$

Apresentamos as iterações na tabela 3.1. Observamos que a precisão  $TOL = 10^{-1}$  foi obtida na quarta iteração com o zero de  $f(x)$  sendo aproximado por  $x^{(4)} = 1,8125$ .

Usando o Scilab neste exemplo, temos:

```
-->deff('y = f(x)', 'y = exp(x) - x - 2')
-->a=-2, b=0, x=(a+b)/2, TOL = (b-a)/2, sign(f(a)*f(x))
-->b=x, x=(a+b)/2, TOL = (b-a)/2, sign(f(a)*f(x))
```

e, assim, sucessivamente. Veja o código completo na Seção 3.2.1.  $\diamond$

Vamos, agora, discutir sobre a **convergência** do método da bisseção. O próximo teorema 3.2.1 nos garante a convergência do método da bisseção.

**Teorema 3.2.1** (Convergência do método da bisseção). *Sejam  $f : [a, b] \rightarrow \mathbb{R}$  uma função contínua tal que  $f(a) \cdot f(b) < 0$  e  $x^*$  o único zero de  $f(x)$  no intervalo  $(a, b)$ . Então, a sequência  $\{x^{(n)}\}_{n \geq 0}$  do método da bisseção satisfaz:*

$$|x^{(n)} - x^*| < \frac{b - a}{2^{n+1}}, \quad \forall n \geq 0,$$

isto é,  $x^{(n)} \rightarrow x^*$  quando  $n \rightarrow \infty$ .

*Demonstração.* Notemos que, a cada iteração, a distância entre a aproximação  $x^{(n)}$  e o zero  $x^*$  da função é menor que a metade do tamanho do intervalo  $[a^{(n)}, b^{(n)}]$  (veja figura 3.2), isto é:

$$|x^{(n)} - x^*| < \frac{b^{(n)} - a^{(n)}}{2}.$$

Por construção do método, temos  $[a^{(n)}, b^{(n)}] \subset [a^{(n-1)}, b^{(n-1)}]$  e:

$$b^{(n)} - a^{(n)} = \frac{b^{(n-1)} - a^{(n-1)}}{2}.$$

Desta forma:

$$|x^{(n)} - x^*| < \frac{b^{(n)} - a^{(n)}}{2} = \frac{b^{(n-1)} - a^{(n-1)}}{2^2} = \dots = \frac{b^{(0)} - a^{(0)}}{2^{n+1}}, \quad \forall n \geq 1.$$

Logo, vemos que:

$$|x^{(n)} - x^*| < \frac{b - a}{2^{n+1}}, \quad \forall n \geq 0.$$

□

Observamos que a hipótese de que  $f(x)$  tenha um único zero no intervalo não é necessária. Se a função tiver mais de um zero no intervalo inicial, as iterações irão convergir para um dos zeros. Veja o exercício 3.2.3.

**Observação 3.2.1.** O teorema 3.2.1 nos fornece uma estimativa para a convergência do método da bisseção. Aproximadamente, temos:

$$|x^{(n+1)} - x^*| \lesssim \frac{1}{2} |x^{(n)} - x^*|.$$

Isto nos leva a concluir que o método da bisseção tem **taxa de convergência** linear.

**Exemplo 3.2.2.** No exemplo 3.2.1, precisamos de 4 iterações do método da bisseção para computar uma aproximação com precisão de  $10^{-1}$  do zero de  $f(x) = e^x - x - 2$  tomando como intervalo inicial  $[a, b] = [-2, 0]$ . Poderíamos ter estimado o número de iterações **a priori**, pois, como vimos acima:

$$|x^{(n)} - x^*| \leq \frac{b - a}{2^{n+1}}, \quad n \geq 0.$$

Logo, temos:

$$\begin{aligned} |x^{(n)} - x^*| &< \frac{b - a}{2^{n+1}} = \frac{2}{2^{n+1}} \\ &= 2^{-n} < 10^{-1} \Rightarrow n > -\log_2 10^{-1} \approx 3,32. \end{aligned}$$

O que está de acordo com o experimento numérico realizado naquele exemplo.

O método da bisseção tem a boa propriedade de garantia de convergência, bem como de fornecer uma simples estimativa da precisão da aproximação calculada. Entretanto, a taxa de convergência linear é superada por outros métodos. A construção de tais métodos está, normalmente, associada a iteração do ponto fixo, a qual exploramos na próxima seção.

### 3.2.1 Código Scilab: método da bisseção

O seguinte código é uma implementação no Scilab do algoritmo da bisseção. As variáveis de entrada são:

- **f** - função objetivo
- **a** - extremo esquerdo do intervalo de inspeção  $[a, b]$
- **b** - extremo direito do intervalo de inspeção  $[a, b]$
- **TOL** - tolerância (critério de parada)
- **N** - número máximo de iterações

A variável de saída é:

- **p** - aproximação da raiz de **f**, isto é,  $f(p) \approx 0$ .

```
function [p] = bissecao(f, a, b, TOL, N)
    i = 1
    fa = f(a)
    while (i <= N)
        //iteracao da bissecao
        p = a + (b-a)/2
        fp = f(p)
        //condicao de parada
        if ((fp == 0) | ((b-a)/2 < TOL)) then
            return p
        end
        //bissecta o intervalo
        i = i+1
        if (fa * fp > 0) then
            a = p
            fa = fp
        else
            b = p
        end
    end
end
```

```

end
end
error('Num. max. de iter. excedido!')
endfunction

```

## Exercícios

**E 3.2.1.** Considere a equação  $\sqrt{x} = \cos(x)$ . Use o método da bisseção com intervalo inicial  $[a, b] = [0, 1]$  e  $x^{(1)} = (a + b)/2$  para calcular a aproximação  $x^{(4)}$  da solução desta equação.

**E 3.2.2.** Trace o gráfico e isole as três primeiras raízes positivas da função:

$$f(x) = 5 \operatorname{sen}(x^2) - \exp\left(\frac{x}{10}\right)$$

em intervalos de comprimento 0,1. Então, use o método da bisseção para obter aproximações dos zeros desta função com precisão de  $10^{-5}$ .

**E 3.2.3.** O polinômio  $p(x) = -4 + 8x - 5x^2 + x^3$  tem raízes  $x_1 = 1$  e  $x_2 = x_3 = 2$  no intervalo  $[1/2, 3]$ .

- Se o método da bisseção for usado com o intervalo inicial  $[1/2, 3]$ , para qual raiz as iterações convergem?
- É possível usar o método da bisseção para a raiz  $x = 2$ ? Justifique sua resposta.

**E 3.2.4.** Mostre que a equação do problema 3.1.7 possui uma solução no intervalo  $[1, v + 1]$  para todo  $v$  positivo. Dica: defina  $f(x) = \ln(x) + x - \frac{1}{x} - v$  e considere a seguinte estimativa:

$$f(v + 1) = f(1) + \int_1^{v+1} f'(x) dx \geq -v + \int_1^{v+1} dx = 0.$$

Use esta estimativa para iniciar o método de bisseção e obtenha o valor da raiz com pelo menos 6 algarismos significativos para  $v = 1, 2, 3, 4$  e  $5$ .

**E 3.2.5.** (Estática) Considere o seguinte problema físico: uma plataforma está fixa a uma parede através de uma dobradiça cujo momento é dado por:

$$\tau = k\theta,$$

onde  $\theta$  é ângulo da plataforma com a horizontal e  $k$  é uma constante positiva. A plataforma é feita de material homogêneo, seu peso é  $P$  e sua largura é  $l$ . Modele a relação entre o ângulo  $\theta$  e o peso  $P$  próprio da plataforma. Encontre o valor de  $\theta$  quando  $l = 1$  m,  $P = 200$  N,  $k = 50$  Nm/rad, sabendo que o sistema está em equilíbrio. Use o método da bisseção e expresse o resultado com 4 algarismos significativos.

**E 3.2.6.** Considere a equação de Lambert dada por:

$$xe^x = t,$$

onde  $t$  é um número real positivo. Mostre que esta equação possui uma única solução  $x^*$  que pertence ao intervalo  $[0, t]$ . Usando esta estimativa como intervalo inicial, quantos passos são necessário para obter o valor numérico de  $x^*$  com erro absoluto inferior a  $10^{-6}$  quando  $t = 1$ ,  $t = 10$  e  $t = 100$  através do método da bisseção? Obtenha esses valores.


**E 3.2.7.** O polinômio  $f(x) = x^4 - 4x^2 + 4$  possui raízes duplas em  $\sqrt{2}$  e  $-\sqrt{2}$ . O método da bisseção pode ser aplicados a  $f$ ? Explique.

**E 3.2.8.** (Eletrônica) O desenho abaixo mostra um circuito não linear envolvendo uma fonte de tensão constante, um diodo retificador e um resistor. Sabendo que a relação entre a corrente ( $I_d$ ) e a tensão ( $v_d$ ) no diodo é dada pela seguinte expressão:

$$I_d = I_R \left( \exp \left( \frac{v_d}{v_t} \right) - 1 \right),$$

onde  $I_R$  é a corrente de condução reversa e  $v_t$ , a tensão térmica dada por  $v_t = \frac{kT}{q}$  com  $k$ , a constante de Boltzmann,  $T$  a temperatura de operação e  $q$ , a carga do elétron. Aqui  $I_R = 1 \mu\text{A} = 10^{-12}$  A,  $T = 300$  K. Escreva o problema como uma equação na incógnita  $v_d$  e, usando o método da bisseção, resolva este problema com 3 algarismos significativos para os seguintes casos:

- a)  $V = 30 \text{ V}$  e  $R = 1 \text{ k}\Omega$ .
- b)  $V = 3 \text{ V}$  e  $R = 1 \text{ k}\Omega$ .
- c)  $V = 3 \text{ V}$  e  $R = 10 \text{ k}\Omega$ .
- d)  $V = 300 \text{ mV}$  e  $R = 1 \text{ k}\Omega$ .
- e)  $V = -300 \text{ mV}$  e  $R = 1 \text{ k}\Omega$ .
- f)  $V = -30 \text{ V}$  e  $R = 1 \text{ k}\Omega$ .
- g)  $V = -30 \text{ V}$  e  $R = 10 \text{ k}\Omega$ .



Dica:  $V = RI_d + v_d$ .

**E 3.2.9.** (Propagação de erros) Obtenha os valores de  $I_d$  no problema 3.2.8. Lembre que existem duas expressões disponíveis:

$$I_d = I_R \left( \exp \left( \frac{v_d}{v_t} \right) - 1 \right)$$

e

$$I_d = \frac{v - v_d}{R}$$

Faça o estudo da propagação do erro e decida qual a melhor expressão em cada caso.

### 3.3 Iteração de Ponto Fixo

Nesta seção, discutimos a abordagem da **iteração do ponto fixo** para a solução numérica de equações de uma variável real. Observamos que sempre podemos reescrever uma equação da forma  $f(x) = 0$  (problema de encontrar os zeros de uma função) em uma equação equivalente na forma  $g(x) = x$  (**problema de ponto fixo**). Um ponto  $x = x^*$  tal que  $g(x^*) = x^*$  é chamado de **ponto fixo** da função  $g(x)$ . Geometricamente, um ponto fixo de uma função é um ponto de interseção entre a reta  $y = x$  com o gráfico da função (veja figura 3.3).

**Exemplo 3.3.1.** Resolver a equação  $e^x = x + 2$  é equivalente a resolver  $f(x) = 0$ , com  $f(x) = e^x - x - 2$ . Estes são equivalentes a resolver  $g(x) = x$ , com  $g(x) = e^x - 2$ .






Figura 3.3: Ponto fixo  $g(x^*) = x^*$ .

Ou seja, temos:

$$e^x = x + 2 \Leftrightarrow e^x - x - 2 = 0 \Leftrightarrow e^x - 2 = x$$

Dada uma função  $g(x)$ , a **iteração do ponto fixo** consiste em computar a seguinte sequência recursiva:

$$x^{(n+1)} = g(x^{(n)}), \quad n \geq 1,$$

onde  $x^{(1)}$  é uma aproximação inicial do ponto fixo.

**Exemplo 3.3.2** (Método babilônico). O método babilônico<sup>3</sup> é de uma iteração de ponto fixo para extrair a raiz quadrada de um número positivo  $A$ , isto é, resolver a equação  $x^2 = A$ .

Seja  $r > 0$  uma aproximação para  $\sqrt{A}$ . Temos três possibilidades:

- $r > \sqrt{A} \Rightarrow \frac{A}{r} < \sqrt{A} \Rightarrow \sqrt{A} \in \left(\frac{A}{r}, r\right)$ ;
- $r = \sqrt{A} \Rightarrow \frac{A}{r} = \sqrt{A}$ ;
- $r < \sqrt{A} \Rightarrow \frac{A}{r} > \sqrt{A} \Rightarrow \sqrt{A} \in \left(r, \frac{A}{r}\right)$ .

Ou seja,  $\sqrt{A}$  sempre está no intervalo entre  $r$  e  $\frac{A}{r}$ , no qual podemos buscar uma nova aproximação como, por exemplo, pelo ponto médio:

$$x = \frac{r + \frac{A}{r}}{2}.$$

<sup>3</sup>Heron de Alexandria, 10 d.C. - 70 d.C., matemático grego.

Aplicando esse método repetidas vezes, podemos construir a iteração (de ponto fixo):

$$\begin{aligned}x^{(1)} &= r \\x^{(n+1)} &= \frac{x^{(n)}}{2} + \frac{A}{2x^{(n)}}, \quad n = 1, 2, 3, \dots\end{aligned}$$

Por exemplo, para obter uma aproximação para  $\sqrt{5}$ , podemos iniciar com a aproximação inicial  $r = 2$  e  $A = 5$ . Então, tomamos  $x^{(1)} = 2$  e daí seguem as aproximações:

$$\begin{aligned}x^{(2)} &= \frac{2}{2} + \frac{2,5}{2} = 2,25 \\x^{(3)} &= \frac{2,25}{2} + \frac{2,5}{2,25} = 2,2361111 \\x^{(4)} &= \frac{2,2361111}{2} + \frac{2,5}{2,2361111} = 2,236068 \\x^{(5)} &= \frac{2,236068}{2} + \frac{2,5}{2,236068} = 2,236068\end{aligned}$$

O método babilônico sugere que a iteração do ponto fixo pode ser uma abordagem eficiente para a solução de equações. Ficam, entretanto, as seguintes perguntas:

1. Será que a iteração do ponto fixo é convergente?
2. Caso seja convergente, será que o limite  $x^* = \lim_{n \rightarrow \infty} x^{(n)}$  é um ponto fixo?
3. Caso seja convergente, qual é a taxa de convergência?

A segunda pergunta é a mais fácil de ser respondida. No caso de  $g(x)$  ser contínua, se  $x^{(n)} \rightarrow x^* \in \text{Dom}(g)$ , então:

$$x^* = \lim_{n \rightarrow \infty} x^{(n)} = \lim_{n \rightarrow \infty} g(x^{(n-1)}) = g\left(\lim_{n \rightarrow \infty} x^{(n-1)}\right) = g(x^*).$$

Antes de respondermos as outras perguntas acima, vejamos mais um exemplo.

**Exemplo 3.3.3.** Considere o problema de encontrar o zero da função  $f(x) = xe^x - 10$ . Uma maneira geral de construir um problema de ponto fixo equivalente é o seguinte:

$$f(x) = 0 \Rightarrow \alpha f(x) = 0 \Rightarrow x - \alpha f(x) = x,$$

para qualquer parâmetro  $\alpha \neq 0$ . Consideremos, então, as seguintes duas funções:

$$g_1(x) = x - 0,5f(x) \quad \text{e} \quad g_2(x) = x - 0,05f(x).$$

Tabela 3.2: Iterações do ponto fixo para o exemplo 3.3.3.

$n$	$x_1^{(n)}$	$x_2^{(n)}$
1	1,700	1,700
2	2,047	1,735
3	-0,8812	1,743
4	4,3013	1,746
5	-149,4	1,746

Notamos que o ponto fixo destas duas funções coincide com o zero de  $f(x)$ . Construindo as iterações do ponto fixo:

$$x_1^{(n+1)} = g_1(x_1^{(n)}) \quad \text{e} \quad x_2^{(n+1)} = g_2(x_2^{(n)}),$$

tomando  $x_1^{(1)} = x_2^{(1)} = 1,7$ , obtemos os resultados apresentados na tabela 3.2. Observamos que, enquanto, a iteração do ponto fixo com a função  $g_1(x)$  ( $\alpha = 0,5$ ) parece divergir, a iteração com a função  $g_2(x)$  ( $\alpha = 0,05$ ) parece convergir.

No **Scilab**, podemos computar as iterações do ponto fixo  $x^{(n+1)} = g_1(x^{(n)})$  com o seguinte código:

```
--> deff('y = f(x)', 'y = x*exp(x)-10')
--> deff('y = g1(x)', 'y = x - 0.5*f(x)')
--> x = 1.7;
--> x = g1(x)
x =
    2.0471
--> x = g1(x)
x =
   -0.88119
```

e, assim, sucessivamente. Itere com a função  $g_2(x)$  e verifique a convergência!

Afim de estudarmos a convergência da iteração do ponto fixo, apresentamos o teorema do ponto fixo.

### 3.3.1 Teorema do ponto fixo

O teorema do ponto fixo nos fornece condições suficientes para a existência e unicidade do ponto fixo, bem como para a convergência das iterações do método.

**Definição 3.3.1.** Uma **contração** é uma função real  $g : [a, b] \rightarrow [a, b]$  tal que:

$$|g(x) - g(y)| \leq \beta |x - y|, \quad 0 \leq \beta < 1.$$

**Observação 3.3.1.** Seja  $g : [a, b] \rightarrow [a, b]$ ,  $y = g(x)$ .

- Se  $g(x)$  é uma contração, então  $g(x)$  função contínua.
- Se  $|g'(x)| < k$ ,  $0 < k < 1$ , para todo  $x \in [a, b]$ , então  $g(x)$  é uma contração.

**Teorema 3.3.1** (Teorema do ponto fixo). Se  $g : [a, b] \rightarrow [a, b]$  é uma contração, então existe um único ponto  $x^* \in [a, b]$  tal que  $g(x^*) = x^*$ , isto é,  $x^*$  é ponto fixo de  $g(x)$ . Além disso, a sequência  $\{x^{(n)}\}_{n \in \mathbb{N}}$  dada por:

$$x^{(n+1)} = g(x^{(n)})$$

converge para  $x^*$  para qualquer  $x^{(1)} \in [a, b]$ .

*Demonstração.* Começamos demonstrando que existe pelo menos um ponto fixo. Para tal definimos a função  $f(x) = x - g(x)$  e observamos que:

$$f(a) = a - g(a) \leq a - a = 0$$

e

$$f(b) = b - g(b) \geq b - b = 0$$

Se  $f(a) = a$  ou  $f(b) = b$ , então o ponto fixo existe. Caso contrário, as desigualdades são estritas e a  $f(x)$  muda de sinal no intervalo. Como esta função é contínua, pelo teorema de Bolzano 3.1.1, existe um ponto  $x^*$  no intervalo  $(a, b)$  tal que  $f(x^*) = 0$ , ou seja,  $g(x^*) = x^*$ . Isto mostra a existência.

Para provar que o ponto fixo é único, observamos que se  $x^*$  e  $x^{**}$  são pontos fixos, eles devem ser iguais, pois:

$$|x^* - x^{**}| = |g(x^*) - g(x^{**})| \leq \beta |x^* - x^{**}|.$$

A desigualdade  $|x^* - x^{**}| \leq \beta |x^* - x^{**}|$  com  $0 \leq \beta < 1$  implica  $|x^* - x^{**}| = 0$ .

Para demonstrar a convergência da sequência, observamos que:

$$|x^{(n+1)} - x^*| = |g(x^{(n)}) - x^*| = |g(x^{(n)}) - g(x^*)| \leq \beta |x^{(n)} - x^*|.$$

Daí, temos:

$$|x^{(n)} - x^*| \leq \beta |x^{(n-1)} - x^*| \leq \beta^2 |x^{(n-2)} - x^*| \leq \dots \leq \beta^n |x^{(0)} - x^*|.$$

Portanto, como  $0 \leq \beta < 1$ , temos:

$$\lim_{n \rightarrow \infty} |x^{(n)} - x^*| = 0,$$

ou seja,  $x^{(n)} \rightarrow x^*$  quando  $n \rightarrow \infty$ . □

**Observação 3.3.2.** Do teorema do ponto fixo, temos que se  $g(x)$  é uma contração com constante  $0 \leq \beta < 1$ , então:

$$|x^{(n+1)} - x^*| \leq \beta |x^{(n)} - x^*|, \quad n \geq 1.$$

Isto é, as iterações do ponto fixo têm taxa de convergência linear.

**Exemplo 3.3.4.** Mostre que o teorema do ponto fixo se aplica a função  $g(x) = \cos(x)$  no intervalo  $[1/2, 1]$ , isto é, a iteração de ponto fixo converge para a solução da equação  $\cos x = x$ . Então, calcule as iterações do ponto fixo com aproximação inicial  $x^{(1)} = 0,7$ , estime o erro absoluto da aproximação e verifique a taxa de convergência.

**Solução.** Basta mostrarmos que:

- a)  $g([1/2, 1]) \subseteq [1/2, 1]$ ;
- b)  $|g'(x)| < \beta$ ,  $0 < \beta < 1$ ,  $\forall x \in [1/2, 1]$ .

Para provar a), observamos que  $g(x)$  é decrescente no intervalo, pelo que temos:

$$0,54 < \cos(1) \leq \cos(x) \leq \cos(1/2) < 0,88$$

Como  $[0,54, 0,88] \subseteq [0,5, 1]$ , temos o item a).

Para provar o item b), observamos que:

$$g'(x) = -\sin(x).$$

Da mesma forma, temos a estimativa:

$$-0,85 < -\sin(1) \leq -\sin(x) \leq -\sin(1/2) < -0,47.$$

Assim,  $|g'(x)| < 0,85$  temos a desigualdade com  $\beta = 0,85 < 1$ .

A Tabela 3.3 apresenta o comportamento numérico da iteração do ponto fixo:

$$\begin{aligned} x^{(1)} &= 0,7 \\ x^{(n+1)} &= \cos(x^{(n)}), \quad n \geq 1. \end{aligned}$$

Para estimar o erro, consideramos  $x^* = 0,7390851605$ . A Figura 3.4 mostrar o decaimento do erro  $\epsilon_n = |x^{(n)} - x^*|$  comparado com a taxa de convergência linear com  $\beta = 0,85$ .

No Scilab, podemos computar estas iterações e o erro absoluto com o seguinte código:

$n$	$x^{(n)}$	$\epsilon_n :=  x^{(n)} - x^* $
1	0,70000	3,9E-02
2	0,76484	2,6E-02
3	0,72149	1,8E-02
4	0,75082	1,2E-02
5	0,73113	8,0E-03
6	0,74442	5,3E-03
7	0,73548	3,6E-03

Tabela 3.3: Iteração do ponto fixo para o exemplo 3.3.4.




Figura 3.4: Decaimento do erro  $\epsilon_n = |x^{(n)} - x^*|$  da iteração do ponto fixo estudada no Exemplo 3.3.4.

```
//est. da solucao
deff('y = f(x)', 'y = cos(x)-x')
xe = fsolve(0.7, f)

#funcao do pto. fixo
deff('y = g(x)', 'y = cos(x)')

#aprox. inicial
x0 = 0.7
eps = abs(x0-xe)
disp([x0, eps])

for i=2:7
    x = g(x0)
    eps = abs(x-xe)
    disp([x, eps])
    x0 = x
end
```

◇

### 3.3.2 Teste de convergência

Seja  $g : [a, b] \rightarrow \mathbb{R}$  uma função  $C^0[a, b]$  e  $x^* \in (a, b)$  um ponto fixo de  $g$ . Então  $x^*$  é dito estável se existe uma região  $(x^* - \delta, x^* + \delta)$  chamada bacia de atração tal que  $x^{(n+1)} = g(x^{(n)})$  é convergente sempre que  $x^{(0)} \in (x^* - \delta, x^* + \delta)$ .

**Proposição 3.3.1** (Teste de convergência). *Se  $g \in C^1[a, b]$  e  $|g'(x^*)| < 1$ , então  $x^*$  é estável. Se  $|g'(x^*)| > 1$  é instável e o teste é inconclusivo quando  $|g'(x^*)| = 1$ .*

**Exemplo 3.3.5.** No exemplo 3.3.3, observamos que a função  $g_1(x)$  nos forneceu uma iteração divergente, enquanto que a função  $g_2(x)$  forneceu uma iteração convergente (veja a figura 3.5). A razão destes comportamentos é explicada pelo teste da convergência. Com efeito, sabemos que o ponto fixo destas funções está no intervalo  $[1, 6, 1, 8]$  e temos:

$$|g'_1(x)| = |1 - 0,5(x+1)e^x| > 4,8, \quad \forall x \in [1, 6, 1, 8],$$

enquanto:

$$|g'_2(x)| = |1 - 0,05(x+1)e^x| < 0,962, \quad \forall x \in [1, 6, 1, 8].$$




Figura 3.5: Ilustração das iterações do ponto fixo para: (esquerda)  $y = g_1(x)$  e (direita)  $y = g_2(x)$ . Veja exemplo 3.3.5.

### 3.3.3 Estabilidade e convergência

A fim de compreendermos melhor os conceitos de estabilidade e convergência, considere uma função  $\Phi(x)$  com um ponto fixo  $x^* = g(x^*)$  e analisemos o seguinte processo iterativo:

$$\begin{aligned} x^{(n+1)} &= g(x^{(n)}) \\ x^{(0)} &= x \end{aligned}$$

Vamos supor que a função  $g(x)$  pode ser aproximada por seu polinômio de Taylor em torno do ponto fixo:

$$\begin{aligned} g(x) &= g(x^*) + (x - x^*)g'(x^*) + O((x - x^*)^2), n \geq 0 \\ &= x^* + (x - x^*)g'(x^*) + O((x - x^*)^2) \\ &\approx x^* + (x - x^*)g'(x^*) \end{aligned}$$

Substituindo na relação de recorrência, temos

$$x^{(n+1)} = g(x^{(n)}) \approx x^* + (x^{(n)} - x^*)g'(x^*)$$

Ou seja:

$$(x^{(n+1)} - x^*) \approx (x^{(n)} - x^*)g'(x^*)$$

Tomando módulos, temos:

$$\underbrace{|x^{(n+1)} - x^*|}_{\epsilon_{n+1}} \approx \underbrace{|x^{(n)} - x^*|}_{\epsilon_n} |g'(x^*)|,$$



onde  $\epsilon_n = |x^{(n)} - x^*|$ .

**Observação 3.3.3.** A análise acima, concluímos:

- Se  $|g'(x^*)| < 1$ , então, a distância de  $x^{(n)}$  até o ponto fixo  $x^*$  está diminuindo a cada passo.
- Se  $|g'(x^*)| > 1$ , então, a distância de  $x^{(n)}$  até o ponto fixo  $x^*$  está aumentando a cada passo.
- Se  $|g'(x^*)| = 1$ , então, nossa aproximação de primeira ordem não é suficiente para compreender o comportamento da sequência.

### 3.3.4 Erro absoluto e tolerância

Na prática, quando se aplica uma iteração como esta, não se conhece de antemão o valor do ponto fixo  $x^*$ . Assim, o erro  $\epsilon_n = |x^{(n)} - x^*|$  precisa ser estimado com base nos valores calculados  $x^{(n)}$ . Uma abordagem frequente é analisar a evolução da diferença entre dois elementos da sequência:

$$\Delta_n = |x^{(n+1)} - x^{(n)}|$$

A pergunta natural é: Será que o erro  $\epsilon_n = |x^{(n)} - x^*|$  é pequeno quando  $\Delta_n = |x^{(n+1)} - x^{(n)}|$  for pequeno?

Para responder a esta pergunta, observamos que

$$x^* = \lim_{n \rightarrow \infty} x^{(n)}$$

portanto:

$$\begin{aligned} x^* - x^{(N)} &= (x^{(N+1)} - x^{(N)}) + (x^{(N+2)} - x^{(N+1)}) + (x^{(N+3)} - x^{(N+2)}) + \dots \\ &= \sum_{k=0}^{\infty} (x^{(N+k+1)} - x^{(N+k)}) \end{aligned}$$

Usamos também as expressões:

$$\begin{aligned} x^{(n+1)} &\approx x^* + (x^{(n)} - x^*)g'(x^*) \\ x^{(n)} &\approx x^* + (x^{(n-1)} - x^*)g'(x^*) \end{aligned}$$

Subtraindo uma da outra, temos:

$$x^{(n+1)} - x^{(n)} \approx (x^{(n)} - x^{(n-1)})g'(x^*)$$

Portanto:

$$x^{(N+k+1)} - x^{(N+k)} \approx (x^{(N+1)} - x^{(N)}) (g'(x^*))^k$$

E temos:

$$\begin{aligned} x^* - x^{(N)} &= \sum_{k=0}^{\infty} (x^{(N+k+1)} - x^{(N+k)}) \\ &\approx \sum_{k=0}^{\infty} (x^{(N+1)} - x^{(N)}) (g'(x^*))^k \\ &= (x^{(N+1)} - x^{(N)}) \frac{1}{1 - g'(x^*)}, \quad |g'(x^*)| < 1 \end{aligned}$$

Tomando módulo, temos:

$$\begin{aligned} |x^* - x^{(N)}| &\approx |x^{(N+1)} - x^{(N)}| \frac{1}{1 - g'(x^*)} \\ \epsilon_N &\approx \frac{\Delta_N}{1 - g'(x^*)} \end{aligned}$$

**Observação 3.3.4.** Tendo em mente a relação  $x^{(n+1)} - x^{(n)} \approx (x^{(n)} - x^{(n-1)})g'(x^*)$ , concluímos:

- Quando  $g'(x^*) < 0$ , o esquema é alternante, isto é, o sinal do erro se altera a cada passo. O erro  $\epsilon_N$  pode ser estimado diretamente da diferença  $\Delta_N$ , pois o denominador  $1 - g'(x^*) > 1$ .
- Quando  $0 < g'(x^*) < 1$ , o esquema é monótono e  $\frac{1}{1 - g'(x^*)} > 1$ , pelo que o erro  $\epsilon_N$  é maior que a diferença  $\Delta_N$ . A relação será tão mais importante quando mais próximo da unidade for  $g'(x^*)$ , ou seja, quando mais lenta for a convergência. Para estimar o erro em função da diferença  $\Delta_N$ , observamos que  $g'(x^*) \approx \frac{x^{(n+1)} - x^{(n)}}{x^{(n)} - x^{(n-1)}}$  e

$$|g'(x^*)| \approx \frac{\Delta_n}{\Delta_{n-1}}$$

e portanto

$$\epsilon_N \approx \frac{\Delta_N}{1 - \frac{\Delta_n}{\Delta_{n-1}}}.$$

## Exercícios

**E 3.3.1.** Resolver a equação  $e^x = x + 2$  é equivalente a calcular os pontos fixos da função  $g(x) = e^x + 2$  (veja o exemplo 3.3.1). Use a iteração do ponto fixo  $x^{(n+1)} = g(x^n)$  com  $x^{(1)} = -1,8$  para obter uma aproximação de uma das soluções da equação dada com 8 dígitos significativos.

**E 3.3.2.** Mostre que a equação:

$$\cos(x) = x$$

possui uma única solução no intervalo  $[0, 1]$ . Use a iteração do ponto fixo e encontre uma aproximação para esta solução com 4 dígitos significativos.

**E 3.3.3.** Mostre que a equação  $xe^x = 10$  é equivalente às seguintes equações:

$$x = \ln\left(\frac{10}{x}\right) \quad \text{e} \quad x = 10e^{-x}.$$

Destas, considere as seguintes iterações de ponto fixo:

a)  $x^{(n+1)} = \ln\left(\frac{10}{x^{(n)}}\right)$

b)  $x^{(n+1)} = 10e^{-x^{(n)}}$

Tomando  $x^{(1)} = 1$ , verifique se estas sequências são convergentes.

**E 3.3.4.** Verifique (analiticamente) que a única solução real da equação:

$$xe^x = 10$$

é ponto fixo das seguintes funções:

a)  $g(x) = \ln\left(\frac{10}{x}\right)$

b)  $g(x) = x - \frac{xe^x - 10}{15}$

c)  $g(x) = x - \frac{xe^x - 10}{10 + e^x}$

Implemente o processo iterativo  $x^{(n+1)} = g(x^{(n)})$  para  $n \geq 0$  e compare o comportamento. Discuta os resultados com base na teoria estudada.

**E 3.3.5.** Verifique (analiticamente) que a única solução real da equação:

$$\cos(x) = x$$

é ponto fixo das seguintes funções:

- a)  $g(x) = \cos(x)$   
 b)  $g(x) = 0,4x + 0,6 \cos(x)$   
 c)  $g(x) = x + \frac{\cos(x)-x}{1+\sin(x)}$

Implemente o processo iterativo  $x^{(n+1)} = g(x^{(n)})$  para  $n \geq 0$  e compare o comportamento. Discuta os resultados com base na teoria estudada.

**E 3.3.6.** Encontre a solução de cada equação com erro absoluto inferior a  $10^{-6}$ .

- a)  $e^x = x + 2$  no intervalo  $(-2,0)$ .  
 b)  $x^3 + 5x^2 - 12 = 0$  no intervalo  $(1,2)$ .  
 c)  $\sqrt{x} = \cos(x)$  no intervalo  $(0,1)$ .

**E 3.3.7.** Encontre numericamente as três primeiras raízes positivas da equação dada por:

$$\cos(x) = \frac{x}{10 + x^2}$$

com erro absoluto inferior a  $10^{-6}$ .

**E 3.3.8.** Considere os seguintes processos iterativos:

$$a \begin{cases} x^{(n+1)} &= \cos(x^{(n)}) \\ x^{(1)} &= .5 \end{cases}$$

e

$$b \begin{cases} x^{(n+1)} &= .4x^{(n)} + .6 \cos(x^{(n)}) \\ x^{(1)} &= .5 \end{cases}$$

Use o teorema do ponto fixo para verificar que cada um desses processos converge para a solução da equação  $x^*$  de  $\cos(x) = x$ . Observe o comportamento numérico dessas sequências. Qual estabiliza mais rápido com cinco casas decimais? Discuta.

Dica: Verifique que  $\cos([0.5,1]) \subseteq [0.5,1]$  e depois a mesma identidade para a função  $f(x) = 0,4x + 0,6 \cos(x)$ .

**E 3.3.9.** Use o teorema do ponto fixo aplicado a um intervalo adequado para mostrar que a função  $g(x) = \ln(100 - x)$  possui um ponto fixo estável.

**E 3.3.10.** (Fluidos) Na hidráulica, o fator de atrito de Darcy é dado pela implicitamente pela equação de Colebrook-White:

$$\frac{1}{\sqrt{f}} = -2 \log_{10} \left( \frac{\varepsilon}{14.8 R_h} + \frac{2.51}{\text{Re} \sqrt{f}} \right)$$

onde  $f$  é o fator de atrito,  $\varepsilon$  é a rugosidade do tubo em metros,  $R_h$  é o raio hidráulico em metros e  $\text{Re}$  é o número de Reynolds. Considere  $\varepsilon = 2\text{mm}$ ,  $R_h = 5\text{cm}$  e  $\text{Re} = 10000$  e obtenha o valor de  $f$  pela iteração:

$$x^{(n+1)} = -2 \log_{10} \left( \frac{\varepsilon}{14.8 R_h} + \frac{2.51 x^{(n)}}{\text{Re}} \right)$$

**E 3.3.11.** Encontre uma solução aproximada para equação algébrica

$$180 - 100x = 0.052 \sinh^{-1}(10^{13}x)$$

com erro absoluto inferior a  $10^{-3}$  usando um método iterativo. Estime o erro associado ao valor de  $v = 180 - 100x = 0.052 \sinh^{-1}(10^{13}x)$ , usando cada uma dessas expressões. Discuta sucintamente o resultado obtido. Dica: Este caso é semelhante ao problema 3.2.8.

**E 3.3.12.** Considere que  $x_n$  satisfaz a seguinte relação de recorrência:

$$x_{n+1} = x_n - \beta (x_n - x^*)$$

onde  $\beta$  e  $x^*$  são constantes. Prove que

$$x_n - x^* = (1 - \beta)^{n-1} (x_1 - x^*).$$

Conclua que  $x_n \rightarrow x^*$  quando  $|1 - \beta| < 1$ .

**E 3.3.13.** (Convergência lenta) Considere o seguinte esquema iterativo:

$$\begin{aligned} x^{(n+1)} &= x_n + q^n, \\ x^{(0)} &= 0, \end{aligned}$$

onde  $q = 1 - 10^{-6}$ .

a) Calcule o limite

$$x_\infty = \lim_{n \rightarrow \infty} x^{(n)}$$

analiticamente.

- b) Considere que o problema de obter o limite da sequência numericamente usando como critério de parada que  $|x^{(n+1)} - x^{(n)}| < 10^{-5}$ . Qual o valor é produzido pelo esquema numérico? Qual o desvio entre o valor obtido pelo esquema numérico e o valor do limite obtido no item a? Discuta. (Dica: Você não deve implementar o esquema iterativo, obtendo o valor de  $x^{(n)}$  analiticamente)
- c) Qual deve ser a tolerância especificada para obter o resultado com erro relativo inferior a  $10^{-2}$ ?

**E 3.3.14.** (Convergência sublinear) Considere o seguinte esquema iterativo:

$$x^{(n+1)} = x^{(n)} - [x^{(n)}]^3, \quad x^{(n)} \geq 0$$

com  $x^{(0)} = 10^{-2}$ . Prove que  $\{x^{(n)}\}$  é sequência de número reais positivos convergindo para zero. Verifique que são necessários mais de mil passos para que  $x^{(n)}$  se torne menor que  $0.9x^{(0)}$ .

**E 3.3.15.** (Taxa de convergência)

- a) Use o teorema do ponto fixo para mostrar que a função  $g(x) = 1 - \sin(x)$  possui um único ponto fixo estável o intervalo  $[\frac{1}{10}, 1]$ . Construa um método iterativo  $x^{(n+1)} = g(x^{(n)})$  para encontrar esse ponto fixo. Use o computador para encontrar o valor numérico do ponto fixo.
- b) Verifique que função  $\psi(x) = \frac{1}{2}[x + 1 - \sin(x)]$  possui um ponto fixo  $x^*$  que também é o ponto fixo da função  $g$  do item a. Use o computador para encontrar o valor numérico do ponto fixo através da iteração  $x^{(n+1)} = \psi(x^{(n)})$ . Qual método é mais rápido?

**E 3.3.16.** (Esquemas oscilantes)(*Esquemas oscilantes*)

- a) Considere a função  $g(x)$  e função composta  $\psi(x) = g \circ g = g(g(x))$ . Verifique todo ponto fixo de  $g$  também é ponto fixo de  $\psi$ .
- b) Considere a função

$$g(x) = 10 \exp(-x)$$

e função composta  $\psi(x) = g \circ g = g(g(x))$ . Mostre que  $\psi$  possui dois pontos fixos que não são pontos fixos de  $g$ .

- c) No problema anterior, o que acontece quando o processo iterativo  $x^{(n+1)} = g(x^{(n)})$  é inicializado com um ponto fixo de  $\psi$  que não é ponto fixo de  $g$ ?

**E 3.3.17.** (Aceleração de convergência - introdução ao método de Newton) Mostre que se  $f(x)$  possui uma raiz  $x^*$  então a  $x^*$  é um ponto fixo de  $\phi(x) = x + \gamma(x)f(x)$ . Encontre uma condição em  $\gamma(x)$  para que o ponto fixo  $x^*$  de  $\phi$  seja estável. Encontre uma condição em  $\gamma(x)$  para que  $\phi'(x^*) = 0$ .

**E 3.3.18.** (Aceleração de convergência - introdução ao método de Newton) Considere que  $x^{(n)}$  satisfaz a seguinte relação de recorrência:

$$x^{(n+1)} = x^{(n)} - \gamma f(x^{(n)})$$

onde  $\gamma$  é uma constante. Suponha que  $f(x)$  possui um zero em  $x^*$ . Aproxime a função  $f(x)$  em torno de  $x^*$  por

$$f(x) = f(x^*) + f'(x^*)(x - x^*) + O((x - x^*)^2).$$

Em vista do problema anterior, qual valor de  $\gamma$  você escolheria para que a sequência  $x^{(n)}$  convirja rapidamente para  $x^*$ .

**E 3.3.19.** Considere o problema da questão 3.2.8 e dois seguintes esquemas iterativos.

$$A \begin{cases} I^{(n+1)} = \frac{1}{R} \left[ V - v_t \ln \left( 1 + \frac{I^{(n)}}{I_R} \right) \right], n > 0 \\ I^{(0)} = 0 \end{cases}$$

e

$$B \begin{cases} I^{(n+1)} = I_R \left[ \exp \left( \frac{V - RI^{(n)}}{v_t} \right) - 1 \right], n > 0 \\ I^{(0)} = 0 \end{cases}$$

Verifique numericamente que apenas o processo A é convergente para a, b e c; enquanto apenas o processo B é convergente para os outros itens.

## 3.4 Método de Newton-Raphson

Nesta seção, apresentamos o **método de Newton-Raphson**<sup>45</sup> para calcular o zero de funções reais de uma variável real.

Assumimos que  $x^*$  é um zero de uma dada função  $f(x)$  continuamente diferenciável, isto é,  $f(x^*) = 0$ . Afim de usar a iteração do ponto fixo, observamos que, equivalentemente,  $x^*$  é um ponto fixo da função:

$$g(x) = x + \alpha(x)f(x), \quad \alpha(x) \neq 0,$$

<sup>4</sup>Joseph Raphson, 1648 - 1715, matemático inglês.

<sup>5</sup>Também chamado apenas de método de Newton.

onde  $\alpha(x)$  é uma função arbitrária que queremos escolher de forma que a iteração do ponto fixo tenha ótima taxa de convergência.

Do **Teorema do ponto fixo** temos que a taxa de convergência é dada em função do valor absoluto da derivada de  $g(x)$ . Calculando a derivada temos:

$$g'(x) = 1 + \alpha(x)f'(x) + \alpha'(x)f(x).$$

No ponto  $x = x^*$ , temos:

$$g'(x^*) = 1 + \alpha(x^*)f'(x^*) + \alpha'(x^*)f(x^*).$$

Como  $f(x^*) = 0$ , temos:

$$g'(x^*) = 1 + \alpha(x^*)f'(x^*).$$

Sabemos que o processo iterativo converge tão mais rápido quanto menor for  $|g'(x)|$  nas vizinhanças de  $x^*$ . Isto nos leva a escolher:

$$g'(x^*) = 0,$$

e, então, temos:

$$\alpha(x^*) = -\frac{1}{f'(x^*)},$$

se  $f'(x^*) \neq 0$ .

A discussão acima nos motiva a introduzir o método de Newton, cujas iterações são dada por:

$$x^{(n+1)} = x^{(n)} - \frac{f(x^{(n)})}{f'(x^{(n)})}, \quad n \geq 1,$$

sendo  $x^{(1)}$  uma aproximação inicial dada.

### 3.4.1 Interpretação geométrica

Seja dada uma função  $f(x)$  conforme na figura 3.6. Para tanto, escolhemos uma aproximação inicial  $x^{(1)}$  e computamos:

$$x^{(2)} = x^{(1)} - \frac{f(x^{(1)})}{f'(x^{(1)})}.$$

Geometricamente, o ponto  $x^{(2)}$  é a interseção da reta tangente ao gráfico da função  $f(x)$  no ponto  $x = x^{(1)}$  com o eixo das abscissas. Com efeito, a equação desta reta é:

$$y = f'(x^{(1)})(x - x^{(1)}) + f(x^{(1)}).$$






Figura 3.6: Interpretação do método de Newton.

Assim, a interseção desta reta com o eixo das abscissas ocorre quando ( $y = 0$ ):

$$f'(x^{(1)})(x - x^{(1)}) + f(x^{(1)}) = 0 \Rightarrow x = x^{(1)} - \frac{f(x^{(1)})}{f'(x^{(1)})}.$$

Ou seja, dado  $x^{(n)}$  a próxima aproximação  $x^{(n+1)}$  é o ponto de interseção entre o eixo das abscissas e a reta tangente ao gráfico da função no ponto  $x = x^{(n)}$ . Observe a figura 3.6.

### 3.4.2 Análise de convergência

Seja  $f(x)$  um função com derivadas primeira e segunda contínuas tal que  $f(x^*) = 0$  e  $f'(x^*) \neq 0$ . Seja também a função  $g(x)$  definida como:

$$g(x) = x - \frac{f(x)}{f'(x)}.$$

Expandimos em série de Taylor em torno de  $x = x^*$ , obtemos:

$$g(x) = g(x^*) + g'(x^*)(x - x^*) + \frac{g''(x^*)}{2}(x - x^*)^2 + O((x - x^*)^3).$$

Observamos que:

$$\begin{aligned} g(x^*) &= x^* \\ g'(x^*) &= 1 - \frac{f'(x^*)f'(x^*) - f(x^*)f''(x^*)}{(f'(x^*))^2} = 0 \end{aligned}$$

Portanto:

$$g(x) = x^* + \frac{g''(x^*)}{2}(x - x^*)^2 + O((x - x^*)^3)$$

Com isso, temos:

$$x^{(n+1)} = g(x^{(n)}) = x^* + \frac{g''(x^*)}{2}(x^{(n)} - x^*)^2 + O((x - x^*)^3),$$

ou seja:

$$|x^{(n+1)} - x^*| \leq C |x^{(n)} - x^*|^2,$$

com constante  $C = |g''(x^*)/2|$ . Isto mostra que o método de Newton tem **taxa de convergência quadrática**. Mais precisamente, temos o seguinte teorema.

**Teorema 3.4.1** (Método de Newton). *Sejam  $f \in C^2([a, b])$  com  $x^* \in (a, b)$  tal que  $f(x^*) = 0$  e:*

$$m := \min_{x \in [a, b]} |f'(x)| > 0 \quad e \quad M := \max_{x \in [a, b]} |f''(x)|.$$

Escolhendo  $\rho > 0$  tal que:

$$q := \frac{M}{2m}\rho < 1,$$

definimos a **bacia de atração** do método de Newton pelo conjunto:

$$K_\rho(x^*) := \{x \in \mathbb{R}; |x - x^*| \leq \rho\} \subset [a, b].$$

Então, para qualquer  $x^{(1)} \in K_\rho(x^*)$  a iteração do método de Newton:

$$x^{(n+1)} = x^{(n)} - \frac{f(x^{(n)})}{f'(x^{(n)})},$$

fornece uma sequência  $x^{(n)}$  que converge para  $x^*$ , isto é,  $x^{(n)} \rightarrow x^*$  quando  $n \rightarrow \infty$ . Além disso, temos a seguinte estimativa de erro **a priori**:

$$|x^{(n)} - x^*| \leq \frac{2m}{M} q^{(2^{n-1})}, \quad n \geq 2,$$

e a seguinte estimativa de erro **a posteriori**:

$$|x^{(n)} - x^*| \leq \frac{M}{2m} |x^{(n)} - x^{(n-1)}|^2, \quad n \geq 2.$$

*Demonstração.* Para  $n \in \mathbb{N}$ ,  $n \geq 2$ , temos:

$$x^{n+1} - x^* = x^{(n)} - \frac{f(x^{(n)})}{f'(x^{(n)})} - x^* = -\frac{1}{f'(x^{(n)})} [f(x^{(n)}) + (x^* - x^{(n)})f'(x^{(n)})]. \quad (3.1)$$

Agora, para estimar o lado direito desta equação, usamos o polinômio de Taylor de grau 1 da função  $f(x)$  em torno de  $x = x^{(n)}$ , isto é:

$$f(x^*) = f(x^{(n)}) + (x^* - x^{(n)})f'(x^{(n)}) + \int_{x^{(n)}}^{x^*} f''(t)(x^* - t) dt.$$

Pela mudança de variável  $t = x^{(n)} + s(x^{(n)} - x^*)$ , observamos que o resto deste polinômio de Taylor na forma integral é igual a:

$$R(x^*, x^{(n)}) := (x^* - x^{(n)})^2 \int_0^1 f''(x^{(n)} + s(x^* - x^{(n)})) (1 - s) ds.$$

Assim, da cota da segunda derivada de  $f(x)$ , temos:

$$|R(x^*, x^{(n)})| \leq M|x^* - x^{(n)}|^2 \int_0^1 (1 - s) ds = \frac{M}{2}|x^* - x^{(n)}|^2. \quad (3.2)$$

Se  $x^{(n)} \in K_\rho(x^*)$ , então de (3.1) e (3.2) temos:

$$|x^{(n+1)} - x^*| \leq \frac{M}{2m}|x^{(n)} - x^*|^2 \leq \frac{M}{2m}\rho^2 < \rho. \quad (3.3)$$

Isto mostra que se  $x^{(n)} \in K_\rho(x^*)$ , então  $x^{(n+1)} \in K_\rho(x^*)$ , isto é,  $x^{(n)} \in K_\rho(x^*)$  para todo  $n \in \mathbb{R}$ .

Agora, obtemos a estimativa **a priori** de (3.4.2), pois:

$$|x^{(n)} - x^*| \leq \frac{2m}{M} \left( \frac{M}{2m} |x^{(n-1)} - x^*| \right)^2 \leq \dots \leq \frac{2m}{M} \left( \frac{M}{2m} |x^{(1)} - x^*| \right)^{2^{n-1}}.$$

Logo:

$$|x^{(n)} - x^*| \leq \frac{2m}{M} q^{2^{n-1}},$$

donde também vemos que  $x^{(n)} \rightarrow x^*$  quando  $n \rightarrow \infty$ , pois  $q < 1$ .

Por fim, para provarmos a estimativa **a posteriori** tomamos a seguinte expansão em polinômio de Taylor:

$$f(x^{(n)}) = f(x^{(n-1)}) + (x^{(n)} - x^{(n-1)})f'(x^{(n-1)}) + R(x^{(n)}, x^{(n-1)}).$$

Aqui, temos:

$$f(x^{(n-1)}) + (x^{(n)} - x^{(n-1)})f'(x^{(n-1)}) = 0$$

e, então, conforme acima:

$$|f(x^{(n)})| = |R(x^{(n)}, x^{(n-1)})| \leq \frac{M}{2} |x^{(n)} - x^{(n-1)}|^2.$$

Com isso e do teorema do valor médio, concluímos:

$$|x^{(n)} - x^*| \leq \frac{1}{m} |f(x^{(n)}) - f(x^*)| \leq \frac{M}{2m} |x^{(n)} - x^{(n-1)}|^2.$$

□

**Exemplo 3.4.1.** Estime o raio  $\rho$  da bacia de atração  $K_\rho(x^*)$  para a função  $f(x) = \cos(x) - x$  restrita ao intervalo  $[0, \pi/2]$ .

**Solução.** O raio da bacia de atração é tal que:

$$\rho < \frac{2m}{M}$$

onde  $m := \min |f'(x)|$  e  $M := \max |f''(x)|$  com o mínimo e o máximo tomados em um intervalo  $[a, b]$  que contenha o zero da função  $f(x)$ . Aqui, por exemplo, podemos tomar  $[a, b] = [0, \pi/2]$ . Como, neste caso,  $f'(x) = -\sin(x) - 1$ , temos que  $m = 1$ . Também, como  $f''(x) = -\cos(x)$ , temos  $M = 1$ . Assim, concluímos que  $\rho < 2$  (lembrando que  $K_\rho(x^*) \subset [0, \pi/2]$ ). Ou seja, neste caso as iterações de Newton convergem para o zero de  $f(x)$  para qualquer escolha da aproximação inicial  $x^{(1)} \in [0, \pi/2]$ . ◇

## Exercícios

**E 3.4.1.** Encontre a raiz positiva da função  $f(x) = \cos(x) - x^2$  pelo método de Newton inicializando-o com  $x^{(0)} = 1$ . Realize a iteração até obter estabilidade no *quinto* dígito significativo.

**E 3.4.2.** Considere o problema de calcular as soluções positivas da equação:

$$\operatorname{tg}(x) = 2x^2.$$

- Use o método gráfico para isolar as duas primeiras raízes positivas em pequenos intervalos. Use a teoria para argumentar quanto à existência e unicidade das raízes dentro intervalos escolhidos.
- Calcule cada uma das raízes pelo método de Newton com oito dígitos significativos e discuta a convergência comparando com o item b).

**E 3.4.3.** Considere a equação

$$e^{-x^2} = x$$

trace o gráfico com auxílio do computador e verifique que ela possui uma raiz positiva. Encontre uma aproximação para esta raiz pelo gráfico e use este valor para inicializar o método de Newton e obtenha uma aproximação para a raiz com 8 dígitos significativos. (Use o comando `format('v',16)` para alterar a visualização no Scilab.)

**E 3.4.4.** Isole e encontre as cinco primeiras raízes positivas da equação com 6 dígitos corretos através de traçado de gráfico e do método de Newton.

$$\cos(10x) = e^{-x}.$$

Dica: a primeira raiz positiva está no intervalo  $(0, 0,02)$ . Fique atento.

**E 3.4.5.** Encontre as raízes do polinômio  $f(x) = x^4 - 4x^2 + 4$  através do método de Newton. O que você observa em relação ao erro obtido? Compare com a situação do problema 3.2.7.

**E 3.4.6.** Encontre as raízes reais do polinômio  $f(x) = \frac{x^5}{100} + x^4 + 3x + 1$  isolando-as pelo método do gráfico e depois usando o método de Newton. Expresse a solução com 7 dígitos significativos.

**E 3.4.7.** Considere o método de Newton aplicado para encontrar a raiz de  $f(x) = x^3 - 2x + 2$ . O que acontece quando  $x^{(0)} = 0$ ? Escolha um valor adequado para inicializar o método e obter a única raiz real desta equação.

**E 3.4.8.** Justifique a construção do processo iterativo do método de Newton através do conceito de estabilidade de ponto fixo e convergência do método da iteração. Dica: Considere os problemas 3.3.17 e 3.3.18.

**E 3.4.9.** Entenda a interpretação geométrica ao método de Newton. Encontre um valor para iniciar o método de Newton aplicado ao problema  $f(x) = xe^{-x} = 0$  tal que o esquema iterativo divirja.

**E 3.4.10.** (Computação) Aplique o método de Newton à função  $f(x) = \frac{1}{x} - A$  e construa um esquema computacional para calcular a inversa de  $A$  com base em operações de multiplicação e soma/subtração.

**E 3.4.11.** (Computação) Aplique o método de Newton à função  $f(x) = x^n - A$  e construa um esquema computacional para calcular  $\sqrt[n]{A}$  para  $A > 0$  com base em operações de multiplicação e soma/subtração.

**E 3.4.12.** (Computação) Aplique o método de Newton à função  $f(x) = \frac{1}{x^2} - A$  e construa um esquema computacional para calcular  $\frac{1}{\sqrt{A}}$  para  $A > 0$  com base em operações de multiplicação e soma/subtração.

**E 3.4.13.** Considere a função dada por

$$\psi(x) = \ln(15 - \ln(x))$$

definida para  $x \in (0, e^{15})$

- a) (1.5) Use o teorema do ponto fixo para provar que se  $x^{(0)}$  pertence ao intervalo  $[1, 3]$ , então a sequência dada iterativamente por

$$x^{(n+1)} = \psi(x^{(n)}), n \geq 0$$

converge para o único ponto fixo,  $x^*$ , de  $\psi$ . Construa a iteração  $x^{(n+1)} = \psi(x^{(n)})$  e obtenha numericamente o valor do ponto fixo  $x^*$ . Expresse a resposta com 5 algarismos significativos corretos.

- b) (1.0) Construa a iteração do método de Newton para encontrar  $x^*$ , explicitando a relação de recorrência e iniciando com  $x_0 = 2$ . Use o computador para obter a raiz e expresse a resposta com oito dígitos significativos corretos.

### 3.5 Método das secantes

O **método das secantes** é uma variação do método de Newton, evitando a necessidade de conhecer-se a derivada analítica de  $f(x)$ . Dada uma função  $f(x)$ , a ideia é aproximar sua derivada pela razão fundamental:

$$f'(x) \approx \frac{f(x) - f(x_0)}{x - x_0}, \quad x \approx x_0.$$

Mais precisamente, o método de Newton é uma iteração de ponto fixo da forma:

$$x^{(n+1)} = x^{(n)} - \alpha(x^{(n)})f(x^{(n)}), \quad n \geq 1,$$

onde  $x^{(1)}$  é uma aproximação inicial dada e  $\alpha(x^{(n)}) = 1/f'(x^{(n)})$ . Usando a aproximação da derivada acima, com  $x = x^{(n)}$  e  $x_0 = x^{(n-1)}$ , temos:

$$\alpha(x^{(n)}) = \frac{1}{f'(x^{(n)})} \approx \frac{x^{(n)} - x^{(n-1)}}{f(x^{(n)}) - f(x^{(n-1)})}.$$

Isto nos motiva a introduzir a **iteração do método das secantes** dada por:

$$x^{(n+1)} = x^{(n)} - f(x^{(n)}) \frac{x^{(n)} - x^{(n-1)}}{f(x^{(n)}) - f(x^{(n-1)})}, \quad n \geq 2.$$

Observe que para inicializarmos a iteração acima precisamos de duas aproximações iniciais, a saber,  $x^{(1)}$  e  $x^{(2)}$ . Maneiras apropriadas de escolher estas aproximações podem ser inferidas da interpretação geométrica do método.

**Exemplo 3.5.1.** Encontre as raízes de  $f(x) = \cos(x) - x$ .

**Solução.** Da inspeção do gráfico das funções  $y = \cos(x)$  e  $y = x$ , sabemos que esta equação possui uma raiz em torno de  $x = 0,8$ . Iniciamos o método com  $x_0 = 0,7$  e  $x_1 = 0,8$ .

$x^{(n-1)}$	$x^{(n)}$	$m$	$x^{(n+1)}$
		$\frac{f(0,8)-f(0,7)}{0,8-0,7} =$	$0,8 - \frac{f(0,8)}{-1,6813548} =$
0,7	0,8	-1,6813548	0,7385654
0,8	0,7385654	-1,6955107	0,7390784
0,7385654	0,7390784	-1,6734174	0,7390851
0,7390784	0,7390851	-1,6736095	0,7390851

◇

### 3.5.1 Interpretação geométrica

Enquanto, o método de Newton está relacionado às retas tangentes ao gráfico da função objetivo  $f(x)$ , o método das secantes, como o próprio nome indica, está relacionado às retas secantes.

Sejam  $f(x)$  e as aproximações  $x^{(1)}$  e  $x^{(2)}$  do zero  $x^*$  desta função (veja figura 3.7). A iteração do método das secantes fornece:

$$x^{(3)} = x^{(2)} - f(x^{(2)}) \frac{x^{(2)} - x^{(1)}}{f(x^{(2)}) - f(x^{(1)})}.$$

De fato,  $x^{(3)}$  é o ponto de interseção da reta secante ao gráfico de  $f(x)$  pelos pontos  $x^{(1)}$  e  $x^{(2)}$  com o eixo das abscissas. Com efeito, a equação desta reta secante é:

$$y = \frac{f(x^{(2)}) - f(x^{(1)})}{x^{(2)} - x^{(1)}}(x - x^{(2)}) + f(x^{(2)}).$$

Esta reta intercepta o eixo das abscissas no ponto  $x$  tal que  $y = 0$ , isto é:

$$\frac{f(x^{(2)}) - f(x^{(1)})}{x^{(2)} - x^{(1)}}(x - x^{(2)}) + f(x^{(2)}) \Rightarrow x = x^{(2)} - f(x^{(2)}) \frac{x^{(2)} - x^{(1)}}{f(x^{(2)}) - f(x^{(1)})}.$$



Figura 3.7: Método das secantes.

### 3.5.2 Análise de convergência

Uma análise assintótica semelhante àquela feita para o método de Newton na subseção 3.4.2 nos indica que, para uma função  $f(x)$  duas vezes diferenciável, as iterações do método da secante satisfazem:

$$|x^{(n+1)} - x^*| \approx C|x^{(n)} - x^*||x^{(n-1)} - x^*|,$$

para aproximações iniciais suficientemente próximas de  $x^*$ , onde  $f(x^*) = 0$ . Além disso, veremos que:

$$|x^{(n+1)} - x^*| \leq C|x^{(n)} - x^*|^p, \quad p = \frac{\sqrt{5} + 1}{2} \approx 1,618$$

sob certas condições. Ou seja, o método das secantes tem **taxa de convergência superlinear**.

**Teorema 3.5.1** (Método das secantes). *Seja  $f \in C^2([a, b])$  uma função com  $x^* \in (a, b)$  tal que  $f(x^*) = 0$ . Sejam, também:*

$$m := \min_{x \in [a, b]} |f'(x)| > 0 \quad e \quad M := \max_{x \in [a, b]} |f''(x)| < \infty.$$

*Além disso, seja  $\rho > 0$  tal que:*

$$q := \frac{M}{2m}\rho < 1, \quad K_\rho(x^*) := \{x \in \mathbb{R}; |x - x^*| \leq \rho\} \subset [a, b].$$



Então, para aproximações iniciais  $x^{(1)}, x^{(2)} \in K_\rho(x^*)$ , com  $x^{(1)} \neq x^{(2)}$ , temos que as iterações do método das secantes  $x^{(n)} \in K_\rho(x^*)$ ,  $n \geq 1$ , e  $x^{(n)} \rightarrow x^*$ , quando  $n \rightarrow \infty$ . Além disso, vale a seguinte estimativa de convergência **a priori**:

$$|x^{(n)} - x^*| \leq \frac{2m}{M} q^{\gamma_{n-1}}, \quad n \geq 1,$$

onde  $\{\gamma_n\}_{n \in \mathbb{N}}$  é a sequência de Fibonacci<sup>67</sup>, bem como vale a estimativa **a posteriori**:

$$|x^{(n)} - x^*| \leq \frac{M}{2m} |x^{(n)} - x^{(n-1)}| |x^{(n-1)} - x^{(n-2)}|, \quad n \geq 3.$$

*Demonstração.* Sejam  $n \in \mathbb{N}$  com  $n \geq 2$  e  $x^{(n)}, x^{(n-1)} \in K_\rho(x^*)$ , tal que  $x^{(n)} \neq x^{(n-1)}$ ,  $x^{(n)} \neq x^*$  e  $x^{(n-1)} \neq x^*$ . Seja, também:

$$g(x^{(n)}, x^{(n-1)}) := x^{(n)} - f(x^{(n)}) \frac{x^{(n)} - x^{(n-1)}}{f(x^{(n)}) - f(x^{(n-1)})}.$$

Com isso, temos:

$$\begin{aligned} g(x^{(n)}, x^{(n-1)}) - x^* &= x^{(n)} - f(x^{(n)}) \frac{x^{(n)} - x^{(n-1)}}{f(x^{(n)}) - f(x^{(n-1)})} - x^* \\ &= \frac{x^{(n)} - x^{(n-1)}}{f(x^{(n)}) - f(x^{(n-1)})} \left\{ (x^{(n)} - x^*) \frac{f(x^{(n)}) - f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}} - f(x^{(n)}) + f(x^*) \right\}. \end{aligned}$$

Então, da cota assumida para primeira derivada de  $f(x)$  e do teorema do valor médio, temos:

$$|g(x^{(n)}, x^{(n-1)}) - x^*| \leq \frac{|x^{(n)} - x^*|}{m} \left| \frac{f(x^{(n)}) - f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}} - \frac{f(x^{(n)}) - f(x^*)}{x^{(n)} - x^*} \right|. \quad (3.4)$$

Agora, iremos estimar este último termo a direita. Para tanto, começamos observando que da expansão em polinômio de Taylor de ordem 0 da função  $f(x)$  com resto na forma integral, temos:

$$\begin{aligned} \frac{f(x^{(n)}) - f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}} &= - \int_0^1 \frac{d}{dr} f(x^{(n)} + r(x^{(n-1)} - x^{(n)})) \frac{dr}{x^{(n)} - x^{(n-1)}} \\ &= \int_0^1 f'(x^{(n)} + r(x^{(n-1)} - x^{(n)})) dr \end{aligned}$$

De forma análoga, temos:

$$\frac{f(x^{(n)}) - f(x^*)}{x^{(n)} - x^*} = \int_0^1 f'(x^{(n)} + r(x^* - x^{(n)})) dr$$

<sup>6</sup>Leonardo Fibonacci, c. 1170 - c. 1250, matemático italiano.

<sup>7</sup>A sequência de Fibonacci  $\{\gamma_n\}_{n \in \mathbb{N}}$  é definida por  $\gamma_0 = \gamma_1 = 1$  e  $\gamma_{n+1} = \gamma_n + \gamma_{n-1}$ ,  $n \geq 1$ .

Logo, temos:

$$\begin{aligned} \frac{f(x^{(n)}) - f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}} - \frac{f(x^{(n)}) - f(x^*)}{x^{(n)} - x^*} = \\ \int_0^1 \left[ f'(x^{(n)} + r(x^{(n-1)} - x^{(n)})) - f'(x^{(n)} + r(x^* - x^{(n)})) \right] dr. \end{aligned} \quad (3.5)$$

Agora, novamente temos:

$$\begin{aligned} & f'(x^{(n)} + r(x^{(n-1)} - x^{(n)})) - f'(x^{(n)} + r(x^* - x^{(n)})) \\ &= \int_0^r \frac{d}{ds} f'(x^{(n)} + r(x^{(n-1)} - x^{(n)}) + s(x^* - x^{(n-1)})) ds \\ &= \int_0^r f''(x^{(n)} + r(x^{(n-1)} - x^{(n)}) + s(x^* - x^{(n-1)})) ds (x^* - x^{(n-1)}). \end{aligned}$$

Retornando à equação (3.5) e usando a cota para a segunda derivada, obtemos:

$$\left| \frac{f(x^{(n)}) - f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}} - \frac{f(x^{(n)}) - f(x^*)}{x^{(n)} - x^*} \right| \leq \frac{M}{2} |x^{(n-1)} - x^*|.$$

Utilizando a equação (3.4), obtemos:

$$|g(x^{(n)}, x^{(n-1)}) - x^*| \leq \frac{M}{2m} |x^{(n)} - x^*| |x^{(n-1)} - x^*| \leq \frac{M}{2m} \rho^2 < \rho.$$

Portanto, concluímos que as iterações do método das secantes  $x^{(n)}$  permanecem no conjunto  $K_\rho(x^*)$ , se começarem nele. Além disso, temos demonstrado que:

$$|x^{(n+1)} - x^*| \leq \frac{M}{2m} |x^{(n)} - x^*| |x^{(n-1)} - x^*|.$$

Com isso, temos:

$$\rho_n := \frac{M}{2m} |x^{(n)} - x^*| \Rightarrow \rho_{n+1} \leq \rho_n \rho_{n-1}, \quad n \geq 2.$$

Como  $\rho_1 \leq q$  e  $\rho_2 \leq q$ , temos  $\rho_n \leq q^{\gamma_{n-1}}$ ,  $n \geq 1$ . Isto mostra a estimativa de convergência **a priori**:

$$|x^n - x^*| \leq \frac{2m}{M} q^{\gamma_{n-1}}.$$

Além disso, como  $\gamma_n \rightarrow \infty$  quando  $n \rightarrow \infty$  e  $q < 1$ , temos que as iterações do método das secantes  $x^{(n)} \rightarrow x^*$  quando  $n \rightarrow \infty$ .

Por fim, mostramos a estimativa de convergência **a posteriori**. Para tanto, da cota assumida para a primeira derivada e do teorema do valor médio, temos,

para  $n \geq 3$ :

$$\begin{aligned} |x^{(n)} - x^*| &\leq \frac{1}{m} |f(x^{(n)} - f(x^*))| \\ &= \frac{1}{m} \left| f(x^{(n-1)}) + (x^{(n)} - x^{(n-1)}) \frac{f(x^{(n)}) - f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}} \right| \\ &= \frac{1}{m} |x^{(n)} - x^{(n-1)}| \left| \frac{f(x^{(n)}) - f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}} + \frac{f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}} \right|. \end{aligned}$$

Agora, a iteração do método das secantes fornece:

$$x^{(n)} = x^{(n-1)} - f(x^{(n-1)}) \frac{x^{(n-1)} - x^{(n-2)}}{f(x^{(n-1)}) - f(x^{(n-2)})}$$

e temos:

$$\frac{f(x^{(n-1)})}{x^{(n)} - x^{(n-1)}} = - \frac{f(x^{(n-1)}) - f(x^{(n-2)})}{x^{(n-1)} - x^{(n-2)}}.$$

Portanto:

$$|x^{(n)} - x^*| \leq \frac{1}{m} |x^{(n)} - x^{(n-1)}| \left| \frac{f(x^{(n-1)}) - f(x^{(n)})}{x^{(n-1)} - x^{(n)}} - \frac{f(x^{(n-1)}) - f(x^{(n-2)})}{x^{(n-1)} - x^{(n-2)}} \right|.$$

Observamos que o último termo pode ser estimado como feito acima para o termo análogo na Inequação (3.4). Com isso, obtemos a estimativa desejada:

$$|x^{(n)} - x^*| \leq \frac{M}{2m} |x^{(n)} - x^{(n-1)}| |x^{(n)} - x^{(n-2)}|.$$

□

**Proposição 3.5.1** (Sequência de Fibonacci). *A sequência de Fibonacci  $\{\gamma_n\}_{n \in \mathbb{N}}$  é assintótica a  $\gamma_n \sim \lambda_1^{n+1}/\sqrt{5}$  e:*

$$\lim_{n \rightarrow \infty} \frac{\gamma_{n+1}}{\gamma_n} = \lambda_1,$$

onde  $\lambda_1 = (1 + \sqrt{5})/2 \approx 1,618$  é a porção áurea.

*Demonstração.* A sequência de Fibonacci  $\{\gamma_n\}_{n \in \mathbb{N}}$  é definida por  $\gamma_0 = \gamma_1 = 1$  e  $\gamma_{n+1} = \gamma_n + \gamma_{n-1}$ ,  $n \geq 1$ . Logo, satisfaz a seguinte equação de diferenças:

$$\gamma_{n+2} - \gamma_{n+1} - \gamma_n = 0, \quad n \in \mathbb{N}.$$

Tomando  $\gamma_n = \lambda^n$ ,  $\lambda \neq 0$  temos:

$$\lambda^n (\lambda^2 - \lambda - 1) = 0 \Rightarrow \lambda^2 - \lambda - 1 = 0 \Rightarrow \lambda_{1,2} = \frac{1 \pm \sqrt{5}}{2}.$$

Portanto,  $\gamma_n = c_1 \lambda_1^n + c_2 \lambda_2^n$ . Como  $\gamma_0 = \gamma_1 = 1$ , as constantes satisfazem:

$$\begin{aligned} c_1 + c_2 &= 1 \\ c_1 \lambda_1 + c_2 \lambda_2 &= 1 \end{aligned} \Rightarrow c_1 = \frac{1 + \sqrt{5}}{2\sqrt{5}}, \quad c_2 = -\frac{1 - \sqrt{5}}{2\sqrt{5}}.$$

Ou seja, obtemos a seguinte forma explícita para os números de Fibonacci:

$$\gamma_n = \frac{1}{\sqrt{5}} \left[ \left( \frac{1 + \sqrt{5}}{2} \right)^{n+1} - \left( \frac{1 - \sqrt{5}}{2} \right)^{n+1} \right].$$

Daí, segue imediatamente o enunciado.  $\square$

**Observação 3.5.1.** Sob as hipóteses do teorema 3.5.1 e da proposição 3.5.1, temos:

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{|x^{(n+1)} - x^*|}{|x^{(n)} - x^*|^{\lambda_1}} &\leq \lim_{n \rightarrow \infty} \frac{M}{2m} |x^{(n)} - x^*|^{1-\lambda_1} |x^{(n-1)} - x^*| \\ &\leq \lim_{n \rightarrow \infty} \left( \frac{2m}{M} \right)^{1-\lambda_1} q^{(2-\lambda_1)\lambda_1^n / \sqrt{5}} = 0. \end{aligned}$$

Isto mostra que o método das secantes (nestas hipóteses) tem taxa de convergência superlinear ( $\lambda_1 \approx 1,6$ ).

## 3.6 Critérios de parada

Quando usamos métodos iterativos precisamos determinar um critério de parada. A tabela 3.4 indica critérios de parada usuais para os métodos que estudamos neste capítulo.

**Observação 3.6.1.** O erro na tabela sempre se refere ao erro absoluto esperado. Nos três últimos métodos, é comum que se exija como critério de parada que a condição seja satisfeita por alguns poucos passos consecutivos. Outros critérios podem ser usados. No métodos das secantes, deve-se ter o cuidado de evitar divisões por zero quando  $x_{n+1} - x_n$  muito pequeno em relação à resolução do sistema de numeração.

## Exercícios

**E 3.6.1.** Refaça as questões 3.4.3, 3.4.4, 3.4.5 e 3.4.6, usando o método das secantes.

Tabela 3.4: Quadro comparativo.

Método	Convergência	Erro	Critério de parada
Bisseção	Linear ( $p = 1$ )	$\epsilon_{n+1} = \frac{1}{2}\epsilon$	$\frac{b_n - a_n}{2} < \text{erro}$
Iteração linear	Linear ( $p = 1$ )	$\epsilon_{n+1} \approx  \phi'(x^*) \epsilon_n$	$\frac{ \Delta_n }{1 - \frac{\Delta_n}{\Delta_{n-1}}} < \text{erro}$ $\Delta_n < \Delta_{n-1}$
Newton	Quadrática ( $p = 2$ )	$\epsilon_{n+1} \approx \frac{1}{2} \left  \frac{f''(x^*)}{f'(x^*)} \right  \epsilon_n^2$	$ \Delta_n  < \text{erro}$
Secante	$p = \frac{\sqrt{5} + 1}{2}$ $\approx 1,618$	$\epsilon_{n+1} \approx \left  \frac{f''(x^*)}{f'(x^*)} \right  \epsilon_n \epsilon_{n-1}$ $\approx M \epsilon_n^\phi$	$ \Delta_n  < \text{erro}$

**E 3.6.2.** Dê uma interpretação geométrica ao método das secantes. Qual a vantagem do método das secantes sobre o método de Newton?

**E 3.6.3.** Aplique o método das secantes para resolver a equação

$$e^{-x^2} = 2x$$

**E 3.6.4.** Refaça o problema 3.2.8 usando o método de Newton e das secantes.

**E 3.6.5.** Seja uma função  $f(x)$  dada duas vezes continuamente diferenciável. Faça uma análise assintótica para mostrar que as iterações do método das secantes satisfazem:

$$|x^{(n+1)} - x^*| \approx C|x^{(n)} - x^*||x^{(n-1)} - x^*|,$$

para aproximações iniciais  $x^{(1)}$  e  $x^{(2)}$  suficientemente próximas de  $x^*$ , onde  $f(x^*) = 0$ .

## 3.7 Exercícios finais

**E 3.7.1.** Calcule uma equação da reta tangente a curva  $y = e^{-(x-1)^2}$  que passa pelo ponto  $(3, 1/2)$ .

**E 3.7.2.** Resolva numericamente a inequação:

$$e^{-x^2} < 2x$$

**E 3.7.3.** A equação

$$\cos(\pi x) = e^{-2x}$$

tem infinitas raízes. Usando métodos numéricos encontre as primeiras raízes dessa equação. Verifique a  $j$ -ésima raiz ( $z_j$ ) pode ser aproximada por  $j - 1/2$  para  $j$  grande. Use o método de Newton para encontrar uma aproximação melhor para  $z_j$ .

**E 3.7.4.** (Eletricidade) A corrente elétrica,  $I$ , em Ampères em uma lâmpada em função da tensão elétrica,  $V$ , é dada por

$$I = \left( \frac{V}{150} \right)^{0.8}$$

Qual a potência da lâmpada quando ligada em série com uma resistência de valor  $R$  a uma fonte de 150V quando. (procure erro inferior a 1%)

- a)  $R = 0\Omega$
- b)  $R = 10\Omega$
- c)  $R = 50\Omega$
- d)  $R = 100\Omega$
- E)  $R = 500\Omega$

**E 3.7.5.** (Bioquímica) A concentração sanguínea de um medicamento é modelado pela seguinte expressão

$$c(t) = Ate^{-\lambda t}$$

onde  $t > 0$  é o tempo em minutos decorrido desde a administração da droga.  $A$  é a quantidade administrada em  $mg/ml$  e  $\lambda$  é a constante de tempo em  $\text{min}^{-1}$ . Responda:

- a) Sendo  $\lambda = 1/3$ , em que instantes de tempo a concentração é metade do valor máximo. Calcule com precisão de segundos.

- b) Sendo  $\lambda = 1/3$  e  $A = 100mg/ml$ , durante quanto tempo a concentração permanece maior que  $10mg/ml$ .

**E 3.7.6.** Considere o seguinte modelo para crescimento populacional em um país:

$$P(t) = A + Be^{\lambda t}.$$

onde  $t$  é dado em anos. Use  $t$  em anos e  $t = 0$  para 1960. Encontre os parâmetros  $A$ ,  $B$  e  $\lambda$  com base nos anos de 1960, 1970 e 1991 conforme tabela:

Ano	população
1960	70992343
1970	94508583
1980	121150573
1991	146917459

Use esses parâmetros para calcular a população em 1980 e compare com o valor do censo. Dica: considere  $\frac{P(31)-P(0)}{P(10)-P(0)}$  e reduza o sistema a uma equação apenas na variável  $\lambda$ .

**E 3.7.7.** (Fluidos) Uma boia esférica flutua na água. Sabendo que a boia tem  $10\ell$  de volume e  $2Kg$  de massa. Calcule a altura da porção molhada da boia.

**E 3.7.8.** (Fluidos) Uma boia cilíndrica tem secção transversal circular de raio  $10cm$  e comprimento  $2m$  e pesa  $10Kg$ . Sabendo que a boia flutua sobre água com o eixo do cilindro na posição horizontal, calcule a altura da parte molhada da boia.

**E 3.7.9.** Encontre com 6 casas decimais o ponto da curva  $y = \ln x$  mais próximo da origem.

**E 3.7.10.** (Matemática financeira) Um computador é vendido pelo valor a vista de R\$2.000,00 ou em  $1+15$  prestações de R\$200,00. Calcule a taxa de juros associada à venda a prazo.

**E 3.7.11.** (Matemática financeira) O valor de R\$110.000,00 é financiado conforme a seguinte programa de pagamentos:

Mês	pagamento
1	20.000,00
2	20.000,00
3	20.000,00
4	19.000,00
5	18.000,00
6	17.000,00
7	16.000,00

Calcule a taxa de juros envolvida. A data do empréstimo é o mês zero.

**E 3.7.12.** (Controle de sistemas) Depois de acionado um sistema de aquecedores, a temperatura em um forno evolui conforme a seguinte equação

$$T(t) = 500 - 800e^{-t} + 600e^{-t/3}.$$

onde  $T$  é a temperatura em Kelvin e  $t$  é tempo em horas.

- Obtenha analiticamente o valor de  $\lim_{t \rightarrow \infty} T(t)$ .
- Obtenha analiticamente o valor máximo de  $T(t)$  e o instante de tempo quando o máximo acontece
- Obtenha numericamente com precisão de minutos o tempo decorrido até que a temperatura passe pela primeira vez pelo valor de equilíbrio obtido no item a.
- Obtenha numericamente com precisão de minutos a duração do período durante o qual a temperatura permanece pelo menos 20% superior ao valor de equilíbrio.

**E 3.7.13.** Encontre os pontos onde a elipse que satisfaz  $\frac{x^2}{3} + y^2 = 1$  intersepta a parábola  $y = x^2 - 2$ .

**E 3.7.14.** (Otimização) Encontre a área do maior retângulo que é possível inscrever entre a curva  $e^{-x^2}(1 + \cos(x))$  e o eixo  $y = 0$ .

**E 3.7.15.** (Otimização) Uma indústria consome energia elétrica de duas usinas fornecedoras. O custo de fornecimento em reais por hora como função da potência



consumida em  $kW$  é dada pelas seguintes funções

$$\begin{aligned}C_1(x) &= 500 + .27x + 4.1 \cdot 10^{-5}x^2 + 2.1 \cdot 10^{-7}x^3 + 4.2 \cdot 10^{-10}x^4 \\C_2(x) &= 1000 + .22x + 6.3 \cdot 10^{-5}x^2 + 8.5 \cdot 10^{-7}x^3\end{aligned}$$

Onde  $C_1(x)$  e  $C_2(x)$  são os custos de fornecimento das usinas 1 e 2, respectivamente. Calcule o custo mínimo da energia elétrica quando a potência total consumida é  $1500kW$ . Obs: Para um problema envolvendo mais de duas usinas, veja [5.1.12](#).

**E 3.7.16.** (Termodinâmica) A pressão de saturação (em bar) de um dado hidrocarboneto pode ser modelada pela equação de Antoine:

$$\ln(P^{sat}) = A - \frac{B}{T + C}$$

onde  $T$  é a temperatura e  $A$ ,  $B$  e  $C$  são constantes dadas conforme a seguir:

Hidrocarboneto	A	B	C
N-pentano	9.2131	2477.07	-39.94
N-heptano	9.2535	2911.32	-56.51

- a) Calcule a temperatura de bolha de uma mistura de N-pentano e N-heptano à pressão de 1.2bar quando as frações molares dos gases são  $z_1 = z_2 = 0.5$ . Para tal utilize a seguinte equação:

$$P = \sum_i z_i P_i^{sat}$$

- b) Calcule a temperatura de orvalho de uma mistura de N-pentano e N-heptano à pressão de 1.2bar quando as frações molares dos gases são  $z_1 = z_2 = 0.5$ . Para tal utilize a seguinte equação:

$$\frac{1}{P} = \sum_i \frac{z_i}{P_i^{sat}}$$

**E 3.7.17.** Encontre os três primeiros pontos de mínimo da função

$$f(x) = e^{-x/11} + x \cos(2x)$$

para  $x > 0$  com erro inferior a  $10^{-7}$ .

## Capítulo 4

# Solução de sistemas lineares

Muitos problemas da engenharia, física e matemática estão associados à solução de sistemas de equações lineares. Nesse capítulo, tratamos de técnicas numéricas empregadas para obter a solução desses sistemas. Iniciamos por uma rápida revisão do método de eliminação gaussiana do ponto de vista computacional. No contexto de análise da propagação dos erros de arredondamento, introduzimos o método de eliminação gaussiana com pivotamento parcial, bem como, apresentamos o conceito de condicionamento de um sistema linear. Então, passamos a discutir sobre técnicas iterativos, mais especificamente, sobre os métodos de Jacobi e Gauss-Seidel.

Considere o sistema de equações lineares:

$$\begin{aligned}a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\&\vdots \\a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &= b_m\end{aligned}$$

onde  $m$  é o número de equações e  $n$  é o número de incógnitas. Este sistema pode ser escrito na forma matricial:

$$Ax = b$$

onde:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}, x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \text{ e } b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}$$

Definimos também a matriz completa de uma sistema como  $Ax = b$  como  $[A|b]$ , isto é:

$$[A|b] = \left[ \begin{array}{cccc|c} a_{11} & a_{12} & \cdots & a_{1n} & b_1 \\ a_{21} & a_{22} & \cdots & a_{2n} & b_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} & b_m \end{array} \right]$$

Salvo especificado ao contrário, assumiremos ao longo deste capítulo que a matriz dos coeficientes  $A$  é uma matriz real não singular.

## 4.1 Eliminação gaussiana

A **eliminação gaussiana**, também conhecida como **escalonamento**, é um método para resolver sistemas lineares. Este método consiste em manipular o sistema através de determinadas operações elementares, transformando a matriz estendida do sistema em uma matriz triangular. Uma vez, triangularizado o sistema, a solução pode ser obtida via substituição regressiva. Naturalmente estas operações elementares devem preservar a solução do sistema e consistem em:

1. multiplicação de um linha por uma constante não nula.
2. substituição de uma linha por ela mesma somada a um múltiplo de outra linha.
3. permutação de duas linhas.

**Exemplo 4.1.1.** Resolva o sistema

$$\begin{aligned} x + y + z &= 1 \\ 4x + 4y + 2z &= 2 \\ 2x + y - z &= 0 \end{aligned}$$

pelo método de eliminação gaussiana.

**Solução.** A matriz estendida do sistema é escrita como

$$\left[ \begin{array}{cccc} 1 & 1 & 1 & 1 \\ 4 & 4 & 2 & 2 \\ 2 & 1 & -1 & 0 \end{array} \right]$$

No primeiro passo, subtraímos da segunda linha o quádruplo da primeira e subtraímos da terceira linha o dobro da primeira linha:

$$\begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 0 & -2 & -2 \\ 0 & -1 & -3 & -1 \end{bmatrix}$$

No segundo passo, permutamos a segunda linha com a terceira:

$$\begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & -1 & -3 & -1 \\ 0 & 0 & -2 & -2 \end{bmatrix}$$

Neste momento, a matriz já se encontra na forma triangular. Da terceira linha, encontramos  $-2z = -2$ , ou seja,  $z = 1$ . Substituindo na segunda equação, temos  $-y - 3z = -2$ , ou seja,  $y = -1$  e finalmente, da primeira linha,  $x + y + z = 1$ , resultando em  $x = 1$ .  $\diamond$

#### 4.1.1 Eliminação gaussiana com pivotamento parcial

A eliminação gaussiana com **pivotamento parcial** consiste em fazer uma permutação de linhas de forma a escolher o maior pivô (em módulo) a cada passo.

**Exemplo 4.1.2.** Resolva o sistema

$$\begin{aligned} x + y + z &= 1 \\ 2x + y - z &= 0 \\ 2x + 2y + z &= 1 \end{aligned}$$

por eliminação gaussiana com pivotamento parcial.

**Solução.** A matriz estendida do sistema é

$$\begin{aligned}
 \begin{bmatrix} 1 & 1 & 1 & 1 \\ 2 & 1 & -1 & 0 \\ 2 & 2 & 1 & 1 \end{bmatrix} &\sim \begin{bmatrix} 2 & 1 & -1 & 0 \\ 1 & 1 & 1 & 1 \\ 2 & 2 & 1 & 1 \end{bmatrix} \\
 &\sim \begin{bmatrix} 2 & 1 & -1 & 0 \\ 0 & 1/2 & 3/2 & 1 \\ 0 & 1 & 2 & 1 \end{bmatrix} \\
 &\sim \begin{bmatrix} 2 & 1 & -1 & 0 \\ 0 & 1 & 2 & 1 \\ 0 & 1/2 & 3/2 & 1 \end{bmatrix} \\
 &\sim \begin{bmatrix} 2 & 1 & -1 & 0 \\ 0 & 1 & 2 & 1 \\ 0 & 0 & 1/2 & 1/2 \end{bmatrix}
 \end{aligned}$$

Encontramos  $1/2z = 1/2$ , ou seja,  $z = 1$ . Substituímos na segunda equação e temos  $y + 2z = 1$ , ou seja,  $y = -1$  e, finalmente  $2x + y - z = 0$ , resultando em  $x = 1$ .

No Scilab, podemos fazer estas computações da seguinte forma:

```

E = [1 1 1 1; 2 1 -1 0; 2 2 1 1]
disp(E)

//L2 <-> L1
aux = E(2,:)
E(2,:) = E(1,:)
E(1,:) = aux
disp(E)

//zera E(2:3,1)
E(2:3,:) = E(2:3,:) - (E(2:3,1)/E(1,1))*E(1,:)
disp(E)

//zera E(3,2)
E(3,:) = E(3,:) - (E(3,2)/E(2,2))*E(2,):

```

```

disp(E)

//subs regressiva
x = zeros(3,1)
x(3) = E(3,4)/E(3,3)
x(2) = (E(2,4) - E(2,3)*x(3))/E(2,2)
x(1) = (E(1,4) - E(1,3)*x(3) - E(1,2)*x(2))/E(1,1)
disp(x)

```

◇

A técnica de eliminação gaussiana com pivotamento parcial ajuda a evitar a propagação dos erros de arredondamento. Vejamos o próximo exemplo.

**Exemplo 4.1.3** (Problema com elementos com grande diferença de escala). Resolva o seguinte sistema usando eliminação gaussiana sem e com pivotamento parcial. Discuta, em cada caso, o resultado frente a aritmética de ponto flutuante quando  $0 < |\epsilon| \ll 1$ .

$$\begin{bmatrix} \epsilon & 2 \\ 1 & \epsilon \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 4 \\ 3 \end{bmatrix}$$

**Solução.** Vamos, primeiramente, executar a eliminação gaussiana sem pivotamento parcial para  $\epsilon \neq 0$  e  $|\epsilon| \ll 1$ :

$$\left[ \begin{array}{cc|c} \epsilon & 2 & 4 \\ 1 & \epsilon & 3 \end{array} \right] \sim \left[ \begin{array}{cc|c} \epsilon & 2 & 4 \\ 0 & \epsilon - \frac{2}{\epsilon} & 3 - \frac{4}{\epsilon} \end{array} \right]$$

Temos

$$y = \frac{3 - 4/\epsilon}{\epsilon - 2/\epsilon}$$

e

$$x = \frac{4 - 2y}{\epsilon}$$

Observe que a expressão obtida para  $y$  se aproxima de 2 quando  $\epsilon$  é pequeno:

$$y = \frac{3 - 4/\epsilon}{\epsilon - 2/\epsilon} = \frac{3\epsilon - 4}{\epsilon^2 - 2} \rightarrow \frac{-4}{-2} = 2, \quad \text{quando } \epsilon \rightarrow 0.$$

Já expressão obtida para  $x$  depende justamente da diferença  $2 - y$ :

$$x = \frac{4 - 2y}{\epsilon} = \frac{2}{\epsilon}(2 - y)$$

Assim, quando  $\varepsilon$  é pequeno, a primeira expressão, implementado em um sistema de ponto flutuante de acurácia finita, produz  $y = 2$  e, conseqüentemente, a expressão para  $x$  produz  $x = 0$ . Isto é, estamos diante um problema de cancelamento catastrófico.

Agora, quando usamos a eliminação gaussiana com pivotamento parcial, fazemos uma permutação de linhas de forma a escolher o maior pivô a cada passo:

$$\left[ \begin{array}{cc|c} \varepsilon & 2 & 4 \\ 1 & \varepsilon & 3 \end{array} \right] \sim \left[ \begin{array}{cc|c} 1 & \varepsilon & 3 \\ \varepsilon & 2 & 4 \end{array} \right] \sim \left[ \begin{array}{cc|c} 1 & \varepsilon & 3 \\ 0 & 2 - \varepsilon^2 & 4 - 3\varepsilon \end{array} \right]$$

Continuando o procedimento, temos:

$$y = \frac{4 - 4\varepsilon}{2 - \varepsilon^2}$$

e

$$x = 3 - \varepsilon y$$

Observe que tais expressões são analiticamente idênticas às anteriores, no entanto, são mais estáveis numericamente. Quando  $\varepsilon$  converge a zero,  $y$  converge a 2, como no caso anterior. No entanto, mesmo que  $y = 2$ , a segunda expressão produz  $x = 3 - \varepsilon y$ , isto é, a aproximação  $x \approx 3$  não depende mais de obter  $2 - y$  com precisão.  $\diamond$

## Exercícios Resolvidos

**ER 4.1.1.** Resolva o sistema por eliminação gaussiana com pivotamento parcial.

$$\begin{bmatrix} 0 & 2 & 2 \\ 1 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 8 \\ 9 \\ 6 \end{bmatrix}$$

**Solução.** Construimos a matriz completa:

$$\begin{aligned}
 \left[ \begin{array}{ccc|c} 0 & 2 & 2 & 8 \\ 1 & 2 & 1 & 9 \\ 1 & 1 & 1 & 6 \end{array} \right] &\sim \left[ \begin{array}{ccc|c} 1 & 2 & 1 & 9 \\ 0 & 2 & 2 & 8 \\ 1 & 1 & 1 & 6 \end{array} \right] \\
 &\sim \left[ \begin{array}{ccc|c} 1 & 2 & 1 & 9 \\ 0 & 2 & 2 & 8 \\ 0 & -1 & 0 & -3 \end{array} \right] \\
 &\sim \left[ \begin{array}{ccc|c} 1 & 2 & 1 & 9 \\ 0 & 2 & 2 & 8 \\ 0 & 0 & 1 & 1 \end{array} \right] \\
 &\sim \left[ \begin{array}{ccc|c} 1 & 2 & 0 & 8 \\ 0 & 2 & 0 & 6 \\ 0 & 0 & 1 & 1 \end{array} \right] \\
 &\sim \left[ \begin{array}{ccc|c} 1 & 0 & 0 & 2 \\ 0 & 2 & 0 & 6 \\ 0 & 0 & 1 & 1 \end{array} \right]
 \end{aligned}$$

Portanto  $x = 2$ ,  $y = 3$  e  $z = 1$ .

◇

## Exercícios

**E 4.1.1.** Resolva o seguinte sistema de equações lineares

$$\begin{aligned}
 x + y + z &= 0 \\
 x + 10z &= -48 \\
 10y + z &= 25
 \end{aligned}$$

Usando eliminação gaussiana com pivotamento parcial (não use o computador para resolver essa questão).



**E 4.1.2.** Resolva o seguinte sistema de equações lineares

$$\begin{aligned}x + y + z &= 0 \\x + 10z &= -48 \\10y + z &= 25\end{aligned}$$

Usando eliminação gaussiana com pivotamento parcial (não use o computador para resolver essa questão).

**E 4.1.3.** Calcule a inversa da matriz

$$A = \begin{bmatrix} 1 & 2 & -1 \\ -1 & 2 & 0 \\ 2 & 1 & -1 \end{bmatrix}$$

usando eliminação gaussiana com pivotamento parcial.

**E 4.1.4.** Demonstre que se  $ad \neq bc$ , então a matriz  $A$  dada por:

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

é inversível e sua inversa é dada por:

$$A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

**E 4.1.5.** Considere as matrizes

$$A = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}$$

e

$$E = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

e o vetor

$$v = \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix}$$

- Resolva o sistema  $Ax = v$  sem usar o computador.
- Sem usar o computador e através da técnica algébrica de sua preferência, resolva o sistema  $(A + \varepsilon E)x_\varepsilon = v$  considerando  $|\varepsilon| \ll 1$  e obtenha a solução exata em função do parâmetro  $\varepsilon$ .
- Usando a expressão analítica obtida acima, calcule o limite  $\lim_{\varepsilon \rightarrow 0} x_\varepsilon$ .
- Resolva o sistema  $(A + \varepsilon E)x = v$  no **Scilab** usando pivotamento parcial e depois sem usar pivotamento parcial para valores muito pequenos de  $\varepsilon$  como  $10^{-10}, 10^{-15}, \dots$ . O que você observa?

**E 4.1.6.** Resolva o seguinte sistema de 5 equações lineares

$$\begin{aligned} x_1 - x_2 &= 0 \\ -x_{i-1} + 2.5x_i - x_{i+1} &= e^{-\frac{(i-3)^2}{20}}, \quad 2 \leq i \leq 4 \\ 2x_5 - x_4 &= 0 \end{aligned}$$

representando-o como um problema do tipo  $Ax = b$  no **Scilab** e usando o comando de contra-barra para resolvê-lo. Repita usando a rotina que implementa eliminação gaussiana.

**E 4.1.7.** Encontre a inversa da matriz

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 2 \\ 1 & 1 & 4 \end{bmatrix}$$

- Usando eliminação gaussiana com pivotamento parcial à mão.
- Usando a rotina 'gausspp()'.
- Usando a rotina 'inv()' do **Scilab**.

## 4.2 Complexidade de algoritmos em álgebra linear

Nesta seção, discutiremos um importante conceito em teoria de algoritmos, a complexidade, isto é, uma medida do custo ou eficiência do algoritmo.

Dados dois algoritmos diferentes para resolver o mesmo problema, como podemos escolher qual desses algoritmos é o melhor? Se pensarmos em termos de **eficiência** (ou custo computacional), queremos saber qual desses algoritmos consome menos recursos para realizar a mesma tarefa.

Em geral podemos responder essa pergunta de duas formas: em termos de tempo ou de espaço.

Quando tratamos de **eficiência espacial**, queremos saber quanta memória (em geral RAM) é utilizada pelo algoritmo para armazenar os dados, sejam matrizes, vetores ou escalares.

Quando tratamos de **eficiência temporal**, queremos saber quanto tempo um algoritmo leva para realizar determinada tarefa. Vamos nos concentrar nessa segunda opção, que em geral é a mais difícil de ser respondida.

Obviamente o tempo vai depender do tipo de computador utilizado. É razoável de se pensar que o tempo vai ser proporcional ao número de operações de ponto flutuante (flops) feito pelo algoritmo (observe que o tempo total não depende apenas disso, mas também de outros fatores como memória, taxas de transferências de dados da memória para o cpu, redes,...). Entretanto vamos nos concentrar na contagem do número de operações (flops) para realizar determinada tarefa.

No passado (antes dos anos 80), os computadores demoravam mais tempo para realizar operações como multiplicação e divisão, se comparados a adição ou subtração. Assim, em livros clássicos eram contados apenas o custo das operações  $\times$  e  $/$ . Nos computadores atuais as quatro operações básicas levam o mesmo tempo. Entretanto, na maioria dos algoritmos de álgebra linear o custo associado as multiplicações e divisões é proporcional ao custo das somas e subtrações (pois a maioria dessas operações podem ser escritas como a combinação de produtos internos). Dessa forma, na maior parte deste material levaremos em conta somente multiplicações e divisões, a não ser que mencionado o contrário.

Teremos em mente que a ideia é estimar o custo quando lidamos com vetores e matrizes muito grande, isto é, o custo quando estas dimensões crescem infinitamente.

**Exemplo 4.2.1** (Produto escalar-vetor). Qual o custo para multiplicar um escalar por um vetor?

**Solução.** Seja  $a \in \mathbf{R}$  e  $\vec{x} \in \mathbf{R}^n$ , temos que

$$a\vec{x} = [a \times x_1, a \times x_2, \dots, a \times x_n] \quad (4.1)$$

usando  $n$  multiplicações, ou seja, um custo computacional,  $C$ , de

$$C = n \text{ flops.} \quad (4.2)$$

◇

**Exemplo 4.2.2** (Produto vetor-vetor). Qual o custo para calcular o produto interno  $\vec{x} \cdot \vec{y}$ ?

**Solução.** Sejam  $\vec{x}, \vec{y} \in \mathbf{R}^n$ , temos que

$$\vec{x} \cdot \vec{y} = x_1 \times y_1 + x_2 \times y_2 + \dots + x_n \times y_n \quad (4.3)$$

São realizadas  $n$  multiplicações (cada produto  $x_i$  por  $y_i$ ) e  $n - 1$  somas, ou seja, o custo total de operações é de

$$C := (n) + (n - 1) = 2n - 1 \text{ flops} \quad (4.4)$$

◇

**Exemplo 4.2.3** (Produto matriz-vetor). Qual o custo para calcular o produto de matriz por vetor  $A\vec{x}$ ?

**Solução.** Sejam  $A \in \mathbf{R}^{n \times n}$  e  $\vec{x} \in \mathbf{R}^n$ , temos que

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ \vdots & & \vdots & \\ a_{n1} & & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} a_{11} \times x_1 + a_{12}x_2 + \dots + a_{1n} \times x_n \\ \vdots \\ a_{n1} \times x_1 + a_{n2}x_2 + \dots + a_{nn} \times x_n \end{bmatrix} \quad (4.5)$$

Para obter o primeiro elemento do vetor do lado direito devemos multiplicar a primeira linha de  $A$  pelo vetor coluna  $\vec{x}$ . Note que esse é exatamente o custo do produto vetor-vetor do exemplo anterior. Como o custo para cada elemento do vetor do lado direito é o mesmo e temos  $n$  elementos, teremos que o custo para multiplicar matriz-vetor é<sup>1</sup>

$$C := n \cdot (2n - 1) = 2n^2 - n \text{ flops.} \quad (4.7)$$

A medida que  $n \rightarrow \infty$ , temos

$$\mathcal{O}(2n^2 - n) = \mathcal{O}(2n^2) = \mathcal{O}(n^2) \text{ flops.} \quad (4.8)$$

◇

---

<sup>1</sup>Contando apenas multiplicações/divisões obtemos

$$n \cdot \mathcal{O}(n) = \mathcal{O}(n^2) \text{ flops.} \quad (4.6)$$

**Exemplo 4.2.4** (Produto matriz-matriz). Qual o custo para calcular o produto de duas matrizes  $AB$ ?

**Solução.** Sejam  $A, B \in \mathbf{R}^{n \times n}$  temos que

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ \vdots & & & \vdots \\ a_{n1} & & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1n} \\ \vdots & & & \vdots \\ b_{n1} & & \cdots & b_{nn} \end{bmatrix} = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ \vdots & & & \vdots \\ c_{n1} & & \cdots & c_{nn} \end{bmatrix} \quad (4.9)$$

onde o elemento  $d_{ij}$  é o produto da linha  $i$  de  $A$  pela coluna  $j$  de  $B$ ,

$$d_{ij} = a_{i1} \times b_{1j} + a_{i2} \times b_{2j} + \dots + a_{in} \times b_{nj} \quad (4.10)$$

Note que esse produto tem o custo do produto vetor-vetor, ou seja,  $2n - 1$ . Como temos  $n \times n$  elementos em  $D$ , o custo total para multiplicar duas matrizes é<sup>2</sup>

$$C = n \times n \times (2n - 1) = 2n^3 - n^2 \text{ flops.} \quad (4.12)$$

◇

## 4.3 Sistemas triangulares

Considere um sistema linear onde a matriz é triangular superior, ou seja,

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ 0 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

tal que todos elementos abaixo da diagonal são iguais a zero.

Podemos resolver esse sistema iniciando pela última equação e isolando  $x_n$  obtemos

$$x_n = b_n / a_{nn} \quad (4.13)$$

---

<sup>2</sup>Contando apenas  $\times$  e  $/$  obtemos

$$n \times n \times (n) = n^3 \text{ flops.} \quad (4.11)$$

Substituindo  $x_n$  na penúltima equação

$$a_{n-1,n-1}x_{n-1} + a_{n-1,n}x_n = b_{n-1} \quad (4.14)$$

e isolando  $x_{n-1}$  obtemos

$$x_{n-1} = (b_{n-1} - a_{n-1,n}x_n)/a_{n-1,n-1} \quad (4.15)$$

e continuando desta forma até a primeira equação obteremos

$$x_1 = (b_1 - a_{12}x_2 \cdots - a_{1n}x_n)/a_{11}. \quad (4.16)$$

De forma geral, temos que

$$x_i = (b_i - a_{i,i+1}x_{i+1} \cdots - a_{i,n}x_n)/a_{i,i}, \quad i = 2, \dots, n. \quad (4.17)$$

### 4.3.1 Código Scilab: resolução de um sistema triangular superior

Para resolver um sistema triangular superior iniciamos da última linha em direção a primeira.

```

1 function [x]=solveU(U,b) // U:= matriz triangular superior
2   n=size(U,1)           // b:= vetor
3   x(n)=b(n)/U(n,n)
4   for i=n-1:-1:1
5       x(i)=(b(i)-U(i,i+1:n)*x(i+1:n))/U(i,i)
6   end
7 endfunction
```

### 4.3.2 Código Scilab: resolução de um sistema triangular inferior

Para resolver um sistema triangular inferior podemos fazer o processo inverso iniciando da primeira equação.

```

1 function [x]=solveL(L,b) // L:= matriz triangular inferior
2   n=size(L,1)           // b:= vetor
3   x(1)=b(1)/L(1,1)
4   for i=2:n
5       x(i)=(b(i)-L(i,1:i-1)*x(1:i-1))/L(i,i)
6   end
7 endfunction
```

### Custo computacional

Vamos contar o número total de flops para resolver um sistema triangular inferior. Note que o custo para um sistema triangular superior será o mesmo.

Na linha 3, temos uma divisão, portanto 1 flop.

Na linha 5 quando  $i = 2$ , temos

$$\mathbf{x}(2) = (\mathbf{b}(2) - \mathbf{L}(2, 1:1) * \mathbf{x}(1:1)) / \mathbf{L}(2, 2),$$

ou seja, 1 subtração + 1 multiplicação + 1 divisão = 3 flops.

Quando  $i = 3$ ,

$$\mathbf{x}(3) = (\mathbf{b}(3) - \mathbf{L}(3, 1:2) * \mathbf{x}(1:2)) / \mathbf{L}(3, 3)$$

temos 1 subtração + (2 multiplicações + 1 soma) + 1 divisão = 5 flops.

Quando  $i = 4$ , temos 1 subtração + (3 multiplicações + 2 somas) + 1 divisão = 7 flops.

Até que para  $i = n$ , temos

$$\mathbf{x}(n) = (\mathbf{b}(n) - \mathbf{L}(n, 1:n-1) * \mathbf{x}(1:n-1)) / \mathbf{L}(n, n),$$

com 1 subtração + ( $n - 1$  multiplicações +  $n - 2$  somas) + 1 divisão, ou seja,  $1 + (n - 1 + n - 2) + 1 = 2n - 1$  flops.

Somando todos esses custos<sup>3</sup> temos que o custo para resolver um sistema triangular inferior é

$$1 + 3 + 5 + 7 + \dots + 2n - 1 = \sum_{k=1}^n (2k - 1) = 2 \sum_{k=1}^n k - \sum_{k=1}^n 1 \quad (4.19)$$

e utilizando que a soma dos  $k$  inteiros é uma progressão aritmética<sup>4</sup>

$$2(n(n + 1)/2) - n = n^2 \text{ flops.} \quad (4.20)$$

## 4.4 Fatoração LU

Considere um sistema linear  $Ax = b$ , onde a matriz  $A$  é densa<sup>5</sup>. A fim de resolver o sistema, podemos fatorar a matriz  $A$  como o produto de uma matriz  $L$  triangular inferior e uma matriz  $U$  triangular superior, ou seja,  $A = LU$ .

---

<sup>3</sup>Contando apenas multiplicações/divisões obtemos

$$(n^2 + n)/2 \text{ flops.} \quad (4.18)$$

<sup>4</sup>Temos que  $\sum_{k=1}^n k = n(n + 1)/2$ ,  $\sum_{k=1}^n 1 = n$

<sup>5</sup>Diferentemente de uma matriz esparsa, uma matriz densa possui a maioria dos elementos diferentes de zero.

Sendo assim, o sistema pode ser reescrito da seguinte forma:

$$\begin{aligned} Ax &= b \\ (LU)x &= b \\ L(Ux) &= b \\ Ly = b &\quad \text{e} \quad Ux = y \end{aligned}$$

Isto significa que, ao invés de resolvermos o sistema original, podemos resolver o sistema triangular inferior  $Ly = b$  e, então, o sistema triangular superior  $Ux = y$ , o qual nos fornece a solução de  $Ax = b$ .

A matriz  $U$  da fatoração<sup>6</sup>  $LU$  é a matriz obtida ao final do escalonamento da matriz  $A$ .

A matriz  $L$  é construída a partir da matriz identidade  $I$ , ao longo do escalonamento de  $A$ . Os elementos da matriz  $L$  são os múltiplos do primeiro elemento da linha de  $A$  a ser zerado dividido pelo pivô acima na mesma coluna.

Por exemplo, para zerar o primeiro elemento da segunda linha de  $A$ , calculamos

$$L_{21} = A_{21}/A_{11}$$

e fazemos

$$A_{2,:} \leftarrow A_{2,:} - L_{21}A_{1,:}$$

Note que denotamos  $A_{i,:}$  para nos referenciarmos a linha  $i$  de  $A$ . Da mesma forma, se necessário usaremos  $A_{:,j}$  para nos referenciarmos a linha  $j$  de  $A$ .

Para zerar o primeiro elemento da terceira linha de  $A$ , temos

$$L_{31} = A_{31}/A_{11}$$

e fazemos

$$A_{3,:} \leftarrow A_{3,:} - L_{31}A_{1,:}$$

até chegarmos ao último elemento da primeira coluna de  $A$ .

Repetimos o processo para as próximas colunas, escalonando a matriz  $A$  e coletando os elementos  $L_{ij}$  abaixo da diagonal<sup>7</sup>.

**Exemplo 4.4.1.** Use a fatoração LU para resolver o seguinte sistema linear:

$$\begin{aligned} x_1 + x_2 + x_3 &= -2 \\ 2x_1 + x_2 - x_3 &= 1 \\ 2x_1 - x_2 + x_3 &= 3 \end{aligned}$$

<sup>6</sup>Não vamos usar pivotamento nesse primeiro exemplo.

<sup>7</sup>Perceba que a partir da segunda coluna para calcular  $L_{ij}$  não usamos os elementos de  $A$ , mas os elementos da matriz  $A$  em processo de escalonamento



**Solução.** Começamos fatorando a matriz  $A$  dos coeficientes deste sistema:

$$\begin{aligned}
 A = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 1 & -1 \\ 2 & -1 & 1 \end{bmatrix} &= \underbrace{\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{I_{3,3}} \underbrace{\begin{bmatrix} 1 & 1 & 1 \\ 2 & 1 & -1 \\ 2 & -1 & 1 \end{bmatrix}}_A \\
 &= \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 2 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 0 & -1 & -3 \\ 0 & -3 & -1 \end{bmatrix} \\
 &= \underbrace{\begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 2 & 3 & 1 \end{bmatrix}}_L \underbrace{\begin{bmatrix} 1 & 1 & 1 \\ 0 & -1 & -3 \\ 0 & 0 & 8 \end{bmatrix}}_U
 \end{aligned}$$

Completada a fatoração LU, resolvemos, primeiramente, o sistema  $Ly = b$ :

$$\begin{aligned}
 y_1 &= -2 \\
 2y_1 + y_2 &= 1 \\
 2y_1 + 3y_2 + y_3 &= 3
 \end{aligned}$$

o qual nos fornece  $y_1 = -2$ ,  $y_2 = 5$  e  $y_3 = -8$ . Por fim, obtemos a solução resolvendo o sistema  $Ux = y$ :

$$\begin{aligned}
 x_1 + x_2 + x_3 &= -2 \\
 -x_2 - 3x_3 &= 5 \\
 8x_3 &= -8
 \end{aligned}$$

o qual fornece  $x_3 = -1$ ,  $x_2 = -2$  e  $x_1 = 1$ . ◇

#### 4.4.1 Código Scilab: Fatoração LU

No Scilab, podemos implementar o algoritmo para fatoração LU da seguinte forma:

```

1 function [L,A]=fatoraLU(A)
2     n=size(A,1)

```

```

3      L=eye(n,n)
4      for j=1:n-1
5          for i=j+1:n
6              L(i,j)=A(i,j)/A(j,j)
7              A(i,j+1:n)=A(i,j+1:n)-L(i,j)*A(j,j+1:n)
8              A(i,j)=0
9          end
10     end
11 endfunction

```

### Custo computacional

Podemos analisar o custo computacional reduzindo o problema em problemas menores.

Na linha 4, iniciamos com  $j = 1$ . Desta forma  $i$  varia de 2 até  $n$  na linha 5.

A linha 6 terá sempre 1 flop.

A linha 7, com  $j = 1$  tem um bloco de tamanho  $2:n$  contabilizando  $n - 1$  flops do produto e  $n - 1$  flops da subtração.

Nas linhas 6-8 são feitas  $(2(n - 1) + 1) = 2n - 1$  flops independente do valor de  $i$ . Como  $i$  varia de 2 até  $n$ , teremos que o bloco é repetido  $n - 1$  vezes, ou seja, o custo das linhas 5-9 é

$$(n - 1) \times (2(n - 1) + 1) = 2(n - 1)^2 + (n - 1) \quad (4.21)$$

Voltamos a linha 4 quando  $j = 2$ . Das linhas 6-8 teremos  $n - 2$  flops (o bloco terá um elemento a menos) que será repetido  $n - 2$  vezes, pois  $i=3:n$ , ou seja,

$$(n - 2) \times (2(n - 2) + 1) = 2(n - 2)^2 + (n - 2) \quad (4.22)$$

Para  $j = 3$ , temos  $2(n - 3)^2 + (n - 3)$ .

Para  $j = n - 2$ , temos  $2(2)^2 + 2$ .

Finalmente, para  $j = n - 1$ , temos  $2 \cdot 1^2 + 1$ .

Somando todos esses custos, temos

$$\begin{aligned}
 & (n - 1) + 2(n - 1)^2 + (n - 2) + 2(n - 2)^2 + \dots + (2) + 2(2)^2 + 1 + 2 \cdot 1 \\
 &= \sum_{k=1}^{n-1} 2k^2 + k \\
 &= 2 \sum_{k=1}^{n-1} k^2 + \sum_{k=1}^{n-1} k \\
 &= 2 \frac{(n - 1)n(2n - 1)}{6} + \frac{n(n - 1)}{2} \\
 &= \frac{2n^3}{3} - \frac{n^2}{2} - \frac{n}{6} \text{ flops.}
 \end{aligned}$$

### 4.4.2 Custo computacional para resolver um sistema linear usando fatoração LU

Para calcularmos o custo computacional de um algoritmo completo, uma estratégia é separar o algoritmo em partes menores mais fáceis de calcular.

Para resolver o sistema, devemos primeiro fatorar a matriz  $A$  nas matrizes  $L$  e  $U$ . Vimos que o custo é

$$\frac{2n^3}{3} - \frac{n^2}{2} - \frac{n}{6} \text{ flops.}$$

Depois devemos resolver os sistemas  $Ly = b$  e  $Ux = y$ . O custo de resolver os dois sistemas é (devemos contar duas vezes)

$$2n^2 \text{ flops.}$$

Somando esses 3 custos, temos que o custo para resolver um sistema linear usando fatoração  $LU$  é

$$\frac{2n^3}{3} + \frac{3n^2}{2} - \frac{n}{6} \text{ flops.}$$

Quando  $n$  cresce, prevaleçam os termos de mais alta ordem, ou seja,

$$\mathcal{O}\left(\frac{2n^3}{3} + \frac{3n^2}{2} - \frac{n}{6}\right) = \mathcal{O}\left(\frac{2n^3}{3} + \frac{3n^2}{2}\right) = \mathcal{O}\left(\frac{2n^3}{3}\right)$$

### 4.4.3 Custo para resolver $m$ sistemas lineares

Devemos apenas multiplicar  $m$  pelo custo de resolver um sistema linear usando fatoração  $LU$ , ou seja, o custo será

$$m\left(\frac{2n^3}{3} + \frac{3n^2}{2} - \frac{n}{6}\right) = \frac{2mn^3}{3} + \frac{3mn^2}{2} - \frac{mn}{6}$$

e com  $m = n$  temos

$$\frac{2n^4}{3} + \frac{3n^3}{2} - \frac{n^2}{6}.$$

Porém, se estivermos resolvendo  $n$  sistemas com *a mesma matriz*  $A$  (e diferente lado direito  $\vec{b}$  para cada sistema) podemos fazer a fatoração LU uma única vez e contar apenas o custo de resolver os sistemas triangulares obtidos.

Custo para fatoração LU de  $A$ :  $\frac{2n^3}{3} - \frac{n^2}{2} - \frac{n}{6}$ .

Custo para resolver  $m$  sistemas triangulares inferiores:  $mn^2$ .

Custo para resolver  $m$  sistemas triangulares superiores:  $mn^2$ .

Somando esses custos obtemos

$$\frac{2n^3}{3} - \frac{n^2}{2} - \frac{n}{6} + 2mn^2$$

que quando  $m = n$  obtemos

$$\frac{8n^3}{3} - \frac{n^2}{2} - \frac{n}{6} \text{ flops.}$$

#### 4.4.4 Custo para calcular a matriz inversa de $A$

Como vemos em Álgebra Linear, um método para obter a matriz  $A^{-1}$  é realizar o escalonamento da matriz  $[A|I]$  onde  $I$  é a matriz identidade. Ao terminar o escalonamento, o bloco do lado direito conterá  $A^{-1}$ .

Isto é equivalente a resolver  $n$  sistemas lineares com a mesma matriz  $A$  e os vetores da base canônica  $\vec{e}_i = [0, \dots, 0, 1, 0, \dots, 0]^T$  tal que

$$A\vec{x}_i = \vec{e}_i, \quad i = 1 : n$$

onde  $\vec{x}_i$  serão as colunas da matriz  $A$  inversa, já que  $AX = I$ .

O custo para resolver esses  $n$  sistemas lineares foi calculado na seção anterior como

$$\frac{8n^3}{3} - \frac{n^2}{2} - \frac{n}{6}.$$

**Exemplo 4.4.2.** Qual o melhor método para resolver um sistema linear: via fatoração LU ou calculando a inversa de  $A$  e obtendo  $x = A^{-1}b$ ?

### 4.5 Método da matriz tridiagonal

O método da matriz tridiagonal ou algoritmo de Thomas<sup>8</sup> ou ainda TDMA (do inglês *tridiagonal matrix algorithm*) é o caso particular da eliminação gaussiana aplicada a matrizes tridiagonais.

Uma matriz tridiagonal é uma matrix quadrada cujos únicos elementos não nulos estão na diagonal principal e nas diagonais imediatamente acima e abaixo da principal. Um sistema tridiagonal é um sistema de equações lineares cuja matriz associada é tridiagonal, conforme a seguir:

$$\begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & \ddots & \\ & & \ddots & \ddots & c_{n-1} \\ & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_n \end{bmatrix}. \quad (4.23)$$

<sup>8</sup>Llewellyn Hilleth Thomas (21 de outubro de 1903 – 20 de abril de 1992) foi um matemático e físico britânico.

Observamos que não é necessário armazenar todos os  $n^2$  elementos da matriz em memória, sendo suficiente armazenar os vetores  $a_n$ ,  $b_n$  e  $c_n$ . Por conveniência, a partir daqui, definiremos os elementos inexistentes na matriz  $a_1$  e  $c_n$  como zero:

$$a_1 = c_n = 0.$$

O algoritmo para a solução do sistema tridiagonal (4.23) pelo algoritmo de Thomas é dada pelas seguintes expressões:

$$c'_i = \begin{cases} \frac{c_i}{b_i}, & i = 1 \\ \frac{c_i}{b_i - a_i c'_{i-1}}, & i = 2, 3, \dots, n-1 \end{cases} \quad (4.24)$$

e

$$d'_i = \begin{cases} \frac{d_i}{b_i}, & i = 1 \\ \frac{d_i - a_i d'_{i-1}}{b_i - a_i c'_{i-1}}, & i = 2, 3, \dots, n. \end{cases} \quad (4.25)$$

Finalmente a solução final é obtida por substituição reversa:

$$x_n = d'_n \quad (4.26)$$

$$x_i = d'_i - c'_i x_{i+1}, \quad i = n-1, n-2, \dots, 1. \quad (4.27)$$

**Teorema 4.5.1.** *A aplicação da eliminação gaussiana sem pivotamento ao sistema (4.23) produz o algoritmo dado em (4.24) e (4.26)*

*Demonstração.* O primeiro passo consiste em dividir todos os elementos da primeira linha de (4.23) por  $b_1$ :

$$\begin{bmatrix} 1 & c'_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & \ddots & \\ & & \ddots & \ddots & c_{n-1} \\ & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} d'_1 \\ d_2 \\ d_3 \\ \vdots \\ d_n \end{bmatrix},$$

onde  $c'_1 = \frac{c_1}{b_1}$  e  $d'_1 = \frac{d_1}{b_1}$ .

O segundo passo consiste em substituir a segunda linha por ela mesma subs-

traída da linha 1 multiplicada por  $a_2$  ( $l_2 \leftarrow l_2 - a_2 l_1$ ):

$$\begin{bmatrix} 1 & c'_1 & & & \\ 0 & b_2 - a_2 c'_1 & c_2 & & \\ & a_3 & b_3 & \ddots & \\ & & \ddots & \ddots & c_{n-1} \\ & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} d'_1 \\ d_2 - a_2 d'_1 \\ d_3 \\ \vdots \\ d_n \end{bmatrix}.$$

Em seguida, dividimos a segunda linha por  $b_2 - a_2 c'_1$ , a fim de normalizar a diagonal principal:

$$\begin{bmatrix} 1 & c'_1 & & & \\ 0 & 1 & c'_2 & & \\ & a_3 & b_3 & \ddots & \\ & & \ddots & \ddots & c_{n-1} \\ & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} d'_1 \\ d'_2 \\ d_3 \\ \vdots \\ d_n \end{bmatrix}.$$

onde  $c'_2 = \frac{c_2}{b_2 - a_2 c'_1}$  e  $d'_2 = \frac{d_2 - a_2 d'_1}{b_2 - a_2 c'_1}$ .

O próximo passo consiste em substituir a terceira linha por ela mesma subtraída da linha 2 multiplicada por  $a_3$  ( $l_3 \leftarrow l_3 - a_3 l_2$ ):

$$\begin{bmatrix} 1 & c'_1 & & & \\ 0 & 1 & c'_2 & & \\ & 0 & b_3 - a_3 c'_2 & \ddots & \\ & & \ddots & \ddots & c_{n-1} \\ & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} d'_1 \\ d'_2 \\ d_3 - a_3 d'_2 \\ \vdots \\ d_n \end{bmatrix}.$$

A fim de normalizar o elemento da diagonal da terceira linha, dividimos toda a linha por  $d_3 - a_3 d'_2$ :

$$\begin{bmatrix} 1 & c'_1 & & & \\ 0 & 1 & c'_2 & & \\ & 0 & 1 & \ddots & \\ & & \ddots & \ddots & c_{n-1} \\ & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} d'_1 \\ d'_2 \\ d'_3 \\ \vdots \\ d_n \end{bmatrix}.$$

Este procedimento é realizado até que se atinja a última linha e temos o seguinte sistema:

$$\begin{bmatrix} 1 & c'_1 & & & \\ 0 & 1 & c'_2 & & \\ & 0 & 1 & \ddots & \\ & & \ddots & \ddots & c'_{n-1} \\ & & & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} d'_1 \\ d'_2 \\ d'_3 \\ \vdots \\ d'_n \end{bmatrix}.$$

Neste estágio, podemos encontrar os  $x_n$  através de substituição reversa, isto é: a última linha diz

$$x_n = d'_n.$$

A penúltima linha diz

$$x_{n-1} + c'_{n-1}x_n = d'_{n-1} \implies x_{n-1} = d'_{n-1} - c'_{n-1}x_n.$$

Esse mesmo procedimento aplicada à linha  $i = 1, \dots, n-1$ , nos dá

$$x_i = d'_i - c'_i x_{i+1}.$$

□

**Exemplo 4.5.1.** Considere a resolução do seguinte sistema tridiagonal pelo algoritmo de Thomas:

$$\begin{bmatrix} 2 & 1 & 0 & 0 & 0 \\ 1 & 2 & 1 & 0 & 0 \\ 0 & 1 & 2 & 1 & 0 \\ 0 & 0 & 1 & 2 & 1 \\ 0 & 0 & 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} 4 \\ 4 \\ 0 \\ 0 \\ 2 \end{bmatrix}. \quad (4.28)$$

Primeiramente identificamos os vetores  $a$ ,  $b$ ,  $c$  e  $d$ :

$$\begin{aligned} a &= (0, 1, 1, 1, 1) \\ b &= (2, 2, 2, 2, 2) \\ c &= (1, 1, 1, 1, 0) \\ d &= (4, 4, 0, 0, 2) \end{aligned}$$

Agora, calculamos os vetores  $c'$  e  $d'$ :

$$\begin{aligned} c'_1 &= \frac{c_1}{b_1} = \frac{1}{2} \\ c'_2 &= \frac{c_2}{b_2 - a_2 c'_1} = \frac{1}{2 - 1 \cdot \frac{1}{2}} = \frac{2}{3} \\ c'_3 &= \frac{c_3}{b_3 - a_3 c'_2} = \frac{1}{2 - 1 \cdot \frac{2}{3}} = \frac{3}{4} \\ c'_4 &= \frac{c_4}{b_4 - a_4 c'_3} = \frac{1}{2 - 1 \cdot \frac{3}{4}} = \frac{4}{5} \\ d'_1 &= \frac{d_1}{b_1} = \frac{4}{2} = 2 \\ d'_2 &= \frac{d_2 - a_2 d'_1}{b_2 - a_2 c'_1} = \frac{4 - 1 \cdot 2}{2 - 1 \cdot \frac{1}{2}} = \frac{4}{3} \\ d'_3 &= \frac{d_3 - a_3 d'_2}{b_3 - a_3 c'_2} = \frac{0 - 1 \cdot \frac{4}{3}}{2 - 1 \cdot \frac{2}{3}} = -1 \\ d'_4 &= \frac{d_4 - a_4 d'_3}{b_4 - a_4 c'_3} = \frac{0 - 1 \cdot (-1)}{2 - 1 \cdot \frac{3}{4}} = \frac{4}{5} \\ d'_5 &= \frac{d_5 - a_5 d'_4}{b_5 - a_5 c'_4} = \frac{2 - 1 \cdot \frac{4}{5}}{2 - 1 \cdot \frac{4}{5}} = 1 \end{aligned}$$

Finalmente, calculamos o vetor  $x$ :

$$\begin{aligned} x_5 &= d'_5 = 1 \\ x_4 &= d'_4 - c'_4 \cdot x_5 = \frac{4}{5} - \frac{4}{5} \cdot 1 = 0 \\ x_3 &= d'_3 - c'_3 \cdot x_4 = -1 - \frac{3}{4} \cdot 0 = -1 \\ x_2 &= d'_2 - c'_2 \cdot x_3 = \frac{4}{3} - \frac{2}{3} \cdot (-1) = 2 \\ x_1 &= d'_1 - c'_1 \cdot x_2 = 2 - \frac{1}{2} \cdot 2 = 1 \end{aligned}$$

E assim, obtemos o vetor  $x = [1, 2, -1, 0, 1]$ .

### Código Scilab: Método da matriz tridiagonal

```
//entradas: vetores coluna a,b,c,d
//saida:     vetor coluna x
function x=TDMA(a,b,c,d)
```



```

n=size(a,1) // Recupera ordem do sistema.

cl=zeros(n,1) //Inicializa cl
dl=zeros(n,1) //Inicializa dl
x=zeros(n,1) //Inicializa x

cl(1)=c(1)/b(1)
for i=2:n-1
    cl(i)=c(i)/(b(i)-a(i)*cl(i-1))
end

dl(1)=d(1)/b(1)
for i=2:n
    dl(i)=(d(i)-a(i)*dl(i-1))/(b(i)-a(i)*cl(i-1))
end

x(n)=dl(n)
for i=n-1:-1:1
    x(i)=dl(i)-cl(i)*x(i+1)
end
endfunction

```

Nesse código, usou-se  $cl$  e  $dl$  para denotar  $c'$  e  $d'$ . Observe que se for desnecessário preservar os valores originais dos vetores  $c$  e  $d$ , eles podem, com economia de memória e simplicidade de código, ser sobrescritos pelos vetores  $c'$  e  $d'$ , respectivamente. Eis uma nova implementação:

```

//entradas: vetores coluna a,b,c,d
//saida:     vetor coluna x
function x=TDMA2(a,b,c,d)
    n=size(a,1) // Recupera ordem do sistema.
    x=zeros(n,1) //Inicializa x

    c(1)=c(1)/b(1)
    for i=2:n-1
        c(i)=c(i)/(b(i)-a(i)*c(i-1))
    end

    d(1)=d(1)/b(1)
    for i=2:n
        d(i)=(d(i)-a(i)*d(i-1))/(b(i)-a(i)*c(i-1))
    end
end

```

```

end

x(n)=d(n)
for i=n-1:-1:1
    x(i)=d(i)-c(i)*x(i+1)
end
endfunction

```

A solução do sistema do exemplo 4.5.1 pode ser obtida através do seguintes comandos:

```

-->a=[0; 1; 1; 1; 1];
-->b=[2; 2; 2; 2; 2];
-->c=[1; 1; 1; 1; 0];
-->d=[4; 4; 0; 0; 2];
-->TDMA(a,b,c,d)

```

**E 4.5.1.** Considere o problema linear tridiagonal dado por

$$\begin{bmatrix} 5 & 4 & 0 & 0 & 0 & 0 \\ 1 & 3 & 1 & 0 & 0 & 0 \\ 0 & 2 & 4 & 1 & 0 & 0 \\ 0 & 0 & 1 & 2 & 1 & 0 \\ 0 & 0 & 0 & 2 & 3 & 2 \\ 0 & 0 & 0 & 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \\ x_6 \end{bmatrix} = \begin{bmatrix} 13 \\ 10 \\ 20 \\ 16 \\ 35 \\ 17 \end{bmatrix}. \quad (4.29)$$

Identifique os vetores  $a$ ,  $b$ ,  $c$  e  $d$  relativos ao algoritmo da matriz tridiagonal. Depois resolva o sistema usando o computador.

**E 4.5.2.** Considere o seguinte sistema de equações lineares:

$$\begin{aligned} x_1 - x_2 &= 0 \\ -x_{j-1} + 5x_j - x_{j+1} &= \cos(j/10), \quad 2 \leq j \leq 10 \\ x_{11} &= x_{10}/2 \end{aligned} \quad (4.30)$$

Identifique os vetores  $a$ ,  $b$ ,  $c$  e  $d$  relativos ao algoritmo da matriz tridiagonal no sistema linear dado. Depois resolva o sistema usando o computador. Veja também exercício 4.7.4

## 4.6 Condicionamento de sistemas lineares

Quando lidamos com matrizes no corpo dos números reais (ou complexos), existem apenas duas alternativas: i) a matriz é inversível; ii) a matriz não é inversível e, neste caso, é chamada de matriz singular. Ao lidarmos em aritmética de precisão finita, encontramos uma situação mais sutil: alguns problemas lineares são mais difíceis de serem resolvidos, pois os erros de arredondamento se propagam de forma mais significativa que em outros problemas. Neste caso falamos de problemas bem-condicionados e mal-condicionados. Intuitivamente falando, um problema bem-condicionado é um problema em que os erros de arredondamento se propagam de forma menos importante; enquanto problemas mal-condicionados são problemas em que os erros se propagam de forma mais relevante.

Um caso típico de sistema mal-condicionado é aquele cujos coeficientes estão muito próximos ao de um problema singular. Considere o seguinte exemplo:

**Exemplo 4.6.1.** Observe que o sistema

$$\begin{bmatrix} 71 & 41 \\ \lambda & 30 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 100 \\ 70 \end{bmatrix} \quad (4.31)$$

é impossível quando  $\lambda = \frac{71 \times 30}{41} \approx 51,95122$ .

Considere os próximos três sistemas:

- a)  $\begin{bmatrix} 71 & 41 \\ 51 & 30 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 100 \\ 70 \end{bmatrix}$ , com solução  $\begin{bmatrix} 10/3 \\ -10/3 \end{bmatrix}$ ,
- b)  $\begin{bmatrix} 71 & 41 \\ 52 & 30 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 100 \\ 70 \end{bmatrix}$ , com solução  $\begin{bmatrix} -65 \\ 115 \end{bmatrix}$ ,
- c)  $\begin{bmatrix} 71 & 41 \\ 52 & 30 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 100,4 \\ 69,3 \end{bmatrix}$ , com solução  $\begin{bmatrix} -85,35 \\ 150,25 \end{bmatrix}$ .

Pequenas variações nos coeficientes das matrizes fazem as soluções ficarem bem distintas, isto é, pequenas variações nos dados de entrada acarretaram em grandes variações na solução do sistema. Quando isso acontece, dizemos que o problema é mal-condicionado.

Precisamos uma maneira de medir essas variações. Como os dados de entrada e os dados de saída são vetores (ou matrizes), precisamos introduzir as definições de norma de vetores e matrizes.

### 4.6.1 Norma de vetores

Definimos a **norma**  $L^p$ ,  $1 \leq p \leq \infty$ , de um vetor em  $v = (v_1, v_2, \dots, v_n) \in \mathbb{R}^n$  por:

$$\|v\|_p := \left( \sum_{i=1}^n |v_i|^p \right)^{1/p} = (|v_1|^p + |v_2|^p + \dots + |v_n|^p)^{1/p}, \quad 1 \leq p < \infty.$$

Para  $p = \infty$ , definimos a norma  $L^\infty$  (**norma do máximo**) por:

$$\|v\|_\infty = \max_{1 \leq j \leq n} \{|v_j|\}.$$

**Proposição 4.6.1** (Propriedades de normas). *Sejam dados  $\alpha \in \mathbb{R}$  um escalar e os vetores  $u, v \in \mathbb{R}^n$ . Então, para cada  $1 \leq p \leq \infty$ , valem as seguintes propriedades:*

- a)  $\|u\|_p = 0 \Leftrightarrow u = 0$ .
- b)  $\|\alpha u\|_p = |\alpha| \|u\|_p$ .
- c)  $\|u + v\|_p \leq \|u\|_p + \|v\|_p$  (**desigualdade triangular**).
- d)  $\|u\|_p \rightarrow \|u\|_\infty$  quando  $p \rightarrow \infty$ .

*Demonstração.* Demonstramos cada item em separado.

- a) Se  $u = 0$ , então segue imediatamente da definição da norma  $L^p$ ,  $1 \leq p \leq \infty$ , que  $\|u\|_p = 0$ . Reciprocamente, se  $\|u\|_\infty = 0$ , então, para cada  $i = 1, 2, \dots, n$ , temos:

$$|u_i| \leq \max_{1 \leq j \leq n} \{|u_j|\} = \|u\|_\infty = 0 \Rightarrow u_i = 0.$$

Isto é,  $u = 0$ . Agora, se  $\|u\|_p = 0$ ,  $1 \leq p < \infty$ , então:

$$0 = \|u\|_p^p := \sum_{i=1}^n |u_i|^p \leq n \|u\|_\infty^p \Rightarrow \|u\|_\infty = 0.$$

Logo, pelo resultado para a norma do máximo, concluímos que  $u = 0$ .

- b) Segue imediatamente da definição da norma  $L^p$ ,  $1 \leq p \leq \infty$ .
- c) Em construção ...
- d) Em construção ...

□

**Exemplo 4.6.2.** Calcule a norma  $L^1$ ,  $L^2$  e  $L^\infty$  do vetor coluna  $v = (1, 2, -3, 0)$ .

**Solução.**

$$\begin{aligned}\|v\|_1 &= 1 + 2 + 3 + 0 = 6 \\ \|v\|_2 &= \sqrt{1 + 2^2 + 3^2 + 0^2} = \sqrt{14} \\ \|v\|_\infty &= \max\{1, 2, 3, 0\} = 3\end{aligned}$$

No **Scilab** podemos computar normas  $L^p$ 's de vetores usando o comando **norm**. Neste exemplo, temos:

```
-->norm(v,1), norm(v,'inf'), norm(v,2)
ans =
    6.
ans =
    3.
ans =
    3.7416574
```

◇

## 4.6.2 Norma de matrizes

Definimos a norma induzida  $L^p$  de uma matriz  $A = [a_{i,j}]_{i,j=1}^{n,n}$  da seguinte forma:

$$\|A\|_p = \sup_{\|v\|_p=1} \|Av\|_p,$$

ou seja, a norma  $p$  de uma matriz é o máximo valor assumido pela norma de  $Av$  entre todos os vetores de norma unitária.

Temos as seguintes propriedades, se  $A$  e  $B$  são matrizes,  $I$  é a matriz identidade,  $v$  é um vetor e  $\lambda$  é um real (ou complexo):

$$\begin{aligned}\|A\|_p &= 0 \iff A = 0 \\ \|\lambda A\|_p &= |\lambda| \|A\|_p \\ \|A + B\|_p &\leq \|A\|_p + \|B\|_p \quad (\text{desigualdade do triângulo}) \\ \|Av\|_p &\leq \|A\|_p \|v\|_p \\ \|AB\|_p &\leq \|A\|_p \|B\|_p \\ \|I\|_p &= 1 \\ 1 &= \|I\|_p = \|AA^{-1}\|_p \leq \|A\|_p \|A^{-1}\|_p \quad (\text{se } A \text{ é inversível})\end{aligned}$$

Casos especiais:

$$\begin{aligned}\|A\|_1 &= \max_{j=1}^n \sum_{i=1}^n |A_{ij}| \\ \|A\|_2 &= \sqrt{\max\{|\lambda| : \lambda \in \sigma(AA^*)\}} \\ \|A\|_\infty &= \max_{i=1}^n \sum_{j=1}^n |A_{ij}|\end{aligned}$$

onde  $\sigma(M)$  é o conjunto de autovalores da matriz  $M$ .

**Exemplo 4.6.3.** Calcule as normas 1, 2 e  $\infty$  da seguinte matriz:

$$A = \begin{bmatrix} 3 & -5 & 7 \\ 1 & -2 & 4 \\ -8 & 1 & -7 \end{bmatrix}$$

**Solução.**

$$\begin{aligned}\|A\|_1 &= \max\{12, 8, 18\} = 18 \\ \|A\|_\infty &= \max\{15, 7, 16\} = 16 \\ \|A\|_2 &= \sqrt{\max\{0,5865124, 21,789128, 195,62436\}} = 13,98657\end{aligned}$$

No **Scilab** podemos computar normas  $L^p$ 's de matrizes usando o comando **norm**. Neste exemplo, temos:

```
-->A = [3 -5 7;1 -2 4;-8 1 -7];
-->norm(A,1), norm(A,'inf'), norm(A,2)
ans =
    18.
ans =
    16.
ans =
    13.986578
```

◇

### 4.6.3 Número de condicionamento

O condicionamento de um sistema linear é um conceito relacionado à forma como os erros se propagam dos dados de entrada para os dados de saída. No

contexto de um sistema linear  $Ax = y$ , temos que a solução  $x$  depende dos dados de entrada  $y$ . Consideremos, então, o problema

$$A(x + \delta_x) = y + \delta_y$$

Aqui,  $\delta_x$  representa uma variação (erro) em  $x$  e  $\delta_y$  representa uma variação em  $y$  (erro). Temos:

$$Ax + A\delta_x = y + \delta_y$$

e, portanto,

$$A\delta_x = \delta_y.$$

Queremos avaliar a razão entre o erro relativo em  $x$  e o erro relativo em  $y$ , i.e.

$$\begin{aligned} \frac{\|\delta_x\| / \|x\|}{\|\delta_y\| / \|y\|} &= \frac{\|\delta_x\|}{\|x\|} \frac{\|y\|}{\|\delta_y\|} \\ &= \frac{\|A^{-1}\delta_y\|}{\|x\|} \frac{\|Ax\|}{\|\delta_y\|} \\ &\leq \frac{\|A^{-1}\|}{\|x\|} \frac{\|\delta_y\|}{\|\delta_y\|} \frac{\|A\|}{\|x\|} \|x\| \\ &= \|A\| \|A^{-1}\| \end{aligned}$$

**Definição 4.6.1** (Número de condicionamento). *O número de condicionamento de uma matriz não-singular  $A$  é*

$$k_p(A) := \|A\|_p \|A^{-1}\|_p$$

**Observação 4.6.1.** • O número de condicionamento depende da norma escolhida.

- O número de condicionamento da matriz identidade é 1.
- O número de condicionamento de qualquer matriz inversível é maior ou igual a 1.

**Exemplo 4.6.4.** No Exemplo 4.6.1 estudamos a solução de sistemas lineares com as seguintes matrizes de coeficientes:

$$A_1 = \begin{bmatrix} 71 & 41 \\ 51 & 30 \end{bmatrix} \quad \text{e} \quad A_2 = \begin{bmatrix} 71 & 41 \\ 52 & 30 \end{bmatrix}.$$

Calcule os números de condicionamento destes sistemas na norma  $L^p$  para  $p = 1$ , 2 e  $\infty$ .

**Solução.** Para a matriz  $A_1$ , temos:

$$\begin{aligned}k_1(A_1) &:= \|A_1\| \|A_1^{-1}\| \approx 350,36, \\k_2(A_1) &:= \|A_2\| \|A_2^{-1}\| \approx 262,12, \\k_\infty(A_1) &:= \|A_\infty\| \|A_\infty^{-1}\| \approx 350,36.\end{aligned}$$

Para a matriz  $A_2$ , temos:

$$\begin{aligned}k_1(A_2) &:= \|A_1\|_1 \|A_1^{-1}\|_1 \approx 6888,0, \\k_2(A_2) &:= \|A_1\|_2 \|A_1^{-1}\|_2 \approx 5163,0, \\k_\infty(A_2) &:= \|A_1\|_\infty \|A_1^{-1}\|_\infty \approx 6888,0.\end{aligned}$$

No Scilab, podemos computar estes números de condicionamento para a matriz  $A_1$  com o seguinte código:

```
A1 = [71 41; 51 30];
cond(A1,1)
cond(A1,2)
cond(A1,'inf')
```

e, análogo para a matriz  $A_2$ .

◇

## Exercícios

**E 4.6.1.** Calcule o valor de  $\lambda$  para o qual o problema

$$\begin{cases} 71x + 41y = 10 \\ \lambda x + 30y = 4 \end{cases}$$

é impossível, depois calcule os números de condicionamento com norma 1,2 e  $\infty$  quando  $\lambda = 51$  e  $\lambda = 52$ .

**E 4.6.2.** Calcule o número de condicionamento da matriz

$$A = \begin{bmatrix} 3 & -5 & 7 \\ 1 & -2 & 4 \\ -8 & 1 & -7 \end{bmatrix}$$

nas normas 1, 2 e  $\infty$ .



**E 4.6.3.** Calcule o número de condicionamento das matrizes

$$\begin{bmatrix} 71 & 41 \\ 52 & 30 \end{bmatrix}$$

e

$$\begin{bmatrix} 1 & 2 & 3 \\ 2 & 3 & 4 \\ 4 & 5 & 5 \end{bmatrix}$$

usando as normas 1, 2 e  $\infty$ .

**E 4.6.4.** Usando a norma 1, calcule o número de condicionamento da matriz

$$A = \begin{bmatrix} 1 & 2 \\ 2 + \varepsilon & 4 \end{bmatrix}$$

em função de  $\varepsilon$  quando  $0 < \varepsilon < 1$ . Interprete o limite  $\varepsilon \rightarrow 0$ .

**E 4.6.5.** Considere os sistemas:

$$\begin{cases} 100000x - 9999.99y = -10 \\ -9999.99x + 1000.1y = 1 \end{cases} \quad \text{e} \quad \begin{cases} 100000x - 9999.99y = -9.999 \\ -9999.99x + 1000.1y = 1.01 \end{cases}$$

Encontre a solução de cada um e discuta.

**E 4.6.6.** Considere os vetores de 10 entradas dados por

$$x_j = \sin(j/10), \quad y_j = j/10 \quad z_j = j/10 - \frac{(j/10)^3}{6}, \quad j = 1, \dots, 10$$

Use o **Scilab** para construir os seguintes vetores de erro:

$$e_j = \frac{|x_j - y_j|}{|x_j|} \quad f_j = \frac{|x_j - z_j|}{x_j}$$

Calcule as normas 1, 2 e  $\infty$  de  $e$  e  $f$

## 4.7 Métodos iterativos para sistemas lineares

Na seção anterior tratamos de métodos diretos para a resolução de sistemas lineares. Em um **método direto** (por exemplo, solução via fatoração LU) obtemos

uma aproximação da solução depois de realizarmos um número finito de operações (só teremos a solução ao final do processo).

Veremos nessa seção dois **métodos iterativos** básicos para obter uma aproximação para a solução de um sistema linear. Geralmente em um método iterativo iniciamos com uma aproximação para a solução (que pode ser ruim) e vamos melhorando essa aproximação através de sucessivas iterações.

### 4.7.1 Método de Jacobi

O método de Jacobi pode ser obtido a partir do sistema linear

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= y_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= y_2 \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= y_n \end{aligned}$$

Isolando o elemento  $x_1$  da primeira equação temos

$$x_1^{(k+1)} = \frac{y_1 - (a_{12}x_2^{(k)} + \cdots + a_{1n}x_n^{(k)})}{a_{11}} \quad (4.32)$$

Note que utilizaremos os elementos  $x_i^{(k)}$  da iteração  $k$  (a direita da equação) para estimar o elemento  $x_1$  da próxima iteração.

Da mesma forma, isolando o elemento  $x_i$  de cada equação  $i$ , para todo  $i = 2, \dots, n$  podemos construir a iteração

$$\begin{aligned} x_1^{(k+1)} &= \frac{y_1 - (a_{12}x_2^{(k)} + \cdots + a_{1n}x_n^{(k)})}{a_{11}} \\ x_2^{(k+1)} &= \frac{y_2 - (a_{21}x_1^{(k)} + a_{23}x_3^{(k)} + \cdots + a_{2n}x_n^{(k)})}{a_{22}} \\ &\vdots \\ x_n^{(k+1)} &= \frac{y_n - (a_{n1}x_1^{(k)} + \cdots + a_{n,n-2}x_{n-2}^{(k)} + a_{n,n-1}x_{n-1}^{(k)})}{a_{nn}} \end{aligned}$$

Em notação mais compacta, o método de Jacobi consiste na iteração

$$\begin{aligned} x^{(1)} &= \text{aproximação inicial} \\ x_i^{(k)} &= \left( y_i - \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}x_j^{(k)} \right) / a_{ii} \end{aligned}$$

**Exemplo 4.7.1.** Resolva o sistema

$$\begin{aligned} 10x + y &= 23 \\ x + 8y &= 26 \end{aligned}$$

usando o método de Jacobi iniciando com  $x^{(1)} = y^{(1)} = 0$ .

$$\begin{aligned} x^{(k+1)} &= \frac{23 - y^{(k)}}{10} \\ y^{(k+1)} &= \frac{26 - x^{(k)}}{8} \\ x^{(2)} &= \frac{23 - y^{(1)}}{10} = 2,3 \\ y^{(2)} &= \frac{26 - x^{(1)}}{8} = 3,25 \\ x^{(3)} &= \frac{23 - y^{(2)}}{10} = 1,975 \\ y^{(3)} &= \frac{26 - x^{(2)}}{8} = 2,9625 \end{aligned}$$

**Código Scilab: Método de Jacobi**

```
function [x,deltax]=jacobi(A,b,x,tol,N)
n=size(A,1)
xnew      =x
convergiu=%F                                //FALSE;

k=1
while k<=N & ~convergiu
    xnew(1)=(b(1) - A(1,2:n)*x(2:n))/A(1,1)
    for i=2:n-1
        xnew(i)=(b(i) -A(i,1:i-1)*x(1:i-1) ...
                  -A(i,i+1:n)*x(i+1:n) )/A(i,i)
    end
    xnew(n)= (b(n) -A(n,1:n-1)*x(1:n-1) )/A(n,n)

    deltax=max( abs(x-xnew) )
    if deltax<tol then
        convergiu=%T                //TRUE
    end
    k=k+1
end
```

```

x=xnew          // atualiza x
disp([k,x',deltax]) // depuracao
end
if ~convergiu then
    error('Nao convergiu')
end

endfunction

```

### 4.7.2 Método de Gauss-Seidel

Assim, como no método de Jacobi, no método de Gauss-Seidel também isolamos o elemento  $x_i$  da equação  $i$ . Porém percebe-se que a equação para  $x_2^{(k+1)}$  depende de  $x_1^{(k)}$  na iteração  $k$ . Intuitivamente podemos pensar em usar  $x_1^{(k+1)}$  que acabou de ser calculado e temos

$$x_2^{(k+1)} = \frac{y_2 - (a_{21}x_1^{(k+1)} + a_{23}x_3^{(k)} + \cdots + a_{2n}x_n^{(k)})}{a_{22}}$$

Aplicando esse raciocínio podemos construir o método de Gauss-Seidel como

$$\begin{aligned}
 x_1^{(k+1)} &= \frac{y_1 - (a_{12}x_2^{(k)} + \cdots + a_{1n}x_n^{(k)})}{a_{11}} \\
 x_2^{(k+1)} &= \frac{y_2 - (a_{21}x_1^{(k+1)} + a_{23}x_3^{(k)} + \cdots + a_{2n}x_n^{(k)})}{a_{22}} \\
 &\vdots \\
 x_n^{(k+1)} &= \frac{y_n - (a_{n1}x_1^{(k+1)} + \cdots + a_{n(n-1)}x_{n-1}^{(k+1)})}{a_{nn}}
 \end{aligned}$$

Em notação mais compacta, o método de Gauss-Seidel consiste na iteração:

$$\begin{aligned}
 x^{(1)} &= \text{aproximação inicial} \\
 x_i^{(k)} &= \frac{y_i - \sum_{j=1}^{i-1} a_{ij}x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij}x_j^{(k)}}{a_{ii}}
 \end{aligned}$$

**Exemplo 4.7.2.** Resolva o sistema

$$\begin{aligned}
 10x + y &= 23 \\
 x + 8y &= 26
 \end{aligned}$$

usando o método de Gauss-Seidel iniciando com  $x^{(1)} = y^{(1)} = 0$ .

$$\begin{aligned}x^{(k+1)} &= \frac{23 - y^{(k)}}{10} \\y^{(k+1)} &= \frac{26 - x^{(k+1)}}{8} \\x^{(2)} &= \frac{23 - y^{(1)}}{10} = 2,3 \\y^{(2)} &= \frac{26 - x^{(2)}}{8} = 2,9625 \\x^{(3)} &= \frac{23 - y^{(2)}}{10} = 2,00375 \\y^{(3)} &= \frac{26 - x^{(3)}}{8} = 2,9995312\end{aligned}$$

### Código Scilab: Método de Gauss-Seidel

```
function [x,deltax]=gauss_seidel(A,b,x,tol,N)
n=size(A,1)
xnew      =x
convergiu=%F                                //FALSE;

k=1
while k<=N & ~convergiu
    xnew(1)=(b(1) - A(1,2:n)*x(2:n))/A(1,1)
    for i=2:n-1
        xnew(i)=(b(i) -A(i,1:i-1)*xnew(1:i-1) ...
                  -A(i,i+1:n)*x(i+1:n) )/A(i,i)
    end
    xnew(n)=(b(n) -A(n,1:n-1)*xnew(1:n-1) )/A(n,n)

    deltax=max( abs(x-xnew) )
    if deltax<tol then
        convergiu=%T                //TRUE
    end
    k=k+1
    x=xnew                          // atualiza x
    disp([k,x',deltax])             // depuracao
end
if ~convergiu then
    error('Nao convergiu')
```

end

endfunction

### 4.7.3 Análise de convergência

Nesta seção, discutimos sobre a análise de convergência de métodos iterativos para solução de sistema lineares. Para tanto, consideramos um sistema linear  $Ax = b$ , onde  $A = [a_{i,j}]_{i,j=1}^{n,n}$  é a matriz (real) dos coeficientes,  $b = (b_j)_{j=1}^n$  é um vetor dos termos constantes e  $x = (x_j)_{j=1}^n$  é o vetor incógnita. No decorrer, assumimos que  $A$  é uma matriz não singular.

Geralmente, métodos iterativos são construídos como uma iteração de ponto fixo. No caso de um sistema linear, reescreve-se a equação matricial em um problema de ponto fixo equivalente, isto é:

$$Ax = b \Leftrightarrow x = Tx + c,$$

onde  $T = [t_{i,j}]_{i,j=1}^{n,n}$  é chamada de **matriz da iteração** e  $c = (c_j)_{j=1}^n$  de **vetor da iteração**. Construídos a matriz  $T$  e o vetor  $c$ , o método iterativo consiste em computar a iteração:

$$x^{(k+1)} = Tx^{(k)} + c, \quad n \geq 1,$$

onde  $x^{(1)}$  é uma aproximação inicial dada.

Afim de construirmos as matrizes e os vetores de iteração do método de Jacobi e de Gauss-Seidel, decompomos a matriz  $A$  da seguinte forma:

$$A = L + D + U,$$

onde  $D$  é a matriz diagonal  $D = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$ , isto é:

$$D := \begin{bmatrix} a_{11} & 0 & 0 & \cdots & 0 \\ 0 & a_{22} & 0 & \cdots & 0 \\ 0 & 0 & a_{33} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & a_{nn} \end{bmatrix},$$

e, respectivamente,  $L$  e  $U$  são as seguintes matrizes triangular inferior e superior:

$$L := \begin{bmatrix} 0 & 0 & 0 & \cdots & 0 \\ a_{21} & 0 & 0 & \cdots & 0 \\ a_{31} & a_{32} & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \cdots & 0 \end{bmatrix}, \quad U := \begin{bmatrix} 0 & a_{12} & a_{13} & \cdots & a_{1n} \\ 0 & 0 & a_{23} & \cdots & a_{2n} \\ 0 & 0 & 0 & \cdots & a_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 0 \end{bmatrix}.$$

**Exemplo 4.7.3.** Considere o seguinte sistema linear:

$$\begin{aligned} 3x_1 + x_2 - x_3 &= 2 \\ -x_1 - 4x_2 + x_3 &= -10 \\ x_1 - 2x_2 - 5x_3 &= 10 \end{aligned}$$

Escreva o sistema na sua forma matricial  $Ax = b$  identificando a matriz dos coeficientes  $A$ , o vetor incógnita  $x$  e o vetor dos termos constantes  $b$ . Em seguida, faça a decomposição  $A = L + D + U$ .

**Solução.** A forma matricial deste sistema é  $Ax = b$ , onde:

$$A = \begin{bmatrix} 3 & 1 & -1 \\ -1 & -4 & 1 \\ 1 & -2 & -5 \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \quad \text{e} \quad b = \begin{bmatrix} 2 \\ -10 \\ 10 \end{bmatrix}.$$

A decomposição da matriz  $A$  nas matrizes  $L$  triangular inferior,  $D$  diagonal e  $U$  triangular superior é:

$$\underbrace{\begin{bmatrix} 3 & 1 & -1 \\ -1 & -4 & 1 \\ 1 & -2 & -5 \end{bmatrix}}_A = \underbrace{\begin{bmatrix} 0 & 0 & 0 \\ -1 & 0 & 0 \\ 1 & -2 & 0 \end{bmatrix}}_L + \underbrace{\begin{bmatrix} 3 & 0 & 0 \\ 0 & -4 & 0 \\ 0 & 0 & -5 \end{bmatrix}}_D + \underbrace{\begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}}_U.$$

No Scilab, podemos construir as matrizes  $L$ ,  $D$  e  $U$ , da seguinte forma:

```
-->A = [3 1 -1;-1 -4 1;1 -2 -5];
-->D = eye(A).*A;
-->L = tril(A)-D;
-->U=triu(A)-D;
```

◇

### Iteração de Jacobi

Vamos, agora, usar a decomposição discutida acima para construir a matriz de iteração  $T_J$  e o vetor de iteração  $c_J$  associado ao método de Jacobi. Neste caso, temos:

$$\begin{aligned} Ax = b &\Leftrightarrow (L + D + U)x = b \\ &\Leftrightarrow Dx = -(L + U)x + b \\ &\Leftrightarrow x = \underbrace{-D^{-1}(L + U)}_{=:T_J} x + \underbrace{D^{-1}b}_{=:c_J}. \end{aligned}$$

Ou seja, a iteração do método de Jacobi escrita na forma matricial é:

$$x^{(k+1)} = T_J x^{(k)} + c_J, \quad k \geq 1,$$

com  $x^{(1)}$  uma aproximação inicial dada, sendo  $T_J := -D^{-1}(L + U)$  a matriz de iteração e  $c_J = D^{-1}b$  o vetor da iteração.

**Exemplo 4.7.4.** Construa a matriz de iteração  $T_J$  e o vetor de iteração  $c_J$  do método de Jacobi para o sistema dado no exemplo 4.7.3.

**Solução.** A matriz de iteração é dada por:

$$T_J := -D^{-1}(L + U) = - \underbrace{\begin{bmatrix} \frac{1}{3} & 0 & 0 \\ 0 & -\frac{1}{4} & 0 \\ 0 & 0 & -\frac{1}{5} \end{bmatrix}}_{D^{-1}} \underbrace{\begin{bmatrix} 0 & 1 & -1 \\ -1 & 0 & 1 \\ 1 & 2 & 0 \end{bmatrix}}_{(L+U)} = \begin{bmatrix} 0 & -\frac{1}{3} & \frac{1}{3} \\ -\frac{1}{4} & 0 & \frac{1}{4} \\ \frac{1}{5} & \frac{2}{5} & 0 \end{bmatrix}.$$

O vetor da iteração de Jacobi é:

$$c_J := D^{-1}b = \underbrace{\begin{bmatrix} \frac{1}{3} & 0 & 0 \\ 0 & -\frac{1}{4} & 0 \\ 0 & 0 & -\frac{1}{5} \end{bmatrix}}_{D^{-1}} \underbrace{\begin{bmatrix} 2 \\ -10 \\ 10 \end{bmatrix}}_b = \begin{bmatrix} \frac{2}{3} \\ \frac{5}{2} \\ -2 \end{bmatrix}.$$

No Scilab, podemos computar  $T_J$  e  $c_J$  da seguinte forma:

```
-->TJ = -inv(D)*(L+U);
-->cJ = inv(D)*b;
```

◇



### Iteração de Gauss-Seidel

A forma matricial da iteração do método de Gauss-Seidel também pode ser construída com base na decomposição  $A = L + D + U$ . Para tanto, fazemos:

$$\begin{aligned} Ax = b &\Leftrightarrow (L + D + U)x = b \\ &\Leftrightarrow (L + D)x = -Ux + b \\ &\Leftrightarrow x = \underbrace{-(L + D)^{-1}U}_{=:T_G}x + \underbrace{(L + D)^{-1}b}_{=:c_G} \end{aligned}$$

Ou seja, a iteração do método de Gauss-Seidel escrita na forma matricial é:

$$x^{(k+1)} = T_G x^{(k)} + c_G, \quad k \geq 1,$$

com  $x^{(1)}$  uma aproximação inicial dada, sendo  $T_G := -(L + D)^{-1}U$  a matriz de iteração e  $c_G = (L + D)^{-1}b$  o vetor da iteração.

**Exemplo 4.7.5.** Construa a matriz de iteração  $T_G$  e o vetor de iteração  $c_G$  do método de Gauss-Seidel para o sistema dado no exemplo 4.7.3.

**Solução.** A matriz de iteração é dada por:

$$T_G = -(L + D)^{-1}U = -\underbrace{\begin{bmatrix} 3 & 0 & 0 \\ -1 & -4 & 0 \\ 1 & -2 & -5 \end{bmatrix}}_{(L+D)^{-1}} \underbrace{\begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}}_U = \begin{bmatrix} 0 & -\frac{1}{3} & \frac{1}{3} \\ 0 & \frac{1}{12} & \frac{1}{6} \\ 0 & -\frac{1}{10} & 0 \end{bmatrix}.$$

O vetor da iteração de Gauss-Seidel é:

$$c_G := (L + D)^{-1}b = \underbrace{\begin{bmatrix} 3 & 0 & 0 \\ -1 & -4 & 0 \\ 1 & -2 & -5 \end{bmatrix}}_{(L+D)^{-1}} \underbrace{\begin{bmatrix} 2 \\ -10 \\ 10 \end{bmatrix}}_b = \begin{bmatrix} \frac{2}{3} \\ \frac{7}{3} \\ -\frac{28}{10} \end{bmatrix}.$$

No Scilab, podemos computar  $T_G$  e  $c_G$  da seguinte forma:

```
-->TG = -inv(L+D)*U;
-->cG = inv(L+D)*b;
```

◇

### Condições de convergência

Aqui, vamos discutir condições necessárias e suficientes para a convergência de métodos iterativos. Isto é, dado um sistema  $Ax = b$  e uma iteração:

$$x^{(k+1)} = Tx^{(k)} + c, \quad k \geq 1,$$

$x^{(1)}$  dado, estabelecemos condições nas quais  $x^{(k)} \rightarrow x^*$ , onde  $x^*$  é a solução do sistema dado, isto é,  $x^* = Tx^* + c$  ou, equivalentemente,  $Ax^* = b$ .

**Lema 4.7.1.** *Seja  $T$  uma matriz real  $n \times n$ . O limite  $\lim_{k \rightarrow \infty} \|T^k\|_p = 0$ ,  $1 \leq p \leq \infty$ , se, e somente se,  $\rho(T) < 1$ .*

*Demonstração.* Aqui, fazemos apenas um esboço da demonstração. Para mais detalhes, veja [8], Teorema 4, pág. 14.

Primeiramente, suponhamos que  $\|T\|_p < 1$ ,  $1 \leq p \leq \infty$ . Como (veja [8], lema 2, pág. 12):

$$\rho(T) \leq \|T\|_p,$$

temos  $\rho(T) < 1$ , o que mostra a implicação.

Agora, suponhamos que  $\rho(T) < 1$  e seja  $0 < \epsilon < 1 - \rho(T)$ . Então, existe  $1 \leq p \leq \infty$  tal que (veja [8], Teorema 3, página 12):

$$\|T\|_p \leq \rho(T) + \epsilon < 1.$$

Assim, temos:

$$\lim_{k \rightarrow \infty} \|T^k\|_p \leq \lim_{k \rightarrow \infty} \|T\|_p^k = 0.$$

Da equivalência entre as normas segue a recíproca. □

**Observação 4.7.1.** Observamos que:

$$\lim_{k \rightarrow \infty} \|T^k\|_p = 0, \quad 1 \leq p \leq \infty, \Leftrightarrow \lim_{k \rightarrow \infty} t_{ij}^k = 0, \quad 1 \leq i, j \leq n.$$

**Lema 4.7.2.** *Se  $\rho(T) < 1$ , então existe  $(I - T)^{-1}$  e:*

$$(I - T)^{-1} = \sum_{k=0}^{\infty} T^k.$$

*Demonstração.* Primeiramente, provamos a existência de  $(I - T)^{-1}$ . Seja  $\lambda$  um autovalor de  $T$  e  $x$  um autovetor associado, isto é,  $Tx = \lambda x$ . Então,  $(I - T)x = (1 - \lambda)x$ . Além disso, temos  $|\lambda| < \rho(T) < 1$ , logo  $(1 - \lambda) \neq 0$ , o que garante que  $(I - T)$  é não singular. Agora, mostramos que  $(I - T)^{-1}$  admite a expansão acima. Do lema 4.7.1 e da observação 4.7.1 temos:

$$(I - T) \sum_{k=0}^{\infty} T^k = \lim_{m \rightarrow \infty} (I - T) \sum_{k=0}^m T^k = \lim_{m \rightarrow \infty} (I - T^{m+1}) = I,$$

o que mostra que  $(I - T)^{-1} = \sum_{k=0}^{\infty} T^k$ . □

**Teorema 4.7.1.** *A sequência recursiva  $\{x^{(k)}\}_{k \in \mathbb{N}}$  dada por:*

$$x^{(k+1)} = Tx^{(k)} + c$$

*converge para solução de  $x = Tx + c$  para qualquer escolha de  $x^{(1)}$  se, e somente se,  $\rho(T) < 1$ .*

*Demonstração.* Primeiramente, assumimos que  $\rho(T) < 1$ . Observamos que:

$$\begin{aligned} x^{(k+1)} &= Tx^{(k)} + c = T(Tx^{(k-1)} + c) + c \\ &= T^2x^{(k-1)} + (I + T)c \\ &\quad \vdots \\ &= T^{(k)}x^{(1)} + \left(\sum_{k=0}^{k-1} T^k\right)c. \end{aligned}$$

Daí, do lema 4.7.1 e do lema 4.7.2 temos:

$$\lim_{k \rightarrow \infty} x^{(k)} = (I - T)^{-1}c.$$

Ora, se  $x^*$  é a solução de  $x = Tx + c$ , então  $(I - T)x^* = c$ , isto é,  $x^* = (I - T)^{-1}c$ . Logo, temos demonstrado que  $x^{(k)}$  converge para a solução de  $x = Tx + c$ , para qualquer escolha de  $x^{(1)}$ .

Agora, suponhamos que  $x^{(k)}$  converge para  $x^*$  solução de  $x = Tx + c$ , para qualquer escolha de  $x^{(1)}$ . Seja, então,  $y$  um vetor arbitrário e  $x^{(1)} = x^* - y$ . Observamos que:

$$\begin{aligned} x^* - x^{(k+1)} &= (Tx^* + c) - (Tx^{(k)} + c) \\ &= T(x^* - x^{(k)}) \\ &\quad \vdots \\ &= T^{(k)}(x^* - x^{(1)}) = T^{(k)}y. \end{aligned}$$

Logo, para qualquer  $1 \leq p \leq \infty$ , temos, :

$$0 = \lim_{k \rightarrow \infty} x^* - x^{(k+1)} = \lim_{k \rightarrow \infty} T^{(k)}y.$$

Como  $y$  é arbitrário, da observação 4.7.1 temos  $\lim_{k \rightarrow \infty} \|T^{(k)}\|_p = 0$ ,  $1 \leq p \leq \infty$ . Então, o lema 4.7.1 garante que  $\rho(T) < 1$ . □

**Observação 4.7.2.** Pode-se mostrar que tais métodos iterativos tem taxa de convergência super linear com:

$$\|x^{(k+1)} - x^*\| \approx \rho(T)^k \|x^{(1)} - x^*\|.$$

Para mais detalhes, veja [8], pág. 61-64.

**Exemplo 4.7.6.** Mostre que, para qualquer escolha da aproximação inicial, ambos os métodos de Jacobi e Gauss-Seidel são convergentes quando aplicados ao sistema linear dado no exemplo 4.7.3.

**Solução.** Do teorema 4.7.1, vemos que é necessário e suficiente que  $\rho(T_J) < 1$  e  $\rho(T_G) < 1$ . Computando estes raios espectrais, obtemos  $\rho(T_J) \approx 0,32$  e  $\rho(T_G) \approx 0,13$ . Isto mostra que ambos os métodos serão convergentes.  $\diamond$

### Condição suficiente

Uma condição suficiente porém não necessária para que os métodos de Gauss-Seidel e Jacobi convirjam é a que a matriz seja **estritamente diagonal dominante**.

**Definição 4.7.1.** Uma matriz  $A$  é **estritamente diagonal dominante** quando:

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, i = 1, \dots, n$$

**Definição 4.7.2.** Uma matriz  $A$  é **diagonal dominante** quando

$$|a_{ii}| \geq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, i = 1, \dots, n$$

e para ao menos um  $i$ ,  $a_{ii}$  é estritamente maior que a soma dos elementos fora da diagonal.

**Teorema 4.7.2.** Se a matriz  $A$  for diagonal dominante<sup>9</sup>, então os métodos de Jacobi e Gauss-Seidel serão convergentes independente da escolha inicial  $x^{(1)}$ .

Se conhecermos a solução exata  $x$  do problema, podemos calcular o erro relativo em cada iteração como:

$$\frac{\|x - x^{(k)}\|}{\|x\|}.$$

Em geral não temos  $x$ , entretanto podemos estimar o vetor **resíduo**  $r^{(k)} = b - Ax^{(k)}$ . Note que quando o erro tende a zero, o resíduo também tende a zero.

<sup>9</sup>E consequentemente estritamente diagonal dominante.

**Teorema 4.7.3.** *O erro relativo e o resíduo estão relacionados como (veja [3])*

$$\frac{\|x - x^{(k)}\|}{\|x\|} \leq \kappa(A) \frac{\|r\|}{\|b\|}$$

onde  $\kappa(A)$  é o número de condicionamento.

**Exemplo 4.7.7.** Ambos os métodos de Jacobi e Gauss-Seidel são convergentes para o sistema dado no exemplo 4.7.3, pois a matriz dos coeficientes deste é uma matriz estritamente diagonal dominante.

## Exercícios

**E 4.7.1.** Considere o problema de 5 incógnitas e cinco equações dado por

$$\begin{aligned} x_1 - x_2 &= 1 \\ -x_1 + 2x_2 - x_3 &= 1 \\ -x_2 + (2 + \varepsilon)x_3 - x_4 &= 1 \\ -x_3 + 2x_4 - x_5 &= 1 \\ x_4 - x_5 &= 1 \end{aligned}$$

- Escreva na forma  $Ax = b$  e resolva usando eliminação gaussiana para  $\varepsilon = 10^{-3}$  no Scilab.
- Obtenha o vetor incógnita  $x$  com  $\varepsilon = 10^{-3}$  usando Jacobi com tolerância  $10^{-2}$ . Compare o resultado com o resultado obtido no item d.
- Obtenha o vetor incógnita  $x$  com  $\varepsilon = 10^{-3}$  usando Gauss-Seidel com tolerância  $10^{-2}$ . Compare o resultado com o resultado obtido no item d.
- Discuta com base na relação esperada entre tolerância e exatidão conforme estudado na primeira área para problemas de uma variável.

**E 4.7.2.** Resolva o seguinte sistema pelo método de Jacobi e Gauss-Seidel:

$$\begin{cases} 5x_1 + x_2 + x_3 &= 50 \\ -x_1 + 3x_2 - x_3 &= 10 \\ x_1 + 2x_2 + 10x_3 &= -30 \end{cases}$$

Use como critério de paragem tolerância inferior a  $10^{-3}$  e inicialize com  $x^0 = y^0 = z^0 = 0$ .

**E 4.7.3.** Refaça o Exercício 4.1.6 construindo um algoritmo que implemente os métodos de Jacobi e Gauss-Seidel.

**E 4.7.4.** Considere o seguinte sistema de equações lineares:

$$\begin{aligned}x_1 - x_2 &= 0 \\ -x_{j-1} + 5x_j - x_{j+1} &= \cos(j/10), \quad 2 \leq j \leq 10 \\ x_{11} &= x_{10}/2\end{aligned}\tag{4.33}$$

Construa a iteração para encontrar a solução deste problema pelos métodos de Gauss-Seidel e Jacobi. Usando esses métodos, encontre uma solução aproximada com erro absoluto inferior a  $10^{-5}$ . Veja também exercício 4.5.2

**E 4.7.5.** Faça uma permutação de linhas no sistema abaixo e resolva pelos métodos de Jacobi e Gauss-Seidel:

$$\begin{aligned}x_1 + 10x_2 + 3x_3 &= 27 \\ 4x_1 + x_3 &= 6 \\ 2x_1 + x_2 + 4x_3 &= 12\end{aligned}$$

## 4.8 Método da potência para cálculo de autovalores

Consideremos uma matriz  $A \in \mathbb{R}^{n,n}$  diagonalizável, isto é, existe um conjunto  $\{v_j\}_{j=1}^n$  de autovetores de  $A$  tais que qualquer elemento  $x \in \mathbb{R}^n$  pode ser escrito como uma combinação linear dos  $v_j$ . Sejam  $\{\lambda_j\}_{j=1}^n$  o conjunto de autovalores associados aos autovetores tal que um deles seja dominante, ou seja,

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n| > 0$$

Como os autovetores são l.i., todo vetor  $x \in \mathbb{R}^n$ ,  $x = (x_1, x_2, \dots, x_n)$ , pode ser escrito com combinação linear dos autovetores da seguinte forma:

$$x = \sum_{j=1}^n \beta_j v_j.\tag{4.34}$$

O método da potência permite o cálculo do autovetor dominante com base no comportamento assintótico (isto é, “no infinito”) da sequência

$$x, Ax, A^2x, A^3x, \dots$$

Por questões de convergência, consideramos a seguinte sequência semelhante à anterior, porém normalizada:

$$\frac{x}{\|x\|}, \frac{Ax}{\|Ax\|}, \frac{A^2x}{\|A^2x\|}, \frac{A^3x}{\|A^3x\|}, \dots,$$

que pode ser obtida pelo seguinte processo iterativo:

$$x^{(k+1)} = \frac{A^k x}{\|A^k x\|}$$

Observamos que se  $x$  está na forma (4.34), então  $A^k x$  pode ser escrito como

$$A^k x = \sum_{j=1}^n \beta_j A^k v_j = \sum_{j=1}^n \beta_j \lambda_j^k v_j = \beta_1 \lambda_1^k \left( v_1 + \sum_{j=2}^n \frac{\beta_j}{\beta_1} \left( \frac{\lambda_j}{\lambda_1} \right)^k v_j \right)$$

Como  $\left| \frac{\lambda_j}{\lambda_1} \right| < 1$  para todo  $j \geq 2$ , temos

$$\sum_{j=2}^n \frac{\beta_j}{\beta_1} \left( \frac{\lambda_j}{\lambda_1} \right)^k v_j \rightarrow 0.$$

Assim

$$\frac{A^k x}{\|A^k x\|} = \frac{\beta_1 \lambda_1^k}{\|A^k x\|} \left( v_1 + O \left( \left| \frac{\lambda_2}{\lambda_1} \right|^k \right) \right) \quad (4.35)$$

Como a norma de  $\frac{A^k x}{\|A^k x\|}$  é igual a um, temos

$$\left\| \frac{\beta_1 \lambda_1^k}{\|A^k x\|} v_1 \right\| \rightarrow 1$$

e, portanto,

$$\left| \frac{\beta_1 \lambda_1^k}{\|A^k x\|} \right| \rightarrow \frac{1}{\|v_1\|}$$

Ou seja, se definimos  $\alpha^{(k)} = \frac{\beta_1 \lambda_1^k}{\|A^k x\|}$ , então

$$|\alpha^{(k)}| \rightarrow 1$$

Retornando a (4.35), temos:

$$\frac{A^k x}{\|A^k x\|} - \alpha^{(k)} v_1 \rightarrow 0$$

Observe que um múltiplo de autovetor também é um autovetor e, portanto,

$$\frac{A^k x}{\|A^k x\|}$$

é um esquema que oscila entre os autovetores ou converge para o autovetor  $v_1$ .

Uma vez que temos o autovetor  $v_1$  de  $A$ , podemos calcular  $\lambda_1$  da seguinte forma:

$$Av_1 = \lambda_1 v_1 \implies v_1^T Av_1 = v_1^T \lambda_1 v_1 \implies \lambda_1 = \frac{v_1^T Av_1}{v_1^T v_1}$$

Observe que a última identidade é válida, pois  $\|v_1\| = 1$  por construção.

## Exercícios

**E 4.8.1.** Calcule o autovalor dominante e o autovetor associado da matriz

$$\begin{bmatrix} 4 & 41 & 78 \\ 48 & 28 & 21 \\ 26 & 13 & 11 \end{bmatrix}$$

Expresse sua resposta com seis dígitos significativos

**E 4.8.2.** Calcule o autovalor dominante e o autovetor associado da matriz

$$\begin{bmatrix} 3 & 4 \\ 2 & -1 \end{bmatrix}$$

usando o método da potência iniciando com o vetor  $x = [1 \ 1]^T$

**E 4.8.3.** A norma  $L_2$  de uma matriz  $A$  é dada pela raiz quadrada do autovalor dominante da matriz  $A^*A$ , isto é:

$$\|A\|_2 = \sqrt{\max\{|\lambda| : \lambda \in \sigma(A^*A)\}}$$

Use o método da potência para obter a norma  $L_2$  da seguinte matriz:

$$A = \begin{bmatrix} 69 & 84 & 88 \\ 15 & -40 & 11 \\ 70 & 41 & 20 \end{bmatrix}$$

Expresse sua resposta com seis dígitos significativos



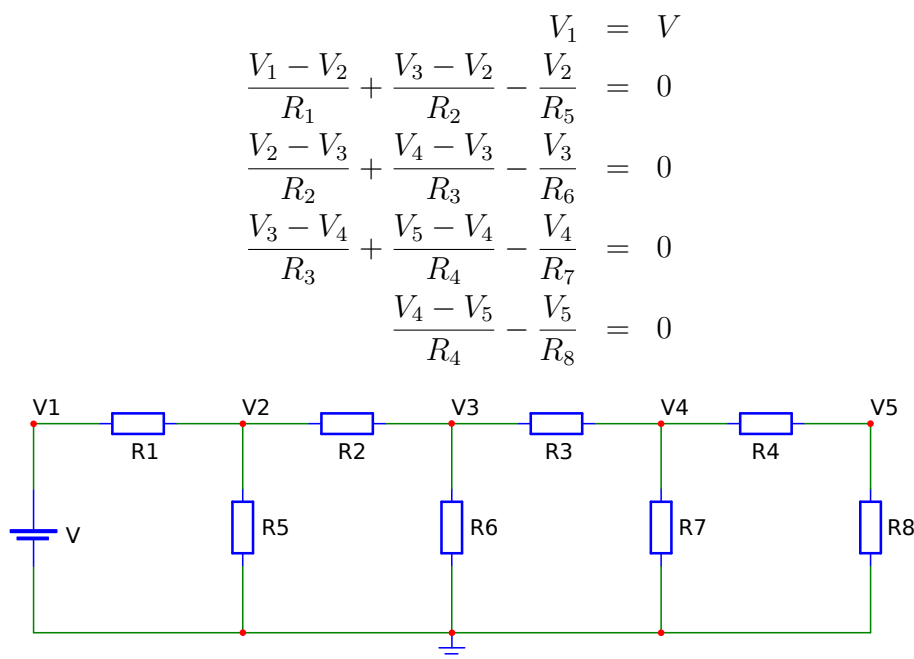
**E 4.8.4.** Os autovalores de uma matriz triangular são os elementos da diagonal principal. Verifique o método da potência aplicada à seguinte matriz:

$$\begin{bmatrix} 2 & 3 & 1 \\ 0 & 3 & -1 \\ 0 & 0 & 1 \end{bmatrix}.$$

## 4.9 Exercícios finais

**E 4.9.1.** O circuito linear da figura 4.9.1 pode ser modelado pelo sistema dado a seguir. Escreva esse sistema na forma matricial sendo as tensões  $V_1$ ,  $V_2$ ,  $V_3$ ,  $V_4$  e  $V_5$  as cinco incógnitas. Resolva esse problema quando  $V = 127$  e

- a)  $R_1 = R_2 = R_3 = R_4 = 2$  e  $R_5 = R_6 = R_7 = 100$  e  $R_8 = 50$   
 b)  $R_1 = R_2 = R_3 = R_4 = 2$  e  $R_5 = 50$  e  $R_6 = R_7 = R_8 = 100$



Complete a tabela abaixo representando a solução com 4 algarismos significativos:

Caso	$V_1$	$V_2$	$V_3$	$V_4$	$V_5$
a					
b					

Então, refaça este problema reduzindo o sistema para apenas 4 incógnitas ( $V_2$ ,  $V_3$ ,  $V_4$  e  $V_5$ ).

**E 4.9.2.** Resolva o problema 4.9.1 pelos métodos de Jacobi e Gauss-Seidel.

**E 4.9.3.** (Interpolação) Resolva os seguintes problemas:

- Encontre o polinômio  $P(x) = ax^2 + bx + c$  que passa pelos pontos  $(-1, -3)$ ,  $(1, -1)$  e  $(2, 9)$ .
- Encontre os coeficientes  $A$  e  $B$  da função  $f(x) = A \sin(x) + B \cos(x)$  tais que  $f(1) = 1.4$  e  $f(2) = 2.8$ .
- Encontre a função  $g(x) = A_1 \sin(x) + B_1 \cos(x) + A_2 \sin(2x) + B_2 \cos(2x)$  tais que  $f(1) = 1$ ,  $f(2) = 2$ ,  $f(3) = 3$  e  $f(4) = 4$ .

## Capítulo 5

# Solução de sistemas de equações não lineares

Neste capítulo, estudaremos o método de Newton aplicado à resolução de sistemas não-lineares de equações.

O método de Newton aplicado a encontrar a raiz  $x^*$  da função  $y = f(x)$  estudado na seção 3.4 consiste em um processo iterativo. Em cada passo deste processo, dispomos de uma aproximação  $x^{(k)}$  para  $x^*$  e construímos uma aproximação  $x^{(k+1)}$ . Cada passo do método de Newton envolve os seguintes procedimentos:

- Linearização da função  $f(x)$  no ponto  $x^{(k)}$ :

$$f(x) = f(x^{(k)}) + (x - x^{(k)})f'(x^{(k)}) + O(|x - x^{(k)}|^2)$$

- A aproximação  $x^{(k+1)}$  é definida como o valor de  $x$  em que a linearização  $f(x^{(k)}) + (x - x^{(k)})f'(x^{(k)})$  passa por zero.

Queremos, agora, generalizar o método de Newton a fim de resolver problemas de várias equações e várias incógnitas, ou seja, encontrar  $x_1, x_2, \dots, x_n$  que satisfazem as seguintes equações:

$$\begin{aligned} f_1(x_1, x_2, \dots, x_n) &= 0 \\ f_2(x_1, x_2, \dots, x_n) &= 0 \\ &\vdots \\ f_n(x_1, x_2, \dots, x_n) &= 0 \end{aligned}$$

Podemos escrever este problema na forma vetorial definindo o vetor  $x = [x_1, x_2, \dots, x_n]^T$

e a função vetorial

$$F(x) = \begin{bmatrix} f_1(x_1, x_2, \dots, x_n) \\ f_2(x_1, x_2, \dots, x_n) \\ \vdots \\ f_n(x_1, x_2, \dots, x_n) \end{bmatrix}$$

**Exemplo 5.0.1.** Suponha que queiramos resolver numericamente os seguinte sistema de duas equações e duas incógnitas:

$$\begin{aligned} \frac{x_1^2}{3} + x_2^2 &= 1 \\ x_1^2 + \frac{x_2^2}{4} &= 1 \end{aligned}$$

Então definimos

$$F(x) = \begin{bmatrix} \frac{x_1^2}{3} + x_2^2 - 1 \\ x_1^2 + \frac{x_2^2}{4} - 1 \end{bmatrix}$$

Neste momento, dispomos de um problema na forma  $F(x) = 0$  e precisamos desenvolver uma técnica para linearizar a função  $F(x)$ . Para tal, precisamos de alguns conceitos do cálculo de várias variáveis.

Observe que  $F(x) - F(x^{(0)})$  pode ser escrito como

$$F(x) - F(x^{(0)}) = \begin{bmatrix} f_1(x_1, x_2, \dots, x_n) - f_1(x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)}) \\ f_2(x_1, x_2, \dots, x_n) - f_2(x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)}) \\ \vdots \\ f_n(x_1, x_2, \dots, x_n) - f_n(x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)}) \end{bmatrix}$$

Usamos a regra da cadeia

$$df_i = \frac{\partial f_i}{\partial x_1} dx_1 + \frac{\partial f_i}{\partial x_2} dx_2 + \dots + \frac{\partial f_i}{\partial x_n} dx_n = \sum_{j=1}^n \frac{\partial f_i}{\partial x_j} dx_j$$

e aproximamos as diferenças por derivadas parciais:

$$f_i(x_1, x_2, \dots, x_n) - f_i(x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)}) \approx \sum_{j=1}^n \frac{\partial f_i}{\partial x_j} (x_j - x_j^{(0)})$$

Portanto,

$$F(x) - F(x^{(0)}) \approx \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_n} \end{bmatrix} \begin{bmatrix} x_1 - x_1^{(0)} \\ x_2 - x_2^{(0)} \\ \vdots \\ x_n - x_n^{(0)} \end{bmatrix}, \quad (5.1)$$

Definimos, então, a matriz jacobiana por

$$J_F = \frac{\partial(f_1, f_2, \dots, f_n)}{\partial(x_1, x_2, \dots, x_n)} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}.$$

Isto é, a matriz jacobiana de uma função ou simplesmente, o jacobiano de uma função  $F(x)$  é a matriz formada pelas suas derivadas parciais:

$$(J_F)_{ij} = \frac{\partial f_i}{\partial x_j}.$$

Nestes termos, podemos reescrever (5.1) como

$$F(x) \approx F(x^{(0)}) + J_F(x^{(0)})(x - x^{(0)})$$

Esta expressão é chamada de linearização de  $F(x)$  no ponto  $x^{(0)}$  e generaliza a linearização em uma dimensão dada por  $f(x) \approx f(x^{(0)}) + f'(x^{(0)})(x - x^{(0)})$ .

## 5.1 Método de Newton para sistemas

Nesta seção, construiremos o método de Newton ou Newton-Raphson generalizado para sistemas. Assumimos, portanto, que a função  $F(x)$  é diferenciável e que existe um ponto  $x^*$  tal que  $F(x^*) = 0$ . Seja  $x^{(k)}$  uma aproximação para  $x^*$ , queremos construir uma nova aproximação  $x^{(k+1)}$  através da linearização de  $F(x)$  no ponto  $x^{(k)}$ .

- Linearização da função  $F(x)$  no ponto  $x^{(k)}$ :

$$F(x) = F(x^{(k)}) + J_F(x^{(k)})(x - x^{(k)}) + O(\|x - x^{(k)}\|^2)$$

- A aproximação  $x^{(k)}$  é definida como o ponto  $x$  em que a linearização  $F(x^{(k)}) + J_F(x^{(k)})(x - x^{(k)})$  é nula, ou seja:

$$F(x^{(k)}) + J_F(x^{(k)})(x^{(k+1)} - x^{(k)}) = 0$$

Supondo que a matriz jacobina seja inversível no ponto  $x^{(k)}$ , temos:

$$\begin{aligned} J_F(x^{(k)})(x^{(k+1)} - x^{(k)}) &= -F(x^{(k)}) \\ x^{(k+1)} - x^{(k)} &= -J_F^{-1}(x^{(k)})F(x^{(k)}) \\ x^{(k+1)} &= x^{(k)} - J_F^{-1}(x^{(k)})F(x^{(k)}) \end{aligned}$$

Desta forma, o método iterativo de Newton-Raphson para encontrar as raízes de  $F(x) = 0$  é dado por:

$$\begin{cases} x^{(k+1)} = x^{(k)} - J_F^{-1}(x^{(k)})F(x^{(k)}), & n \geq 0 \\ x^{(0)} = \text{dado inicial} \end{cases}$$

**Observação 5.1.1.** Usamos subíndices para indicar o elemento de um vetor e superíndices para indicar o passo da iteração. Assim,  $x^{(k)}$  se refere à iteração  $k$  e  $x_i^{(k)}$  se refere à componente  $i$  no vetor  $x^{(k)}$ .

**Observação 5.1.2.** A notação  $J_F^{-1}(x^{(k)})$  enfatiza que a jacobiana deve ser calculada a cada passo.

**Observação 5.1.3.** Podemos definir o passo  $\Delta^{(k)}$  como

$$\Delta^{(k)} = x^{(k+1)} - x^{(k)}$$

Assim,  $\Delta^{(k)} = -J_F^{-1}(x^{(k)}) F(x^{(k)})$ , ou seja,  $\Delta^{(k)}$  resolve o problema linear:

$$J_F(x^{(k)}) \Delta^{(k)} = -F(x^{(k)})$$

Em geral, é menos custoso resolver o sistema acima do que calcular o inverso da jacobiana e multiplicar pelo vetor  $F(x^{(k)})$ .

**Exemplo 5.1.1.** Retornamos ao nosso exemplo inicial, isto é, resolver numericamente os seguinte sistema não-linear:

$$\begin{aligned} \frac{x_1^2}{3} + x_2^2 &= 1 \\ x_1^2 + \frac{x_2^2}{4} &= 1 \end{aligned}$$

Para tal, definimos a função  $F(x)$ :

$$F(x) = \begin{bmatrix} \frac{x_1^2}{3} + x_2^2 - 1 \\ x_1^2 + \frac{x_2^2}{4} - 1 \end{bmatrix}$$

cuja jacobiana é:

$$J_F = \begin{bmatrix} \frac{2x_1}{3} & 2x_2 \\ 2x_1 & \frac{x_2}{2} \end{bmatrix}$$

Faremos a implementação numérica no **Scilab**. Para tal definimos as funções que implementarão  $F(x)$  e a  $J_F(x)$

```
function y=F(x)
    y(1)=x(1)^2/3+x(2)^2-1
    y(2)=x(1)^2+x(2)^2/4-1
endfunction
```

```
function y=JF(x)
    y(1,1)=2*x(1)/3
    y(1,2)=2*x(2)
    y(2,1)=2*x(1)
    y(2,2)=x(2)/2
endfunction
```

Alternativamente, estas funções poderiam ser escritas como

```
function y=F(x)
    y=[x(1)^2/3+x(2)^2-1; x(1)^2+x(2)^2/4-1]
endfunction
```

```
function y=JF(x)
    y=[2*x(1)/3  2*x(2); 2*x(1) x(2)/2]
endfunction
```

Desta forma, se  $x$  é uma aproximação para a raiz, pode-se calcular a próxima aproximação através dos comandos:

```
delta=-JF(x)\F(x)
x=x+delta
```

Ou simplesmente

```
x=x-JF(x)\F(x)
```

Observe que as soluções exatas desse sistema são  $(\pm\sqrt{\frac{9}{11}}, \pm\sqrt{\frac{8}{11}})$ .

**Exemplo 5.1.2.** Encontre uma aproximação para a solução do sistema

$$\begin{aligned}x_1^2 &= \cos(x_1 x_2) + 1 \\ \text{sen}(x_2) &= 2 \cos(x_1)\end{aligned}$$

que fica próxima ao ponto  $x_1 = 1,5$  e  $x_2 = 0,5$ .

**Solução.** Vamos, aqui, dar as principais ideias para se obter a solução usando o método de Newton. Começamos definindo nossa aproximação inicial por  $x^{(1)} = (1,5, 0,5)$ . Então iteramos:

$$x^{(n+1)} = x^{(n)} - J_F^{-1}(x)F(x), \quad n \geq 1.$$

onde

$$F(x) = \begin{bmatrix} x_1^2 - \cos(x_1 x_2) - 1 \\ \text{sen}(x_2) - 2 \cos(x_1) \end{bmatrix}$$

e sua jacobiana é

$$J_F(x) = \begin{bmatrix} 2x_1 + x_2 \text{sen}(x_1 x_2) & x_1 \text{sen}(x_1 x_2) \\ 2 \text{sen}(x_1) & \cos(x_2) \end{bmatrix}$$

As iterações convergem para  $x = (1,3468109, 0,4603195)$ .

No Scilab, podemos implementá-las com o seguinte código:



```
function y=F(x)
    y(1) = x(1)^2-cos(x(1)*x(2))-1
    y(2) = sin(x(2))-2*cos(x(1))
endfunction

function y=JF(x)
    y(1,1) = 2*x(1)+x(2)*sin(x(1)*x(2))
    y(1,2) = x(1)*sin(x(1)*x(2))

    y(2,1) = 2*sin(x(1))
    y(2,2) = cos(x(2))
endfunction
```

E agora, basta iterar:

```
x=[1.5; .5]
x=x-JF(x)\F(x) //(5 vezes)
```

◇

### 5.1.1 Código Scilab: Newton para sistemas

```
function [x] = newton(F,JF,x0,TOL,N)
    x = x0
    k = 1
    //iteracoes
    while (k <= N)
        //iteracao de Newton
        delta = -inv(JF(x))*F(x)
        x = x + delta
        //criterio de parada
        if (norm(delta,'inf')<TOL) then
            return x
        end
        k = k+1
    end
    error('Num. de iter. max. atingido!')
endfunction
```

## Exercícios

**E 5.1.1.** Faça o que se pede:

a) Encontre o gradiente da função

$$f(x,y) = x^2y + \cos(xy) - 4$$

b) Encontre a matriz jacobiana associada à função

$$F(x,y) = \begin{bmatrix} x \cos(x) + y \\ e^{-2x+y} \end{bmatrix}.$$

c) Encontre a matriz jacobiana associada à função

$$L(x) = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 - y_1 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 - y_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 - y_3 \end{bmatrix}.$$

**E 5.1.2.** Encontre uma aproximação numérica para o seguinte problema não-linear de três equações e três incógnitas:

$$\begin{aligned} 2x_1 - x_2 &= \cos(x_1) \\ -x_1 + 2x_2 - x_3 &= \cos(x_2) \\ -x_2 + x_3 &= \cos(x_3) \end{aligned}$$

Partindo das seguintes aproximações iniciais:

a)  $x^{(0)} = [1, 1, 1]^T$

b)  $x^{(0)} = [-0,5, -2, -3]^T$

c)  $x^{(0)} = [-2, -3, -4]^T$

d)  $x^{(0)} = [0, 0, 0]^T$

**E 5.1.3.** Encontre os pontos de intersecção entre a parábola  $y = x^2 + 1$  e a elipse  $x^2 + y^2/4 = 1$  seguindo os seguintes passos:

a) Faça um esboço das duas curvas e entenda o problema. Verifique que existem dois pontos de intersecção, um no primeiro quadrante e outro no segundo quadrante do plano  $xy$ .

b) A partir de seu esboço, encontre aproximações para  $x$  e  $y$  em cada ponto.

c) Escreva o problema na forma  $F \left( \begin{bmatrix} x \\ y \end{bmatrix} \right) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$

d) Encontre a jacobiana  $J_F$ .

e) Construa a iteração do método de Newton.

f) Implemente no computador.

g) Resolva o sistema analiticamente e compare as respostas.

**E 5.1.4.** Encontre os pontos de intersecção entre a parábola  $y = x^2$  e a curva  $y = \cos(x)$  seguindo os seguintes passos:

a ) Faça um esboço das duas curvas, entenda o problema. Verifique que existem dois pontos de intersecção, um no primeiro quadrante e outro no segundo quadrando do plano  $xy$ .

b ) A partir de seu esboço, encontre aproximações para  $x$  e  $y$  em cada ponto.

c ) Escreva o problema na forma  $F \left( \begin{bmatrix} x \\ y \end{bmatrix} \right) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$

d ) Encontre a jacobiana  $J_F$ .

e ) Construa a iteração do método de Newton.

f ) Implemente no **Scilab**.

g ) Transforme o sistema em um problema de uma única variável e compare com a resposta do problema [3.4.1](#).

**E 5.1.5.** Encontre uma aproximação com erro inferior a  $10^{-5}$  em cada incógnita para a solução próxima da origem do sistema

$$\begin{aligned} 6x - 2y + e^z &= 2 \\ \text{sen}(x) - y + z &= 0 \\ \text{sen}(x) + 2y + 3z &= 1 \end{aligned}$$



Figura 5.1: Reta bitangente a uma curva.

**E 5.1.6.** (Entenda casos particulares)

- Considere a função  $L(x) = Ax - b$ , onde  $A$  é uma matriz  $n \times n$  inversível e  $b$  um vetor coluna em  $\mathbb{R}^n$ . O que acontece quando aplicamos o método de Newton para encontrar as raízes de  $L(x)$ ?
- Mostre que o método de Newton-Raphson aplicado a uma função diferenciável do tipo  $f : \mathbb{R} \rightarrow \mathbb{R}$  se reduz ao método de Newton estudado na primeira área.

**E 5.1.7.** Considere a função  $f(x) = \frac{\sin(x)}{x+1}$ , encontre a equação da reta que tangencia dois pontos da curva  $y = f(x)$  próximos ao primeiro e segundo ponto de máximo no primeiro quadrante, respectivamente. Veja a figura 5.1.

**E 5.1.8.** (Estática) Considere o sistema mecânico constituído de dois segmentos de mesmo comprimento  $L$  presos entre si e a uma parede por articulações conforme a figura 5.2.

O momento em cada articulação é proporcional à deflexão com constante de proporcionalidade  $k$ . Os segmentos são feitos de material homogêneo de peso  $P$ . A condição de equilíbrio pode ser expressa em termos dos ângulos  $\theta_1$  e  $\theta_2$  conforme:

$$\begin{aligned} k\theta_1 &= \frac{3PL}{2} \cos \theta_1 + k(\theta_2 - \theta_1) \\ k(\theta_2 - \theta_1) &= \frac{PL}{2} \cos \theta_2 \end{aligned}$$

Considere  $P = 100N$ ,  $L = 1m$  e calcule os ângulos  $\theta_1$  e  $\theta_2$  quando:



Figura 5.2: Sistema mecânico com dois segmentos.

- a)  $k = 1000 \text{ Nm/rad}$
- b)  $k = 500 \text{ Nm/rad}$
- c)  $k = 100 \text{ Nm/rad}$
- d)  $k = 10 \text{ Nm/rad}$

**Obs:** Você deve escolher valores para iniciar o método. Como você interpretaria fisicamente a solução para produzir palpites iniciais satisfatórios? O que se altera entre o caso a e o caso d?

**E 5.1.9.** (estática - problemas de três variáveis) Considere, agora, o sistema mecânico semelhante ao do problema 5.1.8, porém constituído de três segmentos de mesmo comprimento  $L$  presos entre si e a uma parede por articulações.

O momento em cada articulação é proporcional à deflexão com constante de proporcionalidade  $k$ . Os segmentos são feitos de material homogêneo de peso  $P$ . A condição de equilíbrio pode ser expressa em termos dos ângulos  $\theta_1$ ,  $\theta_2$  e  $\theta_3$  conforme:

$$\begin{aligned} k\theta_1 &= \frac{5PL}{2} \cos \theta_1 + k(\theta_2 - \theta_1) \\ k(\theta_2 - \theta_1) &= \frac{3PL}{2} \cos \theta_2 + k(\theta_3 - \theta_2) \\ k(\theta_3 - \theta_2) &= \frac{PL}{2} \cos \theta_3 \end{aligned}$$

Considere  $P = 10\text{N}$ ,  $L = 1\text{m}$  e calcule os ângulos  $\theta_1$ ,  $\theta_2$  e  $\theta_3$  quando:

- a)  $k = 1000\text{Nm/rad}$




Figura 5.3: intersecção entre duas curvas.

b)  $k = 100\text{Nm/rad}$

c)  $k = 10\text{Nm/rad}$

**E 5.1.10.** Considere o problema de encontrar os pontos de intersecção das curvas descritas por (ver figura 5.3):

$$\frac{x^2}{8} + \frac{(y-1)^2}{5} = 1$$

$$\tan^{-1}(x) + x = y + y^3$$

Com base no gráfico, encontre soluções aproximadas para o problema e use-as para iniciar o método de Newton-Raphson. Encontre as raízes com erro inferior a  $10^{-5}$ .

**E 5.1.11.** Considere o sistema de equações dado por

$$\frac{(x-3)^2}{16} + \frac{(y-1)^2}{36} = 1$$

$$\tanh(x) + x = 2 \sin y - 0.01y^3$$

Usando procedimentos analíticos, determine uma região limitada do plano onde se encontram necessariamente todas as raízes do problema. Encontre as raízes desse sistema com pelo menos quatro dígitos significativos corretos usando o método de Newton. Você deve contruir o método de Newton indicando as funções envolvidas e calculando a matriz jacobiana analiticamente. Use que  $\frac{d}{du} \tanh u = 1 - \tanh^2 u$ , se precisar.

**E 5.1.12.** (Otimização) Uma indústria consome energia elétrica de três usinas fornecedoras. O custo de fornecimento em reais por hora como função da potência consumida em kW é dada pelas seguintes funções

$$C_1(x) = 10 + .3x + 10^{-4}x^2 + 3.4 \cdot 10^{-9}x^4$$

$$C_2(x) = 50 + .25x + 2 \cdot 10^{-4}x^2 + 4.3 \cdot 10^{-7}x^3$$

$$C_3(x) = 500 + .19x + 5 \cdot 10^{-4}x^2 + 1.1 \cdot 10^{-7}x^4$$

Calcule a distribuição de consumo que produz custo mínimo quando a potência total consumida é  $1500kW$ . Dica: Denote por  $x_1$ ,  $x_2$  e  $x_3$  as potências consumidas das usinas 1, 2 e 3, respectivamente. O custo total será dado por  $C(x_1, x_2, x_3) = C_1(x_1) + C_2(x_2) + C_3(x_3)$  enquanto o consumo total é  $x_1 + x_2 + x_3 = 1500$ . Isto é, queremos minimizar a função custo total dada por:

$$C(x_1, x_2, x_3) = C_1(x_1) + C_2(x_2) + C_3(x_3)$$

restrita à condição

$$G(x_1, x_2, x_3) = x_1 + x_2 + x_3 - 1500 = 0.$$

Pelos multiplicadores de Lagrange, temos que resolver o sistema dado por:

$$\begin{aligned}\nabla C(x_1, x_2, x_3) &= \lambda \nabla G(x_1, x_2, x_3) \\ G(x_1, x_2, x_3) &= 0\end{aligned}$$

**E 5.1.13.** Encontre a função do tipo  $f(x) = Ab^x$  que melhor aproxima os pontos  $(0, 3,1)$ ,  $(1, 4,4)$  e  $(2, 6,7)$  pelo critério dos mínimos quadrados. Dica: Você deve encontrar os valores de  $A$  e  $b$  que minimizam o resíduo dado por

$$R = [3,1 - f(0)]^2 + [4,4 - f(1)]^2 + [6,7 - f(2)]^2.$$

**Dica:** Para construir aproximações para resposta e iniciar o método, considere a função  $f(x) = Ab^x$  que passa pelo primeiro e terceiro ponto.

**E 5.1.14.** Encontre o valor máximo da função

$$f(x, y) = -x^4 - y^6 + 3xy^3 - x$$

na região  $(x, y) \in [-2, 0] \times [-2, 0]$  seguindo os seguintes passos:

- Defina a função  $z = f(x, y) = -x^4 - y^6 + 3xy^3 - x$  e trace o gráfico de contorno na região.
- Com base no gráfico, encontre valores aproximados para as coordenadas  $xy$  do ponto de máximo.
- Sabendo que o ponto de máximo acontece quando o gradiente é nulo, escreva o problema como um sistema de duas equações não lineares e duas incógnitas.
- Implemente o método de Newton.

**E 5.1.15.** A função  $f(x, y, z) = \sin(x) + \sin(2y) + \sin(3z)$  possui um máximo quando  $x = \pi/2$ ,  $y = \pi/4$  e  $z = \pi/6$ . Calcule numericamente este ponto.

**E 5.1.16.** Encontre as raízes do problema

$$\begin{aligned} 3x - \cos(yz + z) - 1/2 &= 0 \\ 4x^2 - 25y^2 + 0.4y + 2 &= 0 \\ e^{-xy} + 2x - 5z &= 10 \end{aligned}$$

no cubo  $|x| < 2$ ,  $|y| < 2$ ,  $|z| < 2$ . Dica: Reduza a um problema de duas incógnitas e use recursos gráficos para aproximar as raízes na região.

**E 5.1.17.** Considere o seguinte sistema de equações não-lineares:

$$\begin{aligned} x_1 - x_2 &= 0 \\ -x_{j-1} + 5(x_j + x_j^3) - x_{j+1} &= 10 \exp(-j/3), \quad 2 \leq j \leq 10 \\ x_{11} &= 1 \end{aligned} \tag{5.2}$$

a) Escreva este sistema na forma  $F(x) = 0$  onde  $x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_{11} \end{bmatrix}$  e calcule analiticamente a matriz jacobiana  $\frac{\partial(F_1, \dots, F_{11})}{\partial(x_1, \dots, x_{11})}$ . Dica: Use a regularidade nas expressões para abreviar a notação.

b) Construa a iteração para encontrar a única solução deste problema pelo método de Newton e, usando esse método, encontre uma solução aproximada com erro absoluto inferior a  $10^{-4}$ .

**E 5.1.18.** Considere a função

$$f(x, y) = \frac{e^{-(x-1)^2 - (y-2)^2}}{1 + x^2 + y^2}$$

a) Encontre o valor máximo desta função.

b) Usando multiplicadores de Lagrange, encontre o valor máximo desta função restrito à condição

$$(x - 1)^2 + (y - 2)^2 = 1.$$

c) Parametrize a circunferência para transformar o problema de máximo com restrição em um problema de uma única variável. Resolva usando as técnicas de equações lineares de uma variável.



## 5.2 Linearização de uma função de várias variáveis

Nesta seção, discutimos de forma distinta e mais rigorosa os conceitos de matriz jacobiana e linearização de uma função de várias variáveis.

### 5.2.1 Gradiente

Considere primeiramente uma função  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ , ou seja, uma função que mapeia  $n$  variáveis reais em um único real, por exemplo:

$$f(x) = x_1^2 + x_2^2/4$$

Para construirmos a linearização, fixemos uma direção no espaço  $\mathbb{R}^n$ , ou seja, um vetor  $v$ :

$$v = [v_1, v_2, \dots, v_n]^T$$

Queremos estudar como a função  $f(x)$  varia quando “andamos” na direção  $v$  a partir do ponto  $x^{(0)}$ . Para tal, inserimos um parâmetro real pequeno  $h$ , dizemos que

$$x = x^{(0)} + hv$$

e definimos a função auxiliar

$$g(h) = f(x^{(0)} + hv).$$

Observamos que a função  $g(h)$  é uma função de  $\mathbb{R}$  em  $\mathbb{R}$ .

A linearização de  $g(h)$  em torno de  $h = 0$  é dada por

$$g(h) = g(0) + hg'(0) + O(h^2)$$

Observamos que  $g(h) = f(x^{(0)} + hv)$  e  $g(0) = f(x^{(0)})$ . Precisamos calcular  $g'(0)$ :

$$g'(h) = \frac{d}{dh}g(h) = \frac{d}{dh}f(x^{(0)} + hv).$$

Pela regra da cadeia temos:

$$\frac{d}{dh}f(x^{(0)} + hv) = \sum_{j=1}^n \frac{\partial f}{\partial x_j} \frac{dx_j}{dh}.$$

Observamos que  $x_j = x_j^{(0)} + hv_j$ , portanto

$$\frac{dx_j}{dh} = v_j$$

Assim:

$$\frac{d}{dh}f(x^{(0)} + hv) = \sum_{j=1}^n \frac{\partial f}{\partial x_j} v_j.$$

Observamos que esta expressão pode ser vista como o produto interno entre o gradiente de  $f$  e o vetor  $v$ :

$$\nabla f = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix} \quad v = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix}$$

Na notação cálculo vetorial escrevemos este produto interno como  $\nabla f \cdot v = v \cdot \nabla f$  na notação de produto matricial, escrevemos  $(\nabla f)^T v = v^T \nabla f$ . Esta quantidade é conhecida como **derivada direcional** de  $f$  no ponto  $x^{(0)}$  na direção  $v$ , sobretudo quando  $\|v\| = 1$ .

Podemos escrever a linearização  $g(h) = g(0) + hg'(0) + O(h^2)$  como

$$f(x^{(0)} + hv) = f(x^{(0)}) + h \nabla^T f(x^{(0)}) v + O(h^2)$$

Finalmente, escrevemos  $x = x^{(0)} + hv$ , ou seja,  $hv = x - x^{(0)}$

$$f(x) = f(x^{(0)}) + \nabla^T f(x^{(0)}) (x - x^{(0)}) + O(\|x - x^{(0)}\|^2)$$

**Observação 5.2.1.** Observe a semelhança com a linearização no caso em uma dimensão. A notação  $\nabla^T f(x^{(0)})$  é o transposto do vetor gradiente associado à função  $f(x)$  no ponto  $x^{(0)}$ :

$$\nabla^T f(x^{(0)}) = \left[ \frac{\partial f(x^{(0)})}{\partial x_1}, \frac{\partial f(x^{(0)})}{\partial x_2}, \dots, \frac{\partial f(x^{(0)})}{\partial x_n} \right]$$

## 5.2.2 Matriz jacobiana

Interessamo-nos, agora, pela linearização da função  $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ . Lembramos que  $F(x)$  pode ser escrita como um vetor de funções  $f_j : \mathbb{R}^n \rightarrow \mathbb{R}$ :

$$F(x) = \begin{bmatrix} f_1(x) \\ f_2(x) \\ \vdots \\ f_n(x) \end{bmatrix}$$

Linearizando cada uma das funções  $f_j$ , temos:

$$F(x) = \underbrace{\begin{bmatrix} f_1(x^{(0)}) + \nabla^T f_1(x^{(0)}) (x - x^{(0)}) + O(\|x - x^{(0)}\|^2) \\ f_2(x^{(0)}) + \nabla^T f_2(x^{(0)}) (x - x^{(0)}) + O(\|x - x^{(0)}\|^2) \\ \vdots \\ f_n(x^{(0)}) + \nabla^T f_n(x^{(0)}) (x - x^{(0)}) + O(\|x - x^{(0)}\|^2) \end{bmatrix}}_{\text{Vetor coluna}}$$

ou, equivalentemente:

$$F(x) = \underbrace{\begin{bmatrix} f_1(x^{(0)}) \\ f_2(x^{(0)}) \\ \vdots \\ f_n(x^{(0)}) \end{bmatrix}}_{\text{Vetor coluna}} + \underbrace{\begin{bmatrix} \nabla^T f_1(x^{(0)}) \\ \nabla^T f_2(x^{(0)}) \\ \vdots \\ \nabla^T f_n(x^{(0)}) \end{bmatrix}}_{\text{Matriz jacobiana}} \underbrace{\left( \begin{bmatrix} x - x^{(0)} \end{bmatrix} + O(\|x - x^{(0)}\|^2) \right)}_{\text{Vetor coluna}}$$

Podemos escrever a linearização de  $F(x)$  na seguinte forma mais enxuta:

$$F(x) = F(x^{(0)}) + J_F(x^{(0)}) (x - x^{(0)}) + O(\|x - x^{(0)}\|^2)$$

A matriz jacobiana  $J_F$  é matriz cujas linhas são os gradientes transpostos de

$f_j$ , ou seja:

$$J_F = \frac{\partial(f_1, f_2, \dots, f_n)}{\partial(x_1, x_2, \dots, x_n)} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \dots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}$$

A matriz jacobiana de uma função ou simplesmente, o jacobiano de uma função  $F(x)$  é a matriz formada pelas suas derivadas parciais:

$$(J_F)_{ij} = \frac{\partial f_i}{\partial x_j}$$

**Exemplo 5.2.1.** Calcule a matriz jacobiana da função

$$F(x) = \begin{bmatrix} \frac{x_1^2}{3} + x_2^2 - 1 \\ x_1^2 + \frac{x_2^2}{4} - 1 \end{bmatrix}$$

$$J_F = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{bmatrix} = \begin{bmatrix} \frac{2x_1}{3} & 2x_2 \\ 2x_1 & \frac{x_2}{2} \end{bmatrix}$$

# Capítulo 6

## Interpolação

Neste capítulo, discutimos sobre problemas de **interpolação**. Mais precisamente, dada uma sequência de  $n$  reais  $x_1 < x_2 < \dots < x_n$ , um conjunto de pontos  $\{(x_i, y_i) \in I \times \mathbb{R}\}_{i=1}^n$ , onde  $I = [x_1, x_n]$  e uma família de funções  $\mathcal{F}_I = \{\varphi : I \rightarrow \mathbb{R}\}$ , o problema de interpolação consiste em encontrar alguma função  $f \in \mathcal{F}_I$  tal que

$$f(x_i) = y_i, \quad i = 1, 2, \dots, n.$$

Chamamos uma tal  $f$  de **função interpoladora** dos pontos dados. Ou ainda, dizemos que  $f$  interpola os pontos dados.

**Exemplo 6.0.2.** Um dos problemas de interpolação mais simples é o de entrar a equação da reta que passa por dois pontos dados. Por exemplo, sejam dados o conjunto de pontos  $\{(1, 1), (2, 2)\}$  e a família de funções  $\mathcal{F}_{[1,2]}$ :

$$\mathcal{F}_{[1,2]} = \{f : [1,2] \rightarrow \mathbb{R} \mid [1,2] \ni x \mapsto f(x) = a + bx; a, b \in \mathbb{R}\}.$$

Para que uma  $f$  na família seja a função interpoladora do conjunto de pontos dados, precisamos que

$$\begin{array}{ll} a + bx_1 = y_1 & \text{isto é} \quad a + b = 1 \\ a + bx_2 = y_2 & a + 2b = 2 \end{array}$$

o que nos fornece  $a = 0$  e  $b = 1$ . Então, a função interpoladora  $f$  é tal que  $f(x) = x$  para um  $x \in [1,2]$ . Os pontos e a reta interpolada estão esboçados na figura 6.1.

Um problema de interpolação cuja a família de funções constitui-se de polinômios é chamado de problema de interpolação polinomial.



Figura 6.1: Exemplo de interpolação de dois pontos por uma reta, veja o exemplo 6.0.2.

## 6.1 Interpolação polinomial

Interpolação polinomial é um caso particular do problema geral de interpolação, no qual a família de funções é constituída de polinômios. A escolha de polinômios como funções interpolantes é natural por diversos motivos: se  $p$  é um polinômio de grau  $n$ , o valor  $p(x)$  para um  $x$  real é calculado através de  $n + 1$  operações de multiplicação e  $n + 1$  operações de soma<sup>1</sup>; derivadas e primitivas de polinômios são também polinômios cuja relação algébrica com o original é simples; e finalmente o teorema da Aproximação de Weierstrass, segundo o qual, qualquer função contínua definida em um intervalo fechado pode ser aproximada uniformemente por um polinômio tão bem quanto se queira.

**Teorema 6.1.1** (Weierstrass). *Seja  $f$  uma função contínua definida no intervalo fechado  $[a,b]$  e seja  $\delta$  um número positivo. Então existe um polinômio  $p$ , tal que para todo  $x \in [a,b]$ ,*

$$|f(x) - p(x)| < \delta.$$

<sup>1</sup>Essa forma de calcular o valor de  $p(x)$  é denominada algoritmo de Horner<sup>2</sup>. Dado um polinômio  $p$  de grau  $n$  da forma

$$p(x) = \sum_{k=0}^n a_k x^k,$$

é possível reescrevê-lo como a sequência de operações dada por

$$a_0 + x(a_1 + x(a_2 + x(\dots + x(a_{n-1} + xa_n) \dots))).$$

O que requer  $n + 1$  operações de multiplicação e  $n + 1$  operações de soma.

Para o problema ser bem determinado é necessário restringirmos o grau dos polinômios.

Observe que para o problema ser bem determinado, é necessário restringirmos o grau dos polinômios. Dado um conjunto de  $n$  pontos a serem interpolados  $\{(x_i, y_i)\}_{i=1}^n$ ,  $x_i \neq x_j$  para  $i \neq j$ , a família de polinômios  $\mathcal{F} = \mathbb{P}_{n-1}$  deve ser escolhida, onde:

$$\mathbb{P}_{n-1} := \left\{ p : x \mapsto p(x) = \sum_{k=0}^{n-1} a_k x^k; \{a_0, a_1, \dots, a_{n-1}\} \in \mathbb{R} \right\},$$

isto é, a família dos polinômios reais de grau menor ou igual a  $n - 1$ .

O exemplo 6.0.2 discute um dos casos mais simples de interpolação polinomial, o qual consiste em interpolar uma reta por dois pontos. Neste caso, a família de funções consiste de polinômios de grau 1. Se buscarmos interpolar uma parábola pelos dois pontos dados, o problema fica subdeterminado, pois existem infinitas parábolas que passam por dois pontos dados. Além disso, se buscarmos interpolar uma reta por três pontos dados, o problema estaria sobredeterminado e poderia não ter solução se os pontos não fossem colineares. Veja o exercício 6.1.3.

Assim, dado um conjunto com  $n$  pontos  $\{(x_i, y_i)\}_{i=1}^n$ , chamamos de **polinômio interpolador** o polinômio de grau menor ou igual a  $n - 1$  que os interpola.




Figura 6.2: Polinômio interpolador do conjunto de pontos  $\{(0, 1), (1, 6), (2, 5), (3, -8)\}$ . Veja o exemplo 6.1.1.

**Exemplo 6.1.1.** Encontre o polinômio interpolador do conjunto de pontos  $\{(0, 1), (1, 6), (2, 5), (3, -8)\}$ .

$$p(x) = a_0 + a_1x + a_2x^2 + a_3x^3.$$
$$\begin{array}{rcl} a_0 & & = 1 \\ a_0 + a_1 + a_2 + a_3 & = & 6 \\ a_0 + 2a_1 + 4a_2 + 8a_3 & = & 5 \\ a_0 + 3a_1 + 9a_2 + 27a_3 & = & -8 \end{array}$$

No **Scilab**, podemos encontrar o polinômio interpolador e esboçar seu gráfico com os seguintes comandos:

```
-->xi = [0 1 2 3]';
-->yi = [1 6 5 -8]';
-->A = [xi.^0 xi.^1 xi.^2 xi.^3];
-->a = A\yi;
-->p = poly(a,'x','c')
p =
        3
    1 + 6x - x
-->xx = linspace(-0.5,3.25);
-->plot(xi,yi,'ro',xx,horner(p,xx),'b-');xgrid
```



*Demonstração.* Observe que o problema de encontrar os coeficientes  $a_0, a_1, \dots, a_{n-1}$  do polinômio

$$p(x) = a_0 + a_1x + a_2x^2 + \cdots a_{n-1}x^{n-1} = \sum_{k=0}^{n-1} a_kx^k$$

tal que  $p(x_i) = y_i$  é equivalente a resolver o sistema linear com  $n$  equações e  $n$



incógnitas dado por

$$\begin{aligned} a_0 + a_1x_1 + a_1x_1^2 + \cdots + a_{n-1}x_1^{n-1} &= y_1, \\ a_0 + a_1x_2 + a_2x_2^2 + \cdots + a_{n-1}x_2^{n-1} &= y_2, \\ &\vdots \\ a_0 + a_1x_n + a_2x_n^2 + \cdots + a_{n-1}x_n^{n-1} &= y_n. \end{aligned}$$

O qual pode ser escrito na forma matricial como

$$\begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^{n-1} \\ 1 & x_2 & x_2^2 & \cdots & x_2^{n-1} \\ 1 & x_3 & x_3^2 & \cdots & x_3^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^{n-1} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_{n-1} \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix}$$

A matriz envolvida é uma **matriz de Vandermonde**<sup>3</sup> de ordem  $n$  cujo determinante é dado pelo produtório duplo

$$\prod_{1 \leq i < j \leq n} (x_j - x_i)$$

É fácil ver que se as abscissas são diferentes dois a dois, então o determinante é não nulo. Disto decorre que a matriz envolvida é inversível e, portanto, o sistema possui uma solução que é única.  $\square$

Esta abordagem direta que usamos no exemplo 6.1.1 e na demonstração do teorema 6.1.2 se mostra ineficiente quando o número de pontos é grande e quando existe grande variação nas abscissas. Neste caso, a matriz de Vandermonde é mal condicionada (ver [6]), o que acarreta um aumento dos erros de arredondamento na solução do sistema.

Uma maneira de resolver este problema é escrever o polinômio em uma base que produza um sistema bem condicionado.

## Exercícios

**E 6.1.1.** Encontre o polinômio interpolador para o conjunto de pontos  $\{(-2, -47), (0, -3), (1, 4), (2, 41)\}$ . Então, faça um gráfico com os pontos e o polinômio interpolador encontrado.

<sup>3</sup>Alexandre-Théophile Vandermonde, 1735 - 1796, matemático francês.

**E 6.1.2.** Encontre o polinômio interpolador para o conjunto de pontos  $\{(-1, 1,25), (0,5, 0,5), (1, 1,25), (1,25, 1,8125)\}$ .

**E 6.1.3.** Mostre que:

- a) Existem infinitas parábolas que interpolam dois pontos dados  $\{(x_1, y_1), (x_2, y_2)\}$ , com  $x_1 \neq x_2$ .
- b) Não existe reta que interpola os pontos  $\{(1, 1), (2, 2,1), (3, 3)\}$ .
- c) Não existe parábola de equação  $y = a_0 + a_1x + a_2x^2$  que interpola dois pontos dados  $\{(x_1, y_1), (x_1, y_2)\}$ , com  $y_1 \neq y_2$ . Mas, existem infinitas parábolas de equação  $x = a_0 + a_1y + a_2y^2$  que interpolam estes pontos.

## 6.2 Diferenças divididas de Newton

Dado um conjunto com  $n$  pontos  $\{(x_i, y_i)\}_{i=1}^n$ , o **método das diferenças divididas de Newton** consiste em construir o polinômio interpolador da forma

$$\begin{aligned} p(x) &= a_1 + a_2(x - x_1) + a_3(x - x_1)(x - x_2) + \cdots \\ &+ a_n(x - x_1)(x - x_2) \cdots (x - x_{n-1}). \end{aligned}$$

Como  $p(x_i) = y_i$ ,  $i = 1, 2, \dots, n$ , os coeficientes  $a_i$  satisfazem o seguinte sistema triangular inferior:

$$\begin{aligned} a_1 &= y_1 \\ a_1 + a_2(x_2 - x_1) &= y_2 \\ a_1 + a_2(x_3 - x_1) + a_3(x_3 - x_1)(x_3 - x_2) &= y_3 \\ &\vdots \\ a_1 + a_2(x_n - x_1) + \cdots + a_n(x_n - x_1) \cdots (x_n - x_{n-1}) &= y_n \end{aligned}$$

Resolvendo de cima para baixo, obtemos

$$\begin{aligned} a_1 &= y_1 \\ a_2 &= \frac{y_2 - a_1}{x_2 - x_1} = \frac{y_2 - y_1}{x_2 - x_1} \\ a_3 &= \frac{y_3 - a_2(x_3 - x_1) - a_1}{(x_3 - x_1)(x_3 - x_2)} = \frac{\frac{y_3 - y_2}{(x_3 - x_2)} - \frac{y_2 - y_1}{(x_2 - x_1)}}{(x_3 - x_1)} \\ &\dots \end{aligned}$$

Tabela 6.1: Esquema de diferenças divididas para um conjunto com três pontos  $\{(x_i, y_i)\}_{i=1}^3$ .

$j$	$x_j$	$f[x_j]$	$f[x_{j-1}, x_j]$	$f[x_{j-2}, x_{j-1}, x_j]$
1	$x_1$	$f[x_1] = y_1$		
			$f[x_1, x_2] = \frac{f[x_2] - f[x_1]}{x_2 - x_1}$	
2	$x_2$	$f[x_2] = y_2$		$f[x_1, x_2, x_3] = \frac{f[x_2, x_3] - f[x_1, x_2]}{x_3 - x_1}$
			$f[x_2, x_3] = \frac{f[x_3] - f[x_2]}{x_3 - x_2}$	
3	$x_2$	$f[x_2] = y_2$		

Note que os coeficientes são obtidos por diferenças das ordenadas divididas por diferenças das abscissas dos pontos dados. Para vermos isso mais claramente, introduzimos a seguinte notação:

$$\begin{aligned}
f[x_j] &:= y_j \\
f[x_j, x_{j+1}] &:= \frac{f[x_{j+1}] - f[x_j]}{x_{j+1} - x_j} \\
f[x_j, x_{j+1}, x_{j+2}] &:= \frac{f[x_{j+1}, x_{j+2}] - f[x_j, x_{j+1}]}{x_{j+2} - x_j} \\
&\vdots \\
f[x_j, x_{j+1}, \dots, x_{j+k}] &:= \frac{f[x_{j+1}, x_{j+2}, \dots, x_{j+k}] - f[x_j, x_{j+1}, \dots, x_{j+k-1}]}{x_{j+k} - x_j}
\end{aligned}$$

Chamamos  $f[x_j]$  de diferença dividida de ordem zero (ou primeira diferença dividida),  $f[x_i, x_j + 1]$  de diferença dividida de ordem 1 (ou segunda diferença dividida) e assim por diante.

Uma inspeção cuidadosa dos coeficientes obtidos em (6.2) nos mostra que

$$a_k = f[x_1, x_2, \dots, x_k]$$

Isto nos permite esquematizar o método conforme apresentado na tabela 6.1.

**Exemplo 6.2.1.** Use o método de diferenças divididas para encontrar o polinômio que passe pelos pontos  $(-1, 3), (0, 1), (1, 3), (3, 43)$ .

**Solução.** Usando o esquema apresentado na tabela 6.1, obtemos

$j$	$x_j$	$f[x_j]$	$f[x_{j-1}, x_j]$	$f[x_{j-2}, x_{j-1}, x_j]$	$f[x_{j-3}, x_{j-2}, x_{j-1}, x_j]$
1	-1	<b>3</b>			
			$\frac{1-3}{0-(-1)} = -2$		
2	0	1		$\frac{2-(-2)}{1-(-1)} = 2$	
			$\frac{3-1}{1-0} = 2$		$\frac{6-2}{3-(-1)} = 1$
3	1	3		$\frac{20-2}{3-0} = 6$	
			$\frac{43-3}{3-1} = 20$		
4	3	43			

Portanto, o polinômio interpolador do conjunto de pontos dados é

$$p(x) = 3 - 2(x+1) + 2(x+1)x + (x+1)x(x-1)$$

ou, equivalentemente,  $p(x) = x^3 + 2x^2 - x + 1$ .

◇

## 6.3 Polinômios de Lagrange

Outra maneira clássica de resolver o problema da interpolação polinomial é através dos polinômios de Lagrange. Dado um conjunto de pontos  $\{x_j\}_{j=1}^n$  distintos dois a dois, definimos os polinômios de Lagrange como os polinômios de grau  $n-1$  que satisfazem

$$L_k(x_j) = \begin{cases} 1, & \text{se } k = j \\ 0, & \text{se } k \neq j \end{cases}$$

Assim, o polinômio  $p(x)$  de grau  $n-1$  que interpola os pontos dados, i.e.  $p(x_j) = y_j, j = 1, \dots, n$  é dado por

$$p(x) = y_1 L_1(x) + y_2 L_2(x) + \dots + y_n L_n(x) = \sum_{k=1}^n y_k L_k(x).$$

Para construir os polinômios de Lagrange, podemos analisar a sua forma fatorada, ou seja:

$$L_k(x) = c_k \prod_{\substack{j=1 \\ j \neq k}}^n (x - x_j)$$

onde o coeficiente  $c_k$  é obtido da condição  $L_k(x_k) = 1$ :

$$L_k(x_k) = c_k \prod_{\substack{j=1 \\ j \neq i}}^n (x_k - x_j) \implies c_k = \frac{1}{\prod_{\substack{j=1 \\ j \neq i}}^n (x_k - x_j)}$$

Portanto,

$$L_k(x) = \prod_{\substack{j=1 \\ j \neq i}}^n \frac{(x - x_j)}{(x_k - x_j)}$$

**Observação 6.3.1.** O problema de interpolação quando escrito usando como base os polinômios de Lagrange produz um sistema linear diagonal.

**Exemplo 6.3.1.** Encontre o polinômio da forma  $p(x) = a_1 + a_2x + a_3x^2 + a_4x^3$  que passa pelos pontos  $(0, 0)$ ,  $(1, 1)$ ,  $(2, 4)$ ,  $(3, 9)$ .

**Solução.** Escrevemos:

$$\begin{aligned} L_1(x) &= \frac{(x-1)(x-2)(x-3)}{(0-1)(0-2)(0-3)} = -\frac{1}{6}x^3 + x^2 - \frac{11}{6}x + 1 \\ L_2(x) &= \frac{x(x-2)(x-3)}{1(1-2)(1-3)} = \frac{1}{2}x^3 - \frac{5}{2}x^2 + 3x \\ L_3(x) &= \frac{x(x-1)(x-3)}{2(2-1)(2-3)} = -\frac{1}{2}x^3 + 2x^2 - \frac{3}{2}x \\ L_4(x) &= \frac{x(x-1)(x-2)}{3(3-1)(3-2)} = \frac{1}{6}x^3 - \frac{1}{2}x^2 + \frac{1}{3}x \end{aligned}$$

Assim, temos:

$$P(x) = 0 \cdot L_1(x) + 1 \cdot L_2(x) + 4 \cdot L_3(x) + 9 \cdot L_4(x) = x^2$$

$$p(x) = 0 \cdot L_1(x) + 1 \cdot L_2(x) + 0 \cdot L_3(x) + 1 \cdot L_4(x) = \frac{2}{3}x^3 - 3x^2 + \frac{10}{3}x.$$

◇

## 6.4 Aproximação de funções reais por polinômios interpoladores

**Teorema 6.4.1.** Dados  $n + 1$  pontos distintos,  $x_0, x_1, \dots, x_n$ , dentro de um intervalo  $[a, b]$  e uma função  $f$  com  $n + 1$  derivadas contínuas nesse intervalo

( $f \in C^{n+1}[a,b]$ ), então para cada  $x$  em  $[a,b]$ , existe um número  $\xi(x)$  em  $(a,b)$  tal que

$$f(x) = P(x) + \frac{f^{(n+1)}(\xi(x))}{(n+1)!} (x-x_0)(x-x_1) \cdots (x-x_n),$$

onde  $P(x)$  é o polinômio interpolador. Em especial, pode-se dizer que

$$|f(x) - P(x)| \leq \frac{M}{(n+1)!} |(x-x_0)(x-x_1) \cdots (x-x_n)|,$$

onde

$$M = \max_{x \in [a,b]} |f^{(n+1)}(\xi(x))|$$

**Exemplo 6.4.1.** Considere a função  $f(x) = \cos(x)$  e o polinômio  $P(x)$  de grau 2 tal que  $P(0) = \cos(0) = 1$ ,  $P(\frac{1}{2}) = \cos(\frac{1}{2})$  e  $P(1) = \cos(1)$ . Use a fórmula de Lagrange para encontrar  $P(x)$ . Encontre o erro máximo que se assume ao aproximar o valor de  $\cos(x)$  pelo de  $P(x)$  no intervalo  $[0,1]$ . Trace os gráficos de  $f(x)$  e  $P(x)$  no intervalo  $[0,1]$  no mesmo plano cartesiano e, depois, trace o gráfico da diferença  $\cos(x) - P(x)$ . Encontre o erro efetivo máximo  $|\cos(x) - P(x)|$ .

**Solução.** Usando polinômios de Lagrange, obtemos

$$\begin{aligned} P(x) &= 1 \frac{(x - \frac{1}{2})(x - 1)}{(0 - \frac{1}{2})(0 - 1)} \\ &+ \cos\left(\frac{1}{2}\right) \frac{(x - 0)(x - 1)}{(\frac{1}{2} - 0)(\frac{1}{2} - 1)} \\ &+ \cos(1) \frac{(x - 0)(x - \frac{1}{2})}{(1 - 0)(1 - \frac{1}{2})} \\ &\approx 1 - 0,0299720583066x - 0,4297256358252x^2 \end{aligned}$$

No Scilab, podemos computar o polinômio interpolador da seguinte forma:

```
L1=poly([.5 1], 'x'); L1=L1/horner(L1,0)
L2=poly([0 1], 'x'); L2=L2/horner(L2,0.5)
L3=poly([0 .5], 'x'); L3=L3/horner(L3,1)
P=L1+cos(.5)*L2+cos(1)*L3
x=[0:.05:1]
plot(x,cos)
plot(x,horner(P,x), 'red')
plot(x,horner(P,x)-cos(x))
```

Para encontrar o erro máximo, precisamos estimar  $|f'''(x)| = |\sin(x)| \leq \sin(1) < 0,85$  e

$$\max_{x \in [0,1]} \left| x \left( x - \frac{1}{2} \right) (x - 1) \right|$$

O polinômio de grau três  $Q(x) = x \left( x - \frac{1}{2} \right) (x - 1)$  tem um mínimo (negativo) em  $x_1 = \frac{3+\sqrt{3}}{6}$  e um máximo (positivo) em  $x_2 = \frac{3-\sqrt{3}}{6}$ . Logo:

$$\max_{x \in [0,1]} \left| x \left( x - \frac{1}{2} \right) (x - 1) \right| \leq \max\{|Q(x_1)|, |Q(x_2)|\} \approx 0,0481125.$$

Portanto:

$$|f(x) - P(x)| < \frac{0,85}{3!} 0,0481125 \approx 0,0068159 < 7 \cdot 10^{-3}$$

Para encontrar o erro efetivo máximo, basta encontrar o máximo de  $|P(x) - \cos(x)|$ . O mínimo (negativo) de  $P(x) - \cos(x)$  acontece em  $x_1 = 4,29 \cdot 10^{-3}$  e o máximo (positivo) acontece em  $x_2 = 3,29 \cdot 10^{-3}$ . Portanto, o erro máximo efetivo é  $4,29 \cdot 10^{-3}$ .  $\diamond$

**Exemplo 6.4.2.** Considere o problema de aproximar o valor da integral  $\int_0^1 f(x)dx$  pelo valor da integral do polinômio  $P(x)$  que coincide com  $f(x)$  nos pontos  $x_0 = 0$ ,  $x_1 = \frac{1}{2}$  e  $x_2 = 1$ . Use a fórmula de Lagrange para encontrar  $P(x)$ . Obtenha o valor de  $\int_0^1 f(x)dx$  e encontre uma expressão para o erro de truncamento.

O polinômio interpolador de  $f(x)$  é

$$\begin{aligned} P(x) &= f(0) \frac{(x - \frac{1}{2})(x - 1)}{(0 - \frac{1}{2})(0 - 1)} + f\left(\frac{1}{2}\right) \frac{(x - 0)(x - 1)}{(\frac{1}{2} - 0)(\frac{1}{2} - 1)} + f(1) \frac{(x - 0)(x - \frac{1}{2})}{(1 - 0)(1 - \frac{1}{2})} \\ &= f(0)(2x^2 - 3x + 1) + f\left(\frac{1}{2}\right)(-4x^2 + 4x) + f(1)(2x^2 - x) \end{aligned}$$

e a integral de  $P(x)$  é:

$$\begin{aligned} \int_0^1 P(x)dx &= \left[ f(0) \left( \frac{2}{3}x^3 - \frac{3}{2}x^2 + x \right) \right]_0^1 + \left[ f\left(\frac{1}{2}\right) \left( -\frac{4}{3}x^3 + 2x^2 \right) \right]_0^1 \\ &\quad + \left[ f(1) \left( \frac{2}{3}x^3 - \frac{1}{2}x^2 \right) \right]_0^1 \\ &= f(0) \left( \frac{2}{3} - \frac{3}{2} + 1 \right) + f\left(\frac{1}{2}\right) \left( -\frac{4}{3} + 2 \right) + f(1) \left( \frac{2}{3} - \frac{1}{2} \right) \\ &= \frac{1}{6}f(0) + \frac{2}{3}f\left(\frac{1}{2}\right) + \frac{1}{6}f(1) \end{aligned}$$

Para fazer a estimativa de erro usando o teorema 6.4.1 e temos

$$\begin{aligned}
 \left| \int_0^1 f(x)dx - \int_0^1 P(x)dx \right| &= \left| \int_0^1 f(x) - P(x)dx \right| \\
 &\leq \int_0^1 |f(x) - P(x)|dx \\
 &\leq \frac{M}{6} \int_0^1 \left| x \left( x - \frac{1}{2} \right) (x - 1) \right| dx \\
 &= \frac{M}{6} \left[ \int_0^{1/2} x \left( x - \frac{1}{2} \right) (x - 1) dx \right. \\
 &\quad \left. - \int_{1/2}^1 x \left( x - \frac{1}{2} \right) (x - 1) dx \right] \\
 &= \frac{M}{6} \left[ \frac{1}{64} - \left( -\frac{1}{64} \right) \right] = \frac{M}{192}.
 \end{aligned}$$

Lembramos que  $M = \max_{x \in [0,1]} |f'''(x)|$ .

**Observação 6.4.1.** Existem estimativas melhores para o erro de truncamento para este esquema de integração numérica. Veremos com mais detalhes tais esquemas na teoria de integração numérica.

**Exemplo 6.4.3.** Use o resultado do exemplo anterior para aproximar o valor das seguintes integrais:

a)  $\int_0^1 \ln(x+1)dx$

b)  $\int_0^1 e^{-x^2}dx$

**Solução.** Usando a fórmula obtida, temos que

$$\begin{aligned}
 \int_0^1 \ln(x+1)dx &\approx 0,39 \pm \frac{1}{96} \\
 \int_0^1 e^{-x^2}dx &\approx 0,75 \pm \frac{3,87}{192}
 \end{aligned}$$

◇

## Exercícios

**E 6.4.1.** Use as mesmas técnicas usadas o resultado do exemplo 6.4.2 para obter uma aproximação do valor de:

$$\int_0^1 f(x)dx$$

através do polinômio interpolador que coincide com  $f(x)$  nos pontos  $x = 0$  e  $x = 1$ .



## 6.5 Interpolação linear segmentada

Considere o conjunto  $(x_i, y_i)_{i=1}^n$  de  $n$  pontos. Assumiremos que  $x_{i+1} > x_i$ , ou seja, as abscissas são distintas e estão em ordem crescente. A função linear que interpola os pontos  $x_i$  e  $x_{i+1}$  no intervalo  $i$  é dada por

$$P_i(x) = y_i \frac{(x_{i+1} - x)}{(x_{i+1} - x_i)} + y_{i+1} \frac{(x - x_i)}{(x_{i+1} - x_i)}$$

O resultado da interpolação linear segmentada é a seguinte função contínua definida por partes no intervalo  $[x_1, x_n]$ :

$$f(x) = P_i(x), \quad x \in [x_i, x_{i+1}]$$

**Exemplo 6.5.1.** Construa uma função linear por partes que interpola os pontos  $(0,0)$ ,  $(1,4)$ ,  $(2,3)$ ,  $(3,0)$ ,  $(4,2)$ ,  $(5,0)$ .

A função procurada pode ser construída da seguinte forma:

$$f(x) = \begin{cases} 0 \frac{x-1}{0-1} + 1 \frac{x-0}{1-0} & , 0 \leq x < 1 \\ 4 \frac{x-2}{1-2} + 3 \frac{x-1}{2-1} & , 1 \leq x < 2 \\ 3 \frac{x-3}{2-3} + 0 \frac{x-2}{3-2} & , 2 \leq x \leq 3 \end{cases}$$

Simplificando, obtemos:

$$f(x) = \begin{cases} x & , 0 \leq x < 1 \\ -x + 5 & , 1 \leq x < 2 \\ -3x + 9 & , 2 \leq x \leq 3 \end{cases}$$

A figura 6.3 é um esboço da função  $f(x)$  obtida.

Ela foi gerada no Scilab usando os comandos:

```
//pontos fornecidos
xi = [0;1;2;3;4;5]
yi = [0;4;3;0;2;0]
//numero de pontos
n = 6
//funcao interpoladora
function [y] = f(x)
  for i=1:n-2
    if ((x>=xi(i)) & (x<xi(i+1))) then
```

```

        y = yi(i)*(x-xi(i+1))/(xi(i) - xi(i+1)) ...
            + yi(i+1)*(x-xi(i))/(xi(i+1) - xi(i));
    end
end

if ((x>=xi(n-1)) & (x<=xi(n))) then
    y = yi(n-1)*(x-xi(n))/(xi(n-1) - xi(n)) ...
        + yi(n)*(x-xi(n-1))/(xi(n) - xi(n-1));
end
endfunction
//graficando
xx = linspace(xi(1),xi(n),500)';
clear yy
for i=1:max(size(xx))
    yy(i) = f(xx(i))
end
plot(xi,yi,'r.',xx,yy,'b-')

```




Figura 6.3: Interpolação linear segmentada.

## 6.6 Interpolação cúbica segmentada - spline

A ideia empregada na interpolação linear segmentada pode ser estendida através da utilização de polinômios de grau superior. A escolha de polinômios de grau superior implica uma maior liberdade (há um número maior de coeficientes) na construção da interpolação. Parte dessa liberdade pode ser utilizada na exigência de suavidade para a interpolação.

**Definição 6.6.1** (spline de ordem  $m$ ). *Dado um conjunto de  $n$  pontos  $\mathcal{I} = \{(x_j, y_j)\}_{j=1}^n$  tais que  $x_{j+1} > x_j$ , ou seja, as abscissas são distintas e estão em ordem crescente; um spline de ordem  $m$  que interpola estes pontos é uma função  $s$  com as seguintes propriedades:*

- i) Em cada intervalo  $[x_j, x_{j+1})$ ,  $j = 1, 2, \dots, n-2$  e no segmento  $[x_{n-1}, x_n]$   $s$  é um polinômio de grau menor ou igual a  $m$ ;*
- ii) Em algum dos intervalos  $s$  é um polinômio de grau  $m$ ;*
- iii) Em cada  $x_j \in \mathcal{I}$ ,  $s(x_j) = y_j$ , isto é, o spline interpola os pontos dados;*
- iv)  $s$  é uma função de classe  $\mathcal{C}^{m-1}$ , isto é, é função  $m-1$  vezes continuamente diferenciável.*

São  $n-1$  intervalos e em cada um deles há  $m+1$  coeficientes a se determinar. As condições *iii* e *iv* impostas pela definição correspondem respectivamente a  $n$  e  $m(n-2)$  equações. Estas últimas, se devem à exigência de continuidade nos pontos internos, ou seja, os pontos de  $\mathcal{I}$  com índices  $j = 2, 3, \dots, n-1$ . Portanto, há  $m-1$  coeficientes a mais do que o número de equações e, à exceção do caso  $m = 1$  (interpolação linear segmentada), o problema é subdeterminado. Ou seja, uma vez fixada a ordem  $m > 1$ , existem infinitos splines de ordem  $m$  que interpolam os pontos do conjunto  $\mathcal{I}$ .

O caso  $m = 3$ , denominado spline cúbico, é de grande interesse pois reproduz o comportamento físico de réguas delgadas com estrutura elástica homogênea e perfil uniforme sujeitas aos vínculos representados pelos pontos do conjunto  $\mathcal{I}$ . A equação diferencial que rege o comportamento do perfil dessas réguas é um caso particular da equação da viga de Euler-Bernoulli. Neste caso, a equação tem a forma

$$\frac{d^4 y}{dx^4} = 0, \quad (6.1)$$

cujas soluções gerais são polinômios de grau 3.

Vamos supor que um spline cúbico que interpola o conjunto de pontos  $\mathcal{I}$  é conhecido. Como esse spline é uma função de classe  $\mathcal{C}^2$ , as suas derivadas nos pontos do conjunto  $\mathcal{I}$  são conhecidas também. Seja  $y'_j$ , o valor dessa derivada em  $x = x_j$ .

Agora, vamos considerar dois pares de pontos sucessivos de  $\mathcal{I}$ ,  $(x_j, y_j)$  e  $(x_{j+1}, y_{j+1})$ . A forma do spline cúbico no intervalo  $[x_j, x_{j+1})$  pode ser identificada com a solução da equação diferencial (6.1) no intervalo  $(x_j, x_{j+1})$  sujeita às condições de contorno

$$y(x_j) = y_j, \quad y'(x_j) = y'_j, \quad y(x_{j+1}) = y_{j+1} \quad \text{e} \quad y'(x_{j+1}) = y'_{j+1}.$$

A solução desse problema de contorno é escrita de modo conveniente como

$$s_j(x) = a_j + b_j(x - x_j) + c_j(x - x_j)^2 + d_j(x - x_j)^3,$$

onde as constantes  $a_j$ ,  $b_j$ ,  $c_j$  e  $d_j$  se relacionam às do problema de contorno. As duas primeiras seguem imediatamente das condições de contorno em  $x_j$ :

$$a_j = y_j \quad \text{e} \quad b_j = y'_j.$$

As duas últimas são obtidas pela solução do sistema de equações formado pelas condições de contorno em  $x_{j+1}$ :

$$c_j = 3 \frac{y_{j+1} - y_j}{(x_{j+1} - x_j)^2} - \frac{y'_{j+1} + 2y'_j}{x_{j+1} - x_j} \quad \text{e} \quad d_j = -2 \frac{y_{j+1} - y_j}{(x_{j+1} - x_j)^3} + \frac{y'_{j+1} + y'_j}{(x_{j+1} - x_j)^2}$$

Esta relação entre o conjunto de valores para a derivada de um spline cúbico  $\{y'_j\}_j = 1^n$  nos pontos de interpolação  $\mathcal{I}$  e os coeficientes dos polinômios em cada intervalo de interpolação pode ser resumida na seguinte proposição:

**Proposição 6.6.1.** *Seja  $s$  um spline cúbico que interpola o conjunto de pontos  $\mathcal{I} = \{(x_j, y_j)\}_{j=1}^n \subset \mathbb{R}^2$  tais que  $x_{j+1} > x_j$ . Se  $\{y'_j\}_{j=1}^n$  é o conjunto dos valores da derivada de  $s$  em  $x_j$ , então em cada intervalo  $[x_j, x_{j+1})$  (fechado também à direita quando  $j = n - 1$ ) o spline é igual a  $s_j$ :*

$$s_j(x) = a_j + b_j(x - x_j) + c_j(x - x_j)^2 + d_j(x - x_j)^3, \quad (6.2)$$

onde

$$\begin{aligned} a_j &= y_j, & c_j &= 3 \frac{y_{j+1} - y_j}{h_j^2} - \frac{y'_{j+1} + 2y'_j}{h_j}, \\ b_j &= y'_j, & d_j &= -2 \frac{y_{j+1} - y_j}{h_j^3} + \frac{y'_{j+1} + y'_j}{h_j^2} \end{aligned} \quad (6.3)$$

e

$$h_j = x_{j+1} - x_j, \quad j = 1, 2, \dots, n - 1 \quad (6.4)$$

é a distância entre as abscissas de dois pontos de interpolação consecutivos.

De acordo com a proposição anterior, toda informação sobre um spline cúbico é armazenada no conjunto  $\{(x_j, y_j, y'_j)\}_{j=1}^n$ . Por construção, uma função  $s$  definida a partir de (6.2), (6.3) e (6.4) com um conjunto  $\{(x_j, y_j, y'_j)\}_{j=1}^n \subset \mathbb{R}^3$ , onde  $x_{j+1} > x_j$  é de classe  $\mathcal{C}^1$  mas não necessariamente um spline cúbico. Para ser um spline cúbico, as derivadas  $\{y'_j\}_{j=1}^n$  devem garantir a continuidade da derivada segunda de  $s$  em todo intervalo  $(x_1, x_n)$ . Ou seja, devemos ter

$$\lim_{x \nearrow x_{j+1}} s''_j(x) = s''_{j+1}(x_{j+1})$$

em todos os pontos internos  $j = 1, 2, \dots, n-2$ . Em termos dos coeficientes dos polinômios cúbicos (6.2), a equação anterior assume a forma

$$2c_j + 6d_j h_j = 2c_{j+1}, \quad j = 1, 2, \dots, n-2.$$

Esta última equação e (6.3) permitem construir um sistema de equações lineares para as variáveis  $y'_j$ :

**Proposição 6.6.2.** *Dado o conjunto de pontos  $\mathcal{I} = \{(x_j, y_j)\}_{j=1}^n \subset \mathbb{R}^2$  tais que  $x_{j+1} > x_j$ , as derivadas de um spline cúbico que interpola os pontos  $\mathcal{I}$ ,  $y'_j$ ,  $j = 1, 2, \dots, n$  satisfazem o sistema de equações algébricas lineares*

$$h_j y'_{j-1} + 2(h_{j-1} + h_j) y'_j + h_{j-1} y'_{j+1} = 3 \left( h_j \frac{y_j - y_{j-1}}{h_{j-1}} + h_{j-1} \frac{y_{j+1} - y_j}{h_j} \right), \quad (6.5)$$

onde  $j = 2, 3, \dots, n-1$  e  $h_j = x_{j+1} - x_j$ .

O sistema de equações (6.5) é subdeterminado, são  $n$  variáveis e  $n-2$  equações. A inclusão de duas equações adicionais linearmente independentes das  $n-2$  equações (6.5) possibilita a existência de uma única solução. Tipicamente essas equações adicionais envolvem o comportamento do spline na fronteira ou na sua vizinhança. A seguir veremos quatro escolhas mais conhecidas.

### 6.6.1 Spline natural

Uma forma de definir as duas equações adicionais para completar o sistema (6.5) é impor condições de fronteira livres (ou naturais), ou seja,

$$s''(x_1) = s''(x_n) = 0. \quad (6.6)$$

De acordo com (6.2) essas equações implicam respectivamente

$$c_1 = 0 \quad \text{e} \quad 2c_{n-1} + 6d_{n-1}h_{n-1} = 0,$$

ou seja,

$$\begin{cases} 2y'_1 + y'_2 = 3 \frac{y_2 - y_1}{h_1} \\ y'_{n-1} + 2y'_n = 3 \frac{y_n - y_{n-1}}{h_{n-1}} \end{cases} \quad (6.7)$$

Essas duas equações em conjunto com as equações (6.5) formam um sistema de  $n$  equações algébricas lineares  $Ay' = z$ , onde

$$A = \begin{bmatrix} 2 & 1 & 0 & 0 & \cdots & 0 & 0 \\ h_2 & 2(h_1 + h_2) & h_1 & 0 & \cdots & 0 & 0 \\ 0 & h_3 & 2(h_2 + h_3) & h_2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & h_{n-1} & 2(h_{n-1} + h_{n-2}) & h_{n-2} \\ 0 & 0 & 0 & \cdots & 0 & 1 & 2 \end{bmatrix} \quad (6.8)$$

$$y' = \begin{bmatrix} y'_1 \\ y'_2 \\ \vdots \\ y'_n \end{bmatrix} \quad \text{e} \quad z = 3 \begin{bmatrix} \frac{y_2 - y_1}{h_1} \\ h_2 \frac{y_2 - y_1}{h_1} + h_1 \frac{y_3 - y_2}{h_2} \\ h_3 \frac{y_3 - y_2}{h_2} + h_2 \frac{y_4 - y_3}{h_3} \\ \vdots \\ h_{n-1} \frac{y_{n-1} - y_{n-2}}{h_{n-2}} + h_{n-2} \frac{y_n - y_{n-1}}{h_{n-1}} \\ \frac{y_n - y_{n-1}}{h_{n-1}} \end{bmatrix} \quad (6.9)$$

Observe que a matriz  $A$  é diagonal dominante estrita e, portanto, o sistema  $Ay' = z$  possui solução única. Calculado  $y'$ , os valores dos  $a_j$ ,  $b_j$ ,  $c_j$  e  $d_j$  são obtidos diretamente pelas expressões (6.3).

**Exemplo 6.6.1.** Construa um spline cúbico natural que passe pelos pontos  $(2, 4,5)$ ,  $(5, -1,9)$ ,  $(9, 0,5)$  e  $(12, -0,5)$ .

**Solução.** O spline desejado é uma função definida por partes da forma:

$$s(x) = \begin{cases} a_1 + b_1(x - 2) + c_1(x - 2)^2 + d_1(x - 2)^3 & , 2 \leq x < 5 \\ a_2 + b_2(x - 5) + c_2(x - 5)^2 + d_2(x - 5)^3 & , 5 \leq x < 9 \\ a_3 + b_3(x - 9) + c_3(x - 9)^2 + d_3(x - 9)^3 & , 9 \leq x \leq 12 \end{cases} \quad (6.10)$$

As variáveis  $y'_1, y'_2, y'_3$  e  $y'_4$  resolvem o sistema  $Ay' = z$ , onde

$$A = \begin{bmatrix} 2 & 1 & 0 & 0 \\ 4 & 2(4+3) & 3 & 0 \\ 0 & 3 & 2(3+4) & 4 \\ 0 & 0 & 1 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 1 & 0 & 0 \\ 4 & 14 & 3 & 0 \\ 0 & 3 & 14 & 4 \\ 0 & 0 & 1 & 2 \end{bmatrix},$$

$$y = \begin{bmatrix} y'_1 \\ y'_2 \\ y'_3 \\ y'_4 \end{bmatrix} \quad \text{e} \quad z = 3 \begin{bmatrix} \frac{1}{3}(-1,9 - 4,5) \\ \frac{4}{3}(-1,9 - 4,5) + \frac{3}{4}(0,5 - (-1,9)) \\ \frac{3}{4}(0,5 - (-1,9)) + \frac{4}{3}(-0,5 - (0,5)) \\ \frac{1}{3}(-0,5 - (0,5)) \end{bmatrix} = \begin{bmatrix} -6,4 \\ -20,2 \\ 1,4 \\ -1 \end{bmatrix}$$

A solução é  $y'_1 = -2,8\bar{3}$ ,  $y'_2 = -0,7\bar{3}$ ,  $y'_3 = 0,4\bar{6}$  e  $y'_4 = -0,7\bar{3}$ . Calculamos os coeficientes usando as expressões (6.3):

$$a_1 = y_1 = 4,5 \quad b_1 = y'_1 = -2,8\bar{3}$$

$$a_2 = y_2 = -1,9 \quad b_2 = y'_2 = -0,7\bar{3}$$

$$a_3 = y_3 = 0,5 \quad b_3 = y'_3 = 0,4\bar{6}$$

$$c_1 = 0 \quad d_1 = 0,0\bar{7}$$

$$c_2 = 0,7 \quad d_2 = -0,091\bar{6}$$

$$c_3 = -0,4 \quad d_3 = 0,0\bar{4}$$

Portanto:

$$S(x) = \begin{cases} 4,5 - 2,8\bar{3}(x-2) + 0,0\bar{7}(x-2)^3 & , 2 \leq x < 5 \\ -1,9 - 0,7\bar{3}(x-5) + 0,7(x-5)^2 - 0,091\bar{6}(x-5)^3 & , 5 \leq x < 9 \\ 0,5 + 0,4\bar{6}(x-9) - 0,4(x-9)^2 + 0,0\bar{4}(x-9)^3 & , 9 \leq x \leq 12 \end{cases}.$$

No Scilab, podemos utilizar:

```
xi = [2;5;9;12]
yi = [4.5;-1.9;0.5;-0.5]
hi = xi(2:4)-xi(1:3)
A = [2 1 0 0;hi(2) 2*(hi(1)+hi(2)) hi(1) 0; ...
```

```

0 hi(3) 2*(hi(2)+hi(3)) hi(2);0 0 1 2 ]
z = 3*[(yi(2)-yi(1))/hi(1); ...
      hi(2)/hi(1)*(yi(2)-yi(1))+hi(1)/hi(2)*(yi(3)-yi(2));...
      hi(3)/hi(2)*(yi(3)-yi(2))+hi(2)/hi(3)*(yi(4)-yi(3));...
      (yi(4)-yi(3))/hi(3)]
dyi = A\z
a=yi(1:3)
b=dyi(1:3)
c(1)=0
c(2:3)=3*(yi(3:4)-yi(2:3))./hi(2:3).^2 ...
      - (dyi(3:4)+2*dyi(2:3))./hi(2:3)
d=-2*(yi(2:4)-yi(1:3))./hi.^3 + (dyi(2:4)+dyi(1:3))./hi.^2
for i=1:3
    P(i) = poly([a(i) b(i) c(i) d(i)], 'x', 'coeff')
    z = [xi(i):.01:xi(i+1)]
    plot(z, horner(P(i), z-xi(i)))
end

```

O mesmo resultado é obtido através das instruções `splin` e `interp` do Scilab:

```

xi = [2;5;9;12]
yi = [4.5;-1.9;0.5;-0.5]
dyi=splin(xi,yi,'natural')
z=linspace(xi(1),xi($))
plot(z,interp(z,xi,yi,dyi))

```

◇

### 6.6.2 Spline fixado

O spline fixado  $s$  é obtido pela escolha dos valores das derivadas nas extremidades do intervalo de interpolação. Isto diminui o número de variáveis para  $n - 2$  pois  $y'_1$  e  $y'_n$  deixam de ser incógnitas.

As equações (6.5) formam um sistema de  $n - 2$  equações  $Ay' = z$ , onde

$$A = \begin{bmatrix} 2(h_1 + h_2) & h_1 & 0 & 0 & \cdots & 0 & 0 \\ h_3 & 2(h_2 + h_3) & h_2 & 0 & \cdots & 0 & 0 \\ 0 & h_4 & 2(h_3 + h_4) & h_3 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & h_{n-2} & 2(h_{n-3} + h_{n-2}) & h_{n-3} \\ 0 & 0 & 0 & \cdots & 0 & h_{n-1} & 2(h_{n-2} + h_{n-1}) \end{bmatrix},$$



$$y' = \begin{bmatrix} y'_2 \\ y'_3 \\ \vdots \\ y'_{n-1} \end{bmatrix} \quad \text{e} \quad z = 3 \begin{bmatrix} h_2 \frac{y_2 - y_1}{h_1} + h_1 \frac{y_3 - y_2}{h_2} - h_2 y'_1 \\ h_3 \frac{y_3 - y_2}{h_2} + h_2 \frac{y_4 - y_3}{h_3} \\ \vdots \\ h_{n-2} \frac{y_{n-2} - y_{n-3}}{h_{n-3}} + h_{n-3} \frac{y_{n-1} - y_{n-2}}{h_{n-2}} \\ h_{n-1} \frac{y_{n-1} - y_{n-2}}{h_{n-2}} + h_{n-2} \frac{y_n - y_{n-1}}{h_{n-1}} - h_{n-2} y'_n \end{bmatrix}.$$

Observe que a matriz  $A$  é diagonal dominante estrita e, portanto, o sistema  $Ay' = z$  possui solução única.

### 6.6.3 Spline *not-a-knot*

O spline *not-a-knot* é definido com um spline cúbico que satisfaz as equações adicionais

$$\lim_{x \nearrow x_2} s'''(x) = s'''_2(x_2) \quad \text{e} \quad \lim_{x \nearrow x_{n-1}} s'''(x) = s'''_{n-1}(x_{n-1})$$

Em termos dos coeficientes (6.2), as equações anteriores correspondem a

$$d_1 = d_2 \quad \text{e} \quad d_{n-2} = d_{n-1},$$

ou seja,

$$\begin{cases} h_2^2 y'_1 + (h_2^2 - h_1^2) y'_2 - h_1^2 y'_3 = 2 \left( h_2^2 \frac{y_2 - y_1}{h_1} - h_1^2 \frac{y_3 - y_2}{h_2} \right) \\ h_{n-1}^2 y'_{n-2} + (h_{n-1}^2 - h_{n-2}^2) y'_{n-1} - h_{n-2}^2 y'_n = 2 \left( h_{n-1}^2 \frac{y_{n-1} - y_{n-2}}{h_{n-2}} - h_{n-2}^2 \frac{y_n - y_{n-1}}{h_{n-1}} \right) \end{cases}$$

Essas duas equações agregadas às equações (6.5) formam um sistema de  $n$  equações  $Ay' = z$ , onde

$$A = \begin{bmatrix} h_2^2 & h_2^2 - h_1^2 & -h_1^2 & 0 & \cdots & 0 & 0 \\ h_2 & 2(h_1 + h_2) & h_1 & 0 & \cdots & 0 & 0 \\ 0 & h_3 & 2(h_2 + h_3) & h_2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & h_{n-1} & 2(h_{n-2} + h_{n-1}) & h_{n-2} \\ 0 & 0 & 0 & \cdots & h_{n-1}^2 & h_{n-1}^2 - h_{n-2}^2 & -h_{n-2}^2 \end{bmatrix}$$

$$y' = \begin{bmatrix} y'_1 \\ y'_2 \\ \vdots \\ y'_n \end{bmatrix} \quad \text{e} \quad z = \begin{bmatrix} 2 \left( h_2^2 \frac{y_2 - y_1}{h_1} - h_1^2 \frac{y_3 - y_2}{h_2} \right) \\ 3 \left( h_2 \frac{y_2 - y_1}{h_1} + h_1 \frac{y_3 - y_2}{h_2} \right) \\ \vdots \\ 3 \left( h_{n-1} \frac{y_{n-1} - y_{n-2}}{h_{n-2}} + h_{n-2} \frac{y_n - y_{n-1}}{h_{n-1}} \right) \\ 2 \left( h_{n-1}^2 \frac{y_{n-1} - y_{n-2}}{h_{n-2}} - h_{n-2}^2 \frac{y_n - y_{n-1}}{h_{n-1}} \right) \end{bmatrix}$$

Se reduzirmos esse sistema pela eliminação das incógnitas  $y'_1$  e  $y'_n$ , o sistema resultante possui uma matriz de coeficientes diagonal dominante estrita, portanto, a solução é única.

O termo *not-a-knot* (não nó) relaciona-se à nomenclatura dos splines. O termo *nó* é utilizado para os pontos interpolados. Neles, a derivada terceira da função spline é descontínua, portanto, quando impomos a continuidade dessa derivada em  $x_2$  e  $x_{n-1}$  é como se esses pontos deixassem de ser nós.

### 6.6.4 Spline periódico

Se o conjunto de  $n$  pontos da interpolação  $\mathcal{I}$  for tal que  $y_1 = y_n$ , então é possível construir o spline periódico, definido com um spline cúbico que satisfaz as seguintes condições de periodicidade

$$s'_1(x_1) = s'_{n-1}(x_n) \quad \text{e} \quad s''_1(x_1) = s''_{n-1}(x_n),$$

Em termos dos coeficientes (6.2)

$$b_1 = b_{n-1} \quad \text{e} \quad 2c_1 = 2c_{n-1} + 6d_{n-1}h_{n-1},$$

ou seja,

$$\begin{cases} y'_1 - y'_n = 0 \\ 2h_{n-1}y'_1 + h_{n-1}y'_2 + h_1y'_{n-1} + 2h_1y'_n = 3 \left( h_{n-1} \frac{y_2 - y_1}{h_1} + h_1 \frac{y_n - y_{n-1}}{h_{n-1}} \right) \end{cases}. \quad (6.11)$$

Essas duas equações agregadas às equações (6.5) formam um sistema de  $n$  equações  $Ay' = z$ , onde

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 & \cdots & 0 & -1 \\ h_2 & 2(h_1 + h_2) & h_1 & 0 & \cdots & 0 & 0 \\ 0 & h_3 & 2(h_2 + h_3) & h_2 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & h_{n-1} & 2(h_{n-2} + h_{n-1}) & h_{n-2} \\ 2h_{n-1} & h_{n-1} & 0 & \cdots & 0 & h_1 & 2h_1 \end{bmatrix}$$

$$y' = \begin{bmatrix} y'_1 \\ y'_2 \\ \vdots \\ y'_n \end{bmatrix} \quad \text{e} \quad z = 3 \begin{bmatrix} 0 \\ h_2 \frac{y_2 - y_1}{h_1} + h_1 \frac{y_3 - y_2}{h_2} \\ \vdots \\ h_{n-1} \frac{y_{n-1} - y_{n-2}}{h_{n-2}} + h_{n-2} \frac{y_n - y_{n-1}}{h_{n-1}} \\ h_{n-1} \frac{y_2 - y_1}{h_1} + h_1 \frac{y_n - y_{n-1}}{h_{n-1}} \end{bmatrix}.$$

Neste caso também, se reduzirmos esse sistema pela eliminação das incógnitas  $y'_1$  e  $y'_n$ , o sistema resultante possui uma matriz de coeficientes diagonal dominante estrita, portanto, a solução é única.

# Capítulo 7

## Ajuste de curvas

Neste capítulo, discutimos sobre problemas de **ajuste de curvas** pelo **método dos mínimos quadrados**. Mais precisamente, dado um conjunto de  $N$  pontos  $\{(x_j, y_j) \in \mathbb{R}^2\}_{j=1}^N$  e uma família de funções  $\mathcal{F} = \{f : \mathbb{R} \rightarrow \mathbb{R}; y = f(x)\}$ , o problema de ajuste de curvas consiste em encontrar uma função da família  $\mathcal{F}$  que melhor se ajusta aos pontos dados, não necessariamente que os interpola.



Figura 7.1: Exemplo de um problema de ajuste de uma reta entre três pontos, veja o exemplo 7.0.2.

Aqui, o termo “melhor se ajusta” é entendido no sentido de mínimos quadrados, isto é, buscamos encontrar uma função  $f \in \mathcal{F}$  tal que  $f(x)$  resolve o seguinte problema de minimização

$$\min_{f \in \mathcal{F}} \sum_{j=1}^N (f(x_j) - y_j)^2,$$

ou seja,  $f(x)$  é a função da família  $\mathcal{F}$  cujo erro quadrático entre  $y_j$  e  $f(x_j)$ ,  $j = 1, 2, \dots, N$ , é mínimo. A expressão

$$\begin{aligned} R &:= \sum_{j=1}^N (f(x_j) - y_j)^2 \\ &= (f(x_1) - y_1)^2 + (f(x_2) - y_2)^2 + \dots + (f(x_N) - y_N)^2 \end{aligned}$$

é chamada de **resíduo** e consiste na soma dos quadrados das diferenças entre a ordenadas  $y_j$  e o valor da função procurada  $f(x_j)$ .

**Exemplo 7.0.2.** Dado o conjunto de pontos  $\{(1, 1, 2), (1, 5, 1, 3), (2, 2, 3)\}$  e a família de retas  $f(x) = a + bx$ , podemos mostrar que  $f(x) = -0,05 + 1,1x$  é a reta que melhor aproxima os pontos dados no sentido de mínimos quadrados. Os pontos e a reta ajustada e são esboçados na figura 7.1.

Na sequência, discutimos o procedimento de ajuste de uma reta, então, mostramos a generalização da técnica para problemas lineares de ajuste e, por fim, discutimos alguns problemas de ajuste não lineares.

## 7.1 Ajuste de uma reta

Nesta seção, discutiremos o procedimento de ajuste de uma reta a um conjunto de pontos dados. Em outras palavras, discutiremos o método de solução para o problema de encontrar o polinômio do primeiro grau que melhor se aproxima a um dado conjunto de pontos pelo método dos mínimos quadrados.

Seja, então,  $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$  um conjunto de  $N$  pontos dados. Buscamos encontrar a função  $f(x) = a_1 + a_2x$  tal que o resíduo

$$R = \sum_{j=1}^N (f(x_j) - y_j)^2$$

seja mínimo.

Para tal, primeiro observamos que  $f(x_j) = a_1 + a_2x_j$  e, portanto, o resíduo pode ser escrito explicitamente como uma função de  $a_1$  e  $a_2$  conforme a seguinte expressão:

$$R(a_1, a_2) = \sum_{j=1}^N (a_1 + a_2x_j - y_j)^2.$$

Observamos que  $R(a_1, a_2)$  é uma forma quadrática e que seu mínimo ocorre

quando suas derivadas parciais primeiras são iguais a zero, isto é,

$$\begin{aligned}\frac{\partial R}{\partial a_1} &= \frac{\partial}{\partial a_1} \sum_{j=1}^N (a_1 + a_2 x_j - y_j)^2 = 0, \\ \frac{\partial R}{\partial a_2} &= \frac{\partial}{\partial a_2} \sum_{j=1}^N (a_1 + a_2 x_j - y_j)^2 = 0.\end{aligned}$$

Ou seja,

$$\begin{aligned}2 \sum_{j=1}^N (a_1 + a_2 x_j - y_j) \cdot 1 &= 0, \\ 2 \sum_{j=1}^N (a_1 + a_2 x_j - y_j) \cdot x_j &= 0,\end{aligned}$$

e isolando as incógnitas temos

$$\begin{aligned}a_1 \sum_{j=1}^N 1 + a_2 \sum_{j=1}^N x_j &= \sum_{j=1}^N y_j, \\ a_1 \sum_{j=1}^N x_j + a_2 \sum_{j=1}^N x_j^2 &= \sum_{j=1}^N y_j x_j.\end{aligned}$$

Observando que  $\sum_{j=1}^N 1 = N$ , o sistema linear acima pode ser escrito na forma matricial  $Ma = w$ , isto é,

$$\underbrace{\begin{bmatrix} N & \sum_{j=1}^N x_j \\ \sum_{j=1}^N x_j & \sum_{j=1}^N x_j^2 \end{bmatrix}}_M \underbrace{\begin{bmatrix} a_1 \\ a_2 \end{bmatrix}}_a = \underbrace{\begin{bmatrix} \sum_{j=1}^N y_j \\ \sum_{j=1}^N x_j y_j \end{bmatrix}}_w. \quad (7.1)$$

Este sistema linear de duas equações e duas incógnitas admite uma única solução quando o determinante da matriz dos coeficientes for não nulo, isto é,

$$N \sum_{j=1}^N x_j^2 - \left( \sum_{j=1}^N x_j \right)^2 \neq 0$$

Pode-se mostrar usando a **desigualdade de Cauchy–Schwarz** que isto acontece quando existem pelo menos duas abscissas diferentes envolvidas no ajuste. Usando a fórmula da inversa de uma matriz dois-por-dois, chegamos às seguintes

fórmulas para os coeficientes  $a_1$  e  $a_2$ :

$$\begin{aligned} a_1 &= \frac{\sum_{j=1}^N x_j^2 \cdot \sum_{j=1}^N y_j - \sum_{j=1}^N x_j \cdot \sum_{j=1}^N x_j y_j}{N \sum_{j=1}^N x_j^2 - \left(\sum_{j=1}^N x_j\right)^2} \\ a_2 &= \frac{N \sum_{j=1}^N x_j y_j - \sum_{j=1}^N x_j \cdot \sum_{j=1}^N y_j}{N \sum_{j=1}^N x_j^2 - \left(\sum_{j=1}^N x_j\right)^2} \end{aligned} \quad (7.2)$$

Por fim, observamos que o sistema  $Ma = w$  descrito na equação (7.1) pode ser reescrito na forma  $V^T V a = V^T y$ , onde  $V := [1 \ x]$  é a matriz dos coeficientes do seguinte sistema linear sobre determinado:

$$\begin{aligned} a_1 + a_2 x_1 &= y_1 \\ a_1 + a_2 x_2 &= y_2 \\ &\vdots \\ a_1 + a_2 x_N &= y_N \end{aligned} \quad (7.3)$$

Se os pontos dados não são colineares, este sistema não tem solução. Mas, sempre que pelo menos duas abscissas foram diferentes,  $M = V^T V$  é uma matriz invertível e (veja o exercício 7.1.4), então

$$a = (V^T V)^{-1} V^T y, \quad (7.4)$$

nos fornece a chamada solução por mínimos quadrados do sistema (7.3). Note que esta é uma forma de se obter os coeficientes  $a = (a_1, a_2)$  equivalente àquela dada em (7.2).

**Exemplo 7.1.1.** Retornemos ao exemplo 7.0.2. Isto é, dado o conjunto de pontos  $\{(1, 1, 2), (1, 5, 1, 3), (2, 2, 3)\}$ , encontrar a função do tipo  $f(x) = a_1 + a_2 x$  que melhor se ajusta os pontos dados no sentido de mínimos quadrados.

**Solução.** Usando as fórmulas em (7.2), obtemos

$$\begin{aligned} a_1 &= \frac{7,25 \cdot 4,8 - 4,5 \cdot 7,75}{3 \cdot 7,25 - 20,25} = -0,05, \\ a_2 &= \frac{3 \cdot 7,75 - 4,5 \cdot 4,8}{3 \cdot 7,25 - 20,25} = 1,1. \end{aligned}$$

Ou seja, verificamos que, de fato, a função  $f(x) = -0,05 + 1,1x$  corresponde à reta que melhor ajusta os pontos dados no sentido de mínimos quadrados. Os pontos e a reta ajustada estão esboçados na figura 7.1.

Deixamos ao leitor a verificação de que os coeficientes  $a_1$  e  $a_2$  também podem ser obtidos pela expressão (7.4).

Os coeficientes  $a_1$  e  $a_2$  podem ser rapidamente calculados no **Scilab** usando a expressão (7.4). Para tanto, digitamos:

```
-->xj = [1, 1.5, 2]';
-->yj = [1.2, 1.3, 2.3]';
-->V = [ones(3,1) xj];
-->a = inv(V'*V)*V'*yj
a =
    - 0.05
     1.1
```

Então, o gráfico da função ajustada e dos pontos pode ser obtido com os comandos:

```
-->deff('y = f(x)', 'y = a(1) + a(2)*x')
-->xx = linspace(0.5, 2.5);
-->plot(xj, yj, 'ro', xx, f(xx), 'b-')
```

◇

O procedimento apresentado de ajuste de uma reta por mínimos quadrados pode ser generalizado para qualquer família de funções que seja um espaço vetorial de dimensão finita. Problemas de ajuste com tais famílias de funções é o que chamamos de problemas de ajuste linear, os quais exploramos em detalhe na próxima seção.

## Exercícios

**E 7.1.1.** Sejam dados o conjunto de pontos  $\{(0,23, -0,54), (-0,30, -0,54), (0,04, -0,57)\}$ . Encontre a função  $f(x) = a_1 + a_2x$  que melhor se ajusta no sentido de mínimos quadrados aos pontos dados. Faça, então, um gráfico com os pontos e o esboço da função ajustada.

**E 7.1.2.** Seja dado o conjunto de pontos  $\{(-0,35, 0,2), (0,15, -0,5), (0,23, 0,54), (0,35, 0,7)\}$ . Encontre a função  $f(x) = a_1 + a_2x$  que melhor se ajusta no sentido de mínimos quadrados aos pontos dados. Faça, então, um gráfico com os pontos e o esboço da função ajustada.

**E 7.1.3.** Seja dado o conjunto de pontos  $\{(-1,94, 1,02), (-1,44, 0,59), (0,93, -0,28), (1,39, -1,04)\}$ . Encontre a função  $f(x) = a_1 + a_2x$  que melhor se ajusta no sentido de mínimos quadrados aos pontos dados. Então, responda cada item:

- Encontre o valor de  $f(1)$ .
- Encontre o valor de  $f(0,93)$ .
- Encontre o valor de  $|f(0,93) - (-0,28)|$ .



- d) Encontre o valor do resíduo  $R = \sum_{j=1}^N (f(x_j) - y_j)^2$ .

Forneça os valores calculados com 7 dígitos significativo por arredondamento.

#### E 7.1.4.

- a) Mostre que o sistema linear  $Ma = w$  descrito na equação 7.1 pode ser reescrito na forma  $V^T Va = V^T y$ , onde  $V = [1 \ x]$ .
- b) Mostre que  $V$ , como definido no item a), tem posto igual a 2 quando pelo menos duas abscissas do conjunto de pontos  $\{(x_j, y_j)\}_{j=1}^N$  são diferentes. E, portanto,  $M = V^T V$  é uma matriz invertível.

## 7.2 Ajuste linear geral

O problema geral de ajuste linear consiste em dada uma família  $\mathcal{F}$  gerada pelo conjunto de  $m$  funções  $\{f_1(x), f_2(x), \dots, f_m(x)\}$  e um conjunto de  $n$  pontos  $\{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ , calcular os coeficientes  $a_1, a_2, \dots, a_m$  tais que a função dada por

$$f(x) = \sum_{j=1}^m a_j f_j(x) = a_1 f_1(x) + a_2 f_2(x) + \dots + a_m f_m(x)$$

minimiza o resíduo

$$R = \sum_{i=1}^n [f(x_i) - y_i]^2.$$

Aqui, a minimização é feita por todas as possíveis escolhas dos coeficientes  $a_1, a_2, \dots, a_m$ .

Com o objetivo de tornar o desenvolvimento mais claro, vamos escrever  $R$  como a soma dos resíduos parciais:

$$R = \sum_{i=1}^n R_i, \quad \text{onde} \quad R_i := [f(x_i) - y_i]^2.$$

Do fato que  $f(x_i) = \sum_{j=1}^m a_j f_j(x_i)$ , temos que cada resíduo pode ser escrito como

$$R_i = \left[ \sum_{j=1}^m a_j f_j(x_i) - y_i \right]^2.$$

A fim de encontrar o ponto de mínimo, resolvemos o sistema oriundo de igualar a zero cada uma das derivadas parciais de  $R$  em relação aos  $m$  coeficientes  $a_j$ , isto é, devemos resolver:

$$\begin{aligned}\frac{\partial R}{\partial a_1} &= 2 \sum_{i=1}^n \frac{\partial R_i}{\partial a_1} = 2 \sum_{i=1}^n \left[ \sum_{j=1}^m a_j f_j(x_i) - y_i \right] f_1(x_i) = 0, \\ \frac{\partial R}{\partial a_2} &= 2 \sum_{i=1}^n \frac{\partial R_i}{\partial a_2} = 2 \sum_{i=1}^n \left[ \sum_{j=1}^m a_j f_j(x_i) - y_i \right] f_2(x_i) = 0, \\ &\vdots \\ \frac{\partial R}{\partial a_m} &= 2 \sum_{i=1}^n \frac{\partial R_i}{\partial a_m} = 2 \sum_{i=1}^n \left[ \sum_{j=1}^m a_j f_j(x_i) - y_i \right] f_m(x_i) = 0.\end{aligned}$$

Dividindo cada equação por 2 e escrevendo na forma matricial, obtemos  $Ma = w$ , onde a matriz  $M$  é dada por:

$$M = \begin{bmatrix} \sum_{i=1}^n f_1(x_i)^2 & \sum_{i=1}^n f_2(x_i)f_1(x_i) & \cdots & \sum_{i=1}^n f_m(x_i)f_1(x_i) \\ \sum_{i=1}^n f_1(x_i)f_2(x_i) & \sum_{i=1}^n f_2(x_i)^2 & \cdots & \sum_{i=1}^n f_m(x_i)f_2(x_i) \\ \sum_{i=1}^n f_1(x_i)f_3(x_i) & \sum_{i=1}^n f_2(x_i)f_3(x_i) & \cdots & \sum_{i=1}^n f_m(x_i)f_3(x_i) \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n f_1(x_i)f_m(x_i) & \sum_{i=1}^n f_2(x_i)f_m(x_i) & \cdots & \sum_{i=1}^n f_m(x_i)^2 \end{bmatrix}.$$

E os vetores  $a$  e  $w$ , por:

$$a = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix} \quad \text{e} \quad w = \begin{bmatrix} \sum_{i=1}^n f_1(x_i)y_i \\ \sum_{i=1}^n f_2(x_i)y_i \\ \sum_{i=1}^n f_3(x_i)y_i \\ \vdots \\ \sum_{i=1}^n f_m(x_i)y_i \end{bmatrix}$$

Agora, observamos que  $M = V^T V$  e  $w = V^T y$ , onde a matriz  $V$  é dada por:

$$V = \begin{bmatrix} f_1(x_1) & f_2(x_1) & \cdots & f_m(x_1) \\ f_1(x_2) & f_2(x_2) & \cdots & f_m(x_2) \\ f_1(x_3) & f_2(x_3) & \cdots & f_m(x_3) \\ \vdots & \vdots & \ddots & \vdots \\ f_1(x_n) & f_2(x_n) & \cdots & f_m(x_n) \end{bmatrix}$$

e é o vetor coluna  $y = (y_1, y_2, \dots, y_n)$ ,

Então, o problema de ajuste se reduz a resolver o sistema linear  $Ma = w$ , ou  $V^T V a = V^T y$ . Este sistema linear tem solução única se a matriz  $M$  for inversível. O teorema a seguir mostra que isto acontece sempre a matriz  $V$  possui posto  $m$ , ou seja, o número de linhas linearmente independentes for igual ao número de colunas.<sup>1</sup>

**Teorema 7.2.1.** *A matriz  $M = V^T V$  é quadrada de ordem  $m$  e é inversível sempre que o posto da matriz  $V$  é igual a número de colunas  $m$ .*

*Demonstração.* Para provar que  $M$  é inversível, precisamos mostrar que se  $v$  é um vetor de ordem  $m$  e  $Mv = 0$ , então  $v = 0$ . Suponha, então, que  $Mv = 0$ , isto é,  $V^T V v = 0$ . Tomando o produto interno da expressão  $V^T V v = 0$  com  $v$ , temos:

$$0 = \langle V^T V v, v \rangle = \langle V v, V v \rangle = \|V v\|^2$$

Portanto  $Mv = 0$  implica obrigatoriamente  $Vv = 0$ . Como o posto de  $V$  é igual ao número de colunas,  $v$  precisa ser o vetor nulo.  $\square$

**Observação 7.2.1.** Este problema é equivalente a resolver pelo métodos dos mínimos quadrados o seguinte sistema linear:

$$\begin{bmatrix} f_1(x_1) & f_2(x_1) & \cdots & f_m(x_1) \\ f_1(x_2) & f_2(x_2) & \cdots & f_m(x_2) \\ f_1(x_3) & f_2(x_3) & \cdots & f_m(x_3) \\ \vdots & \vdots & \ddots & \vdots \\ f_1(x_n) & f_2(x_n) & \cdots & f_m(x_n) \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix}$$

O caso de ajuste de uma reta para um conjunto de pontos é um caso particular de ajuste linear.

<sup>1</sup>Nota-se que o posto não pode ultrapassar o número de colunas.




Figura 7.2: Gráfico da solução do problema apresentado no exemplo 7.2.1.

**Exemplo 7.2.1.** Encontre a reta que melhor se ajusta aos pontos dados na seguinte tabela:

$i$	1	2	3	4	5
$x_i$	0,01	1,02	2,04	2,95	3,55
$y_i$	1,99	4,55	7,20	9,51	10,82

**Solução.** O problema consiste em ajustar uma função da forma  $f(x) = a_1 + a_2x$  no conjunto de pontos dados. Notamos que  $f(x)$  é uma função da família gerada pelo conjunto de funções  $\{f_1(x) = 1, f_2(x) = x\}$ . Então, aplicando o procedimento acima, temos que o vetor dos coeficientes  $a = (a_1, a_2)$  é solução por mínimos quadrados do sistema linear  $Va = y$ , onde:

$$V = \begin{bmatrix} f_1(x_1) & f_2(x_1) \\ f_1(x_2) & f_2(x_2) \\ f_1(x_3) & f_2(x_3) \\ f_1(x_4) & f_2(x_4) \\ f_1(x_5) & f_2(x_5) \end{bmatrix} = \begin{bmatrix} 1 & 0,01 \\ 1 & 1,02 \\ 1 & 2,04 \\ 1 & 2,95 \\ 1 & 3,55 \end{bmatrix}.$$




Figura 7.3: Gráfico da solução do problema apresentado no exemplo 7.2.2.

Ou seja, é a solução do sistema  $V^T V a = V^T y$  dado por

$$\begin{bmatrix} 5 & 9,57 \\ 9,57 & 26,5071 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 34,07 \\ 85,8144 \end{bmatrix}$$

A solução desse sistema é  $a_1 = 1,9988251$  e  $a_2 = 2,5157653$ . A figura 7.2, apresenta um gráfico dos pontos e da reta ajustada.

◇

**Exemplo 7.2.2.** Encontre a função  $f(x) = a_1 \sin(\pi x) + a_2 \cos(\pi x)$  que melhor se ajusta pelo critérios dos mínimos quadrados aos seguintes pontos dados

$i$	1	2	3	4	5
$x_i$	0,00	0,25	0,50	0,75	1,00
$y_i$	-153	64	242	284	175

**Solução.** Pelo procedimento visto nesta seção, temos que os coeficientes  $a_1$  e  $a_2$  são dados pela solução por mínimos quadrados do seguinte sistema linear  $Va = y$

$$\begin{aligned} a_1 \sin(\pi x_1) + a_2 \cos(\pi x_1) &= y_1 \\ a_1 \sin(\pi x_2) + a_2 \cos(\pi x_2) &= y_2 \\ a_1 \sin(\pi x_3) + a_2 \cos(\pi x_3) &= y_3 \\ a_1 \sin(\pi x_4) + a_2 \cos(\pi x_4) &= y_4 \\ a_1 \sin(\pi x_5) + a_2 \cos(\pi x_5) &= y_5 \end{aligned}$$

cujas matriz de coeficientes  $V$  é:

$$V = \begin{bmatrix} \sin(0) & \cos(0) \\ \sin(0,25\pi) & \cos(0,25\pi) \\ \sin(0,5\pi) & \cos(0,5\pi) \\ \sin(0,75\pi) & \cos(0,75\pi) \\ \sin(\pi) & \cos(\pi) \end{bmatrix}$$

Então, a solução por mínimos quadrados é

$$a = (V^T V)^{-1} V^T y = \begin{bmatrix} 244,03658 \\ -161,18783 \end{bmatrix}.$$

Ou seja,  $f(x) = 244,03658 \sin(\pi x) - 161,18783 \cos(\pi x)$  é a função ajustada ao conjunto de pontos dados. A figura 7.3 apresenta o gráfico de  $f(x)$  e dos pontos dados.

No Scilab, podemos computar os coeficientes da função  $f(x)$  da seguinte forma:

```
-->xi = [0 0.25 0.5 0.75 1]';
-->yi = [-153 64 242 284 175]';
-->V = [sin(%pi*xi) cos(%pi*xi)];
-->a = inv(V'*V)*V'*yi
a =
    244.03658
   -161.18783
```

◇

**Observação 7.2.2.** No Scilab, quando resolvemos um sistema  $Ax = b$  usando

```
-->x = inv(A)*b
```

estamos computando a inversa da matriz  $A$  e multiplicando por  $b$ . Podemos evitar a computação da inversa de  $A$  usando o operador contra-barras ( $/$ ). Neste caso, escrevemos

```
-->x = A/b
```

Quando o sistema  $A$  não é uma matriz quadrada,  $A/b$  retorna a solução por mínimos quadrados do sistema  $Ax = b$ , enquanto  $\text{inv}(A)*b$  retorna um erro, pois  $A$  não é uma matriz quadrada e, portanto, não é invertível.

### 7.2.1 Ajuste polinomial

O **ajuste polinomial** é o caso particular do ajuste linear para **funções polinomiais**, isto é, funções do tipo

$$p(x) = a_1 + a_2x + \cdots + a_mx^{m-1}.$$

Neste caso, a matriz  $V$  associada ao ajuste dos pontos  $\{(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots, (x_n, y_n)\}$  é dada por:

$$V = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^{m-1} \\ 1 & x_2 & x_2^2 & \cdots & x_2^{m-1} \\ 1 & x_3 & x_3^2 & \cdots & x_3^{m-1} \\ \vdots & \vdots & & \ddots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^{m-1} \end{bmatrix}$$

Então, os coeficientes  $a_i$ ,  $i = 1, 2, \dots, m$ , são dados pela solução do sistema linear  $V^T V a = v^T y$ :

$$\underbrace{\begin{bmatrix} n & \sum_{j=1}^n x_j & \cdots & \sum_{j=1}^n x_j^{m-1} \\ \sum_{j=1}^n x_j & \sum_{j=1}^n x_j^2 & & \sum_{j=1}^n x_j^m \\ \vdots & & \ddots & \vdots \\ \sum_{j=1}^n x_j^{m-1} & \sum_{j=1}^n x_j^m & \cdots & \sum_{j=1}^n x_j^{2m-1} \end{bmatrix}}_{V^T V} \underbrace{\begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_{p+1} \end{bmatrix}}_a = \underbrace{\begin{bmatrix} \sum_{j=1}^n y_j \\ \sum_{j=1}^n x_j y_j \\ \vdots \\ \sum_{j=1}^n x_j^{m-1} y_j \end{bmatrix}}_{V^T y}$$

**Exemplo 7.2.3.** Entre o polinômio de grau 2 que melhor se ajusta aos pontos dados na seguinte tabela:

$i$	1	2	3	4	5
$x_i$	0,00	0,25	0,50	0,75	1,00
$y_i$	-153	64	242	284	175

**Solução.** Um polinômio de grau 2 pode ser escrito na seguinte forma:

$$p(x) = a_1 + a_2x + a_3x^2.$$




Figura 7.4: Gráfico da solução do problema apresentado no exemplo 7.2.3.

Assim, o problema se resume em encontrarmos a solução por mínimos quadrados do seguinte sistema linear:

$$\begin{aligned} a_1 + a_2x_1 + a_3x_1^2 &= y_1 \\ a_2 + a_2x_2 + a_3x_2^2 &= y_2 \\ a_3 + a_2x_3 + a_3x_3^2 &= y_3 \\ a_4 + a_2x_4 + a_3x_4^2 &= y_4 \\ a_5 + a_2x_5 + a_3x_5^2 &= y_5 \end{aligned}$$

Ou, escrita na forma matricial,  $Va = y$ , onde:

$$V = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ 1 & x_3 & x_3^2 \\ 1 & x_4 & x_4^2 \\ 1 & x_5 & x_5^2 \end{bmatrix}$$

A solução por mínimos quadrados é, então:

$$a = (V^T V)^{-1} V^T y = \begin{bmatrix} -165,37143 \\ 1250,9714 \\ -900,57143 \end{bmatrix}$$



Ou seja, o polinômio de grau 2 que melhor ajusta os pontos dados no sentido de mínimos quadrados é  $p(x) = -165,37143 + 1250,9714x - 900,57143x^2$ . A figura 7.4 mostra o gráfico do polinômio ajustado e os pontos dados.

No Scilab, podemos computar o polinômio  $p(x)$  da seguinte forma:

```
-->xi = [0 0.25 0.5 0.75 1]';
-->yi = [-153 64 242 284 175]';
-->V = [ones(5,1) xi xi.^2];
-->a = V\yi;
-->p = poly(a,'x','c')
p =
          2
- 165.37143 + 1250.9714x - 900.57143x
```

Para fazermos o gráfico do polinômio e dos pontos, digitamos:

```
-->xx = linspace(-0.25,1.25);
-->plot(xi,yi,'ro',xx,horner(p,xx),'b-');xgrid
```

◇

## Exercícios

**E 7.2.1.** Encontre o polinômio  $p(x) = a_1 + a_2x + a_3x^2$  que melhor se ajusta no sentido de mínimos quadrados aos pontos:

$i$	1	2	3	4
$x_i$	-1,50	-0,50	1,25	1,50
$y_i$	1,15	-0,37	0,17	0,94

**E 7.2.2.** Encontrar a parábola  $y = ax^2 + bx + c$  que melhor aproxima o seguinte conjunto de dados:

$i$	1	2	3	4	5
$x_i$	0,01	1,02	2,04	2,95	3,55
$y_i$	1,99	4,55	7,20	9,51	10,82

**E 7.2.3.** Dado o seguinte conjunto de dados

$x_i$	0,0	0,1	0,2	0,3	0,4	0,5	0,6	0,7	0,8	0,9	1,0
$y_i$	31	35	37	33	28	20	16	15	18	23	31

- a) Encontre a função do tipo  $f(x) = a + b \sin(2\pi x) + c \cos(2\pi x)$  que melhor aproxima os valores dados.
- b) Encontre a função do tipo  $f(x) = a + bx + cx^2 + dx^3$  que melhor aproxima os valores dados.

### 7.3 Aproximando problemas não lineares por problemas lineares

Eventualmente, problemas de ajuste de curvas podem recair em um sistema não linear. Por exemplo, para ajustar função  $y = Ae^{bx}$  ao conjunto de pontos  $(x_1, y_1)$ ,  $(x_2, y_2)$  e  $(x_3, y_3)$ , temos que minimizar o resíduo<sup>2</sup>

$$R = (Ae^{x_1 b} - y_1)^2 + (Ae^{x_2 b} - y_2)^2 + (Ae^{x_3 b} - y_3)^2$$

ou seja, resolver o sistema

$$\begin{aligned} \frac{\partial R}{\partial A} &= 2(Ae^{x_1 b} - y_1)e^{x_1 b} + 2(Ae^{x_2 b} - y_2)e^{x_2 b} + 2(Ae^{x_3 b} - y_3)e^{x_3 b} = 0 \\ \frac{\partial R}{\partial b} &= 2Ax_1(Ae^{x_1 b} - y_1)e^{x_1 b} + 2Ax_2(Ae^{x_2 b} - y_2)e^{x_2 b} \\ &\quad + 2Ax_3(Ae^{x_3 b} - y_3)e^{x_3 b} = 0 \end{aligned}$$

que é não linear em  $A$  e  $b$ . Esse sistema pode ser resolvido pelo método de Newton-Raphson, o que pode se tornar custoso, ou mesmo inviável quando não dispomos de uma boa aproximação da solução para inicializar o método.

Felizmente, algumas famílias de curvas admitem uma transformação que nos leva a um problema linear. No caso da curva  $y = Ae^{bx}$ , observe que  $\ln y = \ln A + bx$ . Assim, em vez de ajustar a curva original  $y = Ae^{bx}$  a tabela de pontos, ajustamos a curva submetida a transformação logarítmica

$$\tilde{y} := a_1 + a_2 \tilde{x} = \ln A + bx.$$

Usamos os pontos  $(\tilde{x}_j, \tilde{y}_j) := (x_j, \ln y_j)$ ,  $j = 1, 2, 3$  e resolvemos o sistema linear

$$V^T V \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = V^T \begin{bmatrix} \tilde{y}_1 \\ \tilde{y}_2 \\ \tilde{y}_3 \end{bmatrix},$$

<sup>2</sup>A soma do quadrado dos resíduos.

onde

$$A = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \end{bmatrix}$$

**Exemplo 7.3.1.** Encontre uma curva da forma  $y = Ae^x$  que melhor ajusta os pontos  $(1, 2)$ ,  $(2, 3)$  e  $(3, 5)$ .

Temos

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}$$

e a solução do sistema leva em  $B = 0,217442$  e  $b = 0,458145$ . Portanto,  $A = e^{0,217442} = 1,24289$ .

**Observação 7.3.1.** Os coeficientes obtidos a partir dessa linearização são aproximados, ou seja, são diferentes daqueles obtidos quando aplicamos mínimos quadrados não linear. Observe que estamos minimizando  $\sum_i [\ln y_i - \ln(f(x_i))]^2$  em vez de  $\sum_i [y_i - f(x_i)]^2$ . No exemplo resolvido, a solução do sistema não linear original seria  $A = 1,19789$  e  $B = 0,474348$ .

**Observação 7.3.2.** Mesmo quando se deseja resolver o sistema não linear, a solução do problema linearizado pode ser usada para construir condições iniciais.

A próxima tabela apresenta algumas curvas e transformações que linearizam o problema de ajuste.

Curva	Transformação	Problema Linearizado
$y = ae^{bx}$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + bx$
$y = ax^b$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + b \ln x$
$y = ax^b e^{cx}$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + b \ln x + cx$
$y = ae^{(b+cx)^2}$	$\tilde{y} = \ln y$	$\tilde{y} = \ln a + b^2 + bcx + c^2 x^2$
$y = \frac{a}{b+x}$	$\tilde{y} = \frac{1}{y}$	$\tilde{y} = \frac{b}{a} + \frac{1}{a}x$
$y = A \cos(\omega x + \phi)$ $\omega$ conhecido	—	$y = a \cos(\omega x) - b \sin(\omega x)$ $a = A \cos(\phi)$ , $b = A \sin(\phi)$

**Exemplo 7.3.2.** Encontre a função  $f$  da forma  $y = f(x) = A \cos(2\pi x + \phi)$  que ajusta a tabela de pontos

$x_i$	$y_i$
0,0	9,12
0,1	1,42
0,2	- 7,76
0,3	- 11,13
0,4	- 11,6
0,5	- 6,44
0,6	1,41
0,7	11,01
0,8	14,73
0,9	13,22
1,0	9,93

**Solução.** Usando o fato que  $y = A \cos(2\pi x + \phi) = a \cos(2\pi x) - b \sin(2\pi x)$ , onde  $a = A \cos(\phi)$  e  $b = A \sin(\phi)$ ,  $z = \begin{bmatrix} a & b \end{bmatrix}^T$  é solução do problema

$$B^T B z = B^T y,$$

onde

$$B = \begin{bmatrix} \cos(2\pi x_0) & -\sin(2\pi x_0) \\ \cos(2\pi x_1) & -\sin(2\pi x_1) \\ \vdots & \\ \cos(2\pi x_{10}) & -\sin(2\pi x_{10}) \end{bmatrix} = \begin{bmatrix} 1. & 0. \\ 0,8090170 & -0,5877853 \\ 0,3090170 & -0,9510565 \\ -0,3090170 & -0,9510565 \\ -0,8090170 & -0,5877853 \\ -1,0000000 & 0,0000000 \\ -0,8090170 & 0,5877853 \\ -0,3090170 & 0,9510565 \\ 0,3090170 & 0,9510565 \\ 0,8090170 & 0,5877853 \\ 1,0000000 & 0,0000000 \end{bmatrix}.$$

Assim,  $a = 7,9614704$  e  $b = 11,405721$  e obtemos o seguinte sistema:

$$\begin{cases} A \cos(\phi) = 7,9614704 \\ A \sin(\phi) = 11,405721 \end{cases}.$$

Observe que

$$A^2 = 7,9614704^2 + 11,405721^2$$

e, escolhendo  $A > 0$ ,  $A = 13,909546$  e

$$\sin(\phi) = \frac{11,405721}{13,909546} = 0,8199923$$

Assim, como  $\cos \phi$  também é positivo,  $\phi$  é um ângulo do primeiro quadrante:

$$\phi = 0,9613976$$

Portanto  $f(x) = 13,909546 \cos(2\pi x + 0,9613976)$ . Observe que nesse exemplo a solução do problema linear é a mesma do problema não linear.  $\diamond$

**Exemplo 7.3.3.** Encontre a função  $f$  da forma  $y = f(x) = \frac{a}{b+x}$  que ajusta a

tabela de pontos

$x_i$	$y_i$
0,0	101
0,2	85
0,4	75
0,6	66
0,8	60
1,0	55

usando uma das transformações tabeladas.

**Solução.** Usando o fato que  $Y = \frac{1}{y} = \frac{b}{a} + \frac{1}{a}x$ ,  $z = [\frac{b}{a} \quad \frac{1}{a}]^T$  é solução do problema

$$A^T A z = A^T Y,$$

onde

$$A = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ 1 & x_3 \\ 1 & x_4 \\ 1 & x_5 \\ 1 & x_6 \end{bmatrix} = \begin{bmatrix} 1 & 0,0 \\ 1 & 0,2 \\ 1 & 0,4 \\ 1 & 0,6 \\ 1 & 0,8 \\ 1 & 1,0 \end{bmatrix}$$

e

$$Y = \begin{bmatrix} 1/y_1 \\ 1/y_2 \\ 1/y_3 \\ 1/y_4 \\ 1/y_5 \\ 1/y_6 \end{bmatrix} = \begin{bmatrix} 0,0099010 \\ 0,0117647 \\ 0,0133333 \\ 0,0151515 \\ 0,0166667 \\ 0,0181818 \end{bmatrix}$$

Assim,  $\frac{1}{a} = 0,0082755$  e  $\frac{b}{a} = 0,0100288$  e, então,  $a = 120,83924$  e  $b = 1,2118696$ , ou seja,  $f(x) = \frac{120,83924}{1,2118696+x}$ .  $\diamond$

# Capítulo 8

## Derivação Numérica

Nesta seção, discutiremos sobre estratégias numéricas de aproximação de derivadas de funções reais. Com as técnicas que abordaremos é possível o cálculo aproximado da derivada de uma função a partir de um conjunto de pontos discretos  $\{(x_i, y_i)\}_{i=1}^n$ . Começamos discutindo sobre as chamadas **aproximações por diferenças finitas** e, então, discutimos sobre aproximações de derivadas via ajuste ou interpolação.

### 8.1 Diferenças finitas

Uma diferença finita é simplesmente uma expressão da forma  $f(x+b) - f(x+a)$ , que ao ser dividida por  $(b-a)$  chama-se um quociente de diferenças.

A técnica de **diferenças finitas** consiste em aproximar a derivada de uma função via fórmulas discretas que requerem apenas um conjunto finito de pares ordenados  $\{(x_i, y_i)\}_{i=1}^n$ , onde geralmente temos que  $y_i = f(x_i)$ .

Essas fórmulas podem ser obtidas de várias maneiras. Começamos com a fórmula mais simples que pode ser obtida do Cálculo diferencial.

Seja  $f$  uma função diferenciável, a derivada de  $f$  no ponto  $x_0$  é, por definição,

$$f'(x_0) = \lim_{h \rightarrow 0} \frac{f(x_0 + h) - f(x_0)}{h}.$$

Deste limite, tomando  $h \neq 0$  pequeno (não muito pequeno para evitar o cancelamento catastrófico), é esperado que possamos obter uma aproximação razoável para  $f'(x_0)$ . Assim, a **diferença finita progressiva** de ordem 1

$$D_{+,h}f(x_0) := \frac{f(x_0 + h) - f(x_0)}{h} \approx f'(x_0) \quad (8.1)$$

é uma aproximação para  $f'(x_0)$ .

**Exemplo 8.1.1.** Usando a diferença finita progressiva de ordem 1, calcule aproximações da derivada de  $f(x) = \cos(x)$  no ponto  $x = 1$  usando  $h = 10^{-1}, 10^{-2}, 10^{-3}, 10^{-4}, 10^{-12}$  e  $10^{-14}$ . Calcule o erro  $|D_{+,h}f(1) - f'(1)|$  obtido para cada valor de  $h$ .

**Solução.** Usando a diferença progressiva em (8.1), devemos calcular

$$D_{+,h}f(1) = \frac{\cos(1+h) - \cos(1)}{h}$$

Fazendo isso, obtemos:

$h$	$D_{+,h}f(1)$	$ f'(1) - D_{+,h}f(1) $
$10^{-1}$	-8,67062E-01	2,55909E-02
$10^{-2}$	-8,44158E-01	2,68746E-03
$10^{-3}$	-8,41741E-01	2,70011E-04
$10^{-4}$	-8,41498E-01	2,70137E-05
$10^{-12}$	-8,41549E-01	7,80679E-05
$10^{-14}$	-8,43769E-01	2,29851E-03

No **Scilab**, podemos calcular a aproximação da derivada  $f'(1)$  com  $h = 0,1$  usando as seguintes linhas de código:

```
--> deff('y = f(x)', 'y = cos(x)')
--> x0 = 1
--> h = 0.1
--> df = (f(x0+h) - f(x0))/h
```

E, similarmente, para outros valores de  $x_0$  e  $h$ .

◇

Exploremos o exemplo 8.1.1 um pouco mais. Observamos que, para valores moderados de  $h$ , o erro  $|f'(1) - D_{+,h}f(1)|$  diminui linearmente com  $h$  (veja figura 8.1). Isto é consequência da ordem de truncamento da fórmula de diferenças finitas aplicada (que é de ordem 1). Porém, para valores muito pequenos de  $h < 10^{-8}$ , o erro passa a aumentar quando diminuimos  $h$ . Isto é devido ao efeito de cancelamento catastrófico.






Figura 8.1: Erro absoluto das derivadas numéricas no exemplo 8.1.1.

### 8.1.1 Diferenças finitas via série de Taylor

Podemos construir fórmulas de diferenças finitas para uma função  $f(x)$  (suave<sup>1</sup>) no ponto  $x = x_0$  a partir de sua expansão em série de Taylor. Em alguns casos, este procedimento acaba por nos fornecer, também, a ordem de truncamento da fórmula.

#### Diferença finita progressiva de ordem 1

Podemos obter uma aproximação para  $f'(x_0)$  a partir da série de Taylor

$$f(x_0 + h) = f(x_0) + hf'(x_0) + h^2 \frac{f''(\xi)}{2}, \quad h > 0, \xi \in (x_0, x_0 + h).$$

Isolando  $f'(x_0)$ , obtemos

$$f'(x_0) = \underbrace{\frac{f(x_0 + h) - f(x_0)}{h}}_{D_{+,h}} - \underbrace{h \frac{f''(\xi)}{2}}_{\mathcal{O}(h)}, \quad (8.2)$$

<sup>1</sup>Uma função suave é uma função infinitamente continuamente diferenciável, isto é,  $f \in C^\infty(\mathbb{R})$ . Uma análise mais cuidadosa, revela que hipóteses mais fracas podem ser assumidas.

o que mostra que o erro de truncamento da **diferença finita progressiva**<sup>2</sup>

$$D_{+,h}f(x_0) := \frac{f(x_0 + h) - f(x_0)}{h}$$

é de ordem  $h$ .

### Diferença finita regressiva de ordem 1

Outra aproximação para a derivada primeira pode ser obtida da série de Taylor de  $f$  em torno de  $(x_0 - h)$  dada por

$$f(x_0 - h) = f(x_0) - hf'(x_0) + h^2 \frac{f''(\xi)}{2}, \quad h > 0, \xi \in (x_0, x_0 + h).$$

Isolando  $f'(x_0)$ , obtemos

$$f'(x_0) = \underbrace{\frac{f(x_0) - f(x_0 - h)}{h}}_{D_{-,h}} + \underbrace{h \frac{f''(\xi)}{2}}_{\mathcal{O}(h)}.$$

que fornece a **diferença finita regressiva**<sup>3</sup>

$$D_{-,h}f(x_0) := \frac{f(x_0) - f(x_0 - h)}{h},$$

que possui erro de truncamento de ordem  $h$ .

### Diferença finita central de ordem 2

Para obter uma aproximação para a derivada primeira com um erro menor, podemos utilizar as séries de Taylor:

$$\begin{aligned} f(x_0 + h) &= f(x_0) + hf'(x_0) + h^2 f''(x_0) + h^3 \frac{f'''(\xi_+)}{3!}, \\ f(x_0 - h) &= f(x_0) - hf'(x_0) + h^2 f''(x_0) + h^3 \frac{f'''(\xi_-)}{3!} \end{aligned}$$

Fazendo a primeira equação menos a segunda, obtemos

$$f(x_0 + h) - f(x_0 - h) = 2hf'(x_0) + h^3 \left( \frac{f'''(\xi_+) - f'''(\xi_-)}{3!} \right).$$

<sup>2</sup>Também chamada de diferença finita progressiva de dois pontos ou diferença pra frente.

<sup>3</sup>Também chamada de diferença finita regressiva de dois pontos ou diferença pra trás.

Dividindo por  $2h$  e isolando  $f'(x_0)$  obtemos

$$f'(x_0) = \underbrace{\frac{f(x_0+h) - f(x_0-h)}{2h}}_{D_{0,h}} - \underbrace{h^2 \left( \frac{f'''(\xi_+) - f'''(\xi_-)}{2 \cdot 3!} \right)}_{\mathcal{O}(h^2)}.$$

Assim, a **diferença finita central**<sup>4</sup>

$$D_{0,h}f(x_0) := \frac{f(x_0+h) - f(x_0-h)}{2h},$$

é uma aproximação para  $f'(x_0)$  com erro de truncamento de ordem  $h^2$ , ou simplesmente ordem 2.

**Exemplo 8.1.2.** Calcule a derivada numérica da função  $f(x) = e^{\frac{1}{2}x}$  no ponto  $x = 2$  usando a diferença progressiva, diferença regressiva e diferença central com  $h = 10^{-1}$ ,  $h = 10^{-2}$  e  $h = 10^{-4}$ . Também, calcule o erro absoluto da aproximação obtida em cada caso.

**Solução.** Usando a diferença progressiva, devemos calcular

$$D_{+,h} = \frac{f(x+h) - f(x)}{h} = \frac{e^{\frac{1}{2}(x+h)} - e^{\frac{1}{2}x}}{h}.$$

Com a diferença regressiva, calculamos

$$D_{-,h} = \frac{f(x) - f(x-h)}{h} = \frac{e^{\frac{1}{2}x} - e^{\frac{1}{2}(x-h)}}{h}.$$

Por fim, usando a diferença central temos

$$D_{0,h} = \frac{f(x+h) - f(x-h)}{2h} = \frac{e^{\frac{1}{2}(x+h)} - e^{\frac{1}{2}(x-h)}}{2h}.$$

As aproximações e os erros absolutos calculados em cada caso estão apresentados na seguinte tabela:

$h$	$D_{+,h}f(2)$	Erro	$D_{-,h}$	Erro	$D_{0,h}$	Erro
$10^{-1}$	1,39369	3,5E-02	1,32572	3,3E-02	1,35971	5,7E-04
$10^{-2}$	1,36254	3,4E-03	1,35575	3,4E-03	1,35915	5,7E-06
$10^{-4}$	1,35917	3,4E-05	1,35911	3,4E-05	1,35914	5,7E-10

◇




Figura 8.2: Erro absoluto das derivadas numéricas no exemplo 8.1.2.

**Observação 8.1.1.** O experimento numérico realizado no exemplo 8.1.2, nos mostra que o erro absoluto na derivação numérica não é da ordem do erro de truncamento. Entretanto, este erro tende a variar com  $h$  na mesma ordem do erro de truncamento. A figura 8.1.2 apresenta o erro absoluto das derivadas numéricas computadas para o exemplo 8.1.2. Note que, devido ao efeito de cancelamento catastrófico, o erro absoluto deixa de variar na ordem do erro de truncamento para valores muito pequenos de  $h$ .

**Exemplo 8.1.3.** Estime o erro absoluto no cálculo da derivada de  $f(x) = e^{-x}$  para  $x > 0$  utilizando a diferença progressiva.

**Solução.** Da equação 8.2, temos:

$$f'(x) = D_{+,h}f(x) - h \frac{f''(\xi)}{2}, \quad \xi > 0,$$

ou seja:

$$|f'(x) - D_{+,h}f(x)| = \left| \frac{f''(\xi)}{2} \right| h, \quad \xi > 0.$$

Agora, como  $|f''(x)| = |e^{-x}| < 1$  para  $x > 0$ , concluímos que:

$$|f'(x) - D_{+,h}f(x)| \leq \frac{1}{2}h, \quad x > 0.$$

<sup>4</sup>Também chamada de diferença finita central de três pontos. Note que o ponto  $f(x_0)$  possui coeficiente 0, por isso 3 pontos.



### 8.1.2 Erros de arredondamento

Para entender como os erros de arredondamento se propagam ao calcular as derivadas numéricas vamos analisar a fórmula de diferenças finitas progressiva

$$D_{+,h}f(x) = \frac{f(x+h) - f(x)}{h}.$$

Nesse contexto temos o valor exato  $f'(x)$  para a derivada, a sua aproximação numérica  $D_{+,h}f(x)$  e a representação em número de máquina do operador  $D_{+,h}f(x)$  que denotaremos por  $\overline{D_{+,h}f(x)}$ . Denotando por  $\varepsilon(x,h)$  o erro de arredondamento ao calcularmos a derivada, vamos assumimos que

$$\overline{D_{+,h}f(x)} = D_{+,h}f(x)(1 + \varepsilon(x,h)) = \frac{\overline{f(x+h)} - \overline{f(x)}}{h}(1 + \varepsilon(x,h)). \quad (8.3)$$

Também, consideremos

$$|\overline{f(x+h)} - f(x+h)| = \delta(x,h) \leq \delta$$

e

$$|\overline{f(x)} - f(x)| = \delta(x,0) \leq \delta,$$

onde  $\overline{f(x+h)}$  e  $\overline{f(x)}$  são as representações em ponto flutuante dos números  $f(x+h)$  e  $f(x)$ , respectivamente.

Então, da equação (8.3), a diferença do valor da derivada e sua aproximação representada em ponto flutuante pode ser estimada por:

$$\left| f'(x) - \overline{D_{+,h}f(x)} \right| = \left| f'(x) - \frac{\overline{f(x+h)} - \overline{f(x)}}{h}(1 + \varepsilon(x,h)) \right|.$$

Podemos reescrever o lado direito desta equação, da seguinte forma

$$\begin{aligned} \left| f'(x) - \overline{D_{+,h}f(x)} \right| &= \left| f'(x) - \left( \frac{\overline{f(x+h)} - \overline{f(x)}}{h} + \frac{f(x+h) - f(x+h)}{h} \right. \right. \\ &\quad \left. \left. + \frac{f(x) - f(x)}{h} \right) (1 + \varepsilon) \right| \\ &= \left| f'(x) + \left( -\frac{f(x+h) - f(x)}{h} - \frac{\overline{f(x+h)} - f(x+h)}{h} \right. \right. \\ &\quad \left. \left. + \frac{\overline{f(x)} - f(x)}{h} \right) (1 + \varepsilon) \right|. \end{aligned}$$

Então, separando os termos e estimando, obtemos:

$$\begin{aligned}
 \left| f'(x) - \overline{D_{+,h}f(x)} \right| &\leq \left| f'(x) - \frac{f(x+h) - f(x)}{h} \right| + \left( \left| \frac{\overline{f(x+h)} - f(x+h)}{h} \right| \right. \\
 &\quad \left. + \left| \frac{\overline{f(x)} - f(x)}{h} \right| \right) |1 + \varepsilon| + \left| \frac{f(x+h) - f(x)}{h} \right| \varepsilon \\
 &\leq Mh + \left( \left| \frac{\delta}{h} \right| + \left| \frac{\delta}{h} \right| \right) |1 + \varepsilon| + |f'(x)|\varepsilon \\
 &\leq Mh + \left( \frac{2\delta}{h} \right) |1 + \varepsilon| + |f'(x)|\varepsilon
 \end{aligned}$$

onde

$$M = \frac{1}{2} \max_{x \leq y \leq x+h} |f''(y)|$$

está relacionado com o erro de truncamento.

Por fim, obtemos a seguinte estimativa para o erro absoluto na computação da derivada numérica:

$$\left| f'(x) - \overline{D_{+,h}f(x)} \right| \leq Mh + \left( \frac{2\delta}{h} \right) |1 + \varepsilon| + |f'(x)|\varepsilon. \quad (8.4)$$

Esta estimativa mostra que se o valor de  $h$  for muito pequeno o erro ao calcular a aproximação numérica cresce. Isso nos motiva a procurar o valor ótimo de  $h$  que minimiza o erro.

**Exemplo 8.1.4.** No exemplo 8.1.2, computamos a derivada numérica da função  $f(x) = e^{\frac{1}{2}x}$  no ponto  $x = 2$  usando as fórmulas de diferenças finitas progressivas, regressivas e central. A figura 8.2, mostra que, para valores  $h$  muito pequenos, os erros de arredondamento passam a dominar os cálculos e, por consequência, o erro da derivada numérica passa a aumentar. Pela figura, podemos inferir que a escolha ótima de  $h$  para as fórmulas progressiva e regressivas é  $h \approx 10^{-7}$ . Agora, para a fórmula central,  $h \approx 10^{-5}$  parece ser a melhor escolha.

**Observação 8.1.2.** Note que a estimativa (8.4), mostra que o erro na computação da derivada numérica depende da função que está sendo derivada. Assim, o  $h$  ótimo depende não somente da fórmula de diferenças finitas, mas também da função a ser derivada.

## Exercícios Resolvidos

**ER 8.1.1.** Aproxime a derivada de  $f(x) = \sin(2x) - x^2$  no ponto  $x = 2$  usando a fórmula de diferenças finitas progressiva de ordem 1 com: a)  $h = 0,1$  e b)  $h = 0,01$ . Compute, também, o erro absoluto de cada aproximação computada.

**Solução.** A fórmula de diferenças finitas de ordem 1 para uma função  $y = f(x)$  em um ponto  $x = x_0$  é dada por:

$$D_{+,h}f(x_0) = \frac{f(x_0 + h) - f(x_0)}{h}.$$

Substituindo  $f(x) = \sin(2x) - x^2$  e  $x_0 = 2$ , obtemos:

$$\begin{aligned} D_{+,h}f(x_0) &= \frac{(\sin(2(x_0 + h)) - (x_0 + h)^2) - (\sin(2x_0) - x_0^2)}{h} \\ &= \frac{\sin(2(x_0 + h)) - x_0^2 + 2x_0h + h^2 - \sin(2x_0) + x_0^2}{h} \\ &= \frac{\sin(4 + 2h) + 4h + h^2 - \sin(4)}{h}. \end{aligned}$$

Então, tomando  $h = 0,1$ , podemos computar a derivada numérica e o erro associado:

$$D_{+,0,1}f(2) = -5,247733, \quad |f'(2) - D_{+,0,1}f(2)| = 5,96 \times 10^{-2},$$

onde  $f'(x) = 2\sin(2x) - 2x$  é a derivada analítica. Tomando  $h = 0,01$  temos:

$$D_{+,0,1}f(2) = -5,302065, \quad |f'(2) - D_{+,0,1}f(2)| = 5,22 \times 10^{-3}.$$

◇

## Exercícios

**E 8.1.1.** Use os esquemas numéricos do exercício 8.1.2 para aproximar as seguintes derivadas:

- a)  $f'(x)$  onde  $f(x) = \sin(x)$  e  $x = 2$ .
- b)  $f'(x)$  onde  $f(x) = e^{-x}$  e  $x = 1$ .

Use  $h = 10^{-2}$  e  $h = 10^{-3}$  e compare com os valores obtidos através da avaliação numérica das derivadas exatas.

**E 8.1.2.** Expanda a função suave  $f(x)$  em um polinômio de Taylor adequado para obter as seguintes aproximações:

- a)  $f'(x) = \frac{f(x+h)-f(x)}{h} + \mathcal{O}(h)$
- b)  $f'(x) = \frac{f(x)-f(x-h)}{h} + \mathcal{O}(h)$
- c)  $f'(x) = \frac{f(x+h)-f(x-h)}{2h} + \mathcal{O}(h^2)$

**E 8.1.3.** Use a expansão da função  $f(x)$  em torno de  $x = 0$  em polinômios de Taylor para encontrar os coeficientes  $a_1$ ,  $a_2$  e  $a_3$  tais que

- a)  $f'(0) = a_1f(0) + a_2f(h) + a_3f(2h) + \mathcal{O}(h^2)$
- b)  $f'(0) = a_1f(0) + a_2f(-h) + a_3f(-2h) + \mathcal{O}(h^2)$
- c)  $f'(0) = a_1f(-h_1) + a_2f(0) + a_3f(h_2) + \mathcal{O}(h^2)$ ,  $|h_1|, |h_2| = \mathcal{O}(h)$

**E 8.1.4.** As tensões na entrada,  $v_i$ , e saída,  $v_o$ , de um amplificador foram medidas em regime estacionário conforme tabela abaixo.

0,0	0,50	1,00	1,50	2,00	2,50	3,00	3,50	4,00	4,50	5,00
0,0	1,05	1,83	2,69	3,83	4,56	5,49	6,56	6,11	7,06	8,29

onde a primeira linha é a tensão de entrada em volts e a segunda linha é tensão de saída em volts. Sabendo que o ganho é definido como

$$\frac{\partial v_o}{\partial v_i}.$$

Calcule o ganho quando  $v_i = 1$  e  $v_i = 4.5$  usando as seguintes técnicas:

- a) Derivada primeira numérica de primeira ordem usando o próprio ponto e o próximo.
- b) Derivada primeira numérica de primeira ordem usando o próprio ponto e o anterior.
- c) Derivada primeira numérica de segunda ordem usando o ponto anterior e o próximo.
- d) Derivada primeira analítica da função do tipo  $v_o = a_1v_i + a_3v_i^3$  que melhor se ajusta aos pontos pelo critério dos mínimos quadrados.

Caso	a	b	c	d
$v_i = 1$				
$v_i = 4.5$				

**E 8.1.5.** Estude o comportamento da derivada de  $f(x) = e^{-x^2}$  no ponto  $x = 1,5$  quando  $h$  fica pequeno.



## 8.2 Diferença finita para derivada segunda

Para aproximar a derivada segunda, considere as expansões em série de Taylor

$$f(x_0 + h) = f(x_0) + hf'(x_0) + \frac{h^2}{2}f''(x_0) + \frac{h^3}{6}f'''(x_0) + O(h^4)$$

$$f(x_0 - h) = f(x_0) - hf'(x_0) + \frac{h^2}{2}f''(x_0) - \frac{h^3}{6}f'''(x_0) + O(h^4).$$

Somando as duas expressões, temos:

$$f(x_0 + h) + f(x_0 - h) = 2f(x_0) + h^2 f''(x_0) + O(h^4)$$

ou seja, uma aproximação de segunda ordem para a derivada segunda em  $x_0$  é

$$f''(x_0) = \frac{f(x_0 + h) - 2f(x_0) + f(x_0 - h)}{h^2} + \mathcal{O}(h^2) := D_{0,h}^2 f(x_0) + \mathcal{O}(h^2),$$

onde

$$D_{0,h}^2 f(x_0) = \frac{f(x_0 + h) - 2f(x_0) + f(x_0 - h)}{h^2}.$$

**Exemplo 8.2.1.** Calcule a derivada segunda numérica de  $f(x) = e^{-x^2}$  em  $x = 1,5$  para  $h = 0,1$ ,  $h = 0,01$  e  $h = 0,001$ .

**Solução.** A tabela mostra os resultados:

$h$	$h = 0,1$	$h = 0,01$	$h = 0,001$
$D_{0,h}^2 f(1,5)$	0,7364712	0,7377814	0,7377944

Observe que  $f''(x) = (4x^2 - 2)e^{-x^2}$  e  $f''(1,5) = 0,7377946$ .

◇

## 8.3 Diferenças finitas de ordem mais alta

Para aproximar a derivada de uma função  $f(x)$  em  $x_0$ ,  $x_1$  ou  $x_2$  usaremos os três pontos vizinhos  $(x_0, f(x_0))$ ,  $(x_1, f(x_1))$  e  $(x_2, f(x_2))$ . Uma interpolação usando polinômios de Lagrange para esses três pontos é da forma:

$$\begin{aligned} f(x) &= f(x_0) \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} + f(x_1) \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} \\ &+ f(x_2) \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} + \frac{f'''(\xi(x))}{6} (x - x_0)(x - x_1)(x - x_2). \end{aligned}$$

A derivada de  $f(x)$  é

$$\begin{aligned}
 f'(x) &= f(x_0) \frac{2x - x_1 - x_2}{(x_0 - x_1)(x_0 - x_2)} + f(x_1) \frac{2x - x_0 - x_2}{(x_1 - x_0)(x_1 - x_2)} \\
 &\quad + f(x_2) \frac{2x - x_0 - x_1}{(x_2 - x_0)(x_2 - x_1)} \\
 &\quad + \frac{f'''(\xi(x))}{6} ((x - x_1)(x - x_2) + (x - x_0)(2x - x_1 - x_2)) \\
 &\quad + D_x \left( \frac{f'''(\xi(x))}{6} \right) (x - x_0)(x - x_1)(x - x_2).
 \end{aligned} \tag{8.5}$$

Trocando  $x$  por  $x_0$ , temos

$$\begin{aligned}
 f'(x_0) &= f(x_0) \frac{2x_0 - x_1 - x_2}{(x_0 - x_1)(x_0 - x_2)} + f(x_1) \frac{2x_0 - x_0 - x_2}{(x_1 - x_0)(x_1 - x_2)} \\
 &\quad + f(x_2) \frac{2x_0 - x_0 - x_1}{(x_2 - x_0)(x_2 - x_1)} \\
 &\quad + \frac{f'''(\xi(x_0))}{6} ((x_0 - x_1)(x_0 - x_2) + (x_0 - x_0)(2x_0 - x_1 - x_2)) \\
 &\quad + D_x \left( \frac{f'''(\xi(x_0))}{6} \right) (x_0 - x_0)(x_0 - x_1)(x_0 - x_2).
 \end{aligned}$$

Considerando uma malha equiespaçada onde  $x_1 = x_0 + h$  e  $x_2 = x_0 + 2h$ , temos:

$$\begin{aligned}
 f'(x_0) &= f(x_0) \frac{-3h}{(-h)(-2h)} + f(x_1) \frac{-2h}{(h)(-h)} \\
 &\quad + f(x_2) \frac{-h}{(2h)(h)} + \frac{f'''(\xi(x_0))}{6} ((-h)(-2h)) \\
 &= \frac{1}{h} \left[ -\frac{3}{2}f(x_0) + 2f(x_1) - \frac{1}{2}f(x_2) \right] + h^2 \frac{f'''(\xi(x_0))}{3}
 \end{aligned}$$

Similarmente, trocando  $x$  por  $x_1$  ou trocando  $x$  por  $x_2$  na expressão (8.5), temos outras duas expressões

$$\begin{aligned}
 f'(x_1) &= \frac{1}{h} \left[ -\frac{1}{2}f(x_0) + \frac{1}{2}f(x_2) \right] + h^2 \frac{f'''(\xi(x_1))}{6} \\
 f'(x_2) &= \frac{1}{h} \left[ \frac{1}{2}f(x_0) - 2f(x_1) + \frac{3}{2}f(x_2) \right] + h^2 \frac{f'''(\xi(x_2))}{3}
 \end{aligned}$$

Podemos reescrever as três fórmulas da seguinte forma:

$$\begin{aligned} f'(x_0) &= \frac{1}{h} \left[ -\frac{3}{2}f(x_0) + 2f(x_0 + h) - \frac{1}{2}f(x_0 + 2h) \right] + h^2 \frac{f'''(\xi(x_0))}{3} \\ f'(x_0 + h) &= \frac{1}{h} \left[ -\frac{1}{2}f(x_0) + \frac{1}{2}f(x_0 + 2h) \right] + h^2 \frac{f'''(\xi(x_0 + h))}{6} \\ f'(x_0 + 2h) &= \frac{1}{h} \left[ \frac{1}{2}f(x_0) - 2f(x_0 + h) + \frac{3}{2}f(x_0 + 2h) \right] + h^2 \frac{f'''(\xi(x_0 + 2h))}{3} \end{aligned}$$

ou ainda

$$f'(x_0) = \frac{1}{2h} [-3f(x_0) + 4f(x_0 + h) - f(x_0 + 2h)] + h^2 \frac{f'''(\xi(x_0))}{3} \quad (8.6)$$

$$f'(x_0) = \frac{1}{2h} [f(x_0 + h) - f(x_0 - h)] + h^2 \frac{f'''(\xi(x_0))}{6} \quad (8.7)$$

$$f'(x_0) = \frac{1}{2h} [f(x_0 - 2h) - 4f(x_0 - h) + 3f(x_0)] + h^2 \frac{f'''(\xi(x_0))}{3} \quad (8.8)$$

Observe que uma das fórmulas é exatamente as diferenças centrais obtida anteriormente.

Analogamente, para construir as fórmulas de cinco pontos tomamos o polinômio de Lagrange para cinco pontos e chegamos a cinco fórmulas, sendo uma delas a seguinte:

$$f'(x_0) = \frac{1}{12h} [f(x_0 - 2h) - 8f(x_0 - h) + 8f(x_0 + h) - f(x_0 + 2h)] + \frac{h^4}{30} f^{(5)}(\xi(x_0)) \quad (8.9)$$

**Exemplo 8.3.1.** Calcule a derivada numérica de  $f(x) = e^{-x^2}$  em  $x = 1,5$  pelas fórmulas de três e cinco pontos para  $h = 0,1$ ,  $h = 0,01$  e  $h = 0,001$ .

**Solução.** No Scilab, podemos computar estas derivadas numéricas com  $h = 0.1$  da seguinte forma:

```
--> deff('y=f(x)', 'y=exp(-x^2)')
--> x=1.5
--> h=0.1
--> //progressivas de ordem 1
--> dp1 = (f(x+h)-f(x))/h
--> //regressivas de ordem 1
--> dr1 = (f(x)-f(x-h))/h
--> //central de ordem 2
--> dc2 = (f(x+h)-f(x-h))/(2*h)
--> //progressivas de ordem 2
```

Diferenças Finitas	$h = 0,1$	0,01	0,001
Progressiva $\mathcal{O}(h)$	-0,2809448	-0,3125246	-0,3158289
Regressiva $\mathcal{O}(h)$	-0,3545920	-0,3199024	-0,3165667
Progressiva $\mathcal{O}(h^2)$	-0,3127746	-0,3161657	-0,3161974
Central $\mathcal{O}(h^2)$	-0,3177684	-0,3162135	-0,3161978
Regressiva $\mathcal{O}(h^2)$	-0,3135824	-0,3161665	-0,3161974
Central $\mathcal{O}(h^4)$	-0,3162384	-0,3161977	-0,31619767

Tabela 8.1: Derivadas numéricas de  $f(x) = e^{-x^2}$  em  $x = 1,5$ . Veja o exemplo 8.3.1.

```
--> dp2 = (-3*f(x)+4*f(x+h)-f(x+2*h))/(2*h)
--> //regressivas de ordem 2
--> dr2 = (f(x-2*h)-4*f(x-h)+3*f(x))/(2*h)
--> //central de ordem 4
--> dc4 = (f(x-2*h)-8*f(x-h)+8*f(x+h)-f(x+2*h))/(12*h)
```

e, análogo, para  $h = 0.01$  e  $h = 0.001$ . O valor analítico da derivada é  $f'(1,5) \approx -0,3161976736856$ . A tabela 8.1 mostra os resultados computados com as derivadas numéricas.

◇

## Exercícios

Em construção ... Gostaria de colaborar na escrita deste livro? Veja como em:

<http://www.ufrgs.br/numerico>

## 8.4 Fórmulas de diferenças finitas

Veremos nessa seção uma outra maneira de obter fórmulas de diferenças finitas para derivadas de qualquer ordem de tal forma que elas possuam alta ordem de precisão.

Dados  $n + 1$  pontos  $[x_1, x_2, \dots, x_n]$ , queremos obter uma aproximação para a derivada de  $f(x)$  calculada em  $x^*$  do tipo

$$f'(x^*) \approx c_1 f(x_1) + c_2 f(x_2) + \dots + c_n f(x_n) \quad (8.10)$$

que seja exata para polinômios até ordem  $n - 1$ .

Seja  $q(x) = c_1\phi_1(x) + c_2\phi_2(x) + \dots + c_n\phi_n(x)$  o polinômio de ordem  $n$  que aproxima  $f(x)$ . Fixe a base  $\phi_k(x) = x^k$ . Como a regra (8.10) deve ser exata para qualquer  $q(x)$  até ordem  $n-1$ , então também deve ser exata para qualquer função da base. Substituindo  $f(x)$  por  $\phi_1(x) = 1$  em (8.10) obtemos

$$\phi_1'(x)|_{x^*} = (1)'|_{x^*} = \quad (8.11)$$

$$0 = c_1\phi_1(x_1) + c_2\phi_1(x_2) + \dots + c_n\phi_1(x_n) \quad (8.12)$$

$$0 = c_1 + c_2 + \dots + c_n \quad (8.13)$$

Da mesma forma para  $k = 1, \dots, n-1$ , obtemos

$$(x)'_{x^*} = 1 = c_1x_1 + c_2x_2 + \dots + c_nx_n \quad (8.14)$$

$$(x^2)'_{x^*} = 2x^* = c_1x_1^2 + c_2x_2^2 + \dots + c_nx_n^2 \quad (8.15)$$

$$(x^3)'_{x^*} = 3(x^*)^2 = c_1x_1^3 + c_2x_2^3 + \dots + c_nx_n^3 \quad (8.16)$$

$$\vdots = \vdots \quad (8.17)$$

$$(x^{n-1})'_{x^*} = (n-1)(x^*)^{n-2} = c_1x_1^{n-1} + c_2x_2^{n-1} + \dots + c_nx_n^{n-1} \quad (8.18)$$

que pode ser escrito na forma matricial

$$\begin{pmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_n \\ x_1^2 & x_2^2 & \dots & x_n^2 \\ \vdots & \vdots & & \vdots \\ x_1^{n-1} & x_2^{n-1} & \dots & x_n^{n-1} \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ c_3 \\ \vdots \\ c_n \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 2x^* \\ \vdots \\ (n-1)(x^*)^{n-2} \end{pmatrix} \quad (8.19)$$

Resolvendo o sistema obtemos os coeficientes  $c_k$  para a regra de diferenciação.

**Exemplo 8.4.1.** Sejam  $[x_1, x_2, x_3] = [-h, 0, h]$  e  $x^* = x_2 = 0$ , obtenha uma regra de diferenciação para aproximar  $f'(x^*)$ .

**Solução.** A regra terá a forma

$$f'(x^*) \approx c_1f(x_1) + c_2f(x_2) + c_3f(x_3) \quad (8.20)$$

$$\approx c_1f_1 + c_2f_2 + c_3f_3 \quad (8.21)$$

Considere a base polinomial  $[\phi_1(x), \phi_2(x), \phi_3(x)] = [1, x, x^2]$  e substitua  $f(x)$  por  $\phi_k(x)$  obtendo

$$(1)'_{x=0} = 0 = c_1(1) + c_2(1) + c_3(1) \quad (8.22)$$

$$(x)'_{x=0} = 1 = c_1(-h) + c_2(0) + c_3(h) \quad (8.23)$$

$$(x^2)'_{x=0} = 0 = c_1(-h)^2 + c_2(0)^2 + c_3(h)^2 \quad (8.24)$$

que pode ser escrito na forma matricial

$$\begin{pmatrix} 1 & 1 & 1 \\ -h & 0 & h \\ h^2 & 0 & h^2 \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ c_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad (8.25)$$

Resolvendo o sistema obtemos  $[c_1, c_2, c_3] = [-\frac{1}{2h}, 0, \frac{1}{2h}]$  fornecendo a regra

$$f'|_{x=x_1} \approx -\frac{1}{2h}f_1 + \frac{1}{2h}f_3 \quad (8.26)$$

$$\approx \frac{f_3 - f_1}{2h} \quad (8.27)$$

◇

**E 8.4.1.** Seja  $[x_0, x_1, x_2] = [0, h, 2h]$  e  $x^* = x_0 = 0$ , obtenha uma regra unilateral de diferenciação para aproximar  $f'(x_0)$ .

**E 8.4.2.** Seja  $[x_0, x_1, x_2] = [-h, 0, h]$  e  $x^* = x_1 = 0$ , obtenha uma regra de diferenciação para aproximar  $f''(x^*)$ .

**E 8.4.3.** Seja  $[x_0, x_1, \dots, x_4] = [-2h, -h, 0, h, 2h]$  e  $x^* = 0$ , obtenha uma regra de diferenciação para aproximar  $f'(x^*)$ .

**E 8.4.4.** Seja  $[x_0, x_1, \dots, x_4] = [-2h, -h, 0, h, 2h]$  e  $x^* = 0$ , obtenha uma regra de diferenciação para aproximar  $f''(x^*)$ .

**E 8.4.5.** Seja  $[x_0, x_1, \dots, x_4] = [0, h, 3h, 6h, 10h]$  e  $x^* = 0$ , obtenha uma regra de diferenciação para aproximar  $f'(x^*)$ .

## Exercícios

**E 8.4.6.** Use a expansão da função  $f(x)$  em torno de  $x = 0$  em polinômios de Taylor para encontrar os coeficientes  $a_1$ ,  $a_2$  e  $a_3$  tais que

a)  $f''(0) = a_1f(0) + a_2f(h) + a_3f(2h) + \mathcal{O}(h)$

b)  $f''(0) = a_1f(0) + a_2f(-h) + a_3f(-2h) + \mathcal{O}(h)$

## 8.5 Derivada via ajuste ou interpolação

Dado os valores de uma função em pontos  $\{(x_i, y_i)\}_{i=1}^N$ , as derivadas  $\left(\frac{dy}{dx}\right)_i$  podem ser obtidas através da derivada de uma curva que melhor ajusta ou interpola os pontos. Esse tipo de técnica é necessário quando os pontos são muito espaçados entre si ou quando a função oscila muito. Por exemplo, dado os pontos (0,1), (1,2), (2,5), (3,9), a parábola que melhor ajusta os pontos é

$$Q(x) = 0,95 + 0,45x + 0,75x^2.$$

Usando esse ajuste para calcular as derivadas, temos:


$$Q'(x) = 0,45 + 1,5x$$

e

$$\begin{aligned} y'(x_1) \approx Q'(x_1) &= 0,45, & y'(x_2) \approx Q'(x_2) &= 1,95, \\ y'(x_3) \approx Q'(x_3) &= 3,45 & \text{e} & y'(x_4) \approx Q'(x_4) &= 4,95 \end{aligned}$$

Agora olhe o gráfico da seguinte tabela de pontos.

x	y
0	1,95
1	1,67
2	3,71
3	3,37
4	5,12
5	5,79
6	7,50
7	7,55
8	9,33
9	9,41
10	11,48



Observe que as derivadas calculadas por diferenças finitas oscilam entre um valor pequeno e um grande em cada intervalo e além disso, a fórmula progressiva difere da regressiva significativamente. Por exemplo, por diferenças regressivas  $f'(7) \approx \frac{(7,55-7,50)}{1} = 0,05$  e por diferenças progressivas  $f'(7) \approx \frac{(9,33-7,55)}{1} = 1,78$ . A melhor forma de calcular a derivada aqui é fazer um ajuste de curva. A reta que melhor ajusta os dados da tabela é  $y = f(x) = 1,2522727 + 0,9655455x$ . Usando esse ajuste, temos  $f'(7) \approx 0,9655455$ .

## Exercícios

Em construção ... Gostaria de colaborar na escrita deste livro? Veja como em:

<http://www.ufrgs.br/numerico>

## 8.6 Exercícios finais

Em construção ... Gostaria de colaborar na escrita deste livro? Veja como em:

<http://www.ufrgs.br/numerico>



# Capítulo 9

## Integração Numérica

Neste capítulo discutiremos técnicas numéricas para aproximar **integrais** definidas de funções reais.

Considere o problema de calcular (ou estimar) a integral de  $f(x)$  no intervalo  $[a, b]$ , ou seja,

$$I = \int_a^b f(x) \, dx.$$

Uma maneira de estimar esta integral numericamente consiste em subdividir o intervalo  $[a, b]$  em  $n - 1$  intervalos a partir de um conjunto ordenado de pontos  $a = x_1 < x_2 < \dots < x_n = b$ . Em cada intervalo  $i$ , a integral será aproximada por  $\Delta S_i$  e a integral será aproximada por

$$I \approx S = \sum_{i=1}^{n-1} \Delta S_i$$

O tamanho de cada intervalo é dado por  $h_i = x_{i+1} - x_i$ . No caso uniforme, todos os intervalos possuem o mesmo tamanho  $h = h_i = \frac{b-a}{n}$ .

Nas próximas seções apresentaremos formas diferentes de aproximar  $\Delta S_i$  iniciando com o caso mais simples que é um retângulo. Cada uma das regras obtidas também é chamada de quadratura.

**Exemplo 9.0.1.** A figura 9.1 mostra um exemplo quando  $f(x) = x^2 + 1$ ,  $0 \leq x \leq 2$ . Temos a aproximação por um retângulo com base  $h_1 = 2$ , depois com dois retângulos de base  $h_2 = 1$  e, finalmente com quatro retângulos de bases  $h_3 = 0,5$ .

Os valores aproximados para a integral são dados na seguinte tabela:



Figura 9.1: Aproximação por retângulos.

	$\int_0^2 (x^2 + 1) dx$
$h_1 = 2$	$h_1 f(1) = 4$
$h_2 = 1$	$h_2 f(0,5) + h_2 f(1,5) = 4,5$
$h_3 = 0,5$	4,625
$h_4 = 0,25$	4,65625

Observe que:

$$\int_0^2 (x^2 + 1) dx = \left[ \frac{x^3}{3} + x \right]_0^2 = \frac{8}{3} + 2 = 4,6666667$$

## 9.1 Regras de Newton-Cotes

O método básico para encontrar as regras de integração consiste em aproximar a integral de  $f$  por uma combinação linear de  $n$  valores<sup>1</sup> de  $f_i := f(x_i)$ , ou seja,

$$I = \int_a^b f(x) dx \approx \sum_{i=1}^n A_i f_i.$$

Podemos obter os coeficientes  $A_i$  aproximando a função  $f$  pelo polinômio de Lagrange  $p_n$  que interpola  $\{(x_i, f_i)\}_{i=1}^n$ , tal que,

$$f(x) = p_n(x) + E_{LAG}^n(x) \quad (9.1)$$

$$= \sum_{i=1}^n f_i L_i(x) + E_{LAG}^n(x) \quad (9.2)$$

onde o erro na interpolação de Lagrange é

$$E_{LAG}^n(x) = \frac{f^{(n)}(\xi(x))}{n!} \prod_{i=1}^n (x - x_i). \quad (9.3)$$

Substituindo na integral obtemos

$$\int_a^b f(x) dx = \sum_{i=1}^n \left[ f_i \int_a^b L_i(x) dx \right] + \int_a^b E_{LAG}^n(x) dx. \quad (9.4)$$

A fórmula de quadratura é então

$$\int_a^b f(x) dx \approx \sum_{i=1}^n A_i f_i, \quad (9.5)$$

onde

$$A_i = \int_a^b L_i(x) dx. \quad (9.6)$$

<sup>1</sup>Utilizaremos neste capítulo a notação  $f_i$  para indicar  $f(x_i)$ .

### 9.1.1 Somas de Riemann

O método mais simples de aproximar

$$I = \int_a^b f(x) dx.$$

com apenas um intervalo, é aproximar  $f(x)$  por um polinômio constante no intervalo  $[a, b]$ , ou seja,  $f(x) = c$ . Se aproximarmos  $f(x)$  pelo ponto a esquerda do intervalo temos que  $f(x) \approx f(a)$  e

$$I = \int_a^b f(x) dx \approx \int_a^b f(a) dx \quad (9.7)$$

$$= f(a) \int_a^b dx = f(a)(b - a) \quad (9.8)$$

Esta é a regra de quadratura local para 1 intervalo.

Quando subdividimos  $[a, b]$  em  $n$  intervalos com tamanho  $h = (b - a)/n$  nos pontos  $x_i = a + (i - 1)h$ , em cada intervalo  $i$  aproximamos a área por

$$\Delta S_i \approx f(x_i)h$$

tal que a área total será aproximada pelas **somas de Riemann à esquerda**

$$S = \sum_{i=1}^{n-1} \Delta S_i = \sum_{i=1}^{n-1} f(x_i)h$$

Podemos obter uma fórmula similar se usarmos os pontos a direita do intervalo, ou seja, as **somas de Riemann à direita**

$$S = \sum_{i=1}^{n-1} f(x_{i+1})h$$

Uma terceira opção é utilizar o ponto médio do intervalo  $[x_i, x_{i+1}]$  o qual fornece a **regra do ponto médio**

$$S = \sum_{i=1}^{n-1} f(\xi_i)h, \quad \xi_i = \frac{x_i + x_{i+1}}{2}. \quad (9.9)$$

### 9.1.2 Regra do trapézio

A regra do trapézio consiste em aproximar a função  $f(x)$  por um polinômio de grau 1. Se utilizarmos uma reta ligando extremos do intervalo obtemos um trapézio que fornece o nome da regra.

Desta forma, utilizando  $x_1 := a$ ,  $x_2 := b$ ,  $h = x_2 - x_1$  e a notação  $f_i = f(x_i)$  obtemos através da interpolação de Lagrange o polinômio

$$p_1(x) = f_1 L_1(x) + f_2 L_2(x) \quad (9.10)$$

Aproximando  $f(x)$  por  $p_1(x)$  e integrando obtemos

$$\begin{aligned} \int_a^b f(x) dx &\approx \int_a^b p_1(x) dx \\ &= \int_a^b f_1 L_1(x) + f_2 L_2(x) dx \\ &= f_1 \int_a^b L_1(x) dx + f_2 \int_a^b L_2(x) dx \\ &= A_1 f_1 + A_2 f_2 \end{aligned}$$

onde

$$\begin{aligned} A_1 &= \int_a^b \frac{x - x_2}{x_1 - x_2} dx = \left[ \frac{(x - x_2)^2}{2(x_1 - x_2)} \right]_{x_1}^{x_2} \\ &= \frac{(x_2 - x_2)^2}{2(x_1 - x_2)} - \frac{(x_1 - x_2)^2}{2(x_1 - x_2)} = \frac{0 - h^2}{2(-h)} = \frac{h^2}{2h} = \frac{1}{2}h \end{aligned}$$

Da mesma forma,

$$A_2 = \int_a^b \frac{(x - x_1)}{(x_2 - x_1)} dx = \frac{1}{2}h$$

de onde obtemos a **regra do trapézio** dada por

$$\int_a^b f(x) dx \approx \left( \frac{1}{2}f_1 + \frac{1}{2}f_2 \right) h \quad (9.11)$$

### Erro na regra do trapézio

O *erro na regra do trapézio* pode ser obtida integrando o erro da interpolação de Lagrange,

$$E_{TRAP} = \int_a^b E_{LAG}^2(x) dx = \int_a^b \frac{f''(\xi(x))}{2!} (x - x_1)(x - x_2) dx$$

Pelo teorema do valor médio, existe  $a \leq \eta \leq b$  tal que

$$E_{TRAP} = \frac{f''(\eta)}{2!} \int_a^b (x - x_1)(x - x_2) dx,$$

portanto

$$\begin{aligned}
 E_{TRAP} &= \frac{f''(\eta)}{2} \left[ \frac{x^3}{3} - \frac{x^2}{2}(x_2 + x_1) + x_1 x_2 x \right]_{x_1}^{x_2} \\
 &= \frac{f''(\eta)}{2} \left( \frac{x_2^3}{3} - \frac{x_2^2}{2}(x_2 + x_1) + x_1 x_2 x_2 - \frac{x_1^3}{3} + \frac{x_1^2}{2}(x_2 + x_1) - x_1 x_2 x_1 \right) \\
 &= \frac{f''(\eta)}{2} \frac{2x_2^3 - 3x_2^2(x_2 + x_1) + 6x_2^2 x_1 - 2x_1^3 + 3x_1^2(x_2 + x_1) - 6x_2 x_1^2}{6} \\
 &= \frac{f''(\eta)}{12} (x_1^3 - 3x_1^2 x_2 + 3x_2^2 x_1 - x_2^3) = \frac{f''(\eta)}{12} (x_1 - x_2)^3 \\
 &= -\frac{f''(\eta)}{12} h^3.
 \end{aligned}$$

Assim, o erro na regra do trapézio é

$$E_{TRAP} = -\frac{f''(\eta)}{12} h^3 = \mathcal{O}(h^3).$$

**Exemplo 9.1.1.** Use a regra do trapézio para aproximar a integral

$$\int_0^1 e^{-x^2} dx.$$

Depois divida a integral em duas

$$\int_0^{1/2} e^{-x^2} dx + \int_{1/2}^1 e^{-x^2} dx.$$

e aplique a regra do trapézio em cada uma delas. Finalmente, repita o processo dividindo em quatro integrais.

Usando o intervalo  $[0,1]$ , temos  $h = 1$ ,  $x_0 = 0$  e  $x_1 = 1$ . A regra do trapézio resulta em

$$\int_0^1 e^{-x^2} dx \approx \frac{1}{2}(e^0 + e^{-1}) = 0,6839397$$

Usando dois intervalos,  $[0,1/2]$  e  $[1/2,1]$  e usando a regra do trapézio em cada um dos intervalos, temos:

$$\begin{aligned}
 \int_0^1 e^{-x^2} dx &\approx \frac{0,5}{2} (e^0 + e^{-1/4}) + \frac{0,5}{2} (e^{-1/4} + e^{-1}) \\
 &= 0,4447002 + 0,2866701 = 0,7313703.
 \end{aligned}$$

Agora, usando quatro intervalos, temos

$$\begin{aligned}
 \int_0^1 e^{-x^2} dx &\approx \frac{0,25}{2} (e^0 + e^{-1/16}) + \frac{0,25}{2} (e^{-1/16} + e^{-1/4}) \\
 &+ \frac{0,25}{2} (e^{-1/4} + e^{-9/16}) + \frac{0,25}{2} (e^{-9/16} + e^{-1}) \\
 &= 0,7429841
 \end{aligned}$$

### 9.1.3 Regra de Simpson

Na regra de Simpson aproximamos  $f$  por um polinômio de grau 2, portanto precisamos de três pontos do intervalo  $[a, b]$ . Utilizando, por definição,

$$x_1 := a, \quad x_2 := \frac{a+b}{2} \quad \text{e} \quad x_3 := b$$

com  $h = x_3 - x_1$ , podemos obter o polinômio de Lagrange

$$p_2(x) = f_1 L_1(x) + f_2 L_2(x) + f_3 L_3(x)$$

Aproximando  $f$  por  $p_2$  e integrando temos

$$\int_a^b f(x) dx \approx \int_a^b p_2(x) dx \quad (9.12)$$

$$= \int_a^b f_1 L_1(x) + f_2 L_2(x) + f_3 L_3(x) dx \quad (9.13)$$

$$= f_1 A_1 + f_2 A_2 + f_3 A_3 \quad (9.14)$$

onde

$$A_i = \int_a^b L_i(x) dx \quad (9.15)$$

Calculando essas integrais obtemos **a regra de Simpson**

$$\int_a^b f(x) dx = \left( \frac{1}{6} f(x_1) + \frac{4}{6} f(x_2) + \frac{1}{6} f(x_3) \right) h.$$

**Exemplo 9.1.2.** Obtenha os coeficientes  $A_i$  do método de Simpson integrando os polinômios de Lagrange  $L_i(x)$ .

Fazendo uma translação para a origem (subtraindo  $x_1$  de  $x_2$  e  $x_3$ )

$$\begin{aligned} A_1 &= \int_{x_1}^{x_3} \frac{(x - x_2)(x - x_3)}{(x_1 - x_2)(x_1 - x_3)} dx \\ &= \int_0^h \frac{(x - h/2)(x - h)}{(0 - h/2)(0 - h)} dx = \frac{2}{h^2} \int_0^h (x - h/2)(x - h) dx \\ &= \frac{2}{h^2} \int_0^h x^2 - \frac{3}{2}hx + \frac{h^2}{2} dx = \frac{2}{h^2} (x^3/3 - \frac{3}{4}hx^2 + \frac{h^2x}{2})_0^h \\ &= \frac{2}{h^2} (h^3/3 - \frac{3}{4}h^3 + \frac{h^3}{2}) = (\frac{2}{3} - \frac{3}{2} + 1)h \\ &= \frac{1}{6}h \end{aligned}$$

Apesar de longa, é apenas a integral de um polinômio de grau 2. De forma semelhante podemos obter

$$A_2 = \frac{4}{6}h, \quad A_3 = \frac{1}{6}h$$

## Erro na regra de Simpson

Se usarmos a mesma metodologia da regra dos trapézios, teremos

$$\int_a^b f(x) dx = \int_a^b p_2(x) dx + \int_a^b \frac{(x-x_1)(x-x_2)(x-x_3)}{6} f'''(\xi(x)) dx$$

e obteremos o fórmula de Simpson com um erro de quarta ordem. O fato é que a regra de Simpson tem ordem cinco e, para isso, usaremos uma abordagem alternativa.

Considere o polinômio de Taylor em  $x_2$ ,

$$f(x) = f(x_2) + f'(x_2)(x-x_2) + \frac{f''(x_2)}{2}(x-x_2)^2 + \frac{f'''(x_2)}{6}(x-x_2)^3 + \frac{f^{(4)}(\xi(x))}{24}(x-x_2)^4,$$

onde  $x_1 \leq \xi(x) \leq x_3$  e integre no intervalo  $[a, b] = [x_1, x_3]$ :

$$\begin{aligned} \int_a^b f(x) dx &= \left[ f(x_2)(x-x_2) + f'(x_2)\frac{(x-x_2)^2}{2} + \frac{f''(x_2)}{6}(x-x_2)^3 \right. \\ &\quad \left. + \frac{f'''(x_2)}{24}(x-x_2)^4 \right]_{x_1}^{x_3} \\ &\quad + \frac{1}{24} \int_{x_1}^{x_3} f^{(4)}(\xi(x))(x-x_2)^4 dx, \end{aligned}$$

Pelo teorema do valor médio, existe  $x_1 \leq \eta \leq x_3$  tal que

$$\begin{aligned} \int_a^b f(x) dx &= \left[ f(x_2)(x-x_2) + f'(x_2)\frac{(x-x_2)^2}{2} + \frac{f''(x_2)}{6}(x-x_2)^3 \right. \\ &\quad \left. + \frac{f'''(x_2)}{24}(x-x_2)^4 \right]_{x_1}^{x_3} \\ &\quad + \frac{f^{(4)}(\eta)}{24} \int_{x_1}^{x_3} (x-x_2)^4 dx \\ &= \left[ f(x_2)(x-x_2) + f'(x_2)\frac{(x-x_2)^2}{2} + \frac{f''(x_2)}{6}(x-x_2)^3 \right. \\ &\quad \left. + \frac{f'''(x_2)}{24}(x-x_2)^4 \right]_{x_1}^{x_3} \\ &\quad + \frac{f^{(4)}(\eta)}{120} \left[ (x-x_2)^5 \right]_{x_1}^{x_3} \end{aligned}$$

Usando o fato que

$$(x_3 - x_2)^3 - (x_1 - x_2)^3 = 2h^3,$$



$$(x_3 - x_2)^4 - (x_1 - x_2)^4 = 0$$

e

$$(x_3 - x_2)^5 - (x_1 - x_2)^5 = 2h^5,$$

temos

$$\int_a^b f(x) dx = hf(x_2) + \frac{h^3}{3}f''(x_2) + \frac{h^5 f^{(4)}(\eta)}{60}.$$

Usando a fórmula de diferenças finitas centrais para a derivada segunda:

$$f''(x_2) = \frac{f(x_1) - 2f(x_2) + f(x_3)}{h^2} + \frac{h^2}{12}f^{(4)}(\eta_2),$$

$x_1 \leq \eta_2 \leq x_3$ , temos

$$\begin{aligned} \int_a^b f(x) dx &= 2hf(x_2) + \frac{h^3}{3} \left( \frac{f(x_1) - 2f(x_2) + f(x_3)}{h^2} + \frac{h^2}{12}f^{(4)}(\eta_2) \right) \\ &+ \frac{h^5 f^{(4)}(\eta)}{60} \\ &= \frac{h}{3} (f(x_1) + 4f(x_2) + f(x_3)) - \frac{h^5}{12} \left( \frac{1}{3}f^{(4)}(\eta_2) - \frac{1}{5}f^{(4)}(\eta) \right). \end{aligned}$$

Pode-se mostrar que é possível escolher  $\eta_3$  que substitua  $\eta$  e  $\eta_2$  com a seguinte estimativa

$$\int_a^b f(x) dx = \frac{h}{3} (f(x_1) + 4f(x_2) + f(x_3)) - \frac{h^5}{90}f^{(4)}(\eta_3).$$

**Exemplo 9.1.3.** Use a regra de Simpson para aproximar a integral

$$\int_0^1 e^{-x^2} dx.$$

Depois divida a integral em duas

$$\int_0^{1/2} e^{-x^2} dx + \int_{1/2}^1 e^{-x^2} dx.$$

e aplica a regra de Simpson em cada uma delas.

Usando o intervalo  $[0,1]$ , temos  $h = 1/2$ ,  $x_0 = 0$ ,  $x_1 = 1/2$  e  $x_2 = 1$ . A regra de Simpson resulta em

$$\int_0^1 e^{-x^2} dx \approx \frac{0,5}{3}(e^0 + 4e^{-1/4} + e^{-1}) = 0,7471804$$

Usando dois intervalos,  $[0,1/2]$  e  $[1/2,1]$  e usando a regra do trapézio em cada um dos intervalos, temos:

$$\int_0^1 e^{-x^2} dx \approx \frac{0,25}{3}(e^0 + 4e^{-1/16} + e^{-1/4}) + \frac{0,25}{3}(e^{-1/4} + 4e^{-9/16} + e^{-1}) = 0,7468554$$

## Exercícios

**E 9.1.1.** Calcule numericamente as seguintes integrais:

$$\begin{aligned} \text{a)} \quad & \int_0^1 e^{-x} dx & \text{b)} \quad & \int_0^1 x^2 dx \\ \text{c)} \quad & \int_0^1 x^3 dx & \text{d)} \quad & \int_0^1 x e^{-x^2} dx \\ \text{e)} \quad & \int_0^1 \frac{1}{x^2+1} dx & \text{e)} \quad & \int_0^1 \frac{x}{x^2+1} dx \end{aligned}$$

usando os métodos simples do Ponto médio, Trapézio e Simpson. Calcule, também, o valor analítico destas integrais e o erro nas aproximações dadas pelas quadraturas numérica.

**E 9.1.2.** Dê a interpretação geométrica dos métodos do ponto médio, trapézio e Simpson. A partir desta construção geométrica, deduza as fórmulas para aproximar

$$\int_a^b f(x) dx.$$

Verifique o método de Simpson pode ser entendido como uma média aritmética ponderada entre os métodos de trapézio e ponto médio. Encontre os pesos envolvidos. Explique o que são os métodos compostos.

**E 9.1.3.** Calcule numericamente o valor de  $\int_2^5 e^{4-x^2} dx$  usando os métodos compostos do ponto médio, trapézio e Simpson. Obtenha os resultados utilizando, em cada quadratura, o número de pontos indicado.

n	Ponto médio	Trapézios	Simpson
3			
5			
7			
9			

## 9.2 Obtenção das regras de quadratura

Na seção anterior, obtivemos as regras de quadraturas pela aproximação do integrando por polinômios interpoladores de Lagrange. Aqui, veremos um outro

método para obter regras de quadratura, que torna-se bastante útil para quando temos muitos pontos ou quando o intervalo entre os pontos não é uniforme.

Dados  $n$  pontos  $[t_1, t_2, \dots, t_n]$ , queremos obter uma aproximação para

$$\int_a^b f(t) dt \approx w_1 f(t_1) + w_2 f(t_2) + \dots + w_n f(t_n) \quad (9.16)$$

que seja exata para polinômios<sup>2</sup> até ordem  $n - 1$ .

Aproxime  $f(t)$  pelo polinômio  $p(t) = w_1 \phi_1(t) + \dots + w_n \phi_n(t)$  de ordem  $n - 1$ . Escolha uma base, como por exemplo  $\phi_k(t) = t^{k-1}$ . Como a regra de quadratura deve ser exata para qualquer polinômio até ordem  $n - 1$ , então também deve ser exata para qualquer função da base. Substituindo  $f(t)$  por  $\phi_1(t) = 1$  em (9.16) obtemos

$$\int_a^b \phi_1(t) dt = t|_a^b = w_1 \phi_1(t_1) + w_2 \phi_1(t_2) + \dots + w_n \phi_1(t_n) \quad (9.17)$$

$$b - a = w_1 + w_2 + \dots + w_n \quad (9.18)$$

Da mesma forma para  $\phi_k(t)$ ,  $k = 2, \dots, n$ , obtemos

$$(t^2/2)|_a^b = \frac{b^2 - a^2}{2} = w_1 t_1 + w_2 t_2 + \dots + w_n t_n \quad (9.19)$$

$$(t^3/3)|_a^b = \frac{b^3 - a^3}{3} = w_1 t_1^2 + w_2 t_2^2 + \dots + w_n t_n^2 \quad (9.20)$$

$$\vdots = \vdots \quad (9.21)$$

$$\frac{b^n - a^n}{n} = w_1 t_1^{n-1} + w_2 t_2^{n-1} + \dots + w_n t_n^{n-1} \quad (9.22)$$

que pode ser escrito na forma matricial

$$\begin{bmatrix} 1 & 1 & \dots & 1 \\ t_1 & t_2 & \dots & t_n \\ t_1^2 & t_2^2 & \dots & t_n^2 \\ \vdots & \vdots & & \vdots \\ t_1^{n-1} & t_2^{n-1} & \dots & t_n^{n-1} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ \vdots \\ w_n \end{bmatrix} = \begin{bmatrix} b - a \\ \frac{b^2 - a^2}{2} \\ \frac{b^3 - a^3}{3} \\ \vdots \\ \frac{b^n - a^n}{n} \end{bmatrix} \quad (9.23)$$

Resolvendo o sistema obtemos os coeficientes  $w_k$  para a regra de integração.

**Exemplo 9.2.1.** Seja  $n = 3$ ,  $[a, b] = [0, h]$ , onde  $[t_1, t_2, t_3] = [0, h/2, h]$ . Obtenha uma regra de integração para aproximar  $\int_a^b f(t) dt$ .

<sup>2</sup>Por exemplo, se  $n = 2$ , então a regra é exata para retas.

**Solução.** A regra terá a forma

$$\int_a^b f(t) dt \approx w_1 f(t_1) + w_2 f(t_2) + w_3 f(t_3) \quad (9.24)$$

$$\approx w_1 f_1 + w_2 f_2 + w_3 f_3 \quad (9.25)$$

Considere a base polinomial  $[\phi_1(t), \phi_2(t), \phi_3(t)] = [1, t, t^2]$  e substitua  $f(t)$  por  $\phi_k(t)$  obtendo

$$\int_0^h 1 dt = h = w_1(1) + w_2(1) + w_3(1) \quad (9.26)$$

$$\int_0^h t dt = h^2/2 = w_1(0) + w_2(h/2) + w_3(h) \quad (9.27)$$

$$\int_0^h t^2 dt = h^3/3 = w_1(0)^2 + w_2(h/2)^2 + w_3(h)^2 \quad (9.28)$$

que pode ser escrito na forma matricial

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & h/2 & h \\ 0 & h^2/4 & h^2 \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix} = \begin{bmatrix} h \\ h^2/2 \\ h^3/3 \end{bmatrix} \quad (9.29)$$

Note que podemos simplificar  $h$  tal que o sistema fique

$$\begin{bmatrix} 1 & 1 & 1 \\ 0 & 1/2 & 1 \\ 0 & 1/4 & 1 \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ w_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 1/2 \\ 1/3 \end{bmatrix} \quad (9.30)$$

Resolvendo o sistema obtemos  $[w_1, w_2, w_3] = h[\frac{1}{6}, \frac{4}{6}, \frac{1}{6}]$  fornecendo a regra de Simpson

$$\int_0^h f(t) dt \approx \frac{h}{6} f_0 + \frac{4h}{6} f_1 + \frac{h}{6} f_2 \quad (9.31)$$

◇

### 9.3 Regras compostas

Vimos que em todas as estimativas de erro que derivamos, o erro depende do tamanho do intervalo de integração. Uma estratégia para reduzir o erro consiste em particionar o intervalo de integração em diversos subintervalos menores tal que

$$\int_a^b f(x) dx = \sum_{i=1}^n \int_{x_i}^{x_{i+1}} f(x) dx$$

onde  $a = x_1 < \dots < x_{n+1} = b$ , sendo  $n$  o número de subintervalos da partição do intervalo de integração. No caso uniforme  $x_i = a + (i - 1)h$ ,  $h = (b - a)/n$ .

Depois, aplica-se um método simples de integração em cada subintervalo,

$$\int_{x_i}^{x_{i+1}} f(x) dx \approx \Delta S_i$$

e a integral será aproximada por

$$\int_a^b f(x) dx \approx S = \sum_{i=1}^n \Delta S_i$$

### 9.3.1 Código Scilab: Regras compostas em geral

Devemos fazer um *loop* sobre todos os intervalos e para cada intervalo aplicamos uma regra de quadratura.

```
function S=simpson(a,b,n)
h=(b-a)/n // n numero de intervalos
x=linspace(a,b,n+1)

S=0
for i=1:n
    x1=x(i)
    x3=x(i+1)
    x2=x1+h/2
    A1 =1/6; A2 =4/6; A3=1/6
    dS =(A1*f(x1)+A2*f(x2)+A3*f(x3))*h
    S=S+dS
end
endfunction

function y=f(x)
    y=exp(x)
endfunction
```

Acumulamos o valor da integral em  $S$ . No código acima temos o método de Simpson, mas basta trocarmos a fórmula para termos outras quadraturas.

Note que esta não é a implementação mais eficiente, pois reutiliza os termos no contorno dos intervalos. Nas próximas seções veremos regras compostas específicas para alguns métodos.

### 9.3.2 Método composto dos trapézios

A regra composta dos trapézios assume a seguinte forma:

$$\begin{aligned}\int_a^b f(x) dx &= \sum_{i=1}^n \int_{x_i}^{x_{i+1}} f(x) dx \\ &\approx \sum_{i=1}^n \frac{x_{i+1} - x_i}{2} [f(x_i) + f(x_{i+1})]\end{aligned}$$

Como  $h = x_{i+1} - x_i$ , temos:

$$\begin{aligned}\int_a^b f(x) dx &\approx \frac{h}{2} \sum_{k=1}^{N_i} [f(x_k) + f(x_{k+1})] \\ &= \frac{h}{2} [f(x_1) + 2f(x_2) + 2f(x_3) + \cdots + 2f(x_{N_i}) + f(x_{N_i+1})] \\ &= \frac{h}{2} [f(x_1) + f(x_{N_i+1})] + h \sum_{i=2}^{N_i} f(x_i)\end{aligned}$$

### 9.3.3 Código Scilab: trapézio composto

O código Scilab abaixo é uma implementação do método do trapézio composto para calcular:

$$\int_a^b f(x) dx = \frac{h}{2} [f(x_1) + f(x_{n+1})] + h \sum_{i=2}^n f(x_i) + O(h^3),$$

onde  $h = (b-a)/n$  e  $x_i = a + (i-1)h$ ,  $i = 1, 2, \dots, n+1$ . Os parâmetros de entrada são: **f** o integrando definido como uma função no Scilab, **a** o limite inferior de integração, **b** o limite superior de integração, **n** o número de subintervalos desejado. A variável de saída é **y** e corresponde a aproximação calculada de  $\int_a^b f(x) dx$ .

```
function [y] = trap_comp(f,a,b,n)
    h = (b-a)/n
    x = linspace(a,b,n+1)
    y = h*(f(x(1)) + f(x(n+1)))/2
    for i = 2:n
        y = y + h*f(x(i))
    end
endfunction
```

### 9.3.4 Método composto de Simpson

Já a regra composta de Simpson assume a seguinte forma:

$$\begin{aligned}\int_a^b f(x) dx &= \sum_{k=1}^n \int_{x_k}^{x_{k+1}} f(x) dx \\ &\approx \sum_{k=1}^n \frac{x_{k+1} - x_k}{6} \left[ f(x_k) + 4f\left(\frac{x_{k+1} + x_k}{2}\right) + f(x_{k+1}) \right]\end{aligned}$$

onde, como anteriormente,  $x_k = a + (k-1)h$ ,  $h = (b-a)/n$  e  $i = 1, 2, \dots, n+1$ , sendo  $n$  o número de subintervalos da partição do intervalo de integração. Podemos simplificar o somatório acima, escrevendo:

$$\int_a^b f(x) dx \approx \frac{h}{3} \left[ f(x_1) + 2 \sum_{i=1}^{n-1} f(x_{2i+1}) + 4 \sum_{i=1}^n f(x_{2i}) + f(x_{2n+1}) \right] + O(h^5)$$

onde, agora,  $h = (b-a)/(2n)$ ,  $x_i = a + (i-1)h$ ,  $i = 1, 2, \dots, 2n+1$ .

### 9.3.5 Código Scilab: Simpson composto

O código Scilab abaixo é uma implementação do método de Simpson composto para calcular:

$$\int_a^b f(x) dx = \frac{h}{3} \left[ f(x_1) + 2 \sum_{i=1}^{n-1} f(x_{2i+1}) + 4 \sum_{i=1}^n f(x_{2i}) + f(x_{2n+1}) \right] + O(h^3),$$

onde  $h = (b-a)/(2n)$  e  $x_i = a + (i-1)h$ ,  $i = 1, 2, \dots, 2n+1$ . Os parâmetros de entrada são: **f** o integrando definido como uma função no Scilab, **a** o limite inferior de integração, **b** o limite superior de integração, **n** o número de subintervalos desejado. A variável de saída é **y** e corresponde a aproximação calculada de  $\int_a^b f(x) dx$ .

```
function [y] = simp_comp(f,a,b,n)
  h = (b-a)/(2*n)
  x = linspace(a,b,2*n+1)
  y = f(x(1))
  for i = 1:n-1
    y = y + 2*f(x(2*i+1))
  end
  for i = 1:n
    y = y + 4*f(x(2*i))
  end
end
```

```

y = y + f(x(2*n+1))
y = h*y/3
endfunction

```

**Exemplo 9.3.1.** Calcule numericamente a integral

$$\int_0^2 x^2 e^{x^2} dx$$

pelas regras compostas do ponto médio, trapézio e Simpson variando o número de intervalos  $n = 1, 2, 3, 6, 12, 24, 48$  e  $96$ .

**Solução.** As aproximações calculadas são apresentadas na seguinte tabela:

n	Ponto Médio	Trapézios	Simpson
1	5,4365637	218,3926	76,421909
2	21,668412	111,91458	51,750469
3	31,678746	80,272022	47,876505
6	41,755985	55,975384	46,495785
12	45,137529	48,865685	46,380248
24	46,057757	47,001607	46,372373
48	46,292964	46,529682	46,37187
96	46,352096	46,411323	46,371838

◇

## Exercícios

**E 9.3.1.** Use as rotinas construídas em aula e calcule numericamente o valor das seguintes integrais usando o método composto dos trapézios para os seguintes



números de pontos:

$n$	$h$	$\int_0^1 e^{-4x^2} dx$	$\int_0^1 \frac{1}{1+x^2} dx$	$\int_0^1 x^4(1-x)^4 dx$	$\int_0^1 e^{-\frac{1}{x^2+1}} dx$
17		0.4409931			
33		0.4410288			
65		0.4410377			
129		0.4410400			
257		0.4410405			
513		0.4410406			
1025		0.4410407	0.7853981	$1.5873015873016 \cdot 10^{-3}$	$4.6191723776309 \cdot 10^{-1}$

**E 9.3.2.** O valor exato da integral imprópria  $\int_0^1 x \ln(x) dx$  é dado por

$$\int_0^1 x \ln(x) dx = \left( \frac{x^2}{2} \ln x - \frac{x^2}{4} \right) \Big|_0^1 = -1/4$$

Aproxime o valor desta integral usando a regra de Simpson para  $n = 3$ ,  $n = 5$  e  $n = 7$ . Como você avalia a qualidade do resultado obtido? Por que isso acontece.

**E 9.3.3.** O valor exato da integral imprópria  $\int_0^\infty e^{-x^2} dx$  é dado por  $\frac{\sqrt{\pi}}{2}$ . Escreva esta integral como

$$I = \int_0^1 e^{-x^2} dx + \int_0^1 u^{-2} e^{-1/u^2} du = \int_0^1 \left( e^{-x^2} + x^{-2} e^{-1/x^2} \right) dx$$

e aproxime seu valor usando o esquema de trapézios e Simpson para  $n = 5$ ,  $n = 7$  e  $n = 9$ .

**E 9.3.4.** Estamos interessados em avaliar numericamente a seguinte integral:

$$\int_0^1 \ln(x) \sin(x) dx$$

cujo valor com 10 casas decimais corretas é  $-0.2398117420$ .

- a) Aproxime esta integral via Gauss-Legendre com  $n = 2, n = 3, n = 4, n = 5, n = 6$  e  $n = 7$ .

b) Use a identidade

$$\begin{aligned}\int_0^1 \ln(x) \sin(x) \, dx &= \int_0^1 \ln(x)x \, dx + \int_0^1 \ln(x) [\sin(x) - x] \, dx \\ &= \left( \frac{x^2}{2} \ln x - \frac{x^2}{4} \right) \Big|_0^1 + \int_0^1 \ln(x) [\sin(x) - x] \, dx \\ &= -\frac{1}{4} + \int_0^1 \ln(x) [\sin(x) - x] \, dx\end{aligned}$$

e aproxime a integral  $\int_0^1 \ln(x) [\sin(x) - x] \, dx$  numericamente via Gauss-Legendre com  $n = 2$ ,  $n = 3$ ,  $n = 4$ ,  $n = 5$ ,  $n = 6$  e  $n = 7$ .

c) Compare os resultados e discuta levando em consideração as respostas às seguintes perguntas: 1) Qual função é mais bem-comportada na origem? 2) Na segunda formulação, qual porção da solução foi obtida analiticamente e, portanto, sem erro de truncamento?

## 9.4 O método de Romberg

O método de Romberg é um método simplificado para construir quadraturas de alta ordem.

Considere o método de trapézios composto aplicado à integral

$$\int_a^b f(x) \, dx$$

Defina  $I(h)$  a aproximação desta integral pelo método dos trapézios composto com malha de largura constante igual a  $h$ . Aqui  $h = \frac{b-a}{N_i}$  para algum  $N_i$  inteiro, i.e.:

$$I(h) = \frac{h}{2} \left[ f(a) + 2 \sum_{j=2}^{N_i} f(x_j) + f(b) \right], \quad N_i = \frac{b-a}{h}$$

**Teorema 9.4.1.** *Se  $f(x)$  é uma função analítica no intervalo  $(a,b)$ , então a função  $I(h)$  admite uma representação na forma*

$$I(h) = I_0 + I_2 h^2 + I_4 h^4 + I_6 h^6 + \dots$$

Para uma demonstração, veja [4]. Em especial observamos que

$$\int_a^b f(x) \, dx = \lim_{h \rightarrow 0} I(h) = I_0$$

Ou seja, o valor exato da integral procurada é dado pelo coeficiente  $I_0$ .

A ideia central do método de Romberg, agora, consiste em usar a extrapolação de Richardson para construir métodos de maior ordem a partir do métodos dos trapézios para o intervalo  $(a,b)$

**Exemplo 9.4.1.** Construção do método de quarta ordem.

$$\begin{aligned} I(h) &= I_0 + I_2 h^2 + I_4 h^4 + I_6 h^6 + \dots \\ I\left(\frac{h}{2}\right) &= I_0 + I_2 \frac{h^2}{4} + I_4 \frac{h^4}{16} + I_6 \frac{h^6}{64} + \dots \end{aligned}$$

Usamos agora uma eliminação gaussiana para obter o termo  $I_0$ :

$$\frac{4I(h/2) - I(h)}{3} = I_0 - \frac{1}{4}I_4 h^4 - \frac{5}{16}I_6 h^6 + \dots$$

Vamos agora aplicar a fórmula para  $h = b - a$ ,

$$\begin{aligned} I(h) &= \frac{h}{2} [f(a) + f(b)] \\ I(h/2) &= \frac{h}{4} [f(a) + 2f(c) + f(b)], \quad c = \frac{a+b}{2} \end{aligned}$$

$$\begin{aligned} \frac{4I(h/2) - I(h)}{3} &= \frac{h}{3} [f(a) + 2f(c) + f(b)] - \frac{h}{6} [f(a) + f(b)] \\ &= \frac{h}{6} [f(a) + 4f(c) + f(b)] \end{aligned}$$

Observe que esquema coincide com o método de Simpson.

A partir de agora, usaremos a seguinte notação

$$\begin{aligned} R_{1,1} &= I(h) \\ R_{2,1} &= I(h/2) \\ R_{3,1} &= I(h/4) \\ &\vdots \\ R_{n,1} &= I(h/2^{n-1}) \end{aligned}$$

Observamos que os pontos envolvidos na quadratura  $R_{k,1}$  são os mesmos pontos envolvidos na quadratura  $R(k-1,1)$  acrescidos dos pontos centrais, assim, temos a seguinte fórmula de recorrência:

$$R_{k,1} = \frac{1}{2}R_{k-1,1} + \frac{h}{2^{k-1}} \sum_{i=1}^{2^{k-2}} f\left(a + (2i-1)\frac{h}{2^{k-1}}\right)$$

Definimos  $R_{k,2}$  para  $k \geq 2$  como o esquema de ordem quatro obtido da fórmula do exemplo 9.4.1:

$$R_{k,2} = \frac{4R_{k,1} - R_{k-1,1}}{3}$$

Os valores  $R_{k,2}$  representam então os valores obtidos pelo método de Simpson composto aplicado a uma malha composta de  $2^{k-1} + 1$  pontos.

Similarmente os valores de  $R_{k,j}$  são os valores obtidos pela quadratura de ordem  $2j$  obtida via extrapolação de Richardson. Pode-se mostrar que

$$R_{k,j} = R_{k,j-1} + \frac{R_{k,j-1} - R_{k-1,j-1}}{4^{j-1} - 1}.$$

**Exemplo 9.4.2.** Construa o esquema de Romberg para aproximar o valor de  $\int_0^2 e^{-x^2} dx$  com erro de ordem 8.

O que nos fornece os seguintes resultados:

55,59815	0,000000	0,000000	0,000000
30,517357	22,157092	0,000000	0,000000
20,644559	17,353626	17,033395	0,000000
17,565086	16,538595	16,484259	<b>16,475543</b>

Ou seja, temos:

$$\int_0^2 e^{-x^2} dx \approx 16,475543$$

usando uma aproximação de ordem 8.

**Exemplo 9.4.3.** Construa o esquema de Romberg para aproximar o valor de  $\int_0^2 x^2 e^{x^2} dx$  com erro de ordem 12.

O que nos fornece:

218,3926					
111,91458	76,421909				
66,791497	51,750469	50,105706			
51,892538	46,926218	46,604601	46,549028		
47,782846	46,412949	46,378731	46,375146	46,374464	
46,72661	46,374531	46,37197	46,371863	46,37185	<b>46,371847</b>

Ou seja, temos:

$$\int_0^2 x^2 e^{x^2} dx \approx 46,371847$$

com uma aproximação de ordem 12.

## Exercícios

**E 9.4.1.** Para cada integrando encontre o função  $I(h) = a_0 + a_1h + a_2h^2 + a_3h^3 + a_4h^4$  que melhor se ajusta aos dados, onde  $h = \frac{1}{n-1}$ . Discuta os resultados com base no teorema envolvido na construção do método de Romberg.

**E 9.4.2.** Calcule os valores da quadratura de Romberg de  $R_{1,1}$  até  $R_{4,4}$  para  $\int_0^\pi \sin(x) dx$ . Não use rotinas prontas neste problema.


**E 9.4.3.** Sem usar rotinas prontas, use o método de integração de Romberg para obter a aproximação  $R_{3,3}$  das seguintes integrais:

a)  $\int_0^1 e^{-x^2} dx$

b)  $\int_0^2 \sqrt{2 - \cos(x)} dx$

c)  $\int_0^2 \frac{1}{\sqrt{2 - \cos(x)}} dx$

**E 9.4.4.** Encontre uma expressão para  $R_{2,2}$  em termos de  $f(x)$  e verifique o método de Romberg  $R_{2,2}$  é equivalente ao método de Simpson.

**E 9.4.5.** Considere o problema de aproximar numericamente o valor de

$$\int_0^{100} \left( e^{\frac{1}{2} \cos(x)} - 1 \right) dx$$

pelo método de Romberg. Usando rotinas prontas, faça o que se pede.

- Calcule  $R(6,k)$ ,  $k = 1, \dots, 6$  e observe os valores obtidos.

- Calcule  $R(7, k)$ ,  $k = 1, \dots, 6$  e observe os valores obtidos.
- Calcule  $R(8, k)$ ,  $k = 1, \dots, 6$  e observe os valores obtidos.
- Discuta os resultados anteriores e proponha uma estratégia mais eficiente para calcular o valor da integral.

## 9.5 Ordem de precisão

Todos os métodos de quadratura que vimos até o momento são da forma

$$\int_a^b f(x) dx \approx \sum_{j=1}^N w_j f(x_j)$$

**Exemplo 9.5.1.** (a) Método do trapézio

$$\begin{aligned} \int_a^b f(x) dx &\approx [f(a) + f(b)] \frac{b-a}{2} \\ &= \frac{b-a}{2} f(a) + \frac{b-a}{2} f(b) \\ &:= w_1 f(x_1) + w_2 f(x_2) = \sum_{j=1}^2 w_j f(x_j) \end{aligned}$$

(b) Método do trapézio com dois intervalos

$$\begin{aligned} \int_a^b f(x) dx &\approx \left[ f(a) + 2f\left(\frac{a+b}{2}\right) + f(b) \right] \frac{b-a}{4} \\ &= \frac{b-a}{4} f(a) + \frac{b-a}{2} f\left(\frac{a+b}{2}\right) + \frac{b-a}{4} f(b) \\ &:= w_1 f(x_1) + w_2 f(x_2) + w_3 f(x_3) = \sum_{j=1}^3 w_j f(x_j) \end{aligned}$$

(c) Método de Simpson

$$\begin{aligned} \int_a^b f(x) dx &\approx \left[ f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right] \frac{b-a}{6} \\ &= \frac{b-a}{6} f(a) + \frac{2(b-a)}{3} f\left(\frac{a+b}{2}\right) + \frac{b-a}{6} f(b) \\ &:= \sum_{j=1}^3 w_j f(x_j) \end{aligned}$$

(d) Método de Simpson com dois intervalos

$$\begin{aligned}
 \int_a^b f(x) dx &\approx \left[ f(a) + 4f\left(\frac{3a+b}{4}\right) + 2f\left(\frac{a+b}{2}\right) \right. \\
 &\quad \left. + 4f\left(\frac{a+3b}{4}\right) + f(b) \right] \frac{b-a}{12} \\
 &= \frac{b-a}{12} f(a) + \frac{b-a}{3} f\left(\frac{3a+b}{4}\right) + \frac{b-a}{6} f\left(\frac{a+b}{2}\right) \\
 &\quad + \frac{b-a}{3} f\left(\frac{a+3b}{4}\right) + \frac{b-a}{12} f(b) \\
 &:= \sum_{j=1}^5 w_j f(x_j)
 \end{aligned}$$

A principal técnica que temos usado para desenvolver os métodos numéricos é o **polinômio de Taylor**:

$$f(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n + R_n(x)$$

Integrando termo a termo, temos:

$$\begin{aligned}
 \int_a^b f(x) dx &= \int_a^b a_0 dx + \int_a^b a_1x dx + \int_a^b a_2x^2 dx + \dots + \\
 &\quad \int_a^b a_nx^n dx + \int_a^b R_n(x) dx \\
 &= a_0(b-a) + a_1\frac{b^2-a^2}{2} + a_2\frac{b^3-a^3}{3} + \dots + \\
 &\quad a_n\frac{b^{n+1}-a^{n+1}}{n+1} + \int_a^b R_n(x) dx
 \end{aligned}$$

Neste momento, é natural investigar o desempenho de um esquema numérico aplicado a funções do tipo  $f(x) = x^n$ .

**Definição 9.5.1.** A ordem de precisão ou ordem de exatidão de um esquema de quadratura numérica como o maior inteiro positivo  $n$  para o qual o esquema é exato para todas as funções do tipo  $x^k$  com  $0 \leq k \leq n$ , ou seja, Um esquema é dito de ordem  $n$  se

$$\sum_{j=1}^n w_j f(x_j) = \int_a^b f(x) dx, \quad f(x) = x^k, \quad k = 0, 1, \dots, n$$

ou, equivalentemente:

$$\sum_{j=1}^n w_j x_j^k = \int_a^b x^k dx = \frac{b^{k+1} - a^{k+1}}{k+1}, \quad k = 0, 1, \dots, n$$

**Observação 9.5.1.** Se o método tem ordem 0 ou mais, então

$$\sum_{j=1}^n w_j = b - a$$

**Exemplo 9.5.2.** A ordem de precisão do esquema de trapézios é 1:

$$\int_a^b f(x) dx \approx [f(a) + f(b)] \frac{b-a}{2} = \sum_{j=1}^2 w_j f(x_j)$$

onde  $w_j = \frac{b-a}{2}$ ,  $x_1 = a$  e  $x_2 = b$ .

$$(k=0): \quad \sum_{j=1}^n w_j = b - a$$

$$(k=1): \quad \sum_{j=1}^n w_j x_j = (a+b) \frac{b-a}{2} = \frac{b^2-a^2}{2}$$

$$(k=2): \quad \sum_{j=1}^n w_j x_j^2 = (a^2+b^2) \frac{b-a}{2} \neq \frac{b^3-a^3}{3}$$

**Exemplo 9.5.3.** A ordem de precisão do esquema de Simpson é 3:

$$\int_a^b f(x) dx \approx \left[ f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right] \frac{b-a}{6} = \sum_{j=1}^3 w_j f(x_j)$$

onde  $w_1 = w_3 = \frac{b-a}{6}$ ,  $w_2 = 4\frac{b-a}{6}$ ,  $x_1 = a$ ,  $x_2 = \frac{a+b}{2}$  e  $x_3 = b$

$$(k=0): \quad \sum_{j=1}^n w_j = (1+4+1) \frac{b-a}{6} = b - a$$

$$(k=1): \quad \sum_{j=1}^n w_j x_j = (a + 4\frac{a+b}{2} + b) \frac{b-a}{6} = (a+b) \frac{b-a}{2} = \frac{b^2-a^2}{2}$$

$$(k=2): \quad \sum_{j=1}^n w_j x_j^2 = (a^2 + 4\left(\frac{a+b}{2}\right)^2 + b^2) \frac{b-a}{6} = \frac{b^3-a^3}{3}$$

$$(k=3): \quad \sum_{j=1}^n w_j x_j^3 = (a^3 + 4\left(\frac{a+b}{2}\right)^3 + b^3) \frac{b-a}{6} = \frac{b^4-a^4}{4}$$

$$(k=4): \quad \sum_{j=1}^n w_j x_j^4 = (a^4 + 4\left(\frac{a+b}{2}\right)^4 + b^4) \frac{b-a}{6} \neq \frac{b^5-a^5}{5}$$

**Exemplo 9.5.4.** Encontre os pesos  $w_j$  e as abscissas  $x_j$  tais que o esquema de dois pontos

$$\int_{-1}^1 f(x) dx = w_1 f(x_1) + w_2 f(x_2)$$

é de ordem 3.

**Solução.** Temos um sistema de quatro equações e quatro incógnitas dado por:

$$w_1 + w_2 = 2$$

$$x_1 w_1 + x_2 w_2 = 0$$

$$x_1^2 w_1 + x_2^2 w_2 = \frac{2}{3}$$

$$x_1^3 w_1 + x_2^3 w_2 = 0$$



Da segunda e quarta equação, temos:

$$\frac{w_1}{w_2} = -\frac{x_2}{x_1} = -\frac{x_2^3}{x_1^3}$$

Como  $x_1 \neq x_2$ , temos  $x_1 = -x_2$  e  $w_1 = w_2$ . Da primeira equação, temos  $w_1 = w_2 = 1$ . Da terceira equação, temos  $-x_1 = x_2 = \frac{\sqrt{3}}{3}$ .

Esse esquema de ordem de precisão três e dois pontos chama-se quadratura de Gauss-Legendre com dois pontos:

$$\int_{-1}^1 f(x) dx = f\left(\frac{\sqrt{3}}{3}\right) + f\left(-\frac{\sqrt{3}}{3}\right)$$

◇

### Exemplo 9.5.5. Comparação

$f(x)$	Exato	Trapézio	Simpson	Gauss-Legendre (2)
$e^x$	$e - e^{-1}$ $\approx 2,35040$	$e^{-1} + e$ $\approx 3,08616$	$\frac{e^{-1} + 4e^0 + e^1}{3}$ $\approx 2,36205$	$e^{-\frac{\sqrt{3}}{3}} + e^{\frac{\sqrt{3}}{3}}$ $\approx 2,34270$
$x^2\sqrt{3+x^3}$	$\frac{16}{9} - \frac{4}{9}\sqrt{2}$ $\approx 1,14924$	3,41421	1,13807	1,15411
$x^2e^{x^3}$	$\frac{e-e^{-1}}{3} \approx 0,78347$	3,08616	1,02872	0,67905

## Exercícios

**E 9.5.1.** Encontre os pesos  $w_1$ ,  $w_2$  e  $w_3$  tais que o esquema de quadratura dado por

$$\int_0^1 f(x) dx \approx w_1 f(0) + w_2 f(1/2) + w_3 f(1)$$

apresente máxima ordem de exatidão. Qual a ordem obtida?

**E 9.5.2.** Encontre a ordem de exatidão do seguinte método de integração:

$$\int_{-1}^1 f(x) dx \approx \frac{2}{3} \left[ f\left(\frac{-\sqrt{2}}{2}\right) + f(0) + f\left(\frac{\sqrt{2}}{2}\right) \right]$$

**E 9.5.3.** Encontre a ordem de exatidão do seguinte método de integração:

$$\int_{-1}^1 f(x) dx = -\frac{1}{210}f'(-1) + \frac{136}{105}f(-1/2) - \frac{62}{105}f(0) + \frac{136}{105}f(1/2) + \frac{1}{210}f'(1)$$

**E 9.5.4.** Encontre os pesos  $w_1$ ,  $w_2$  e  $w_3$  tal que o método de integração

$$\int_0^1 f(x) dx \approx w_1 f(1/3) + w_2 f(1/2) + w_3 f(2/3)$$

tenha ordem de exatidão máxima. Qual é ordem obtida?

**E 9.5.5.** Quantos pontos são envolvidos no esquema de quadratura  $R_{3,2}$ ? Qual a ordem do erro deste esquema de quadratura? Qual a ordem de exatidão desta quadratura?

## 9.6 Quadratura de Gauss-Legendre

Utilizando  $n$  pontos para aproximar a integral de  $f(x)$  em  $[-1,1]$  podemos encontrar a regra de quadratura de Gauss-Legendre

$$\int_{-1}^1 f(t) dt \approx \sum_{j=1}^n w_j f(t_j)$$

cuja ordem de exatidão é  $2n - 1$ .

- Note que temos  $n$  coeficientes  $w_j$  e  $n$  pontos  $t_j$  para determinar. O problema de encontrar os  $n$  pesos e  $n$  abscissas é equivalente a um sistema não linear com  $2n$  equações e  $2n$  incógnitas.
- Pode-se mostrar que este problema sempre tem solução e que a solução é única se  $t_1 < t_2 < \dots < t_n$
- Os nós  $x_j$  são dados pelos zeros do polinômio de Legendre,  $P_n(t)$ .
- Os pesos são dados por

$$w_j = \frac{2}{(1 - t_j^2) [P'_n(t_j)]^2}.$$

Tabela 9.1: Nodos e pesos para quadratura de Gauss-Legendre.

$n$	$t_j$	$w_j$
1	0	2
2	$\pm \frac{\sqrt{3}}{3}$	1
3	0 $\pm \sqrt{\frac{3}{5}}$	$\frac{8}{9}$ $\frac{5}{9}$
4	$\pm \sqrt{\left(3 - 2\sqrt{6/5}\right)/7}$ $\pm \sqrt{\left(3 + 2\sqrt{6/5}\right)/7}$	$\frac{18+\sqrt{30}}{36}$ $\frac{18-\sqrt{30}}{36}$
5	0 $\pm \frac{1}{3}\sqrt{5 - 2\sqrt{\frac{10}{7}}}$ $\pm \frac{1}{3}\sqrt{5 + 2\sqrt{\frac{10}{7}}}$	$\frac{128}{225}$ $\frac{322 + 13\sqrt{70}}{900}$ $\frac{322 - 13\sqrt{70}}{900}$

A Tabela 9.1 lista os nós e os pesos da quadratura de Gauss-Legendre para  $n = 1, 2, 3, 4$  e  $5$ .

**Exemplo 9.6.1.** Aproxime

$$I = \int_{-1}^1 \sqrt{1+x^2} dx$$

pelo método de Gauss-Legendre com 2, 3, 4 e 5 pontos.

**Solução.** A aproximação desta integral usando o método de Gauss-Legendre consiste em computar

$$I = \int_{-1}^1 f(x) dx \approx \sum_{i=1}^n w_i f(t_i),$$

onde  $f(x) = \sqrt{1+x^2}$ ,  $w_i$  é o  $i$ -ésimo peso,  $t_i$  é o  $i$ -ésimo nodo,  $i = 1, \dots, n$ , e  $n$  é o número de nodos (ou pesos) da quadratura. Usando os nodos e pesos dados na Tabela 9.1, obtemos os seguintes resultados:

$n$	$I$
2	2,3094011
3	2,2943456
4	2,2957234
5	2,2955705

No Scilab, temos:

```
deff('y=f(x)', 'y=sqrt(1 + x^2)')

//G-L n=2
x2 = sqrt(3)/3
w2 = 1
I2 = w2(1)*f(x2(1)) + w2(1)*f(-x2(1))
disp(I2)

//G-L n=3
x3 = [0 -sqrt(3/5) sqrt(3/5)]
w3 = [8/9 5/9 5/9]
I3 = w3(1)*f(x3(1)) + w3(2)*f(x3(2)) + w3(2)*f(-x3(2))
disp(I3)

//G-L n=4
x4 = [sqrt((3-2*sqrt(6/5))/7) sqrt((3+2*sqrt(6/5))/7)]
```

```

w4 = [(18+sqrt(30))/36 (18-sqrt(30))/36]
I4 = w4(1)*f(x4(1)) + w4(1)*f(-x4(1)) ...
    + w4(2)*f(x4(2)) + w4(2)*f(-x4(2))
disp(I4)

//G-L n=5
x5 = [0 1/3*sqrt(5-2*sqrt(10/7)) 1/3*sqrt(5+2*sqrt(10/7))]
w5 = [128/225 (322+13*sqrt(70))/900 (322-13*sqrt(70))/900]
I5 = w5(1)*f(x5(1)) + w5(2)*f(x5(2)) + w5(2)*f(-x5(2)) ...
    + w5(3)*f(x5(3)) + w5(3)*f(-x5(3))
disp(I5)

```

◇

### Mudança de intervalo

Os coeficientes da quadratura de Gauss-Legendre forma obtidos no intervalo  $[-1,1]$ . Para aproximar a integral de  $f(x)$  no intervalo  $[a,b]$  devemos fazer a mudança de variável

$$\bar{x}_i = \alpha t_i + \beta, \quad \alpha = (b-a)/2, \quad \beta = (b+a)/2$$

tal que

$$\int_a^b f(x) dx \approx \sum_{i=1}^n w_i f(\bar{x}_i) (b-a)/2$$

Quando subdividimos o intervalo inicial  $[a,b]$  em  $N$  intervalos com extremos  $[x_i, x_{i+1}]$  a transformação torna-se

$$\bar{x}_i = \alpha t_i + \beta, \quad \alpha = (x_{i+1} - x_i)/2, \quad \beta = (x_{i+1} + x_i)/2$$

e

$$\int_{x_i}^{x_{i+1}} f(x) dx \approx \sum_{i=1}^n w_i f(\bar{x}_i) (x_{i+1} - x_i)/2$$

**Exemplo 9.6.2.** Aproximar

$$I = \int_0^1 \sqrt{1+x^2} dx$$

pelo método de Gauss-Legendre com 3 pontos.

**Solução.** Para tanto, fazemos a mudança de variáveis  $u = 2x - 1$ :

$$\begin{aligned}
 I &= \int_0^1 \sqrt{1+x^2} dx \\
 &= \frac{1}{2} \int_{-1}^1 \sqrt{1 + \left(\frac{u+1}{2}\right)^2} du.
 \end{aligned}$$

E, então aplicamos a quadratura gaussiana nesta última integral, o que nos fornece  $I \approx 1,1478011$ . No Scilab, podemos computar estas aproximações com o seguinte código:

```
deff('y = f(u)', 'y = sqrt(1+(u+1)^2/4)/2')

x3 = [0 -sqrt(3/5) sqrt(3/5)]
w3 = [8/9 5/9 5/9]
I3 = f(x3(1))*w3(1) + f(x3(2))*w3(2) + f(-x3(2))*w3(2)
disp(I3)
```

◇

### 9.6.1 Código Scilab: Quadratura gaussiana com $N$ intervalos

**Exemplo 9.6.3.** Aproxime a integral de  $\sin(x)$  em  $[0,1]$  utilizando 5 intervalos iguais e em cada intervalo utilize uma quadratura gaussiana com 3 nós.

O código Scilab abaixo é uma implementação da quadratura gaussiana com subdivisão de intervalos. Devemos definir a função  $f(x) = \sin(x)$  e chamar a função `gaussiana(0,1,5)`.

```
function S=gaussiana(a,b,n)
h=(b-a)/n          // n intervalos
x=linspace(a,b,n+1)

w1=5/9; t1=-sqrt(3/5);
w2=8/9; t2=0;
w3=w1;  t3=-t1;

S=0
for i=1:n
    alpha=(x(i+1)-x(i))/2
    bet  =(x(i+1)+x(i))/2
    x1=alpha*t1+bet;
    x2=alpha*t2+bet;
    x3=alpha*t3+bet;

    A =(w1*f(x1)+w2*f(x2)+w3*f(x3))* h/2
    S=S+A
end
endfunction
```

## Exercícios

**E 9.6.1.** Encontre aproximações para a integral

$$\int_{-1}^1 x^4 e^{x^5} dx$$

usando a quadratura de Gauss-Legendre com 2, 3, 4 e 5 pontos. Então, compare com o seu valor exato.

**E 9.6.2.** Encontre aproximações para as seguintes integrais via Gauss-Legendre com 4 e 5 pontos:

a)  $\int_0^1 e^{-x^4} dx$

b)  $\int_1^4 \log(x + e^x) dx$

c)  $\int_0^1 e^{-x^2} dx$

## 9.7 Exercícios finais

**E 9.7.1.** Considere o problema de calcular numericamente a integral  $I = \int_{-1}^1 f(x) dx$  quando  $f(x) = \frac{\cos(x)}{\sqrt{|x|}}$ .

- a) O que acontece quando se aplica diretamente a quadratura gaussiana com um número ímpar de abscissas?
- b) Calcule o valor aproximado por quadratura gaussiana com  $n = 2$ ,  $n = 4$ ,  $n = 6$  e  $n = 8$ .
- c) Calcule o valor aproximado da integral removendo a singularidade

$$\begin{aligned} I &= \int_{-1}^1 \frac{\cos(x)}{\sqrt{|x|}} dx = \int_{-1}^1 \frac{\cos(x) - 1}{\sqrt{|x|}} dx + \int_{-1}^1 \frac{1}{\sqrt{|x|}} dx \\ &= \int_{-1}^1 \frac{\cos(x) - 1}{\sqrt{|x|}} dx + 2 \int_0^1 \frac{1}{\sqrt{x}} dx = \int_{-1}^1 \frac{\cos(x) - 1}{\sqrt{|x|}} dx + 4 \end{aligned}$$

e aplicando quadratura gaussiana com  $n = 2$ ,  $n = 4$ ,  $n = 6$  e  $n = 8$ .

- d) Calcule o valor aproximado da integral removendo a singularidade, considerando a paridade da função

$$I = 4 + \int_{-1}^1 \frac{\cos(x) - 1}{\sqrt{|x|}} dx = 4 + 2 \int_0^1 \frac{\cos(x) - 1}{\sqrt{x}} dx = 4 + \sqrt{2} \int_{-1}^1 \frac{\cos\left(\frac{1+u}{2}\right) - 1}{\sqrt{1+u}} du$$

e aplicando quadratura gaussiana com  $n = 2$ ,  $n = 4$ ,  $n = 6$  e  $n = 8$ .

- e) Expandindo a função  $\cos(x)$  em série de Taylor, truncando a série depois do  $n$ -ésimo termos não nulo e integrando analiticamente.

- f) Aproximando a função  $\cos(x)$  pelo polinômio de Taylor de grau 4 dado por

$$P_4(x) = 1 - \frac{x^2}{2} + \frac{x^4}{24}$$

e escrevendo

$$\begin{aligned} I &= \int_{-1}^1 \frac{\cos(x)}{\sqrt{|x|}} dx = \int_{-1}^1 \frac{\cos(x) - P_4(x)}{\sqrt{|x|}} dx + \int_{-1}^1 \frac{P_4(x)}{\sqrt{|x|}} dx \\ &= \underbrace{2 \int_0^1 \frac{\cos(x) - P_4(x)}{\sqrt{x}} dx}_{\text{Resolver numericamente}} + \underbrace{2 \int_0^1 \left( x^{-1/2} - \frac{x^{3/2}}{2} + \frac{x^{7/2}}{24} \right) dx}_{\text{Resolver analiticamente}} \end{aligned}$$

**E 9.7.2.** Calcule numericamente o valor das seguintes integrais com um erro relativo inferior a  $10^{-4}$ .

a)  $\int_0^1 \frac{\sin(\pi x)}{x} dx$

b)  $\int_0^1 \frac{\sin(\pi x)}{x(1-x)} dx$

c)  $\int_0^1 \frac{\sin\left(\frac{\pi}{2}x\right)}{\sqrt{x(1-x)}} dx$

d)  $\int_0^1 \ln(x) \cos(x) dx$

**E 9.7.3.** Calcule as integrais  $\int_0^1 \frac{e^x}{|x|^{1/4}} dx$  e  $\int_0^1 \frac{e^{-x}}{|x|^{4/5}} dx$  usando procedimentos analíticos e numéricos.



**E 9.7.4.** Use a técnica de integração por partes para obter a seguinte identidade envolvendo integrais impróprias:

$$I = \int_0^{\infty} \frac{\cos(x)}{1+x} dx = \int_0^{\infty} \frac{\operatorname{sen}(x)}{(1+x)^2} dx.$$

Aplique as técnicas estudadas para aproximar o valor de  $I$  e explique por que a integral da direita é mais bem comportada.

**E 9.7.5.** Resolva a equação

$$x + \int_0^x e^{-y^2} dy = 5$$

com 5 dígitos significativos.

**E 9.7.6.** (Ciência dos materiais) O calor específico (molar) de um sólido pode ser aproximado pela teoria de Debye usando a seguinte expressão

$$C_V = 9Nk_B \left( \frac{T}{T_D} \right)^3 \int_0^{T_D/T} \frac{y^4 e^y}{(e^y - 1)^2} dy$$

onde  $N$  é a constante de Avogadro dado por  $N = 6.022 \times 10^{23}$  e  $k_B$  é a constante de Boltzmann dada por  $k_B = 1.38 \times 10^{-23}$ .  $T_D$  é temperatura de Debye do sólido.

- Calcule o calor específico do ferro em quando  $T = 200K$ ,  $T = 300K$  e  $T = 400K$  supondo  $T_D = 470K$ .
- Calcule a temperatura de Debye de um sólido cujo calor específico a temperatura de  $300K$  é  $24J/K/mol$ . Dica: aproxime a integral por um esquema numérico com um número fixo de pontos.
- Melhore sua cultura geral: A lei de Dulong-Petit para o calor específico dos sólidos precede a teoria de Debye. Verifique que a equação de Debye é consistente com Dulong-Petit, ou seja:

$$\lim_{T \rightarrow \infty} C_v = 3Nk_B.$$

Dica: use  $e^y \approx 1 + y$  quando  $y \approx 0$

**E 9.7.7.** Explique por quê quando um método simples tem estimativa de erro de truncamento local de ordem  $h^n$ , então o método composto associado tem estimativa de erro de ordem  $h^{n-1}$ .

**E 9.7.8.** Encontre os pesos  $w_1$  e  $w_2$  e as abcissas  $x_1$  e  $x_2$  tais que

$$\int_{-1}^1 f(x) = w_1 f(x_1) + w_2 f(x_2)$$

quando  $f(x) = x^k$ ,  $k = 0, 1, 2, 3$ , isto é, o método que apresente máxima ordem de exatidão possível com dois pontos.

Use esse método para avaliar o valor da integral das seguintes integrais e compare com os valores obtidos para Simpson e trapézio, bom como com o valor exato.

a)  $\int_{-1}^1 (2 + x - 5x^2 + x^3) dx$

b)  $\int_{-1}^1 e^x dx$

c)  $\int_{-1}^1 \frac{dx}{\sqrt{x^2+1}}$

**E 9.7.9.** Encontre os pesos  $w_1$ ,  $w_2$  e  $w_3$  tal que o método de integração

$$\int_{-1}^1 f(x) dx \approx w_1 f\left(-\frac{\sqrt{3}}{3}\right) + w_2 f(0) + w_3 f\left(\frac{\sqrt{3}}{3}\right)$$

tenha ordem de exatidão máxima. Qual é ordem obtida?

# Capítulo 10

## Problemas de valor inicial

Neste capítulo, vamos desenvolver técnicas numéricas para aproximar a solução do problema de valor inicial (PVI) dado pela equação diferencial ordinária (EDO) de primeira ordem

$$u'(t) = f(t, u(t)) \quad (10.1a)$$

$$u(t_1) = a \text{ (condição inicial).} \quad (10.1b)$$

A incógnita de um problema de valor inicial é uma função que satisfaz a equação diferencial (10.1a) e a condição inicial (10.1b).

Considere os próximos três exemplos:

**Exemplo 10.0.1.**

$$\frac{du}{dt} = t \quad (10.2)$$

$$u(0) = a \quad (10.3)$$

**Exemplo 10.0.2.**

$$\frac{du}{dt} = u \quad (10.4)$$

$$u(0) = a \quad (10.5)$$

**Exemplo 10.0.3.**

$$\frac{du}{dt} = \sin(u^2 + \sin(t)) \quad (10.6)$$

$$u(0) = a \quad (10.7)$$

A solução do primeiro exemplo é  $u(t) = t^2/2 + a$  pois satisfaz a equação diferencial e a condição inicial.

A solução do segundo exemplo é fácil de ser obtida:  $u(t) = ae^t$ . Porém como podemos resolver o terceiro problema?

Muitos problemas de valor inicial da forma (10.1) não podem ser resolvidos exatamente, ou seja, sabe-se que a solução existe e é única, porém não podemos expressá-la em termos de funções elementares. Por isso é necessário calcular aproximações numéricas. Diversos métodos completamente diferentes estão disponíveis para aproximar uma função real.

Existem várias maneiras de obter aproximações para a solução deste problema. Nos limitaremos a estudar métodos que aproximam  $u(t)$  em um conjunto finito de valores de  $t$  chamado **malha** que será denotado por  $\{t_i\}_{i=1}^N = \{t_1, t_2, t_3, \dots, t_N\}$ . Desta forma, aproximamos a solução  $u(t_i)$  por  $u_i$  em cada ponto da malha usando diferentes esquemas numéricos.

## 10.1 Teoria de equações diferenciais

Uma questão fundamental é analisar se um dado PVI é um problema **bem posto**. Ou seja,

- Existe uma solução para o PVI?
- A solução é única?
- A solução do PVI é pouco sensível a pequenas perturbações nas condições iniciais?

**Definição 10.1.1.** A função  $f(t, u)$  é Lipschitz em  $u$  se existe uma constante  $L$ , tal que  $\forall t \in [a, b]$  e  $u, v \in \mathbb{R}$ ,

$$|f(t, u) - f(t, v)| \leq L|u(t) - v(t)|.$$

**Teorema 10.1.1.** Seja  $f(t, u)$  contínua em  $t$  e Lipschitz em  $u$ . Então existe uma única solução para o PVI

$$u'(t) = f(t, u(t)) \quad (10.8)$$

$$u(t_1) = a. \quad (10.9)$$

**Definição 10.1.2. Estabilidade dinâmica** refere-se a propriedade de pequenas perturbações sobre o estado inicial de um sistema gerarem pequenas variações no estado final deste sistema (haverá decaimento nas variações, ou pelo menos não crescimento, quanto  $t$  cresce).

**Teorema 10.1.2** (Dependência na condição inicial). Se  $u(t)$  e  $v(t)$  são soluções do PVI com  $f$  Lipschitz com  $u(t_1) = u_1$ ,  $v(t_1) = v_1$ , então

$$|u(t) - v(t)| \leq e^{L(t-t_1)}|u_1 - v_1|.$$

## 10.2 Método de Euler

Considere o PVI dado por

$$u'(t) = f(t, u(t)) \quad (10.10)$$

$$u(t_1) = a \quad (10.11)$$

Ao invés de solucionar o problema para qualquer  $t > t_1$ , (encontrar  $u(t)$ ), iremos aproximar  $u(t)$  em  $t_2 = t_1 + h$ .

Integrando (10.10) de  $t_1$  até  $t_2$ ,

$$\int_{t_1}^{t_2} u'(t) dt = \int_{t_1}^{t_2} f(t, u(t)) dt \quad (10.12)$$

$$u(t_2) - u(t_1) = \int_{t_1}^{t_2} f(t, u(t)) dt \quad (10.13)$$

$$u(t_2) = u(t_1) + \int_{t_1}^{t_2} f(t, u(t)) dt \quad (10.14)$$

Seja  $u_n$  a aproximação de  $u(t_n)$ . Para obter o método numérico mais simples aproximamos  $f$  em  $[t_1, t_2]$  pela função constante  $f(t, u(t)) \approx f(t_1, u_1)$ ,

$$u_2 = u_1 + f(t_1, u_1) \int_{t_1}^{t_2} dt \quad (10.15)$$

$$u_2 = u_1 + f(t_1, u_1)(t_2 - t_1) \quad (10.16)$$

$$u_2 = u_1 + hf(t_1, u_1) \quad (10.17)$$

Este procedimento pode ser estendido para  $t_3, t_4, \dots$ , onde

$$t_{n+1} = t_n + h = t_1 + nh, \quad n = 1, 2, \dots$$

e  $h$  é o passo do método, ou espaçamento, que consideraremos constante.

Obtendo, assim, o **método de Euler**,

$$u_{n+1} = u_n + hf(t_n, u_n). \quad (10.18)$$

Podemos também obter o método de Euler a partir da aproximação de  $u'(t)$  por um esquema de primeira ordem do tipo

$$u'(t) = \frac{u(t+h) - u(t)}{h} + \mathcal{O}(h), \quad h > 0.$$

Substituindo na EDO temos

$$\frac{u(t+h) - u(t)}{h} = f(t, u(t)) + \mathcal{O}(h) \quad (10.19)$$

$$u(t+h) = u(t) + hf(t, u(t)) + \mathcal{O}(h^2). \quad (10.20)$$

Sendo  $u_n$  a aproximação de  $u$  em  $t_n$  produzida pelo método de Euler, obtemos

$$u_{n+1} = u_n + hf(t_n, u_n), \quad (10.21)$$

$$u_1 = a. \quad (10.22)$$

**Exemplo 10.2.1.** Considere o problema de valor inicial

$$u'(t) = 2u(t)$$

$$u(0) = 1$$

cujas solução é  $u(t) = e^{2t}$ . O método de Euler aplicado a este problema produz o esquema:

$$u_{k+1} = u_k + 2hu_k = (1 + 2h)u_k$$

$$u_1 = 1,$$

Suponha que queremos calcular o valor aproximado de  $u(1)$  com  $h = 0,2$ . Então os pontos  $t^{(1)} = 0$ ,  $t^{(2)} = 0,2$ ,  $t^{(3)} = 0,4$ ,  $t^{(4)} = 0,6$ ,  $t^{(5)} = 0,8$  e  $t^{(6)} = 1,0$  formam os seis pontos da malha. As aproximações para a solução nos pontos da malha usando o método de Euler são:

$$u(0) \approx u^{(1)} = 1$$

$$u(0,2) \approx u^{(2)} = (1 + 2h)u^{(1)} = 1,4u^{(1)} = 1,4$$

$$u(0,4) \approx u^{(3)} = 1,4u^{(2)} = 1,96$$

$$u(0,6) \approx u^{(4)} = 1,4u^{(3)} = 2,744$$

$$u(0,8) \approx u^{(5)} = 1,4u^{(4)} = 3,8416$$

$$u(1,0) \approx u^{(6)} = 1,4u^{(5)} = 5,37824$$

Essa aproximação é bem grosseira quando comparamos com a solução do problema em  $t = 1$ :  $u(1) = e^2 \approx 7,38906$ .

**Exemplo 10.2.2.** Aproxime a solução do PVI

$$\frac{du}{dt} = -0.5u + 2 + t \quad (10.23)$$

$$u(0) = 8 \quad (10.24)$$

Teste para  $h = 1.6, 0.8, 0.4, 0.2, 0.1$ .

Note que a solução exata do problema é

$$u(t) = 2t + 8e^{-t/2} \quad (10.25)$$

Itere a fórmula

$$u_{n+1} = u_n + h(-0.5u_n + 2 + t_n), \quad u_1 = 8 \quad (10.26)$$

através do código abaixo:

```
%-----
function [u,t]=euler(h,Tmax)
    u(1)= 8;
    t(1)= 0;
    itmax = Tmax/h;
    for n=1:itmax
        t(n+1)= t(n) + h;
        u(n+1)= u(n) + h*(-0.5*u(n)+2+t(n));
    end
    plot(t,u,'g*-');
%-----
```

Vamos agora, analisar o desempenho do método de Euler usando um exemplo mais complicado, porém ainda simples suficiente para que possamos obter a solução exata:

**Exemplo 10.2.3.** Considere o problema de valor inicial relacionado à equação logística:

$$\begin{aligned}u'(t) &= u(t)(1 - u(t)) \\ u(0) &= 1/2\end{aligned}$$

Podemos obter a solução exata desta equação usando o método de separação de variáveis e o método das frações parciais. Para tal escrevemos:

$$\frac{du(t)}{u(t)(1 - u(t))} = dt$$

O termo  $\frac{1}{u(1-u)}$  pode ser decomposto em frações parciais como  $\frac{1}{u} - \frac{1}{1-u}$  e chegamos na seguinte equação diferencial:

$$\left(\frac{1}{u} + \frac{1}{1-u}\right) du = dt.$$

Integrando termo-a-termo, temos a seguinte equação algébrica relacionando  $u(t)$  e  $t$ :

$$\ln(u) - \ln(1 - u) = t + C$$

Onde  $C$  é a constante de integração, que é definida pela condição inicial, isto é,  $u = 1/2$  em  $t = 0$ . Substituindo, temos  $C = 0$ . O que resulta em:

$$\ln\left(\frac{u}{1-u}\right) = t$$

Tabela 10.1: Tabela comparativa entre método de Euler e solução exata para problema 10.2.3.

$t$	Exato	Euler $h = 0,1$	Euler $h = 0,01$
0	1/2	0,5	0,5
1/2	$\frac{e^{1/2}}{1+e^{1/2}} \approx 0,6224593$	0,6231476	0,6225316
1	$\frac{e}{1+e} \approx 0,7310586$	0,7334030	0,7312946
2	$\frac{e^2}{1+e^2} \approx 0,8807971$	0,8854273	0,8812533
3	$\frac{e^3}{1+e^3} \approx 0,9525741$	0,9564754	0,9529609

Equivalente a

$$\frac{u}{1-u} = e^t$$

e

$$u = (1-u)e^t$$

Colocando o termo  $u$  em evidência, encontramos:

$$(1+e^t)u = e^t \quad (10.27)$$

E, finalmente, encontramos a solução exata dada por  $u(t) = \frac{e^t}{1+e^t}$ .

Vejamos, agora, o esquema iterativo produzido pelo método de Euler:

$$\begin{aligned} u_{k+1} &= u_k + hu_k(1-u_k), \\ u_1 &= 1/2. \end{aligned}$$

Para fins de comparação, calculamos a solução exata e aproximada para alguns valores de  $t$  e de passo  $h$  e resumimos na tabela 10.1.

No exemplo a seguir, apresentamos um problema envolvendo uma equação não-autônoma, isto é, quando a função  $f(u)$  depende explicitamente do tempo.

**Exemplo 10.2.4.** Resolva o problema de valor inicial

$$\begin{aligned} u'(t) &= -u(t) + t \\ u(0) &= 1, \end{aligned}$$

cujas solução exata é  $u(t) = 2e^{-t} + t - 1$ .

O esquema recursivo de Euler fica:

$$\begin{aligned} u_{k+1} &= u_k + h(-u_k + t_k) \\ u_1 &= 1 \end{aligned}$$

Comparação



$t$	Exato	Euler $h = 0,1$	Euler $h = 0,01$
0	1	1	1
1	$2e^{-1} \approx 0,7357589$	0,6973569	0,7320647
2	$2e^{-2} + 1 \approx 1,2706706$	1,2431533	1,2679593
3	$2e^{-3} + 2 \approx 2,0995741$	2,0847823	2,0980818

## Exercícios

**E 10.2.1.** Resolva o problema de valor inicial dado por

$$\begin{aligned}u' &= -2u + \sqrt{u} \\ u(0) &= 1\end{aligned}$$

com passo  $h = 0,1$  e  $h = 0,01$  para obter aproximações para  $u(1)$ . Compare com a solução exata dada por  $u(t) = (1 + 2e^{-t} + e^{-2t})/4$

**E 10.2.2.** Resolva o problema de valor inicial dado por

$$\begin{aligned}u' &= -2u + \sqrt{z} \\ z' &= -z + u \\ u(0) &= 0 \\ z(0) &= 2\end{aligned}$$

com passo  $h = 0,2$ ,  $h = 0,02$ ,  $h = 0,002$  e  $h = 0,0002$  para obter aproximações para  $u(2)$  e  $z(2)$ .

**E 10.2.3.** Resolva o problema de valor inicial dado por

$$\begin{aligned}u' &= \cos(tu(t)) \\ u(0) &= 1\end{aligned}$$

com passo  $h = 0,1$ ,  $h = 0,01$ ,  $h = 0,001$ ,  $h = 0,0001$  e  $0,00001$  para obter aproximações para  $u(2)$ .

### 10.2.1 Ordem de precisão

A **precisão** de um método numérico que aproxima a solução de um PVI é dada pela ordem do erro acumulado ao calcular a aproximação em um ponto  $t_{n+1}$  em função do espaçamento da malha  $h$ .

Se  $u(t_{n+1})$  for aproximado por  $u_{n+1}$  com erro da ordem  $\mathcal{O}(h^{p+1})$  dizemos que o método tem **ordem de precisão**  $p$ .

Queremos obter a ordem de precisão do método de Euler. Para isso, substituímos a EDO  $u' = f(t, u)$  na expansão em série de Taylor

$$u(t_{n+1}) = u(t_n) + hu'(t_n) + h^2u''(t_n)/2 + \mathcal{O}(h^3) \quad (10.28)$$

e obtemos

$$u(t_{n+1}) = u(t_n) + hf(t_n, u(t_n)) + h^2u''(t_n)/2 + \mathcal{O}(h^3) \quad (10.29)$$

Subtraindo (10.29) do método de Euler

$$u_{n+1} = u_n + h f(t_n, u_n) \quad (10.30)$$

obtemos

$$e_{n+1} = u_{n+1} - u(t_{n+1}) \quad (10.31)$$

$$= u_n - u(t_n) + h(f(t_n, u(t_n) + e_n) - f(t_n, u(t_n))) + \quad (10.32)$$

$$+ \frac{h^2}{2}u''_n + \mathcal{O}(h^3) \quad (10.33)$$

Defina o **erro numérico** como  $e_n = u_n - u(t_n)$  onde  $u(t_n)$  é a solução exata e  $u_n$  é a solução aproximada. Assim

$$e_{n+1} = e_n + h(f(t_n, u(t_n) + e_n) - f(t_n, u(t_n))) + \frac{h^2}{2}u''_n + \mathcal{O}(h^3) \quad (10.34)$$

Usando a condição de Lipschitz em  $f$  temos

$$|e_{n+1}| \leq |e_n| + h|f(t_n, u(t_n) + e_n) - f(t_n, u(t_n))| + \frac{h^2}{2}|u''_n| + \mathcal{O}(h^3) \quad (10.35)$$

$$\leq |e_n| + hL|u(t_n) + e_n - u(t_n)| + \frac{h^2}{2}|u''_n| + \mathcal{O}(h^3) \quad (10.36)$$

$$\leq |e_n| + hL|e_n| + \frac{h^2}{2}|u''_n| + \mathcal{O}(h^3) \quad (10.37)$$

$$\leq (1 + hL)|e_n| + \frac{h^2}{2}|u''_n| + \mathcal{O}(h^3) \quad (10.38)$$

## 10.2.2 Erro de truncamento Local

O **Erro de Truncamento Local** é o erro cometido em **uma** iteração do método numérico supondo que a solução exata é conhecida no passo anterior.

Assim, supondo que a solução é exata em  $t_n$  ( $|e_n| = 0$ ), obtemos que o ETL é

$$ETL_{Euler}^{n+1} = h^2/2|u''| + \mathcal{O}(h^3) = \mathcal{O}(h^2)$$

Como o  $ETL = \mathcal{O}(h^2)$  temos que o método de Euler possui ordem 1.

### 10.2.3 Erro de truncamento Global

O **Erro de Truncamento Global** é o erro cometido durante **várias** iterações do método numérico.

Supondo que a solução exata é conhecida em  $t_1$  ( $\|e_1\| = 0$ ), então realizando  $n = \frac{T}{h}$  iterações obtemos

$$ETG = nETL \quad (10.39)$$

$$= n[h^2/2|u''| + \mathcal{O}(h^3)] \quad (10.40)$$

$$= Th/2|u''| + \mathcal{O}(h^2) \quad (10.41)$$

ou seja

$$ETG_{Euler}^{n+1} = O(h)$$

## 10.3 Convergência, consistência e estabilidade

Nesta seção veremos três conceitos fundamentais em análise numérica: convergência, consistência e estabilidade.

### 10.3.1 Convergência

Um método é dito **convergente** se para toda EDO com  $f$  Lipschitz e todo  $t > 0$  temos que

$$\lim_{h \rightarrow 0} |u_n - u(t_n)| = 0, \quad \forall n$$

Convergência significa que a solução numérica tende a solução do PVI.

**Teorema 10.3.1.** *O método de Euler é convergente.*

De fato, se  $f$  Lipschitz e  $|e_0| = 0$ , temos que

$$\lim_{h \rightarrow 0} |e_{n+1}| = \lim_{h \rightarrow 0} O(h) = 0 \quad (10.42)$$

### 10.3.2 Consistência

**Definição 10.3.1.** *Dizemos que um método numérico  $R_h(u_n) = f$  é consistente com o PVI  $u'(t) = f$  se para qualquer  $u(t)$*

$$\lim_{h \rightarrow 0} |u'(t_n) - R_h(u_n)| = 0, \quad \forall n \quad (10.43)$$

Isto é equivalente a

$$\lim_{h \rightarrow 0} \frac{ETL}{h} = 0 \quad (10.44)$$

### 10.3.3 Estabilidade

**Definição 10.3.2.** Um método numérico é **estável** se

$$|u_n - v_n| \leq C_1 |u_1 - v_1|, \quad \forall n$$

Isto significa que dadas duas condições iniciais  $u_1$  e  $v_1$ , teremos que as soluções  $u_n$  e  $v_n$  estarão a uma distância limitada por uma constante  $C_1$  vezes  $|u_1 - v_1|$ . Se  $u_1$  e  $v_1$  estiverem próximas então  $u_n$  e  $v_n$  estão também próximas dependendo da constante  $C_1$  (obviamente  $C_1$  depende da função  $f$ ).

Considere o PVI linear bem-posto

$$u'(t) = \lambda u(t), \quad u(0) = 1, \quad (10.45)$$

onde  $\lambda \in \mathbb{C}$ . Note que:

- Possui solução exata  $u(t) = e^{\lambda t}$ .
- O PVI é **assintoticamente estável**, isto é,  $\lim_{t \rightarrow \infty} u(t) = 0$ , se e somente se  $\Re \lambda < 0$ .

**Definição 10.3.3.** O **domínio de estabilidade linear**  $\mathcal{D}$  do método numérico é o conjunto de todos  $h\lambda \in \mathbb{C}$  tal que  $\lim_{n \rightarrow \infty} u_n = 0$ .

Ou seja,  $\mathcal{D}$  é o conjunto de todos  $h\lambda$  para o qual o correto comportamento assintótico de (10.45) seja recuperado.

**Exemplo 10.3.1.** Utilizando o **Método de Euler** para solucionar (10.45) obtemos ( $u_1 = 1$ )

$$u_{n+1} = u_n + h\lambda u_n, \quad (10.46)$$

$$u_{n+1} = (1 + h\lambda)u_n, \quad (10.47)$$

$$u_{n+1} = (1 + h\lambda)^2 u_{n-1}, \quad (10.48)$$

$$u_{n+1} = (1 + h\lambda)^{n+1} u_1 \quad (10.49)$$

$$u_{n+1} = (1 + h\lambda)^{n+1}, \quad n = 0, 1, \dots \quad (10.50)$$

Para que o método de Euler seja estável, é necessário que  $h$  seja escolhido tal que  $|1 + h\lambda| < 1$ . Ou seja,  $h\lambda$  deve estar em  $\mathcal{D}_{Euler}$  onde

$$\mathcal{D}_{Euler} = \{z \in \mathbb{C} : |1 + z| < 1\} \quad (10.51)$$

é o interior de um disco no plano complexo de raio 1 e centro em  $z = -1$  como na Fig.??.

Tal análise pode ser facilmente estendida para  $u' = \lambda u + b$  (veja exercícios).  
Para o caso EDO não-linear, seja

$$u' = f(t, u), \quad t \geq t_0, \quad u(t_0) = u_0 \quad (10.52)$$

é comum requerer que  $h\lambda_{n,k} \in \mathcal{D}$  onde  $\lambda_{n,k}$  são os autovalores da matriz jacobiana  $J_n := \frac{\partial f}{\partial u}|_{(t_n, u_n)}$ , baseado na hipótese que o comportamento local da EDO é modelado por

$$u' = u_n + J_n(u - u_n) \quad (10.53)$$

Esta prática não é exata e fornece apenas uma ideia local do comportamento da EDO (podendo levar a conclusões errôneas).

Um dos teoremas mais importantes em análise numérica é o seguinte:

**Teorema 10.3.2.** *Um método numérico **consistente** para um PVI bem-posto é **convergente** se e somente se ele é **estável**.*

Ele também é usado da seguinte forma:

**Teorema 10.3.3.** *Se um método numérico é **consistente** e **estável** em  $[a, b]$  então ele é **convergente**.*

## 10.4 O método de Euler implícito

Integrando o PVI

$$u'(t) = f(t, u(t)) \quad (10.54)$$

$$u(t_1) = a \quad (10.55)$$

de  $t_1$  até  $t_2$  obtemos (como feito anteriormente)

$$u(t_2) = u(t_1) + \int_{t_1}^{t_2} f(t, u(t)) dt \quad (10.56)$$

Entretanto se aproximarmos a função  $f$  por uma função constante  $f(t, u(t)) \approx f(t_2, u_2)$ , obteremos um novo método

$$u_2 = u_1 + f(t_2, u_2) \int_{t_1}^{t_2} dt \quad (10.57)$$

$$u_2 = u_1 + hf(t_2, u_2) \quad (10.58)$$

Generalizando este procedimento para  $t_n$  obtemos o **método de Euler implícito**

$$u_{n+1} = u_n + h f(t_{n+1}, u_{n+1}). \quad (10.59)$$

Note que este método é **implícito** (a equação é implícita) pois depende de  $u_{n+1}$  dos dois lados da equação. Se a função  $f$  for simples o suficiente, podemos resolver a equação isolando o termo  $u_{n+1}$ . Se isso não for possível, devemos usar um dos métodos vistos anteriormente para calcular as raízes da equação (por exemplo, método da bissecção e método de Newton).

Pode ser mostrado que o erro de truncamento local é

$$ETL_{EulImp}^{n+1} = \mathcal{O}(h^2).$$

portanto o método é de ordem 1. E o erro de truncamento global é

$$ETG_{EulImp}^{n+1} = \mathcal{O}(h).$$

**Exemplo 10.4.1.** Utilizando o **método de Euler implícito** para solucionar (10.45) obtemos

$$u_{n+1} = u_n + h\lambda u_{n+1}, \quad (10.60)$$

$$(1 - h\lambda)u_{n+1} = u_n, \quad (10.61)$$

$$u_{n+1} = \left( \frac{1}{1 - h\lambda} \right) u_n, \quad (10.62)$$

$$u_{n+1} = \left( \frac{1}{1 - h\lambda} \right)^2 u_{n-1}, \quad (10.63)$$

$$u_{n+1} = \left( \frac{1}{1 - h\lambda} \right)^{n+1}, \quad n = 0, 1, \dots \quad (10.64)$$

onde  $u_1 = 1$ . Concluimos então que

$$\mathcal{D}_{EulImp} = \{z \in \mathbb{C} : \left| \frac{1}{1 - z} \right| < 1\} \quad (10.65)$$

ou ainda,

$$\mathcal{D}_{EulImp} = \{z \in \mathbb{C} : |1 - z| > 1\} \quad (10.66)$$

Para que o método de Euler implícito seja estável, é necessário que  $h$  seja escolhido tal que  $\left| \frac{1}{1 - h\lambda} \right| < 1$ , ou ainda,  $|1 - h\lambda| > 1$ . Ou seja,  $h\lambda$  deve estar em  $\mathcal{D}_{EulImp}$  onde

$$\mathcal{D}_{EulImp} = \{z \in \mathbb{C} : |1 - z| > 1\} \quad (10.67)$$

é o exterior de um disco no plano complexo de raio 1 e centro em  $z = 1$ .

Note que  $\mathcal{D}_{EulImp}$  inclui todo o semiplano negativo. Portanto o método de Euler implícito imita a estabilidade assintótica da EDO linear sem restrição no passo  $h$ .

**Definição 10.4.1.** Um método numérico é chamado **A-estável** ou **incondicionalmente estável** se incluir todo o semiplano complexo com parte real negativa,

$$\{z \in \mathbb{C} : \Re z < 0\} \subseteq \mathcal{D}$$

Portanto o método de Euler implícito é A-estável (incondicionalmente estável).

## 10.5 Método Trapezoidal

O método de Euler aproxima  $f$  como uma constante no intervalo  $[t_1, t_2]$ . Podemos melhorar isso usando a regra do trapézio,

$$u(t_2) = u(t_1) + \int_{t_1}^{t_2} f(t, u(t)) dt \quad (10.68)$$

$$u_2 = u_1 + (t_2 - t_1) \left( \frac{1}{2} f(t_1, u_1) + \frac{1}{2} f(t_2, u_2) \right) \quad (10.69)$$

motivando o **método trapezoidal**

$$u_{n+1} = u_n + \frac{h}{2} (f(t_n, u_n) + f(t_{n+1}, u_{n+1})) \quad (10.70)$$

O método trapezoidal é dito **implícito**, pois para obter  $u_{n+1}$  é necessário calcular  $f(t_{n+1}, u_{n+1})$ .

Entretanto, pode ser mostrado que o erro de truncamento local é

$$ETL_{Trap}^{n+1} = O(h^3)$$

portanto o método é de ordem 2. E o erro de truncamento global é

$$ETG_{Trap}^{n+1} = O(h^2)$$

**Exemplo 10.5.1.** Utilizando o **método trapezoidal** para solucionar (10.45) obtemos

$$u_{n+1} = \left( \frac{1 + h\lambda/2}{1 - h\lambda/2} \right)^{n+1}, \quad n = 0, 1, \dots \quad (10.71)$$

Concluimos então que

$$\mathcal{D}_{Tr} = \{z \in \mathbb{C} : \left| \frac{1 + z/2}{1 - z/2} \right| < 1\} \quad (10.72)$$

Note que  $\mathcal{D}_{Tr} = \mathbb{C}^-$ , o semiplano negativo. Portanto o método do trapézio imita a estabilidade assintótica da EDO linear sem restrição no passo  $h$ .

## 10.6 O método de Heun

Também chamado de método de **Euler Modificado**. A ideia é calcular primeiramente um valor intermediário  $\tilde{u}$  usando o método de Euler explícito e usar esse valor na equação para o método do Trapézio. Ou seja, o **método de Heun** é

$$\tilde{u} = u_n + hf(t_n, u_n) \quad (10.73)$$

$$u_{n+1} = u_n + \frac{h}{2} (f(t_n, u_n) + f(t_{n+1}, \tilde{u})) \quad (10.74)$$

Este é um exemplo de um método preditor-corretor.

Felizmente o erro de truncamento local continua sendo

$$ETL_{Heun}^{n+1} = O(h^3)$$

e o erro de truncamento global é

$$ETG_{Heun}^{n+1} = O(h^2)$$

### Exercícios

**E 10.6.1.** Use o método de Euler melhorado para obter uma aproximação numérica do valor de  $u(1)$  quando  $u(t)$  satisfaz o seguinte problema de valor inicial

$$\begin{aligned} u'(t) &= -u(t) + e^{u(t)}, \\ u(0) &= 0, \end{aligned}$$

usando passos  $h = 0,1$  e  $h = 0,01$ .

**E 10.6.2.** Use o método de Euler e o método de Euler melhorado para obter aproximações numéricas para a solução do seguinte problema de valor inicial para  $t \in [0,1]$ :

$$\begin{aligned} u'(t) &= -u(t) - u(t)^2, \\ u(0) &= 1, \end{aligned}$$

usando passo  $h = 0,1$ . Compare os valores da solução exata dada por  $u(t) = \frac{1}{2e^t - 1}$  com os numéricos nos pontos  $t = 0, t = 0.1, t = 0.2, t = 0.3, t = 0.4, t = 0.5, t = 0.6, t = 0.7, t = 0.8, t = 0.9, t = 1.0$ .



## 10.7 O método theta

Tanto o método de Euler quanto o método trapezoidal se encaixam no método

$$u_{n+1} = u_n + h(\theta f(t_n, u_n) + (1 - \theta)f(t_{n+1}, u_{n+1})) \quad (10.75)$$

com  $\theta = 1$  e  $\theta = \frac{1}{2}$  respectivamente. O método é explícito somente para  $\theta = 1$ . Para  $\theta = 0$ , obtemos o método implícito de Euler.

## 10.8 O método de Taylor

Uma maneira simples de aumentar a ordem do método é utilizar diretamente a série de Taylor. Considere a expansão

$$u(t+h) = u(t) + hu'(t) + \frac{h^2}{2!}u''(t) + \frac{h^3}{3!}u'''(t) + \dots \quad (10.76)$$

Utilizando dois termos temos o método de Euler. Utilizando os três primeiros termos da série e substituindo  $u'(t) = f(t, x)$  e  $u''(t) = \frac{\partial f}{\partial t}(t, x)$  temos o **método de Taylor de ordem 2**

$$u_{n+1} = u_n + hf(t_n, u_n) + \frac{h^2}{2!} \frac{\partial f}{\partial t}(t_n, u_n) \quad (10.77)$$

O método de Taylor de ordem 3 é

$$u_{n+1} = u_n + hf(t_n, u_n) + \frac{h^2}{2!} \frac{\partial f}{\partial t}(t_n, u_n) + \frac{h^3}{3!} \frac{\partial^2 f}{\partial t^2}(t_n, u_n)$$

## 10.9 Estabilidade dos métodos de Taylor

**Exemplo 10.9.1.** Prove que para um método de Taylor de ordem  $p$  para a EDO (10.45) temos

$$p(z) = 1 + z + \frac{z^2}{2!} + \frac{z^3}{3!} + \dots + \frac{z^p}{p!} \quad (10.78)$$

onde  $u_n = (p(z))^n u_0$  e a região de estabilidade é dada por

$$\mathcal{D}_T = \{z \in \mathbb{C} : |p(z)| < 1\} \quad (10.79)$$

Plote as regiões de estabilidade para o método de Taylor para  $p = 1, \dots, 6$  no mesmo gráfico.

**Exemplo 10.9.2.** Aproxime a solução do PVI

$$\frac{du}{dt} = \sin t \quad (10.80)$$

$$u(0) = 1 \quad (10.81)$$

para  $t \in [0, 10]$ .

- Plote a solução para  $h = 0.16, 0.08, 0.04, 0.02, 0.01$  para o método de Taylor de ordem 1, 2 e 3. (Plote todos de ordem 1 no mesmo gráfico, ordem 2 em outro gráfico e ordem 3 outro gráfico separado.)
- Utilizando a solução exata, plote um gráfico do erro em escala logarítmica. Comente os resultados (novamente, em cada gráfico separado para cada método repita os valores acima)
- Fixe agora o valor  $h = 0.02$  e plote no mesmo gráfico uma curva para cada método.
- Plote em um gráfico o erro em  $t = 10$  para cada um dos métodos (uma curva para cada ordem) a medida que  $h$  diminui. (Use escala  $\log\log$ )

## 10.10 Métodos de Passo Múltiplo

Seja o PVI

$$u'(t) = f(t, u(t)) \quad (10.82)$$

$$u(t_0) = a \quad (10.83)$$

Integrando a EDO em  $[t_n, t_{n+1}]$  obtemos

$$u_{n+1} = u_n + \int_{t_n}^{t_{n+1}} f(t, u(t)) dt \quad (10.84)$$

Denote por  $f_n \equiv f(t_n, u_n)$ . Um método de passo simples utiliza  $f_{n+1}$  e  $f_n$ . Um método de passo múltiplo utiliza também  $s$  valores anteriores já calculados como  $f_{n-1}, f_{n-2}, \dots, f_{n-s}$ , onde  $s \geq 1$  inteiro.

$$u_{n+1} = u_n + h[b_s f_{n+1} + b_{s-1} f_n + \dots + b_1 f_{n-s+2} + b_0 f_{n-s+1}] \quad (10.85)$$

Para conformidade com [9], translate  $s - 1$  índices,

$$u_{n+s} = u_{n+s-1} + h[b_s f_{n+s} + b_{s-1} f_{n+s-1} + \dots + b_1 f_{n+1} + b_0 f_n] \quad (10.86)$$

e teremos

$$u_{n+s} = u_{n+s-1} + h \sum_{m=0}^s b_m f_{n+m} \quad (10.87)$$

De forma geral um **método de passo múltiplo** será

$$\sum_{m=0}^s a_m u_{n+m} = h \sum_{m=0}^s b_m f_{n+m} \quad (10.88)$$

## 10.11 O método de Adams-Bashforth

Quando  $a_s = 1$ ,  $a_{s-1} = -1$ ,  $a_m = 0$  para  $m = s-2, \dots, 0$ ,  $b_s = 0$  temos um método de Adams-Bashforth do tipo

$$u_{n+s} = u_{n+s-1} + h \sum_{m=0}^{s-1} b_m f_{n+m} \quad (10.89)$$

Note que os métodos de Adams-Bashforth são **explícitos** pois  $b_s = 0$ .

**Exemplo 10.11.1.** Vamos obter o método de Adams-Bashforth para  $s = 4$  como

$$u_{n+4} = u_{n+3} + \int_{t_{n+3}}^{t_{n+4}} f(t, u(t)) dt \quad (10.90)$$

$$u_{n+4} = u_{n+3} + h \sum_{m=0}^3 b_m f_{n+m} \quad (10.91)$$

$$u_{n+4} = u_{n+3} + h[b_3 f_{n+3} + b_2 f_{n+2} + b_1 f_{n+1} + b_0 f_n] \quad (10.92)$$

Para isso devemos obter  $[b_3, b_2, b_1, b_0]$  tal que o método seja exato para polinômios até ordem 3. Podemos obter esses coeficientes de maneira análoga a obter os coeficientes de um método para integração.

Supondo que os nós  $t_k$  estejam igualmente espaçados, e para facilidade dos cálculos, como o intervalo de integração é  $[t_{n+3}, t_{n+4}]$ , translade  $t_{n+3}$  para a origem tal que  $[t_n, t_{n+1}, \dots, t_{n+4}] = [-3h, -2h, -h, 0, h]$ .

Considere a base  $[\phi_0(t), \dots, \phi_3(t)] = [1, t, t^2, t^3]$  e substitua  $f(t)$  por  $\phi_k(t)$  obtendo

$$\begin{aligned} \int_0^h 1 dt &= h &&= h(b_0(1) + b_1(1) + b_2(1) + b_3(1)) \\ \int_0^h t dt &= \frac{h^2}{2} &&= h(b_0(0) + b_1(-h) + b_2(-2h) + b_3(-3h)) \\ \int_0^h t^2 dt &= \frac{h^3}{3} &&= h(b_0(0)^2 + b_1(-h)^2 + b_2(-2h)^2 + b_3(-3h)^2) \\ \int_0^h t^3 dt &= \frac{h^4}{4} &&= h(b_0(0)^3 + b_1(-h)^3 + b_2(-2h)^3 + b_3(-3h)^3) \end{aligned}$$

que pode ser escrito na forma matricial

$$\begin{pmatrix} 1 & 1 & 1 & 1 \\ 0 & -1 & -2 & -3 \\ 0 & 1 & 4 & 9 \\ 0 & -1 & -8 & -27 \end{pmatrix} \begin{pmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1/2 \\ 1/3 \\ 1/4 \end{pmatrix} \quad (10.93)$$

Resolvendo o sistema obtemos

$$[b_0, b_1, b_2, b_3] = [-\frac{9}{24}, \frac{37}{24}, -\frac{59}{24}, \frac{55}{24}]$$

fornecendo o **método de Adams-Bashforth de 4 estágios**

$$u_{n+4} = u_{n+3} + \frac{h}{24}[55f_{n+3} - 59f_{n+2} + 37f_{n+1} - 9f_n] \quad (10.94)$$

**E 10.11.1.** Mostre que o método de Adams-Bashforth para  $s = 2$  é dado por

$$u_{n+2} = u_{n+1} + \frac{h}{2}[3f_{n+1} - f_n] \quad (10.95)$$

**E 10.11.2.** Mostre que o método de Adams-Bashforth para  $s = 3$  é dado por

$$u_{n+3} = u_{n+2} + \frac{h}{12}[23f_{n+2} - 16f_{n+1} + 5f_n] \quad (10.96)$$

## 10.12 O método de Adams-Moulton

Quando  $a_s = 1$ ,  $a_{s-1} = -1$ ,  $a_m = 0$  para  $m = s - 2, \dots, 0$ ,  $b_s \neq 0$  temos um método de Adams-Moulton do tipo

$$u_{n+s} = u_{n+s-1} + h \sum_{m=0}^s b_m f_{n+m} \quad (10.97)$$

Note que os métodos de Adams-Moulton são implícitos pois  $b_s \neq 0$ .

**Exemplo 10.12.1.** Vamos obter o método de Adams-Moulton para  $s = 3$  como

$$u_{n+3} = u_{n+2} + \int_{t_{n+2}}^{t_{n+3}} f(t, u(t)) dt \quad (10.98)$$

$$u_{n+3} = u_{n+2} + h \sum_{m=0}^3 b_m f_{n+m} \quad (10.99)$$

$$u_{n+3} = u_{n+2} + h[b_3 f_{n+3} + b_2 f_{n+2} + b_1 f_{n+1} + b_0 f_n] \quad (10.100)$$

Para isso devemos obter  $[b_3, b_2, b_1, b_0]$  tal que o método seja exato para polinômios até ordem 3. Podemos obter esses coeficientes de maneira análoga a obter os coeficientes de um método para integração.

Supondo que os nós  $t_k$  estejam igualmente espaçados, e para facilidade dos cálculos, como o intervalo de integração é  $[t_{n+2}, t_{n+3}]$ , translate  $t_{n+2}$  para a origem tal que  $[t_n, t_{n+1}, \dots, t_{n+3}] = [-2h, -h, 0, h]$ .

Considere a base  $[\phi_0(t), \dots, \phi_3(t)] = [1, t, t^2, t^3]$  e substitua  $f(t)$  por  $\phi_k(t)$  obtendo

$$\begin{aligned}\int_0^h 1 \, dt &= h &&= h(b_0(1) + b_1(1) + b_2(1) + b_3(1)) \\ \int_0^h t \, dt &= \frac{h^2}{2} &&= h(b_0(h) + b_1(0) + b_2(-h) + b_3(-2h)) \\ \int_0^h t^2 \, dt &= \frac{h^3}{3} &&= h(b_0(h)^2 + b_1(0)^2 + b_2(-h)^2 + b_3(-2h)^2) \\ \int_0^h t^3 \, dt &= \frac{h^4}{4} &&= h(b_0(h)^3 + b_1(0)^3 + b_2(-h)^3 + b_3(-2h)^3)\end{aligned}$$

que pode ser escrito na forma matricial

$$\begin{pmatrix} 1 & 0 & 1 & 1 \\ 1 & 0 & -1 & -2 \\ 1 & 0 & 1 & 4 \\ 1 & 0 & -1 & -8 \end{pmatrix} \begin{pmatrix} b_0 \\ b_1 \\ b_2 \\ b_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 1/2 \\ 1/3 \\ 1/4 \end{pmatrix} \quad (10.101)$$

Resolvendo o sistema obtemos

$$[b_0, b_1, b_2, b_3] = [\frac{1}{24}, -\frac{5}{24}, \frac{19}{24}, \frac{9}{24}]$$

fornecendo a regra

$$u_{n+3} = u_{n+2} + \frac{h}{24}[9f_{n+3} + 19f_{n+2} - 5f_{n+1} + f_n] \quad (10.102)$$

**E 10.12.1.** Encontre o método de Adams-Moulton para  $s = 2$ .

**E 10.12.2.** Encontre o método de Adams-Moulton para  $s = 3$ .

## 10.13 Método BDF

Um método de ordem  $s$  com  $s$  estágios é chamado de **método BDF-Backward Differentiation Formula** se  $\sigma(w) = b_s w^s$ , onde  $b_s \in \mathbb{R}$ , ou seja,

$$a_s u_{n+s} + \dots + a_1 u_{n+1} + a_0 u_n = h b_s f_{n+s} \quad (10.103)$$

**Exemplo 10.13.1.** Mostre que o método BDF com  $s = 3$  é

$$u_{n+3} - \frac{18}{11}u_{n+2} + \frac{9}{11}u_{n+1} - \frac{2}{11}u_n = \frac{6}{11}hf_{n+3} \quad (10.104)$$

**E 10.13.1.** Mostre que o método BDF com  $s = 1$  é o método de Euler implícito.

**E 10.13.2.** Mostre que o método BDF com  $s = 2$  é

$$u_{n+2} - \frac{4}{3}u_{n+1} + \frac{1}{3}u_n = \frac{2}{3}hf_{n+2} \quad (10.105)$$

## 10.14 Ordem e convergência de métodos de passo múltiplo

Mais geralmente, um método de passo múltiplo será da forma

$$a_s u_{n+s} + \dots + a_1 u_{n+1} + a_0 u_n = h[b_s f_{n+s} + \dots + b_1 f_{n+1} + b_0 f_n] \quad (10.106)$$

Por convenção normalizamos a equação acima tomando  $a_s = 1$ . Quando  $b_s = 0$  temos um método explícito e quando  $b_s \neq 0$  temos um método implícito.

O método será de ordem  $p$  se o  $ETL = \mathcal{O}(h^{p+1})$ .

Dois polinômios são usados para estudar o método (10.106):

$$\rho(w) = a_s w^s + \dots + a_1 w + a_0, \quad \sigma(w) = b_s w^s + \dots + b_1 w + b_0, \quad (10.107)$$

**Exemplo 10.14.1.** O método (10.96) de Adams-Bashforth para  $s = 3$  estágios é de ordem 3 de convergência, ou seja,  $ETL = \mathcal{O}(h^4)$ . Ele é construído de tal maneira que seja exato para os polinômios  $1, t, t^2, t^3$ .

### 10.14.1 Consistência, Estabilidade e Convergência

**Teorema 10.14.1.** Um método de passo múltiplo é **consistente** se  $\rho(1) = 0$  e  $\rho'(1) = \sigma(1)$ .

**Teorema 10.14.2.** Um método de passo múltiplo é **estável** se todas as raízes de  $\rho(z)$  estão em  $|z| \leq 1$  e as raízes com  $|z| = 1$  são simples.

**Teorema 10.14.3.** Se um método numérico é **consistente** e **estável** em  $[a, b]$  então ele é **convergente**.

**Exemplo 10.14.2.** Prove que o método de passo 3

$$u_{n+3} + \frac{27}{11}u_{n+2} - \frac{27}{11}u_{n+1} - u_n = \quad (10.108)$$

$$= \frac{h}{11}[3f_{n+3} + 27f_{n+2} + 27f_{n+1} + 3f_n] \quad (10.109)$$

não é estável.

**Solução.** O polinômio

$$\rho(w) = w^3 + \frac{27}{11}w^2 - \frac{27}{11}w - 1 \quad (10.110)$$

$$= (w-1) \left( w + \frac{19+4\sqrt{15}}{11} \right) \left( w + \frac{19-4\sqrt{15}}{11} \right) \quad (10.111)$$

falha na condição da raiz.  $\diamond$

**E 10.14.1.** Prove que todos os métodos de Adams-Bashforth satisfazem a condição da raiz.

**Teorema 10.14.4.** O polinômio  $\rho(w)$  em (10.103) satisfaz a condição da raiz e o método BDF é convergente se e somente se  $1 \leq s \leq 6$ .

**E 10.14.2.** Mostre que os métodos BDF com  $s = 2$  e  $s = 3$  são convergentes.

## 10.14.2 As barreiras de Dahlquist

Um método de passo múltiplo possui  $2s + 1$  coeficientes  $a_m, b_m$ . Poderíamos definir tais coeficientes de tal forma a obter ordem máxima.

Conclusão? Poderíamos obter métodos com  $s$  estágios e ordem  $2s$ .

Entretanto tal método (implícito de passo  $s$  e ordem  $2s$ ) não é convergente para  $s \geq 3$ .

É possível provar que a ordem máxima de convergência para um método de passo múltiplo  $s$  é no máximo  $2\lfloor(s+2)/2\rfloor$  para métodos implícitos e  $s$  para métodos explícitos. Esta é a **primeira barreira de Dahlquist**.

## 10.15 Estabilidade dos métodos de passo múltiplo

**Teorema 10.15.1.** O método BDF de 2 estágios é A-estável.

**Teorema 10.15.2** (A segunda barreira de Dahlquist). A ordem máxima de um método de passo múltiplo A-estável é dois.

## 10.16 Métodos de Runge-Kutta

### 10.16.1 Método de Runge-Kutta Explícito

Seja a EDO

$$u'(t) = f(t, u(t)) \quad (10.112)$$

$$u(t_0) = a \quad (10.113)$$

Integrando a EDO em  $[t_n, t_{n+1}]$  obtemos

$$u_{n+1} = u_n + \int_{t_n}^{t_{n+1}} f(t, u(t)) dt \quad (10.114)$$

Um método de passo simples utiliza  $f_n$  e  $f_{n+1}$ . Queremos aumentar a ordem do método, porém utilizando somente valores de  $f$  entre  $[t_n, t_{n+1}]$ .

$u_n$	$u_{n+1}$
$t_n \qquad \qquad \qquad t_{n+1}$	
$\tau_1 \quad \tau_2 \quad \cdots$	$\tau_\nu$

$$u_{n+1} = u_n + \int_{t_n}^{t_{n+1}} f(t, u(t)) dt \quad (10.115)$$

$$= u_n + h \int_0^1 f(t_n + h\tau, u(t_n + h\tau)) d\tau \quad (10.116)$$

$$= u_n + h \sum_{j=1}^{\nu} b_j f(t_n + c_j h, u(t_n + c_j h)) \quad (10.117)$$

Por exemplo, se  $\nu = 3$  estágios teremos  $[\tau_0, \tau_1, \tau_2] = [t_n + c_0 h, t_n + c_1 h, t_n + c_2 h]$ ,  $U_j \equiv u(\tau_j)$  e  $F_j \equiv f(\tau_j, U_j)$ ,  $j = 1, 2, 3$ . Inicie com  $U_1 = u_n$  ( $c_1 = 0$ ) como a solução no passo anterior e aproxime  $U_2, U_3$ , com uma combinação linear dos valores de  $F_j$  anteriores, ou seja,

$$U_1 = u_n \quad (10.118)$$

$$U_2 = u_n + h a_{21} F_1 \quad (10.119)$$

$$U_3 = u_n + h a_{31} F_1 + h a_{32} F_2 \quad (10.120)$$

$$u_{n+1} = u_n + h [b_1 F_1 + b_2 F_2 + b_3 F_3] \quad (10.121)$$



onde  $A = (a_{ij})$  é a matriz de RK (triangular inferior com diagonal zero),  $b_j$  são os pesos RK e  $c_j$  são os nós RK.

Os coeficientes podem ser resumidos em uma tabela na forma

$$\begin{array}{c|c} c & A \\ \hline & b^T \end{array} = \begin{array}{c|ccc} & c_1 & 0 & 0 & 0 \\ & c_2 & a_{21} & 0 & 0 \\ & c_3 & a_{31} & a_{22} & 0 \\ \hline & b_1 & b_2 & b_3 \end{array}$$

### 10.16.2 Método de RK $\nu = 2$

Assumindo suavidade suficiente em  $f$ , expanda em série de Taylor

$$F_2 = f(t_n + c_2 h, U_2) \quad (10.122)$$

$$= f(t_n + c_2 h, u_n + a_{21} h f_n) \quad (10.123)$$

$$= f_n + h \left[ c_2 \frac{\partial f_n}{\partial t} + a_{21} \frac{\partial f_n}{\partial u} f_n \right] + O(h^2) \quad (10.124)$$

fazendo com que (10.121) se torne

$$u_{n+1} = u_n + h[b_1 F_1 + b_2 F_2] \quad (10.125)$$

$$= u_n + h(b_1 + b_2)f_n + h^2 b_2 \left[ c_2 \frac{\partial f_n}{\partial t} + a_{21} \frac{\partial f_n}{\partial u} f_n \right] + O(h^3) \quad (10.126)$$

Usando a EDO e derivando-a obtemos

$$u_t = f(t, u) \quad (10.127)$$

$$u_{tt} = f_t + f_u u_t = f_t + f_u f \quad (10.128)$$

e expandindo em série de Taylor a solução exata em  $t_{n+1}$ ,

$$u(t_{n+1}) = u_n + h u_t + \frac{h^2}{2} u_{tt} + O(h^3) \quad (10.129)$$

$$= u_n + h f_n + \frac{h^2}{2} [f_t + f_u f] + O(h^3) \quad (10.130)$$

e comparando com (10.126) obtemos as condições para ordem  $p \geq 2$ ,

$$b_1 + b_2 = 1, \quad b_2 c_2 = \frac{1}{2} \quad a_{21} = c_2 \quad (10.131)$$

O sistema possui mais de uma solução. Algumas escolhas comuns são

$$\begin{array}{c|cc} 0 & & \\ \hline \frac{1}{2} & \frac{1}{2} & \\ \hline & 0 & 1 \end{array}, \quad \begin{array}{c|cc} 0 & & \\ \hline \frac{2}{3} & \frac{2}{3} & \\ \hline & \frac{1}{4} & \frac{3}{4} \end{array} \quad \text{e} \quad \begin{array}{c|cc} 0 & & \\ \hline 1 & 1 & \\ \hline & \frac{1}{2} & \frac{1}{2} \end{array}$$

onde a última tabela fornece o método de Heun (ou Euler modificado):

$$U_1 = u_n \quad (10.132)$$

$$U_2 = u_n + hF_1 \quad (10.133)$$

$$u_{n+1} = u_n + h\left[\frac{1}{2}F_1 + \frac{1}{2}F_2\right] \quad (10.134)$$

Note que o método é de ordem  $p = 2$  pois os termos que sobraram são de  $O(h^3)$ .

Seguindo um procedimento similar, podemos obter as condições para um método com  $\nu = 3$  e ordem  $p = 3$ , que são

$$b_1 + b_2 + b_3 = 1, \quad b_2c_2 + b_3c_3 = \frac{1}{2} \quad (10.135)$$

$$b_2c_2^2 + b_3c_3^2 = \frac{1}{3}, \quad b_3a_{32}c_2 = \frac{1}{6} \quad (10.136)$$

Alguns exemplos de métodos de RK de 3 estágios são o método clássico de Runge-Kutta

0			
$\frac{1}{2}$	$\frac{1}{2}$		
1	-1	2	
	$\frac{1}{6}$	$\frac{4}{6}$	$\frac{1}{6}$

e o método de Nystrom

0			
$\frac{2}{3}$	$\frac{2}{3}$		
$\frac{2}{3}$	0	$\frac{2}{3}$	
	$\frac{2}{8}$	$\frac{3}{8}$	$\frac{3}{8}$

Com paciência e a ajuda de um software algébrico (como Maple) é possível encontrar um método de quarta ordem e  $\nu = 4$  estágios como

0				
$\frac{1}{2}$	$\frac{1}{2}$			
$\frac{1}{2}$	0	$\frac{1}{2}$		
1	0	0	1	
	$\frac{1}{6}$	$\frac{2}{6}$	$\frac{2}{6}$	$\frac{1}{6}$

### 10.16.3 Método de Runge-Kutta implícito (IRK)

No conjunto de equações (10.118)-(10.121),  $U_k$  depende em valores conhecidos  $F_1, \dots, F_{k-1}$  tornando o método explícito.

Entretanto se  $U_k$  depender de  $F_1, \dots, F_\nu$  temos um método implícito como

$$U_j = u_n + h \sum_{i=1}^{\nu} a_{ji} F_i, \quad j = 1, \dots, \nu \quad (10.137)$$

$$u_{n+1} = u_n + h \sum_{i=1}^{\nu} b_i F_i \quad (10.138)$$

onde  $A = (a_{ij})$  é a matriz de RK. É necessário que

$$\sum_{i=1}^{\nu} a_{ji} = c_j, \quad j = 1, \dots, \nu \quad (10.139)$$

para que o método possua ordem  $p \geq 1$ .

**Exemplo 10.16.1.** Um método de Runge-Kutta Implícito (IRK) de dois estágios é dado por

$$U_1 = u_n + h/4[f(t_n, U_1) - f(t_n + \frac{2}{3}h, U_2)] \quad (10.140)$$

$$U_2 = u_n + h/12[3f(t_n, U_1) + 5f(t_n + \frac{2}{3}h, U_2)] \quad (10.141)$$

$$u_{n+1} = u_n + h/4[f(t_n, U_1) + 3f(t_n + \frac{2}{3}h, U_2)] \quad (10.142)$$

que possui uma tabela como

0	$\frac{1}{4}$	$-\frac{1}{4}$
$\frac{2}{3}$	$\frac{1}{4}$	$\frac{5}{12}$
	$\frac{1}{4}$	$\frac{3}{4}$

## 10.17 Estimativa da ordem de convergência

Raramente temos a solução exata  $u(t)$  para calcular o erro obtido na solução numérica. Entretanto, se a solução é suave o suficiente e o espaçamento  $h$  é pequeno suficientemente, podemos usar o seguinte procedimento para estimar a ordem do método (ou ainda, o erro na solução).

Como visto nos exemplo numéricos anteriores, em gráficos na escala **loglog**, se  $h$  é grande não obtemos a ordem de convergência utilizada (por exemplo, encontramos que o método de Euler possui ordem  $p \approx 0.7$  onde deveria ser 1). A medida que  $h$  decresce se aproximando de 0, a ordem de convergência tende a se aproximar de  $p \approx 1$ . (Entretanto  $h$  não pode ficar muito pequeno a ponto que as operações de ponto flutuante atrapalhem na convergência).

Portanto existe uma faixa  $h_{min} < h < h_{max}$  onde o método apresenta a ordem desejada. Essa região depende do método e do PVI estudado.

Mas se estivermos nessa região podemos aproximar a ordem do método da seguinte forma: Considere a solução para um determinado  $t = T^*$  fixo,  $u(T^*)$ . Considere também as aproximações das soluções obtidas com espaçamento  $h$ , denotada por  $u^h$ ; a aproximação obtida com espaçamento dividido por 2,  $h/2$ , denotada por  $u^{h/2}$ ; a aproximação obtida com espaçamento  $h/4$ , denotada por  $u^{h/4}$ , ... e assim por diante, todas calculadas em  $t = T^*$ .

### 10.17.1 Método 1

Podemos utilizar uma solução bem refinada, por exemplo,  $u^{h/16}$  como sendo uma boa aproximação da solução exata e supormos que  $u^* = u^{h/16}$ . Desta forma podemos aproximar o erro por  $e^h = \|u^{(h)} - u^*\|$  e a ordem do método é estimada como

$$p \approx \frac{\log(e^h) - \log(e^{h/2})}{\log(h) - \log(h/2)} \quad (10.143)$$

$$\approx \frac{\log\left(\frac{e^h}{e^{h/2}}\right)}{\log(h/(h/2))} \quad (10.144)$$

$$\approx \frac{\log\left(\frac{e^h}{e^{h/2}}\right)}{\log(2)} \quad (10.145)$$

$$\approx \frac{\log\left(\frac{\|u^h - u^*\|}{\|u^{h/2} - u^*\|}\right)}{\log(2)} \quad (10.146)$$

$$(10.147)$$

### 10.17.2 Método 2

Segundo Ferziger/Peric/Roache, podemos também estimar  $p$  diretamente de

$$p \approx \frac{\log\left(\frac{\|u^{h/2} - u^h\|}{\|u^{h/4} - u^{h/2}\|}\right)}{\log(2)} \quad (10.148)$$

$$(10.149)$$

## Exercícios

**E 10.17.1.** Resolva o problema 1 pelos diversos métodos e verifique heurísticamente a estabilidade para diversos valores de  $h$ .

## 10.18 Sistemas de equações diferenciais e equações de ordem superior

O problema (10.1) pode ser um sistema de equações de primeira ordem, isto é, a incógnita  $y(t)$  pode ser um vetor de funções, como mostra o exemplo 10.150

**Exemplo 10.18.1.** O problema de valor inicial

$$u'(t) = v(t), \quad (10.150a)$$

$$v'(t) = u(t), \quad (10.150b)$$

$$u(0) = 1. \quad (10.150c)$$

$$v(0) = 0. \quad (10.150d)$$

pode ser escrito na forma (10.1) com  $y(t)$

No exemplo 10.18.2, mostramos como o método de Euler pode ser facilmente estendido para problemas envolvendo sistemas de equações diferenciais..

**Exemplo 10.18.2.** Escreva o processo iterativo de Euler para resolver numericamente o seguinte sistema de equações diferenciais

$$\begin{aligned} x' &= -y \\ y' &= x \\ x(0) &= 1 \\ y(0) &= 0, \end{aligned}$$

cujas soluções exatas são  $x(t) = \cos(t)$  e  $y(t) = \sin(t)$ .

Para aplicar o método de Euler a um sistema, devemos encarar as diversas incógnitas do sistema como formando um vetor, neste caso, escrevemos:

$$z(t) = \begin{bmatrix} x(t) \\ y(t) \end{bmatrix}.$$

O sistema é igualmente escrito na forma vetorial:

$$\begin{bmatrix} x^{(k+1)} \\ y^{(k+1)} \end{bmatrix} = \begin{bmatrix} x^{(k)} \\ y^{(k)} \end{bmatrix} + h \begin{bmatrix} -y^{(k)} \\ x^{(k)} \end{bmatrix}.$$

Observe que este processo iterativo é equivalente a:

$$\begin{aligned} x^{(k+1)} &= x^{(k)} - hy^{(k)} \\ y^{(k+1)} &= y^{(k)} + hx^{(k)}. \end{aligned}$$

**Exemplo 10.18.3.** Escreva o problema de valor inicial de segunda ordem dado por

$$\begin{aligned}y'' + y' + y &= \cos(t), \\y(0) &= 1, \\y'(0) &= 0,\end{aligned}$$

como um problema envolvendo um sistema de primeira ordem.

A fim de transformar a equação diferencial dada em um sistema de equações de primeira ordem, introduzimos a substituição  $w = y'$ , de forma que obteremos o sistema:

$$\begin{aligned}y' &= w \\w' &= -w - y + \cos(t) \\y(0) &= 1 \\w(0) &= 0\end{aligned}$$

Portanto, o método de Euler produz o seguinte processo iterativo:

$$\begin{aligned}y^{(k+1)} &= y^{(k)} + hw^{(k)}, \\w^{(k+1)} &= w^{(k)} - hw^{(k)} - hy^{(k)} + h\cos(t^{(k)}), \\y^{(1)} &= 1, \\w^{(1)} &= 0.\end{aligned}$$

## Exercícios

**E 10.18.1.** Resolva o problema de valor inicial dado por

$$\begin{aligned}y' &= -2y + \sqrt{z} \\z' &= -z + y \\y(0) &= 0 \\z(0) &= 2\end{aligned}$$

com passo  $h = 0,2$ ,  $h = 0,02$ ,  $h = 0,002$  e  $h = 0,0002$  para obter aproximações para  $y(2)$  e  $z(2)$ .

## 10.19 Exercícios finais

**E 10.19.1.** Considere o seguinte modelo para o crescimento de uma colônia de bactérias:

$$\frac{du}{dt} = \alpha u(A - u)$$

onde  $u$  indica a densidade de bactérias em unidades arbitrárias na colônia e  $\alpha$  e  $A$  são constantes positivas. Pergunta-se:

- Qual a solução quando a condição inicial  $u(0)$  é igual a 0 ou  $A$ ?
- O que acontece quando a condição inicial  $u(0)$  é um número entre 0 e  $A$ ?
- O que acontece quando a condição inicial  $u(0)$  é um número negativo?
- O que acontece quando a condição inicial  $u(0)$  é um número positivo maior que  $A$ ?
- Se  $A = 10$  e  $\alpha = 1$  e  $u(0) = 1$ , use métodos numéricos para obter tempo necessário para que a população dobre?
- Se  $A = 10$  e  $\alpha = 1$  e  $u(0) = 4$ , use métodos numéricos para obter tempo necessário para que a população dobre?

**E 10.19.2.** Considere o seguinte modelo para a evolução da velocidade de um objeto em queda (unidades no SI):

$$v' = g - \alpha v^2$$

Sabendo que  $g = 9,8$  e  $\alpha = 10^{-2}$  e  $v(0) = 0$ . Pede-se a velocidade ao tocar o solo, sabendo que a altura inicial era 100.

**E 10.19.3.** Considere o seguinte modelo para o oscilador não-linear de Van der Pol:

$$u''(t) - \alpha(A - u(t)^2)u'(t) + w_0^2 u(t) = 0$$

onde  $A$ ,  $\alpha$  e  $w_0$  são constantes positivas.

- Encontre a frequência e a amplitude de oscilações quando  $w_0 = 1$ ,  $\alpha = .1$  e  $A = 10$ . (Teste diversas condições iniciais)
- Estude a dependência da frequência e da amplitude com os parâmetros  $A$ ,  $\alpha$  e  $w_0$ . (Teste diversas condições iniciais)
- Que diferenças existem entre esse oscilador não-linear e o oscilador linear?

**E 10.19.4.** Considere o seguinte modelo para um oscilador não-linear:

$$\begin{aligned} u''(t) - \alpha(A - z(t))u'(t) + w_0^2 u(t) &= 0 \\ Cz'(t) + z(t) &= u(t)^2 \end{aligned}$$

onde  $A$ ,  $\alpha$ ,  $w_0$  e  $C$  são constantes positivas.

- Encontre a frequência e a amplitude de oscilações quando  $w_0 = 1$ ,  $\alpha = .1$ ,  $A = 10$  e  $C = 10$ . (Teste diversas condições iniciais)
- Estude a dependência da frequência e da amplitude com os parâmetros  $A$ ,  $\alpha$ ,  $w_0$  e  $C$ . (Teste diversas condições iniciais)

**E 10.19.5.** Considere o seguinte modelo para o controle de temperatura em um processo químico:

$$\begin{aligned} CT'(t) + T(t) &= \kappa P(t) + T_{ext} \\ P'(t) &= \alpha(T_{set} - T(t)) \end{aligned}$$

onde  $C$ ,  $\alpha$  e  $\kappa$  são constantes positivas e  $P(t)$  indica o potência do aquecedor. Sabendo que  $T_{set}$  é a temperatura desejada, interprete o funcionamento desse sistema de controle.

- Calcule a solução quando a temperatura externa  $T_{ext} = 0$ ,  $T_{set} = 1000$ ,  $C = 10$ ,  $\kappa = .1$  e  $\alpha = .1$ . Considere condições iniciais nulas.
- Quanto tempo demora o sistema para atingir a temperatura 900K?
- Refaça os dois primeiros itens com  $\alpha = 0.2$  e  $\alpha = 1$
- Faça testes para verificar a influência de  $T_{ext}$ ,  $\alpha$  e  $\kappa$  na temperatura final.

**E 10.19.6.** Considere a equação do pêndulo dada por:

$$\frac{d^2\theta(t)}{dt^2} + \frac{g}{l} \sin(\theta(t)) = 0$$

onde  $g$  é o módulo da aceleração da gravidade e  $l$  é o comprimento da haste.

- Mostre analiticamente que a energia total do sistema dada por

$$\frac{1}{2} \left( \frac{d\theta(t)}{dt} \right)^2 - \frac{g}{l} \cos(\theta(t))$$

é mantida constante.



- Resolva numericamente esta equação para  $g = 9,8m/s^2$  e  $l = 1m$  e as seguintes condições iniciais:

$$\theta(0) = 0.5 \text{ e } \theta'(0) = 0.$$

$$\theta(0) = 1.0 \text{ e } \theta'(0) = 0.$$

$$\theta(0) = 1.5 \text{ e } \theta'(0) = 0.$$

$$\theta(0) = 2.0 \text{ e } \theta'(0) = 0.$$

$$\theta(0) = 2.5 \text{ e } \theta'(0) = 0.$$

$$\theta(0) = 3.0 \text{ e } \theta'(0) = 0.$$

Em todos os casos, verifique se o método numérico reproduz a lei de conservação de energia e calcule período e amplitude.

**E 10.19.7.** Considere o modelo simplificado de FitzHugh-Nagumo para o potencial elétrico sobre a membrana de um neurônio:

$$\begin{aligned}\frac{dV}{dt} &= V - V^3/3 - W + I \\ \frac{dW}{dt} &= 0.08(V + 0.7 - 0.8W)\end{aligned}$$

onde  $I$  é a corrente de excitação.

- Encontre o único estado estacionário  $(V_0, W_0)$  com  $I = 0$ .
- Resolva numericamente o sistema com condições iniciais dadas por  $(V_0, W_0)$  e

$$I = 0$$

$$I = 0.2$$

$$I = 0.4$$

$$I = 0.8$$

$$I = e^{-t/200}$$

**E 10.19.8.** Considere o problema de valor inicial dado por

$$\begin{aligned}\frac{du(t)}{dt} &= -u(t) + e^{-t} \\ u(0) &= 0\end{aligned}$$

Resolva analiticamente este problema usando as técnicas elementares de equações diferenciais ordinárias. A seguir encontre aproximações numéricas usando os métodos de Euler, Euler modificado, Runge-Kutta Clássico e Adams-Bashforth de ordem 4 conforme pedido nos itens.

- a) Construa uma tabela apresentando valores com 7 algarismos significativos para comparar a solução analítica com as aproximações numéricas produzidas pelos métodos sugeridos. Construa também uma tabela para o erro absoluto obtido por cada método numérico em relação à solução analítica. Nesta última tabela, expresse o erro com 2 algarismos significativos em formato científico. Dica: `format('e',8)` para a segunda tabela.

	0.5	1.0	1.5	2.0	2.5
Analítico					
Euler					
Euler modificado					
Runge-Kutta Clássico					
Adams-Bashforth ordem 4					

	0.5	1.0	1.5	2.0	2.5
Euler					
Euler modificado					
Runge-Kutta Clássico					
Adams-Bashforth ordem 4					

- b) Calcule o valor produzido por cada um desses métodos para  $u(1)$  com passo  $h = 0.1$ ,  $h = 0.05$ ,  $h = 0.01$ ,  $h = 0.005$  e  $h = 0.001$ . Complete a tabela com os valores para o erro absoluto encontrado.

	0.1	0.05	0.01	0.005	0.001
Euler					
Euler modificado					
Runge-Kutta Clássico					
Adams-Bashforth ordem 4					

# Capítulo 11

## Problemas de Valores de Contorno

Neste capítulo, discutimos sobre métodos numéricos para resolver equações diferenciais ordinárias com condições de contorno.

### 11.1 Método de Diferenças Finitas

Nesta seção, discutimos os fundamentos do **método de diferenças finitas** (MDF) para **problemas de valores de contorno** (PVC). Este método consiste na reformulação do problema contínuo em um problema discreto usando fórmulas de diferenças finitas tomadas sobre uma malha apropriada.

Para introduzir os conceitos principais, consideramos o seguinte problema de valor de contorno (PVC)

$$-u_{xx} = f(x, u), \quad a < x < b, \quad (11.1)$$

$$u(a) = u_a, \quad (11.2)$$

$$u(b) = u_b, \quad (11.3)$$

onde  $u_a$  e  $u_b$  são dados. Por ter fixados os valores da variável  $u$  nos contornos, este é chamado de PVC com condições de Dirichlet<sup>1</sup>.

A resolução de um tal problema pelo método de elementos finitos consiste em quatro etapas fundamentais: 1. construção da malha, 2. construção do problema discreto, 3. resolução do problema discreto e 4. visualização e interpretação dos resultados.

**1. Construção da malha.** A malha consiste em uma representação discreta do domínio  $[a, b]$ . Como veremos, sua construção tem impacto direto nas próximas

---

<sup>1</sup>Johann Peter Gustav Lejeune Dirichlet, 1805 - 1859, matemático alemão.



Figura 11.1: Malha uniforme de  $N$  pontos em um intervalo  $[a, b]$ .

etapas do método. Aqui, vamos construir a malha mais simples possível, aquela que consiste de  $N$  pontos igualmente espaçados, isto é, a chamada **malha uniforme**.

Para tanto, seja  $N \in \mathbb{N}$  dado e, então, tomamos o seguinte conjunto discreto  $\mathcal{P}_N = \{x_1, x_2, \dots, x_N\}$  (a malha), onde

$$x_i = a + (i - 1)h, \quad i = 1, 2, \dots, N,$$

com

$$h := \frac{b - a}{N - 1},$$

o qual é chamado de **tamanho (ou passo) da malha** (veja a figura 11.1).

**2. Construção do problema discreto.** A segunda etapa consiste na discretização das equações, no nosso caso, das equações (11.1)-(11.3).

Vamos começar pela equação (11.1). Em um ponto da malha  $x_i$ ,  $i = 2, 3, \dots, N - 1$ , temos

$$-u_{xx}(x_i) = f(x_i, u(x_i)).$$

Usando a fórmula de diferenças finitas central de ordem 2 para a segunda derivada, temos

$$-\left(\frac{u(x_i - h) - 2u(x_i) + u(x_i + h)}{h^2} + O(h^2)\right) = f(x_i, u(x_i)).$$

Rearranjando os termos, obtemos

$$\frac{u(x_i - h) - 2u(x_i) + u(x_i + h)}{h^2} = f(x_i, u(x_i)) + O(h^2).$$

Agora, denotando por  $u_i$  a aproximação numérica de  $u(x_i)$ , a equação acima nos fornece

$$\frac{1}{h^2}u_{i-1} + \frac{2}{h^2}u_i + \frac{1}{h^2}u_{i+1} = f(x_i, u_i), \quad (11.4)$$

para  $i = 2, 3, \dots, N - 1$ . Observamos que trata-se de um sistema de  $N$  incógnitas, a saber  $u_i$ , e de  $N - 2$  equações, isto é, um sistema subdeterminado.

Para obtermos um sistema determina, aplicamos as condições de contorno. Da condição de contorno dada na equação (11.2), temos

$$u(a) = u_a \Rightarrow u_1 = u_a. \quad (11.5)$$

Analogamente, da condição de contorno dada na equação (11.2), temos

$$u(b) = u_b \Rightarrow u_N = u_b. \quad (11.6)$$

Por fim, as equações (11.6), (11.4) e (11.5) determinam o problema discreto associado

$$u_1 = u_a, \quad (11.7)$$

$$\frac{1}{h^2}u_{i-1} + \frac{2}{h^2}u_i + \frac{1}{h^2}u_{i+1} = f(x_i, u_i), \quad i = 2, \dots, N-1, \quad (11.8)$$

$$u_N = u_b. \quad (11.9)$$

Este é um sistema de equações de  $N$  incógnitas e  $N$  equações.

**3. Resolução do sistema discreto.** Esta etapa consiste em resolver o sistema discreto construído na etapa anterior.

Para o PVC (11.1)-(11.3), construímos o problema discreto (11.7)-(11.9). Este é um problema de  $N$  equações e  $N$  incógnitas. Observamos que se  $f(x, u)$  é uma função linear, o sistema será linear e podemos resolver o sistema usando de técnicas numéricas para sistema lineares. Agora, se  $f(x, u)$  é uma função não linear, podemos usar, por exemplo, do método de Newton para sistemas.

**4. Visualização e interpretação dos resultados.** A solução do problema discreto consiste dos valores  $u_i$ , isto é, de aproximações dos valores de  $u$  nos pontos da malha. Para visualizarmos a solução podemos, por exemplo, construir o gráfico do conjunto de pontos  $\{(x_i, u_i)\}$ . Ainda, para obtermos aproximações da solução em outros pontos que não fazem parte da malha, podemos usar de técnicas de interpolação e/ou ajuste.

**Exemplo 11.1.1.** Use o método de diferenças finitas para resolver o seguinte problema de valor de contorno com condições de Dirichlet homogêneas:

$$-u_{xx} = 100(x-1)^2, \quad 0 < x < 1, \quad (11.10)$$

$$u(0) = 0, \quad (11.11)$$

$$u(1) = 0. \quad (11.12)$$

Use a fórmula de diferenças finitas central de ordem 2 para discretizar a derivada em uma malha uniforme de 11 pontos. Calcule, também, a solução analítica deste problema, faça um esboço das soluções numérica e analítica e compute o erro absoluto médio definido por

$$E := \frac{1}{N} \sum_{i=1}^N |u(x_i) - u_i|,$$

onde  $x_i$  é o  $i$ -ésimo ponto da malha,  $i = 1, 2, \dots, N$  e  $N$  é o número de pontos na mesma. Por fim, repita seus cálculos para uma malha com 101 pontos. O que ocorre com o erro absoluto médio?

**Solução.** Vamos seguir as etapas conforme acima.

**1. Construção da malha.** Tomando  $N = 11$ , definimos os pontos da malha no domínio  $[0, 1]$  por:

$$x_i = (i - 1)h, \quad i = 1, 2, \dots, N,$$

com  $h = 1/(N - 1)$ .

No Scilab, podemos construir a malha da seguinte forma:

```
a = 0
b = 1
N = 11
h = (b-a)/(N-1)
x = linspace(a,b,N)
```

**2. Construção do problema discreto.** Usando a fórmula de diferenças finitas central de ordem 2 para aproximar a derivada na equação (11.10), obtemos o seguinte sistema de equações:

$$-\frac{u_{i-1} - 2u_i + u_{i+1}}{h^2} = 100(x_i - 1)^2, \quad i = 2, \dots, N - 1.$$

Completamos este sistema com as condições de contorno dadas nas equações (11.11) e (11.12), donde

$$u_1 = u_N = 0.$$

Ou seja, obtemos o seguinte problema discreto:

$$u_1 = 0, \tag{11.13}$$

$$-\frac{1}{h^2}(u_{i+1} - 2u_i + u_{i-1}) = 100(x_i - 1)^2, \quad i = 2, \dots, N - 1, \tag{11.14}$$

$$u_N = 0. \tag{11.15}$$

Observamos que este é um sistema linear  $N \times N$ , o qual pode ser escrito na forma matricial  $A\mathbf{u} = \mathbf{b}$ , cujos matriz de coeficientes é

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 1 & -2 & 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & -2 & 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & 0 & \cdots & 1 \end{bmatrix},$$

o vetor das incógnitas e o vetor dos termos constantes são

$$\underline{u} = \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ \vdots \\ u_N \end{bmatrix} \quad \text{e} \quad \underline{b} = \begin{bmatrix} 0 \\ -100h^2(x_2 - 1)^2 \\ -100h^2(x_3 - 1)^2 \\ \vdots \\ 0 \end{bmatrix}.$$

No Scilab, podemos construir o problema discreto a seguinte forma:

```
A = zeros(N,N)
b = zeros(N)

A(1,1) = 1
b(1) = 0
for i = 2:N-1
    A(i,i-1) = 1
    A(i,i) = -2
    A(i,i+1) = 1
    b(i) = -100 * h^2 * (x(i)-1)^2
end
A(N,N) = 1
b(N) = 0
```

**3. Resolução do problema discreto.** Neste caso, o problema discreto consiste no sistema linear  $A\underline{u} = \underline{b}$  e, portanto, a solução é

$$\underline{u} = A^{-1}\underline{b}. \quad (11.16)$$

No Scilab, podemos computar a solução do sistema  $A\underline{u} = \underline{b}$  com:

```
u = A\b
```

**4. Visualização e interpretação dos resultados.** Tendo resolvido o problema discreto  $A\underline{u} = \underline{b}$ , obtemos os valores da solução numérico de  $u$  nos pontos da malha, isto é, obtivemos o conjunto de pontos  $\{(x_i, u_i)\}_{i=1}^N$ . Neste exemplo, queremos comparar a solução numérica com a solução analítica.

A solução analítica pode ser obtida por integração. Temos:

$$\begin{aligned} -u_{xx} &= 100(x-1)^2 \Rightarrow -u_x + c_1 = 100 \frac{(x-1)^3}{3} \\ \Rightarrow -u + c_2x + c_1 &= 100 \frac{(x-1)^4}{12}, \end{aligned}$$




Figura 11.2: Esboço dos gráficos das soluções analítica (linha) e numérica (pontos) do PVC dado no exemplo 11.1.1.

ou seja,  $u(x) = -\frac{(x-1)^4}{12} + c_2x + c_1$ . As constantes são determinadas pelas condições de contorno dadas pelas equações (11.11) e (11.12), isto é:

$$\begin{aligned} u(0) = 0 &\Rightarrow c_1 = \frac{100}{12}, \\ u(1) = 0 &\Rightarrow c_2 = -\frac{100}{12}. \end{aligned}$$

Portanto, a solução analítica é:

$$u(x) = -100\frac{(x-1)^4}{12} - 100\frac{x}{12} + \frac{100}{12} \quad (11.17)$$

A figura 11.2 mostra o esboço dos gráficos das soluções analítica (11.17) e a da solução numérica (11.16).

No Scilab, podemos fazer o esboço das soluções analítica e numérica da seguinte forma:

```
//def. sol. analitica
deff('y = ue(x)', 'y = -100.0*(x-1).^4/12 - 100*x/12 + 100.0/12')

//grafico
xx = linspace(0,1)
yy = ue(xx)
```



Tabela 11.1: Erro absoluto médio das soluções numéricas com  $N = 11$  e  $N = 101$  do PVC dado no exemplo 11.1.1.

$N$	$h$	$E$
11	0,1	$1,3 \times 10^{-2}$
101	0,01	$1,4 \times 10^{-4}$

```
plot(x,u,'ro',xx,yy,'b-')
```

Por fim, computamos o erro absoluto médio das soluções numéricas com  $N = 11$  e  $N = 101$ . A tabela 11.1 mostra os resultados obtidos. Observamos, que ao diminuirmos 10 vezes o tamanho da malha  $h$ , o erro absoluto médio diminui aproximadamente 100 vezes. Este resultado é esperado, pois o problema discreto (11.13)-(11.15) aproxima o problema contínuo (11.10)-(11.12) com erro de truncamento de ordem  $h^2$ . Verifique!

No Scilab, podemos computar o erro absoluto médio da seguinte forma:

```
E = sum(abs(ue(x)' - u))/N
```

◇

## Exercícios Resolvidos

**ER 11.1.1.** Use o método de diferenças finitas para resolver o seguinte problema de valor de contorno:

$$-u_{xx} + u = e^{-x}, \quad 0 < x < 1, \quad (11.18)$$

$$u(0,5) = 1, \quad (11.19)$$

$$u(1,5) = 2. \quad (11.20)$$

Para tanto, use a fórmula de diferenças finitas central de ordem 2 para discretizar a derivada em uma malha uniforme com passo  $h = 0,1$ . Faça, então, um esboço do gráfico da solução computada.

**Solução.** O passo  $h$  é uma malha uniforme com  $N$  pontos no domínio  $[0,5, 1,5]$  satisfaz:

$$h = \frac{(b-a)}{N-1} \Rightarrow N = \frac{(b-a)}{h} + 1.$$

Ou seja, a malha deve conter  $N = 11$  pontos igualmente espaçados. Denotamos os pontos na malha por  $x_i$ , onde  $x_i = 0,5 + (i-1)h$ .

$x$	$u$	$x$	$u$
0.50	1.000000	1.00	1.643900
0.60	1.143722	1.10	1.745332
0.70	1.280661	1.20	1.834176
0.80	1.410269	1.30	1.908160
0.90	1.531724	1.40	1.964534
1.00	1.643900	1.50	2.000000

Tabela 11.2: Solução numérica do exercício ER 11.1.1.

Agora, a equação diferencial dada no  $i$ -ésimo ponto da malha é:

$$-u_{xx}(x_i) + u(x_i) = e^{x_i}, \quad i = 2, 3, \dots, N-1.$$

Denotando  $u_i \approx u(x_i)$  e usando a fórmula de diferenças finitas central de ordem dois para a derivada  $u_{xx}$ , obtemos:

$$-\left(\frac{u_{i-1} - 2u_i + u_{i+1}}{h^2}\right) + u_i = e^{x_i},$$

para  $i = 2, 3, \dots, N-1$ . Rearranjando os termos e aplicando as condições de contorno, temos o problema discretizado como segue:

$$\begin{aligned} u_1 &= 1 \\ -u_{i-1} + (2 + h^2)u_i - u_{i+1} &= h^2 e^{x_i}, \quad i = 2, \dots, N-1, \\ u_N &= 2. \end{aligned}$$

O problema discreto obtido é um sistema linear  $N \times N$ . Resolvendo este sistema, obtemos a solução discreta apresentada na tabela 11.2. A figura 11.3 mostra um esboço do gráfico da solução computada.

No Scilab, podemos computar a solução numérica e graficá-la com o seguinte código:

```
//malha
a = 0.5
b = 1.5
N = 11
h = (b-a)/(N-1)
x = linspace(a,b,N) '

//sistema
```




Figura 11.3: Esboço do gráfico da solução numérica do exercício ER 11.1.1.

```

A = zeros(N,N)
b = zeros(N,1)

A(1,1) = 1
b(1) = 1
for i = 2:N-1
    A(i,i-1) = -1
    A(i,i) = 2 + h^2
    A(i,i+1) = -1
    b(i) = h^2 * exp(x(i))
end
A(N,N) = 1
b(N) = 2

//solucao
u = A\b

//grafico
plot(x,u,'b-o')

```

◇

## Exercícios

**E 11.1.1.** Considere o seguinte problema de valor de contorno para a equação de calor no estado estacionário:

$$\begin{cases} -u_{xx} = 32, & 0 < x < 1. \\ u(0) = 5 \\ u(1) = 10 \end{cases}$$

Defina  $u_j = u(x_j)$  onde  $x_j = (j-1)h$  e  $j = 1, \dots, 5$ . Aproxime a derivada segunda por um esquema de segunda ordem e transforme a equação diferencial em um sistema de equações lineares. Escreva este sistema linear na forma matricial e resolva-o. Faça o mesmo com o dobro de subintervalos, isto é, com malha de 9 pontos.

**E 11.1.2.** Considere o seguinte problema de valor de contorno para a equação de calor no estado estacionário:

$$\begin{cases} -u_{xx} = 200e^{-(x-1)^2}, & 0 < x < 2. \\ u(0) = 120 \\ u(2) = 100 \end{cases}$$

Defina  $u_j = u(x_j)$  onde  $x_j = (j-1)h$  e  $j = 1, \dots, 21$ . Aproxime a derivada segunda por um esquema de segunda ordem e transforme a equação diferencial em um sistema de equações lineares. Resolva o sistema linear obtido.

**E 11.1.3.** Considere o seguinte problema de valor de contorno para a equação de calor no estado estacionário:

$$\begin{cases} -u_{xx} = 200e^{-(x-1)^2}, & 0 < x < 2. \\ u'(0) = 0 \\ u(2) = 100 \end{cases}$$

Defina  $u_j = u(x_j)$  onde  $x_j = (j-1)h$  e  $j = 1, \dots, 21$ . Aproxime a derivada segunda por um esquema de segunda ordem, a derivada primeira na fronteira por um esquema de primeira ordem e transforme a equação diferencial em um sistema de equações lineares. Resolva o sistema linear obtido.

**E 11.1.4.** Considere o seguinte problema de valor de contorno para a equação de calor no estado estacionário com um termo não linear de radiação:

$$\begin{cases} -u_{xx} = 100 - \frac{u^4}{10000}, & 0 < x < 2. \\ u(0) = 0 \\ u(2) = 10 \end{cases}$$

Defina  $u_j = u(x_j)$  onde  $x_j = (j-1)h$  e  $j = 1, \dots, 21$ . Aproxime a derivada segunda por um esquema de segunda ordem e transforme a equação diferencial em um sistema de equações não lineares. Resolva o sistema obtido. Expresse a solução com dois algarismos depois do separador decimal. Dica: Veja problema 38 da lista 2, seção de sistemas não lineares.

**E 11.1.5.** Considere o seguinte problema de valor de contorno para a equação de calor no estado estacionário com um termo não linear de radiação e um termo de convecção:

$$\begin{cases} -u_{xx} + 3u_x = 100 - \frac{u^4}{10000}, & 0 < x < 2. \\ u'(0) = 0 \\ u(2) = 10 \end{cases}$$

Defina  $u_j = u(x_j)$  onde  $x_j = (j-1)h$  e  $j = 1, \dots, 21$ . Aproxime a derivada segunda por um esquema de segunda ordem, a derivada primeira na fronteira por um esquema de primeira ordem, a derivada primeira no interior por um esquema de segunda ordem e transforme a equação diferencial em um sistema de equações não lineares. Resolva o sistema obtido.

**E 11.1.6.** Considere o seguinte problema de valor de contorno:

$$\begin{cases} -u'' + 2u' = e^{-x} - \frac{u^2}{100}, & 1 < x < 4. \\ u'(1) + u(1) = 2 \\ u'(4) = -1 \end{cases}$$

Defina  $u_j = u(x_j)$  onde  $x_j = 1 + (j-1)h$  e  $j = 1, \dots, 101$ . Aproxime a derivada segunda por um esquema de segunda ordem, a derivada primeira na fronteira por um esquema de primeira ordem, a derivada primeira no interior por um esquema de segunda ordem e transforme a equação diferencial em um sistema de equações não lineares. Resolva o sistema obtido.

# Apêndice A

## Rápida Introdução ao Scilab

### A.1 Sobre o Scilab

Scilab é uma linguagem de programação associada com uma rica coleção de algoritmos numéricos que cobrem muitos aspectos de problemas de computação científica. Do ponto de vista de *software*, Scilab é uma linguagem interpretada. A linguagem Scilab permite a compilação dinâmica e ligação com outras linguagens como Fortran e C. Do ponto de vista de licença, Scilab é um software gratuito no sentido que o usuário não paga por ele. Além disso, Scilab é um software de código aberto disponível sobre a licença Cecill [1]. Scilab está disponível para Linux, Mac Os e Windows. Ajuda *online* está disponível em português e muitas outras línguas. Do ponto de vista científico, Scilab começou focado em soluções computacionais para problemas de álgebra linear, mas, rapidamente, o número de aplicações se estendeu para muitas áreas da computação científica.

As informações deste apêndice foram adaptadas do tutorial “Introduction to Scilab” [2], veja-o para maiores informações. Além disso, recomendamos visitar o site oficial do Scilab:

<http://www.scilab.org/>

O manual oficial do Scilab em português pode ser obtido em:

[http://help.scilab.org/docs/5.5.2/pt\\_BR/index.html](http://help.scilab.org/docs/5.5.2/pt_BR/index.html)

#### A.1.1 Instalação e Execução

O Scilab pode ser executado normalmente nos sistemas operacionais Linux, Mac Os e Windows. Muitas distribuições de Linux (Linux Mint, Ubuntu, etc.) têm o Scilab no seu sistema de pacotes (incluindo binário e documentação em várias línguas). Alternativamente, no [site de internet oficial do Scilab](http://www.scilab.org/) pode-se

obter mais versões de binários e documentação para instalação em sistemas Linux. Para a instalação em sistemas Mac Os e Windows, visite [sítio de internet oficial do Scilab](#).

### A.1.2 Usando o Scilab

O uso do Scilab pode ser feito de três formas básicas:

- usando o **console** de modo iterativo;
- usando a função **exec** para executar um código Scilab digitado em um arquivo externo;
- usando processamento *bash*.

**Exemplo A.1.1.** Considere o seguinte pseudocódigo:

```
s = "Olá Mundo!". (Sem imprimir na tela o resultado.)  
saída(s). (Imprime na tela.)
```

Implemente este pseudocódigo no Scilab: a) usando somente o console do Scilab; b) usando o editor do Scilab e executando o código com a função **exec**; c) usando processamento *bash*.

**Solução.** Seguem as soluções de cada item:

a) No console temos:

```
-->s = "Olá Mundo!";  
-->disp(s)
```

b) Para abrir o editor do Scilab pode-se digitar no **prompt**:

```
-->editor()
```

ou, alternativamente:

```
-->scinotes
```

Então, digita-se no editor o código:

```
s = "Olá Mundo!"  
disp(s)
```

salva-se em um arquivo de sua preferência (por exemplo, `~/foo.sce`) e executa-se o código clicando no botão “*play*” disponível na barra de botões do Scinotes.

- c) Para executar o código em processamento *bash*, digita-se em um editor o código:

```
s = "Olá Mundo!"
disp(s)
```

salva-se em um arquivo de sua preferência (por exemplo, `~/foo.sce`) e executa-se em um console do sistema usando a linha de comando:

```
$ scilab -nw -f ~/foo.sce
```

Digite, então, `quit` para voltar ao prompt do sistema.



## A.2 Elementos da linguagem

Scilab é uma linguagem interpretada em que todas as variáveis são matrizes. Uma variável é criada quando um valor é atribuído a ela. Por exemplo:

```
-->x=1
x =
    1.
-->y = x * 2
y =
    2.
```

a variável `x` recebe o valor `double` 1 e, logo após, na segunda linha de comando, a variável `y` recebe o valor `double` 2. Observamos que o símbolo `=` significa o operador de atribuição não o de igualdade. O operador lógico de igualdade no Scilab é `==`.

Comentários e continuação de linha de comando são usados como no seguinte exemplo:

```
-->//Isto é um comentário
-->x = 1 ..
-->+ 2
x =
    3.
```



### A.2.1 Operações matemáticas elementares

No Scilab, os operadores matemáticos elementares são os seguintes:

- + adição
- subtração
- \* multiplicação
- / divisão
- ^ potenciação (igual a \*\*)
- ' transposto conjugado

### A.2.2 Funções e constantes elementares

Várias funções e constantes elementares já estão pré-definidas no Scilab. Por exemplo:

```
-->cos(%pi) //cosseno de pi
ans =
- 1.

-->exp(1) == %e //número de Euler
ans =
T

-->log(1) //logarítmo natual de 1
ans =
0.
```

Para mais informações sobre quais as funções e constantes pré-definidas no Scilab, consulte o manual, seções “Funções elementares” e o carácter especial “%”.

### A.2.3 Operadores lógicos

No Scilab, o valor lógico verdadeiro é escrito como %T e o valor lógico falso como %F. Temos os seguintes operadores lógicos disponíveis:

- & e lógico
- | ou lógico
- ~ negação
- == igualdade
- ~= diferente
- < menor que
- > maior que

`<=` menor ou igual que  
`>=` maior ou igual que

**Exemplo A.2.1.** Se  $x = 2$ , então  $x$  é maior ou igual a 1 e menor que 3?

**Solução.** No Scilab, temos:

```
-->x=2;

-->(x >= 1) & (x < 3)
ans  =

T
```

◇

## A.3 Matrizes

No Scilab, matriz é o tipo básico de dados, a qual é definida por seu número de linhas, colunas e tipo de dado (real, inteiro, lógico, etc.). Uma matriz  $A = [a_{i,j}]_{i,j=1}^{m,n}$  no Scilab é definida usando-se a seguinte sintaxe:

$A = [ \text{a11} , \text{a12} , \dots , \text{a1n} ; \dots ; \text{am1} , \text{am2} , \dots , \text{amn} ]$

**Exemplo A.3.1.** Defina a matriz:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

**Solução.** No Scilab, digitamos:

```
-->A = [1 , 2 , 3 ; 4 , 5 , 6]
A  =
```

```
1.    2.    3.
4.    5.    6.
```

◇

A seguinte lista contém uma série de funções que geram matrizes particulares:

```
eye      matriz identidade
linspace vetor de elementos linearmente espaçados
ones     matriz cheia de uns
zeros    matriz nula
```

### A.3.1 O operador “:”

O operador “:” cria um vetor linha de elementos. A sintaxe:

```
v = i:s:j
```

cria um vetor linha:

$$v = [i, i + s, i + 2s, \dots, i + ns]$$

onde  $n$  é o maior inteiro tal que  $i + ns \leq j$ .

**Exemplo A.3.2.** Veja as seguintes linhas de comando:

```
-->v = 10:-2:3
```

```
v =
```

```
10.    8.    6.    4.
```

```
-->u = 2:6
```

```
u =
```

```
2.    3.    4.    5.    6.
```

### A.3.2 Obtendo dados de uma matriz

A função `size` retorna as dimensões de uma matriz, por exemplo:

```
-->A = ones(3,2)
```

```
A =
```

```
1.    1.
1.    1.
1.    1.
```

```
-->[nl, nc] = size(A)
```

```
nc =
```

```
2.
```

```
nl =
```

```
3.
```

informando que a matriz **A** tem três linhas e duas colunas.

Existem vários métodos para se acessar os elementos de uma matriz dada **A**:

- a matriz inteira acessa-se com a sintaxe:

$A$

- o elemento da  $i$ -ésima linha e  $j$ -ésima coluna acessa-se usando a sintaxe:

$A(i,j)$

- o bloco formado pelas linhas  $i_1, i_2$  e pelas colunas  $j_1, j_2$  obtém-se usando a sintaxe:

$A(i1:i2, j1:j2)$

**Exemplo A.3.3.** Veja as seguintes linhas de comando:

```
-->A = rand(3,4) //gera uma matriz randômica
A =

    0.2113249    0.3303271    0.8497452    0.0683740
    0.7560439    0.6653811    0.6857310    0.5608486
    0.0002211    0.6283918    0.8782165    0.6623569

-->A //mostra toda a matriz A
ans =

    0.2113249    0.3303271    0.8497452    0.0683740
    0.7560439    0.6653811    0.6857310    0.5608486
    0.0002211    0.6283918    0.8782165    0.6623569

-->A(2,3) //acessa o elemento a23
ans =

    0.6857310

-->A(2:3,2:4) //acessa um bloco de A
ans =

    0.6653811    0.6857310    0.5608486
    0.6283918    0.8782165    0.6623569
```

Definida uma matriz  $A$  no Scilab, as seguintes sintaxes são bastante úteis:

$A(:, :)$  toda a matriz

$A(i:j,k)$  os elementos das linhas  $i$  até  $j$  (inclusive) da  $k$ -ésima coluna

$A(i,j:k)$  os elementos da  $i$ -ésima linha das colunas  $j$  até  $k$  (inclusive)  
 $A(i,:)$  a  $i$ -ésima linha da matriz  
 $A(:,j)$  a  $j$ -ésima coluna da matriz  
 $A(i,\$)$  o elemento da  $i$ -ésima linha e da última coluna  
 $A(\$ ,j)$  o elemento da última linha e da  $j$ -ésima coluna

**Exemplo A.3.4.** Veja as seguintes linhas de comando:

```
-->B = rand(4,4)
B =

    0.2113249    0.6653811    0.8782165    0.7263507
    0.7560439    0.6283918    0.0683740    0.1985144
    0.0002211    0.8497452    0.5608486    0.5442573
    0.3303271    0.6857310    0.6623569    0.2320748

-->aux = B(:,2); B(:,2) = B(:,3); B(:,3) = aux
B =

    0.2113249    0.8782165    0.6653811    0.7263507
    0.7560439    0.0683740    0.6283918    0.1985144
    0.0002211    0.5608486    0.8497452    0.5442573
    0.3303271    0.6623569    0.6857310    0.2320748
```

### A.3.3 Operações matriciais e elemento-a-elemento

As operações matriciais elementares seguem a mesma sintaxe que as operações elementares de números. Agora, no Scilab, também podemos fazer operações elemento-a-elemento colocando um ponto “.” antes da operação desejada.

Aqui, temos as sintaxes análogas entre operações matriciais e operações elemento-a-elemento:

+	adição	+.	adição elemento-a-elemento
-	subtração	-.	subtração elemento-a-elemento
*	multiplicação	.*	multiplicação elemento-a-elemento
		./	divisão elemento-a-elemento
^	potenciação	.^	potenciação elemento-a-elemento
'	transposta conjugada	.'	transposta (não conjugada)

**Exemplo A.3.5.** Veja as seguintes linhas de comando:

```
-->A = ones (2 ,2)
A =
```

```

1.      1.
1.      1.

-->B = 2 * ones (2 ,2)
B =

2.      2.
2.      2.

-->A * B
ans =

4.      4.
4.      4.

-->A .* B
ans =

2.      2.
2.      2.

```

## A.4 Estruturas de ramificação e repetição

O Scilab contém estruturas de repetição e ramificação padrões de linguagens estruturadas.

### A.4.1 A instrução de ramificação “if”

A instrução “if” permite executar um pedaço do código somente se uma dada condição for satisfeita.

**Exemplo A.4.1.** Veja o seguinte código Scilab:

```

i = 2
if ( i == 1 ) then
    disp ( " Hello ! " )
elseif ( i == 2 ) then
    disp ( " Goodbye ! " )
elseif ( i == 3 ) then
    disp ( " Tchau ! " )

```

```
else
    disp ( " Au Revoir ! " )
end
```

Qual é a saída apresentada no console do Scilab? Por quê?

### A.4.2 A instrução de repetição “for”

A instrução `for` permite que um pedaço de código seja executado repetidamente.

**Exemplo A.4.2.** Veja o seguinte código:

```
for i = 1:5
    disp(i)
end
```

O que é mostrado no console do Scilab?

**Exemplo A.4.3.** Veja o seguinte código:

```
for j = 1:2:8
    disp(j)
end
```

O que é mostrado no console do Scilab?

**Exemplo A.4.4.** Veja o seguinte código:

```
for k = 10:-3:1
    disp(k)
end
```

O que é mostrado no console do Scilab?

**Exemplo A.4.5.** Veja o seguinte código:

```
for i = 1:3
    for j = 1:3
        disp([i,j])
    end
end
```

O que é mostrado no console do Scilab?

### A.4.3 A instrução de repetição “while”

A instrução `while` permite que um pedaço de código seja executado repetidamente até que uma dada condição seja satisfeita.

**Exemplo A.4.6.** Veja o seguinte código Scilab:

```
s = 0
i = 1
while ( i <= 10 )
    s = s + i
    i = i + 1
end
```

Qual é o valor de `s` ao final da execução? Por quê?

## A.5 Funções

Além das muitas funções já pré-definidas no Scilab, podemos definir nossas próprias funções. Para tanto, existem duas instruções no Scilab:

- `deff`
- `function`

A instrução `deff` é apropriada para definirmos funções com poucas computações. Quando a função exige um grande quantidade de código para ser definida, a melhor opção é usar a instrução `function`. Veja os seguintes exemplos:

**Exemplo A.5.1.** O seguinte código:

```
-->deff('y = f(x)', 'y = x + sin(x)')
```

define, no Scilab, a função  $f(x) = x + \sin x$ .

Observe que  $f(\pi) = \pi$ . Confirme isso computando:

```
-->f(%pi)
```

no Scilab.

Alternativamente, definimos a mesma função com o código:

```
function [y] = f(x)
    y = x + sin(x)
endfunction
```



Verifique!

**Exemplo A.5.2.** O seguinte código Scilab:

```
function [z] = h(x,y)
    if (x < y) then
        z = y - x
    else
        z = x - y
    end
endfunction
```

define a função:

$$h(x,y) = \begin{cases} y - x & , x < y \\ x - y & , x \geq y \end{cases}$$

**Exemplo A.5.3.** O seguinte código:

```
function [y] = J(x)
    y(1,1) = 2*x(1)
    y(1,2) = 2*x(2)

    y(2,1) = -x(2)*sin(x(1)*x(2))
    y(2,2) = -x(1)*sin(x(1)*x(2))
endfunction
```

define a matriz jacobiana  $J(x_1, x_2) := \frac{\partial(f_1, f_2)}{\partial(x_1, x_2)}$  da função:

$$f(x_1, x_2) = (x_1^2 + x_2^2, \cos(x_1 x_2)).$$

## A.6 Gráficos

Para criar um esboço do gráfico de uma função de uma variável real  $y = f(x)$ , podemos usar a função `plot`. Esta função faz uma representação gráfica de pontos  $(x_i, y_i)$  fornecidos. O Scilab oferece uma série de opções para esta função de forma que o usuário pode ajustar várias questões de visualização. Consulte sobre a função `plot` no [manual do Scilab](#).

**Exemplo A.6.1.** Veja as seguintes linhas de código:

```
-->deff('y = f(x)', 'y = x.^ 3 + 1')
-->x = linspace(-2, 2, 100);
-->plot(x, f(x)); xgrid
```

# Resposta dos Exercícios

Recomendamos ao leitor o uso criterioso das respostas aqui apresentadas. Devido a ainda muito constante atualização do livro, as respostas podem conter imprecisões e erros.

**E 2.1.1.**

a) 4; b) 9; c)  $b^2$ ; d) 7; e) 170; f) 7,125; g) 3,28

**E 2.1.5.**

$(101,1)_2$

**E 2.1.6.**

$(11,1C)_{16}$

**E 2.1.7.**

50; 18

**E 2.1.8.**

10,5;  $(1010,1)_2$

**E 2.2.1.**

a)  $2,99792458 \times 10^5$     b)  $6,62607 \times 10^{-34}$   
c)  $6,674 \times 10^{-8}$     d)  $9,80665 \times 10^4$

**E 2.2.2.** No Scilab, temos:

```
-->printf("%1.7e", 29979.458)
2.9979458e+04
-->printf("%1.5e", 66.2607)
6.62607e+01
-->printf("%1.3e", 0.6674)
6.674e-01
-->printf("%1.5e", 9806.65e1)
9.80665e+04
```

**E 2.5.2.**

a) 1,7889; b) 1788,9; c) 0,0017889; d) 0,0045966; e)  $2,1755 \times 10^{-10}$ ; f)  $2,1755 \times 10^{10}$

**E 2.5.6.**

a)  $\delta_{\text{abs}} = 3,46 \times 10^{-7}$ ,  $\delta_{\text{rel}} = 1,10 \times 10^{-7}$ ; b)  $\delta_{\text{abs}} = 1,43 \times 10^{-4}$ ,  $\delta_{\text{rel}} = 1,00 \times 10^{-3}$

**E 2.8.1.**

2% , deve-se melhorar a medida na variável  $x$ , pois, por mais que o erro relativo seja maior para esta variável, a propagação de erros através desta variáveis é muito menos importante do que para a outra variável.

**E 2.8.2.**

3,2% pela aproximação ou 3,4% pelo segundo método ( $0,96758 \leq I \leq 1,0342$ ).

**E 2.9.1.**

Quando  $\mu$  é pequeno,  $e^{1/\mu}$  é um número grande. A primeira expressão produz um "overflow" (número maior que o máximo representável) quando  $\mu$  é pequeno. A segunda expressão, no entanto, reproduz o limite 1 quando  $\mu \rightarrow 0+$ .

**E 2.9.2.**

a)  $\frac{1}{2} + \frac{x^2}{4!} + O(x^4)$ ; b)  $x/2 + O(x^2)$ ; c)  $5 \cdot 10^{-4}x + O(x^2)$ ; d)  $\frac{\sqrt{2}}{4}y + O(y^2) = \frac{\sqrt{2}}{4}x + O(x^2)$

**E 2.9.5.**

$4,12451228 \times 10^{-16}$  J; 0,002%;  $0,26654956 \times 10^{-14}$  J; 0,002%;  $4,98497440 \times 10^{-13}$  J; 0,057%;  $1,74927914 \times 10^{-12}$  J; 0,522%.

**E 2.9.6.**

Em ambos casos, temos a seguinte estrutura:

$$\begin{bmatrix} S_{11} & S_{12} \\ S_{21} & S_{22} \end{bmatrix} \begin{bmatrix} [A] \\ [B] \end{bmatrix} = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

De forma que

$$\begin{bmatrix} [A] \\ [B] \end{bmatrix} = \begin{bmatrix} S_{11} & S_{12} \\ S_{21} & S_{22} \end{bmatrix}^{-1} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \frac{1}{S_{11}S_{22} - S_{12}S_{21}} \begin{bmatrix} S_{22} & -S_{12} \\ -S_{21} & S_{11} \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

Portanto

$$\begin{aligned} [A] &= \frac{S_{22}v_1 - S_{12}v_2}{S_{11}S_{22} - S_{12}S_{21}} \\ [B] &= \frac{-S_{21}v_1 + S_{11}v_2}{S_{11}S_{22} - S_{12}S_{21}} \end{aligned}$$

Usando derivação logarítmica, temos

$$\begin{aligned} \frac{1}{[A]} \frac{\partial [A]}{\partial S_{11}} &= -\frac{S_{22}}{S_{11}S_{22} - S_{12}S_{21}} \\ \frac{1}{[A]} \frac{\partial [A]}{\partial S_{12}} &= -\frac{v_2}{S_{22}v_1 - S_{12}v_2} + \frac{S_{21}}{S_{11}S_{22} - S_{12}S_{21}} = -\frac{[A]}{[B]} \cdot \frac{S_{22}}{S_{11}S_{22} - S_{12}S_{21}} \\ \frac{1}{[A]} \frac{\partial [A]}{\partial S_{21}} &= \frac{S_{12}}{S_{11}S_{22} - S_{12}S_{21}} \\ \frac{1}{[A]} \frac{\partial [A]}{\partial S_{22}} &= \frac{v_1}{S_{22}v_1 - S_{12}v_2} - \frac{S_{11}}{S_{11}S_{22} - S_{12}S_{21}} = \frac{[A]}{[B]} \cdot \frac{S_{12}}{S_{11}S_{22} - S_{12}S_{21}} \end{aligned}$$

e

$$\begin{aligned} \frac{1}{[B]} \frac{\partial [B]}{\partial S_{11}} &= \frac{v_2}{-S_{21}v_1 + S_{11}v_2} - \frac{S_{22}}{S_{11}S_{22} - S_{12}S_{21}} = \frac{[B]}{[A]} \frac{S_{21}}{S_{11}S_{22} - S_{12}S_{21}} \\ \frac{1}{[B]} \frac{\partial [B]}{\partial S_{12}} &= \frac{S_{21}}{S_{11}S_{22} - S_{12}S_{21}} \\ \frac{1}{[B]} \frac{\partial [B]}{\partial S_{21}} &= -\frac{v_1}{-S_{21}v_1 + S_{11}v_2} + \frac{S_{21}}{S_{11}S_{22} - S_{12}S_{21}} = -\frac{[B]}{[A]} \frac{S_{11}}{S_{11}S_{22} - S_{12}S_{21}} \\ \frac{1}{[B]} \frac{\partial [B]}{\partial S_{22}} &= -\frac{S_{11}}{S_{11}S_{22} - S_{12}S_{21}} \end{aligned}$$

E o erro associado às medidas pode ser aproximado por

$$\begin{aligned} \frac{1}{[A]} \delta_{[A]} &= \left| \frac{1}{[A]} \frac{\partial [A]}{\partial S_{11}} \right| \delta_{S_{11}} + \left| \frac{1}{[A]} \frac{\partial [A]}{\partial S_{12}} \right| \delta_{S_{12}} + \left| \frac{1}{[A]} \frac{\partial [A]}{\partial S_{21}} \right| \delta_{S_{21}} + \left| \frac{1}{[A]} \frac{\partial [A]}{\partial S_{22}} \right| \delta_{S_{22}} \\ &= \frac{1}{|\det S|} \left[ S_{22} \delta_{S_{11}} + \frac{[A]}{[B]} S_{22} \delta_{S_{12}} + S_{12} \delta_{S_{21}} + \frac{[A]}{[B]} S_{12} \delta_{S_{22}} \right] \end{aligned}$$

Analogamente, temos:

$$\frac{1}{[B]} \delta_{[B]} = \frac{1}{|\det S|} \left[ \frac{[B]}{[A]} S_{21} \delta_{S_{11}} + S_{21} \delta_{S_{11}} + \frac{[B]}{[A]} S_{11} \delta_{S_{21}} + S_{11} \delta_{S_{22}} \right]$$

onde não se indicou  $|S_{ij}|$  nem  $|\cdot|$  pois são todos positivos.

Fazemos agora a aplicação numérica:

**Caso do par 1-2:**

$$\det S = \begin{vmatrix} 270 & 30 \\ 140 & 20 \end{vmatrix} = 1200$$

$$\begin{aligned} \frac{1}{[A]} \delta_{[A]} &= \frac{1}{1200} [20 \times 270 \times 2\% + 20 \times 30 \times 2\% + 30 \times 140 \times 2\% + 30 \times 20 \times 2\%] \\ &= \frac{216}{1200} = 0.18 = 18\% \\ \frac{1}{[B]} \delta_{[B]} &= \frac{1}{1200} [140 \times 270 \times 2\% + 140 \times 30 \times 2\% + 270 \times 140 \times 2\% + 270 \times 20 \times 2\%] \\ &= \frac{426}{1200} = 0.355 = 35.5\% \end{aligned}$$

**Caso do par 1-3:**

$$\det S = \begin{vmatrix} 270 & 30 \\ 15 & 200 \end{vmatrix} = 53550$$

$$\begin{aligned} \frac{1}{[A]} \delta_{[A]} &= \frac{1}{53550} [200 \times 270 \times 2\% + 200 \times 30 \times 2\% + 30 \times 15 \times 10\% + 30 \times 200 \times 10\%] \\ &= \frac{1804,6}{52550} \approx 0.0337 = 3.37\% \\ \frac{1}{[B]} \delta_{[B]} &= \frac{1}{53550} [15 \times 270 \times 2\% + 15 \times 30 \times 2\% + 270 \times 15 \times 10\% + 270 \times 200 \times 10\%] \\ &= \frac{5895}{53550} \approx 0.11 = 11\% \end{aligned}$$

Conclusão, apesar de o sensor 3 apresentar uma incerteza cinco vezes maior na sensibilidade, a escolha do sensor 3 para fazer par ao sensor 1 parece mais adequada.

#### E 3.1.1.

Observamos que a equação é equivalente a  $\cos(x) - x = 0$ . Tomando, então,  $f(x) = \cos(x) - x$ , temos que  $f(x)$  é contínua em  $[0, \pi/2]$ ,  $f(0) = 1$  e  $f(\pi/2) = -\pi/2 < 0$ . Logo, do teorema de Bolzano 3.1.1, concluímos que a equação dada tem pelo menos uma solução no intervalo  $(0, \pi/2)$ .

#### E 3.1.2.

No exercício 3.1.1, mostramos que a função  $f(x) = \cos(x) - x$  tem um zero no intervalo  $[0, \pi/2]$ . Agora, observamos que  $f'(x) = -\sin(x) - 1$ . Como  $0 < \sin x < 1$  para todo  $x \in (0, \pi/2)$ , temos que  $f'(x) < 0$  em  $(0, \pi/2)$ , isto é,  $f(x)$  é monotonicamente decrescente neste intervalo. Logo, da proposição 3.1.1, temos que existe um único zero da função neste intervalo.

#### E 3.1.3.

$$k \approx 0,161228$$

#### E 3.1.5.

Escolhendo o intervalo  $[a, b] = [-1,841 - 10^{-3}, -1,841 + 10^{-3}]$ , temos  $f(a) \approx 5 \times 10^{-4} > 0$  e  $f(b) \approx -1,2 \times 10^{-3} < 0$ , isto é,  $f(a) \cdot f(b) < 0$ . Então, o teorema de Bolzano nos garante que o zero exato  $x^*$  de  $f(x)$  está no intervalo  $(a, b)$ . Logo, da escolha feita,  $|-1,841 - x^*| < 10^{-3}$ .

**E 3.1.6.** Basta aplicar as ideias da solução do exercício 3.1.5.

#### E 3.2.2.

A primeira raiz se encontra no intervalo  $(0,4,0,5)$ . A segunda raiz no intervalo  $(1,7,1,8)$ . A terceira raiz se encontra no intervalo  $(2,5,2,6)$ .

**E 3.2.4.**

1,390054; 1,8913954; 2,4895673; 3,1641544; 3,8965468

**E 3.2.5.** $k\theta = \frac{IP}{2} \cos(\theta)$  com  $\theta \in (0, \pi/2)$ ; 1,030.**E 3.2.6.**

19; 23; 26; 0,567143; 1,745528; 3,385630

**E 3.2.8.**

a) 0,623; b) 0,559; c) 0,500; d) 0,300; e) -0,3; f) -30; g) -30

**E 3.2.9.**a) 0,0294; b)  $2.44e - 3$ ; c)  $2.50e - 4$ ; d)  $1.09 \cdot 10^{-7}$ ; e)  $-10^{-12}$ ; f)  $-10^{-12}$ ; g)  $-10^{-12}$ **E 3.3.1.**

-1,8414057

**E 3.3.2.**

0,7391

**E 3.3.3.**Tomemos  $x^{(1)} = 1$  como aproximação inicial para a solução deste problema, iterando a primeira sequência a), obtemos:

$$\begin{aligned}
 x^{(1)} &= 1 \\
 x^{(2)} &= \ln\left(\frac{10}{1}\right) = 2,3025851 \\
 x^{(3)} &= \ln\left(\frac{10}{2,3025851}\right) = 1,4685526 \\
 &\vdots \\
 x^{(21)} &= 1,7455151 \\
 x^{(31)} &= 1,745528 \\
 x^{(32)} &= 1,745528
 \end{aligned}$$

Iterando a segunda sequência b), obtemos:

$$\begin{aligned}
 x^{(1)} &= 1 \\
 x^{(2)} &= 10e^{-1} = 3,6787944 \\
 x^{(3)} &= 10e^{-3,6787944} = 0,2525340 \\
 x^{(4)} &= 10e^{-0,2525340} = 7,7682979 \\
 x^{(5)} &= 10e^{-7,7682979} = 0,0042293 \\
 x^{(6)} &= 10e^{-0,0042293} = 9,9577961
 \end{aligned}$$

Este experimento numérico sugere que a iteração a) converge para 1,745528 e a iteração b) não é convergente.

**E 3.3.10.**

0.0431266

**E 3.4.1.** raiz:0,82413, processo iterativo:  $x^{(n+1)} = x^{(n)} + \frac{\cos(x) - x^2}{\sin(x) + 2x}$ 

```

-->x=1
-->x=x+(cos(x)-x^2)/(sin(x)+2*x)
-->x=x+(cos(x)-x^2)/(sin(x)+2*x)
-->x=x+(cos(x)-x^2)/(sin(x)+2*x)
-->x=x+(cos(x)-x^2)/(sin(x)+2*x)

```

**E 3.4.2.**

- a) Primeiramente, deve-se observar que a função  $\operatorname{tg}(x)$  não está definida quando  $x$  é um múltiplo ímpar de  $\frac{\pi}{2}$ , pelo que devemos cuidado nas singularidades. Traçamos o gráfico da função  $f(x) = \operatorname{tg}(x) - 2x^2$  no Scilab usando os seguintes comandos:

```
-->def('y=f(x)', 'y=tan(x)-2*x^2')
-->plot([0:.01:1.3], f)
```

Observamos facilmente uma raiz no intervalo  $(0,5, 0,6)$  e outra no intervalo  $(1,2, 1,3)$ . Como a função  $f(x)$  é contínua fora dos pontos de singularidade da tangente, é fácil verificar que existe pelo menos uma solução nos intervalos dados pelo teorema de Bolzano [3.1.1](#):

$$\begin{aligned} f(0,5) &\approx 0,046302 > 0 \\ f(0,6) &\approx -0,035863 < 0 \\ f(1,2) &\approx -0,30784e - 1 < 0 \\ f(1,3) &\approx 0,22210e - 1 > 0 \end{aligned}$$

Para provar a unicidade da solução em cada intervalo, precisamos mostra que a função é monótona, ou seja, a derivada não muda de sinal em cada intervalo:

$$\begin{aligned} f'(x) = \sec^2(x) - 4x &= \frac{1}{\cos^2(x)} - 4x \leq \frac{1}{\cos^2(0,6)} - 4 * 0,5 < 0, \quad x \in [0,5, 0,6] \\ f'(x) = \sec^2(x) - 4x &= \frac{1}{\cos^2(x)} - 4x \geq \frac{1}{\cos^2(1,2)} - 4 * 1,3 > 0, \quad x \in [1,2, 1,3] \end{aligned}$$

- b) Para recalculas as raízes pelo método de Newton, basta executar a interação

$$x^{(n+1)} = x^{(n)} - \frac{f(x^{(n)})}{f'(x^{(n)})}$$

Em relação à observação, o erro se deveu à falta de cuidado em compreender o problema antes de tentar resolvê-lo, em especial, à falta de observar que a função é descontínua em múltiplos ímpares de  $\frac{\pi}{2}$ . Nestes pontos, a função  $f(x)$  troca de sinal, mas não passa por zero.

**E 3.4.3.** 0,65291864

**E 3.4.4.** 0,0198679; 0,533890; 0,735412; 1,13237 e 1,38851.

**E 3.4.6.** -99.99970, -0.3376513; -1.314006.

**E 3.4.9.**

$x_0 > 1$ .

**E 3.4.10.**

$$\begin{aligned} x^{(0)} &= \text{C.I.} \\ x^{(n+1)} &= x^{(n)} \left( 2 - Ax^{(n)} \right) \end{aligned}$$

**E 3.4.11.**

$$\begin{aligned} x_0 &= \text{C.I.} \\ x^{(n+1)} &= x^{(n)} \left( 1 - \frac{1}{n} \right) + \frac{A}{nx^{(n)}} \end{aligned}$$

**E 3.4.12.**

$$\begin{aligned} x_0 &= \text{C.I.} \\ x^{(n+1)} &= x^{(n)} + \frac{x^{(n)} - Ax^{(n)}}{2} = \frac{(3-A)x^{(n)}}{2} \end{aligned}$$

**E 3.6.5.**

Seja  $f(x) \in C^2$  um função tal que  $f(x^*) = 0$  e  $f'(x^*) \neq 0$ . Considere o processo iterativo do método das secantes:

$$x^{(n+1)} = x^{(n)} - \frac{f(x^{(n)})}{f(x^{(n)}) - f(x^{(n-1)})} (x^{(n)} - x^{(n-1)})$$

Esta expressão pode ser escrita como:

$$\begin{aligned} x^{(n+1)} &= x^{(n)} - \frac{f(x^{(n)})(x^{(n)} - x^{(n-1)})}{f(x^{(n)}) - f(x^{(n-1)})} \\ &= \frac{x^{(n)} \left( f(x^{(n)}) - f(x^{(n-1)}) \right) - f(x^{(n)})(x^{(n)} - x^{(n-1)})}{f(x^{(n)}) - f(x^{(n-1)})} \\ &= \frac{x^{(n)} f(x^{(n-1)}) - x^{(n-1)} f(x^{(n)})}{f(x^{(n)}) - f(x^{(n-1)})} \end{aligned}$$

Subtraindo  $x^*$  de ambos os lados temos:

$$\begin{aligned} x^{(n+1)} - x^* &= \frac{x^{(n)} f(x^{(n-1)}) - x^{(n-1)} f(x^{(n)})}{f(x^{(n)}) - f(x^{(n-1)})} - x^* \\ &= \frac{x^{(n)} f(x^{(n-1)}) - x^{(n-1)} f(x^{(n)}) - x^* \left( f(x^{(n)}) - f(x^{(n-1)}) \right)}{f(x^{(n)}) - f(x^{(n-1)})} \\ &= \frac{(x^{(n)} - x^*) f(x^{(n-1)}) - (x^{(n-1)} - x^*) f(x^{(n)})}{f(x^{(n)}) - f(x^{(n-1)})} \end{aligned}$$

Definimos  $\epsilon_n = x_n - x^*$ , equivalente a  $x_n = x^* + \epsilon_n$

$$\epsilon_{n+1} = \frac{\epsilon_n f(x^* + \epsilon_{n-1}) - \epsilon_{n-1} f(x^* + \epsilon_n)}{f(x^* + \epsilon_n) - f(x^* + \epsilon_{n-1})}$$

Aproximamos a função  $f(x)$  no numerador por

$$\begin{aligned} f(x^* + \epsilon) &\approx f(x^*) + \epsilon f'(x^*) + \epsilon^2 \frac{f''(x^*)}{2} \\ f(x^* + \epsilon) &\approx \epsilon f'(x^*) + \epsilon^2 \frac{f''(x^*)}{2} \end{aligned}$$

$$\begin{aligned} \epsilon_{n+1} &\approx \frac{\epsilon_n \left[ \epsilon_{n-1} f'(x^*) + \epsilon_{n-1}^2 \frac{f''(x^*)}{2} \right] - \epsilon_{n-1} \left[ \epsilon_n f'(x^*) + \epsilon_n^2 \frac{f''(x^*)}{2} \right]}{f(x^* + \epsilon_n) - f(x^* + \epsilon_{n-1})} \\ &= \frac{\frac{f''(x^*)}{2} (\epsilon_n \epsilon_{n-1}^2 - \epsilon_{n-1} \epsilon_n^2)}{f(x^* + \epsilon_n) - f(x^* + \epsilon_{n-1})} \\ &= \frac{1}{2} f''(x^*) \frac{\epsilon_n \epsilon_{n-1} (\epsilon_{n-1} - \epsilon_n)}{f(x^* + \epsilon_n) - f(x^* + \epsilon_{n-1})} \end{aligned}$$

Observamos, agora, que

$$\begin{aligned} f(x^* + \epsilon_n) - f(x^* + \epsilon_{n-1}) &\approx \left[ f(x^*) + f'(x^*) \epsilon_n \right] - \left[ f(x^*) + f'(x^*) \epsilon_{n-1} \right] \\ &= f'(x^*) (\epsilon_n - \epsilon_{n-1}) \end{aligned} \tag{3.6}$$

Portanto:

$$\epsilon_{n+1} \approx \frac{1}{2} \frac{f''(x^*)}{f'(x^*)} \epsilon_n \epsilon_{n-1} \quad (3.7)$$

ou, equivalentemente:

$$x^{(n+1)} - x^* \approx \frac{1}{2} \frac{f''(x^*)}{f'(x^*)} (x^{(n)} - x^*) (x^{(n-1)} - x^*) \quad (3.8)$$

**E 3.7.2.**

$x > a$  com  $a \approx 0,4193648$ .

**E 3.7.3.**

$z_1 \approx 0.3252768$ ,  $z_2 \approx 1.5153738$ ,  $z_3 \approx 2.497846$ ,  $z_4 \approx 3.5002901$ ,  $z_j \approx j - 1/2 - (-1)^j \frac{e^{-2j+1}}{\pi}$ ,  $j > 4$

**E 3.7.4.**

150 W, 133 W, 87 W, 55 W, 6,5 W

**E 3.7.5.**

a) 42 s e 8 min2 s, b) 14 min56 s.

**E 3.7.6.**

118940992

**E 3.7.7.**

7,7 cm

**E 3.7.8.**

4,32 cm

**E 3.7.9.**

(0,652919, 0,426303)

**E 3.7.10.**

7,19% ao mês

**E 3.7.11.**

4,54% ao mês.

**E 3.7.12.**

500 K, 700 K em  $t = 3 \ln(2)$ , 26 min, 4 h27 min.

**E 3.7.13.**

$(\pm 1,1101388, -0,7675919)$ ,  $(\pm 1,5602111, 0,342585)$

**E 3.7.14.**

1,5318075

**E 3.7.15.**

Aproximadamente 2500 reais por hora.

**E 3.7.16.**

a) 332,74 K b) 359,33 K

**E 3.7.17.**

1,2285751, 4,76770758, 7,88704085



**E 4.1.1.**

Escrevemos o sistema na forma matricial e resolvemos:

$$\begin{aligned}
 \left[ \begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 1 & 0 & 10 & -48 \\ 0 & 10 & 1 & 25 \end{array} \right] &\sim \left[ \begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 0 & -1 & 9 & -48 \\ 0 & 10 & 1 & 25 \end{array} \right] \sim \left[ \begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 0 & 10 & 1 & 25 \\ 0 & -1 & 9 & -48 \end{array} \right] \sim \\
 &\sim \left[ \begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 0 & 10 & 1 & 25 \\ 0 & 0 & 9.1 & -45.5 \end{array} \right] \sim \left[ \begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 0 & 10 & 1 & 25 \\ 0 & 0 & 1 & -5 \end{array} \right] \sim \\
 &\sim \left[ \begin{array}{ccc|c} 1 & 1 & 0 & 5 \\ 0 & 10 & 0 & 30 \\ 0 & 0 & 1 & -5 \end{array} \right] \sim \left[ \begin{array}{ccc|c} 1 & 1 & 0 & 5 \\ 0 & 1 & 0 & 3 \\ 0 & 0 & 1 & -5 \end{array} \right] \sim \\
 &\sim \left[ \begin{array}{ccc|c} 1 & 0 & 0 & 2 \\ 0 & 1 & 0 & 3 \\ 0 & 0 & 1 & -5 \end{array} \right]
 \end{aligned}$$

Portanto  $x = 2$ ,  $y = 3$ ,  $z = -5$

**E 4.1.5.**

a)  $x = [4 \ 3 \ 2]^T$

b) O sistema é equivalente a

$$\begin{array}{rclclcl}
 \varepsilon x_1 & + & \varepsilon x_2 & + & (1 + \varepsilon)x_3 & = & 2 \\
 \varepsilon x_1 & + & (1 + \varepsilon)x_2 & + & \varepsilon x_3 & = & 3 \\
 (1 + \varepsilon)x_1 & + & \varepsilon x_2 & + & \varepsilon x_3 & = & 4
 \end{array}$$

Somando as três equações temos

$$(1 + 3\varepsilon)(x_1 + x_2 + x_3) = 9 \implies x_1 + x_2 + x_3 = \frac{9}{1 + 3\varepsilon}$$

Subtraímos  $\varepsilon(x_1 + x_2 + x_3)$  da cada equação do sistema original e temos:

$$\begin{aligned}
 x_3 &= 2 - \frac{9\varepsilon}{1+3\varepsilon} \\
 x_2 &= 3 - \frac{9\varepsilon}{1+3\varepsilon} \\
 x_1 &= 4 - \frac{9\varepsilon}{1+3\varepsilon}
 \end{aligned}$$

Assim, temos:

$$x_\varepsilon = [4 \ 3 \ 2]^T - \frac{9\varepsilon}{1 + 3\varepsilon} [1 \ 1 \ 1]^T$$

**E 4.1.6.**  $x = [1.6890368 \ 1.6890368 \ 1.5823257 \ 1.2667776 \ 0.6333888]^T$

**E 4.1.7.**

$$\left[ \begin{array}{ccc} 1 & 1/2 & -1/2 \\ 1/3 & -1/2 & 1/6 \\ -1/3 & 0 & 1/3 \end{array} \right]$$

**E 4.5.1.**

$$\begin{aligned}
 a &= (0, 1, 2, 1, 2, 1) \\
 b &= (5, 3, 4, 2, 3, 2) \\
 c &= (4, 1, 1, 1, 2, 0) \\
 d &= (13, 10, 20, 16, 35, 17) \\
 x &= (1, 2, 3, 4, 5, 6)
 \end{aligned}$$

**E 4.5.2.**

$$\begin{aligned}
a &= (0, -1, -1, -1, -1, -1, -1, -1, -1, -1, -1/2) \\
b &= (1, 5, 5, 5, 5, 5, 5, 5, 5, 5, 1) \\
c &= (-1, -1, -1, -1, -1, -1, -1, -1, -1, -1, 0) \\
d &= (0, \cos(2/10), \cos(3/10), \cos(4/10), \cos(5/10), \\
&\quad \cos(6/10), \cos(7/10), \cos(8/10), \cos(9/10), \cos(1), 0) \\
x &= (0,324295, 0,324295, 0,317115, 0,305943, 0,291539, \\
&\quad 0,274169, 0,253971, 0,230846, 0,20355, 0,165301, 0,082650)
\end{aligned}$$

**E 4.6.1.**

$\lambda = \frac{71 \times 30}{41} \approx 51.95122$ , para  $\lambda = 51$ :  $k_1 = k_\infty = 350.4$ ,  $k_2 = 262.1$ . Para  $\lambda = 52$ :  $k_1 = k_\infty = 6888$ ,  $k_2 = 5163$ .

**E 4.6.2.**

$k_1(A) = 36$ ,  $k_2(A) = 18,26$ ,  $K_\infty(A) = 20,8$ .

**E 4.6.3.**

$k_1 = k_\infty = 6888$ ,  $k_2 = \sqrt{26656567}$  e  $k_1 = 180$ ,  $k_2 = 128,40972$  e  $k_\infty = 210$

**E 4.6.4.**

$\frac{18}{\varepsilon} + 3$ . Quando  $\varepsilon \rightarrow 0+$ , a matriz converge para uma matriz singular e o número de condicionamento diverge para  $+\infty$ .

**E 4.6.5.**

As soluções são  $[-0.0000990 \ 0.0000098]^T$  e  $[0.0098029 \ 0.0990294]^T$ . A grande variação na solução em função de pequena variação nos dados é devido ao mau condicionamento da matriz ( $k_1 \approx 1186274.3$ ).

Exemplo de implementação:

```

A=[1e5 -1e4+1e-2; -1e4+1e-2 1000.1]
b1=[-10 1]'
b2=[-9.999 1.01]'
A\b1
A\b2

```

**E 4.6.6.** 0,695; 0,292; 0,188; 0,0237; 0,0123; 0,00967

Exemplo de implementação:

```

J=[1:1:10]
x=sin(J/10)
y=J/10
z=y-y.^3/6
e=abs(x-y)./x
f=abs(x-z)./x
norm(e,1)
norm(e,2)
norm(e,'inf')
norm(f,1)
norm(f,2)
norm(f,'inf')

```

**E 4.7.1.**

```

epsilon=1e-3;

A=[1 -1 0 0 0; -1 2 -1 0 0; 0 -1 (2+epsilon) -1 0; 0 0 -1 2 -1; 0 0 0 1 -1]

v=[1 1 1 1 1]'
xgauss=gauss([A v])

function x=q_Jacobi()
    x0=[0 0 0 0 0]'

    i=0
    controle=0
    while controle<3 & i<1000
        i=i+1
    end
end

```

```

x(1)=1+x0(2)
x(2)=(1+x0(3)+x0(1))/2
x(3)=(1+x0(2)+x0(4))/(2+epsilon)
x(4)=(1+x0(3)+x0(5))/2
x(5)=x0(4)-1

delta=norm(x-x0,2)
if delta<1e-6 then
    controle=controle+1
else
    controle=0
end
mprintf('i=%d, x1=%f, x5=%f, tol=%.12f\n', i, x(1), x(5), delta)
x0=x;
end

endfunction

function x=q_Gauss_Seidel()
    x0=[0 0 0 0 0]';

    i=0
    controle=0
    while controle<3 & i<15000
        i=i+1

        x(1)=1+x0(2)
        x(2)=(1+x0(3)+x(1))/2
        x(3)=(1+x(2)+x0(4))/(2+epsilon)
        x(4)=(1+x(3)+x0(5))/2
        x(5)=x(4)-1

        delta=norm(x-x0,2)
        if delta<1e-2 then
            controle=controle+1
        else
            controle=0
        end
        mprintf('i=%d, x1=%f, x5=%f, tol=%.12f\n',i,x(1),x(5),delta)
        x0=x;
    end

endfunction

```

**E 4.7.4.**

0,324295, 0,324295, 0,317115, 0,305943, 0,291539, 0,274169, 0,253971, 0,230846, 0,203551, 0,165301, 0,082650  
 Exemplos de rotinas:

```

function x=jacobi()
    x0=zeros(11,1)
    k=0;
    controle=0;
    while controle<3 & k<1000
        k=k+1
        x(1)=x0(2)
        for j=2:10
            x(j)=(cos(j/10)+x0(j-1)+x0(j+1))/5
        end
        x(11)=x0(10)/2

        delta=norm(x-x0) //norma 2
        if delta<1e-5 then
            controle=controle+1
        else
            controle=0;
        end
        mprintf('k=%d, x=[%f,%f,%f], tol=%.12f\n',k,x(1),x(2),x(3),delta)
        x0=x;
    end

endfunction

function x=gs()
    x0=zeros(11,1)
    k=0;
    controle=0;
    while controle<3 & k<1000
        k=k+1
        x(1)=x0(2)

```

```

for j=2:10
x(j)=(cos(j/10)+x(j-1)+x0(j+1))/5
end
x(11)=x0(10)/2

delta=norm(x-x0) //norma 2
if delta<1e-5 then
    controle=controle+1
else
    controle=0;
end
fprintf('k=%d, x=[%f,%f,%f], tol=%.12f\n',k,x(1),x(2),x(3),delta)
x0=x;
end
endfunction

```

**E 4.7.5.**

Permute as linhas 1 e 2.

**E 4.8.1.**

$\lambda = 86.1785$  associado ao autovetor dado por  $v_1 = [0.65968 \ 0.66834 \ 0.34372]^T$ .

**E 4.8.3.**

158,726

**E 4.9.1.**

a)  $V_5 = 98.44V$  b)  $V_5 = 103.4V$

O problema com cinco incógnitas pode ser escrito na forma matricial conforme a seguir:

$$\begin{bmatrix}
 1 & 0 & 0 & 0 & 0 \\
 \frac{1}{R_1} & -\left(\frac{1}{R_1} + \frac{1}{R_2} + \frac{1}{R_5}\right) & \frac{1}{R_2} & 0 & 0 \\
 0 & \frac{1}{R_2} & -\left(\frac{1}{R_2} + \frac{1}{R_3} + \frac{1}{R_6}\right) & \frac{1}{R_3} & 0 \\
 0 & 0 & \frac{1}{R_3} & -\left(\frac{1}{R_3} + \frac{1}{R_4} + \frac{1}{R_7}\right) & \frac{1}{R_4} \\
 0 & 0 & 0 & \frac{1}{R_4} & -\left(\frac{1}{R_4} + \frac{1}{R_8}\right)
 \end{bmatrix}
 \begin{bmatrix}
 V_1 \\
 V_2 \\
 V_3 \\
 v_4 \\
 V_5
 \end{bmatrix}
 =
 \begin{bmatrix}
 V \\
 0 \\
 0 \\
 0 \\
 0
 \end{bmatrix}$$

Este problema pode ser implementado no Scilab (para o item a) com o seguinte código:

R1=2, R2=2, R3=2, R4=2, R5=100, R6=100, R7=100, R8=50, V=127

```

A=[1      0      0      0      0;
   1/R1  -(1/R1+1/R2+1/R5)  1/R2      0      0;
   0      1/R2  -(1/R2+1/R3+1/R6)  1/R3      0;
   0      0      1/R3  -(1/R3+1/R4+1/R7)  1/R4;
   0      0      0      1/R4  -(1/R4+1/R8)]
v=[V; 0; 0; 0; 0]
y=A\v

```

O problema com quatro incógnitas pode ser escrito na forma matricial conforme a seguir:

$$\begin{bmatrix}
 -\left(\frac{1}{R_1} + \frac{1}{R_2} + \frac{1}{R_5}\right) & \frac{1}{R_2} & 0 & 0 \\
 \frac{1}{R_2} & -\left(\frac{1}{R_2} + \frac{1}{R_3} + \frac{1}{R_6}\right) & \frac{1}{R_3} & 0 \\
 0 & \frac{1}{R_3} & -\left(\frac{1}{R_3} + \frac{1}{R_4} + \frac{1}{R_7}\right) & \frac{1}{R_4} \\
 0 & 0 & \frac{1}{R_4} & -\left(\frac{1}{R_4} + \frac{1}{R_8}\right)
 \end{bmatrix}
 \begin{bmatrix}
 V_2 \\
 V_3 \\
 v_4 \\
 V_5
 \end{bmatrix}
 =
 \begin{bmatrix}
 -\frac{V}{R_1} \\
 0 \\
 0 \\
 0
 \end{bmatrix}$$

Cuja implementação pode ser feita conforme

$$A = \begin{bmatrix} -(1/R1+1/R2+1/R5) & 1/R2 & 0 & 0; \\ 1/R2 & -(1/R2+1/R3+1/R6) & 1/R3 & 0; \\ 0 & 1/R3 & -(1/R3+1/R4+1/R7) & 1/R4; \\ 0 & 0 & 1/R4 & -(1/R4+1/R8) \end{bmatrix}$$

$$v = [-V/R1; 0; 0; 0]$$

$$y = A \backslash v$$

**E 4.9.3.**

Dica:  $P(-1) = -3$ ,  $P(1) = -1$  e  $P(2) = 9$  produzem três equações lineares para os coeficientes  $a$ ,  $b$  e  $c$ . Resp: a)  $P(x) = 3x^2 + x - 5$ , b)  $A \approx 2.49$  e  $B \approx -1.29$  c)  $A_1 \approx 1.2872058$ ,  $A_2 \approx -4.3033034$ ,  $B_1 \approx 2.051533$  e  $B_2 \approx -0.9046921$ .

$$\mathbf{E\ 5.1.1.} \quad \nabla f = [2xy - y \sin(xy), x^2 - x \sin(xy)]^T$$

$$J_F = \begin{bmatrix} \cos(x) - x \sin(x) & 1 \\ -2e^{-2x+y} & e^{-2x+y} \end{bmatrix}$$

$$(J_L)_{ij} = a_{ij}$$

**E 5.1.3.** As curvas possuem dois pontos de intersecção. A posição exata destes pontos de intersecção é dada por  $\left(\sqrt{2\sqrt{3}-3}, 2\sqrt{3}-2\right)$  e  $\left(-\sqrt{2\sqrt{3}-3}, 2\sqrt{3}-2\right)$ . Use a solução exata para comparar com a solução aproximada obtida.

$$\mathbf{E\ 5.1.4.} \quad (\pm 0.8241323, 0.6791941)$$

$$\mathbf{E\ 5.1.5.} \quad x \approx 0,259751, y \approx 0,302736, z \approx 0,045896$$

$$\mathbf{E\ 5.1.7.} \quad y = mx + b \text{ com } m \approx -0.0459710 \text{ e } b \approx 0.479237$$

Uma metodologia possível para resolver este problema é dada a seguir:

Sejam  $x_1$  e  $x_2$  as abscissas dos dois pontos em que a reta tangencia a curva. A equação da reta bitangente assume a seguinte forma:

$$y = f(x_1) + m(x - x_1)$$

onde o coeficiente angular  $m$  é dado por

$$m = \frac{f(x_2) - f(x_1)}{x_2 - x_1}$$

Da condição de tangência, temos que o coeficiente angular da reta,  $m$ , deve igual à derivada da função  $f(x)$  nos dois pontos de tangência.

$$m = f'(x_1) = f'(x_2)$$

E sabemos que:

$$f'(x) = \frac{\cos(x)}{1+x} - \frac{\sin(x)}{(1+x)^2}.$$

Assim, podemos reescrever o problema como

$$\frac{\cos(x_1)}{1+x_1} - \frac{\sin(x_1)}{(1+x_1)^2} - \frac{\cos(x_2)}{1+x_2} + \frac{\sin(x_2)}{(1+x_2)^2} = 0$$

$$\frac{\cos(x_1)}{1+x_1} - \frac{\sin(x_1)}{(1+x_1)^2} - \frac{f(x_2) - f(x_1)}{x_2 - x_1} = 0$$

Este é um sistema não-linear de duas incógnitas.

Os valores iniciais para o método podem ser obtidos do gráfico buscando valores próximos aos dois primeiros pontos de máximos. Por exemplo:  $x_1^{(0)} = 1$  e  $x_2^{(0)} = 8$ . Obtemos  $x_1 \approx 1,2464783$  e  $x_2 \approx 8,1782997$  e  $m$  pode ser obtido através desses valores.

$$\mathbf{E\ 5.1.8.} \quad (0.1956550; 0.2441719), (0.3694093; 0.4590564), (0.9990712; 1.1865168) \text{ e } (1.4773606; 1.5552232)$$

**E 5.1.9.** (0.0449310; 0.0648872; 0.0698750), (0.3981385; 0.5658310; 0.6069019),

(1.1862966; 1.4348545; 1.480127)

**E 5.1.10.**  $(-1,2085435, -1,0216674)$  e  $(2,7871115, 1,3807962)$

Exemplo de implementação:

```
function z=f(x,y)
    z=x^2/8+(y-1)^2/5-1
endfunction
function z=g(x,y)
    z=atan(x)+x-y-y^3
endfunction

contour([-3:.1:3],[-2:.1:4],f,[0 0])
contour([-3:.1:3],[-2:.1:4],g,[0 0])

function y=F(x)
    y(1)=f(x(1),x(2))
    y(2)=g(x(1),x(2))
endfunction
function y=JF(x)
    y(1,1)=x(1)/4
    y(1,2)=2*(x(2)-1)/5
    y(2,1)=1/(1+x(1)^2)+1
    y(2,2)=-1-3*x(2)^2
endfunction

//primeiro ponto
//x=[-1.2;-1.0]

//segundo ponto
//x=[2.8;1.4]

x=x-JF(x)\F(x)    // 4 vezes
```

**E 5.1.11.** A primeira curva trata-se de uma elipse de centro (3,1) e semi-eixos 4 e 6, portanto seus pontos estão contidos no retângulo  $-1 \leq x \leq 7$  e  $-5 \leq y \leq 7$ .

A soluções são  $(-0,5384844, -1,7978634)$  e  $(2,8441544, 6,9954443)$ .

Uma possível implementação é

```
function z=f(x,y)
    z=(x-3)^2/16+(y-1)^2/36-1
endfunction

function z=g(x,y)
    z=atan(x)+x-sin(y)-0.01*y^3
endfunction

contour([-1:.1:7],[-5:.1:7],f,[0 0])
contour([-1:.1:7],[-5:.1:7],g,[0 0])

function y=F(x)
    y(1)=f(x(1),x(2))
    y(2)=g(x(1),x(2))
endfunction
function y=JF(x)
    y(1,1)=(x(1)-3)/8
    y(1,2)=(x(2)-1)/18
    y(2,1)=1/(1+x(1)^2)+1
    y(2,2)=-cos(x(2))-0.03*x(2)^2
endfunction
\end{resp}

//primeiro ponto
//x=[-.5;-2.0]

//segundo ponto
//x=[3;7]

x=x-JF(x)\F(x)    // 4 vezes
```

**E 5.1.12.**  $(x_1, x_2, x_3) \approx (453,62, 901,94, 144,43)$

**E 5.1.13.** Inicialização do método:  $A^{(0)} = 3,1$  e  $b^{(0)} = \sqrt{\frac{6,7}{3,1}}$   $A \approx 3.0297384$  e  $b \approx 1.4835346$ .

**E 5.1.14.**  $f(-1,1579702, -1,2020694) \approx 2.376985$

Um exemplo de implementação no Scilab é:

```
deff('z=f(x,y)', 'z=-x^4-y^6+3*x*y^3-x')
contour([-2:.01:0], [-2:.01:0], f, [ 0:.2: 3])
deff('z=F(x)', 'z=[-4*x(1)^3+3*x(2)^3-1;-6*x(2)^5+9*x(1)*x(2)^2]')
deff('z=JF(x)', 'z=[-12*x(1)^2,9*x(2)^2;9*x(2)^2,-30*x(2)^4+18*x(1)*x(2)]')
x=[-1.2;-1.2]
x=x-JF(x)\F(x)
x=x-JF(x)\F(x)
x=x-JF(x)\F(x)
x=x-JF(x)\F(x)
mprintf('f(%f,%f)=%f',x(1),x(2),f(x(1),x(2)))
```

**E 5.1.16.**  $x \approx 0,2982646$ ,  $y \approx -0,2990796$ ,  $z \approx -1,6620333$  e  $x \approx -0,0691328$ ,  $y \approx 0,2923039$ ,  $z \approx -0,8235705$ .

**E 5.1.17.**

$$F(x) = \begin{bmatrix} x_1 - x_2 \\ -x_1 + 5(x_2 + x_2^3) - x_3 - 10 \exp(-2/3) \\ -x_2 + 5(x_3 + x_3^3) - x_4 - 10 \exp(-3/3) \\ -x_3 + 5(x_4 + x_4^3) - x_5 - 10 \exp(-4/3) \\ \vdots \\ -x_9 + 5(x_{10} + x_{10}^3) - x_{11} - 10 \exp(-10/3) \\ x_{11} - 1 \end{bmatrix}$$

$$J_F(x) = \begin{bmatrix} 1 & -1 & 0 & 0 & 0 & \dots & 0 \\ -1 & 5(1 + 3x_2^2) & -1 & 0 & 0 & \dots & 0 \\ 0 & -1 & 5(1 + 3x_3^2) & -1 & 0 & \dots & 0 \\ 0 & 0 & -1 & 5(1 + 3x_4^2) & -1 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & & \ddots & \vdots \\ 0 & 0 & 0 & 0 & 0 & \dots & 1 \end{bmatrix}$$

Exemplo de implementação no Scilab:

```
function y=F(x)
y(1)=x(1)-x(2)
for j=2:10
y(j)=-x(j-1)+5*(x(j)+x(j)^3)-x(j+1)-10*exp(-j/3)
end
y(11)=x(11)-1
endfunction

function y=JF(x)
y=zeros(11,11)
y(1,1)=1
y(1,2)=-1
for j=2:10
y(j,j-1)=-1
y(j,j)=5*(1+3*x(j)^2)
y(j,j+1)=-1
end
y(11,11)=1
endfunction
```

Resposta final: 0,80447, 0,80447, 0,68686, 0,57124, 0,46535, 0,37061, 0,28883, 0,22433, 0,19443, 0,28667, 1

**E 5.1.18.**  $f(0,8108792, 1,6217584) \approx 0,1950369$  e  $f(0,5527864, 1,1055728) \approx 0,1455298$

**E 6.1.1.**

$$p(x) = -3 + 2x + 5x^3.$$

**E 6.1.2.**

$$p(x) = 0,25 + x^2.$$

**E 6.1.3.**

a) Uma parábola de equação  $y = a_1 + a_2x + a_3x^2$  que interpola os pontos deve satisfazer o sistema:

$$a_1 + a_2x_1 + a_3x_1^2 = y_1$$

$$a_1 + a_2x_2 + a_3x_2^2 = y_2$$

Sem perda de generalidade, para cada  $a_3 \in \mathbb{R}$  dado, temos:

$$a_1 + a_2x_1 = y_1 - a_3x_1^2$$

$$a_1 + a_2x_2 = y_2 - a_3x_2^2,$$

o qual tem solução única, pois  $x_1 \neq x_2$ . Ou seja, para cada  $a_3 \in \mathbb{R}$  dado, existem  $a_1, a_2 \in \mathbb{R}$  tais que a parábola de equação  $y = a_1 + a_2x + a_3x^2$  interpola os pontos dados.

b) Certamente não existem retas de equação  $x = a$  que interpolam os pontos dados. Consideremos então retas de equação  $y = a_1 + a_2x$ . Para uma tal reta interpolar os pontos dados é necessário que:

$$a_1 + a_2 = 1$$

$$a_1 + 2a_2 = 2,1,$$

$$a_1 + 3a_2 = 3$$

o qual é um sistema impossível.

c) Não existe uma parábola de equação  $y = a_1 + a_2x + a_3x^2$  que interpole os pontos dados, pois tal equação determina uma função de  $x$  em  $y$ . Agora, para mostrar que existem infinitas parábolas de equação  $x = a_1 + a_2y + a_3y^2$  que interpolam os pontos dados, basta seguir um raciocínio análogo ao do item a), trocando  $x$  por  $y$  e  $y$  por  $x$ .

**E 6.4.1.**

$$\int_0^1 P(x)dx = \frac{f(0)+f(1)}{2}, \quad \frac{1}{12} \max_{x \in [0,1]} |f''(x)|$$

**E 7.1.1.**  $f(x) = -0,55 - 0,01x$ .

**E 7.1.2.**  $f(x) = 0,19 - 0,47x$ .

**E 7.1.3.**

a)  $-0,6025387$ ; b)  $-0,5651848$ ; c)  $0,2851848$ ; d)  $0,1488041$ .

**E 7.1.4.**

a) Basta observar que

$$V^T V = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_N \end{bmatrix} \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_N \end{bmatrix} = \begin{bmatrix} N & \sum_{j=1}^N x_j \\ \sum_{j=1}^N x_j & \sum_{j=1}^N x_j^2 \end{bmatrix} = M$$

e

$$V^T y = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_N \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^N y_j \\ \sum_{j=1}^N x_j y_j \end{bmatrix} = w.$$



- b) Sejam  $x_i \neq x_j$  duas abscissas diferentes. Então, a  $i$ -ésima e  $j$ -ésima linhas na matriz  $V$  são linearmente independentes e, portanto, o posto de  $V$  é igual a 2. Por fim,  $V^T V$  é não singular, pois, se  $u$  é tal que  $V^T V u = 0$ , então

$$0 = u^T V^T V u = (Vu)^T (Vu) = (Vu) \cdot (Vu) \Rightarrow Vu = 0.$$

Agora,  $Vu = 0$  é uma combinação linear das linhas de  $V$  igual a zero, logo  $u = 0$ , pois as linhas de  $V$  são linearmente independentes como mostrado antes. Concluímos que se  $V^T V u = 0$ , então  $u = 0$ , isto é,  $V^T V$  é não singular.

**E 7.2.1.**  $a_1 = -0,1946029$ ,  $a_2 = 0,585986$ ,  $a_3 = -0,0112599$ .

**E 7.2.2.**  $y = -0,0407898x^2 + 2,6613293x + 1,9364598$ .

**E 7.2.3.**

a)  $a = 25,638625$ ,  $b = 9,8591874$ ,  $c = 4,9751219$ ; b)  $a = 31,475524$ ,  $b = 65,691531$ ,  $c = -272,84382$ ,  $d = 208,23621$ .

**E 8.1.3.**

a)  $f'(0) = \frac{-3f(0)+4f(h)-f(2h)}{2h} + \mathcal{O}(h^2)$

b)  $f'(0) = \frac{3f(0)-4f(-h)+f(-2h)}{2h} + \mathcal{O}(h^2)$

c)  $f'(0) = \frac{1}{h_1+h_2} l \left[ -\frac{h_2}{h_1} f(-h_1) + \left( \frac{h_2}{h_1} - \frac{h_1}{h_2} \right) f(0) + \frac{h_1}{h_2} f(h_2) \right]$

**E 8.1.4.**

Caso	a	b	c	d
$v_i = 1$	1.72	1.56	1.64	1.86
$v_i = 4.5$	2.46	1.90	2.18	1.14

**E 8.1.5.**

Segue a tabela com os valores da derivada para vários valores de  $h$ .

$h$	$10^{-2}$	$10^{-4}$	$10^{-6}$	$10^{-7}$	$10^{-8}$	$10^{-9}$
$D_{+,h}f(1,5)$	-0,3125246	-0,3161608	-0,3161973	-0,3161976	-0,3161977	-0,3161977

$h$	$10^{-10}$	$10^{-11}$	$10^{-12}$	$10^{-13}$	$10^{-14}$	$10^{-15}$
$D_{+,h}f(1,5)$	-0,3161976	-0,3161971	-0,3162332	-0,3158585	-0,3178013	-0,3747003

Observe que o valor exato é  $-0,3161977$  e o  $h$  ótimo é algo entre  $10^{-8}$  e  $10^{-9}$ .

**E 8.4.6.**

a)  $f''(0) = \frac{f(0)-2f(h)+f(2h)}{h^2} + \mathcal{O}(h)$

b)  $f''(0) = \frac{f(0)-2f(-h)+f(-2h)}{h^2} + \mathcal{O}(h)$

**E 9.1.2.**

$$I_{Simpson} = \frac{1}{3} I_{Trap} + \frac{2}{3} I_{PM}$$

**E 9.1.3.**

$n$	Ponto médio	Trapézios	Simpson
3	0.1056606	0.7503919	0.5005225
5	0.1726140	0.3964724	0.2784992
7	0.1973663	0.3062023	0.2393551
9	0.2084204	0.2721145	0.2306618

**E 9.3.2.**

-0.2310491, -0.2452073, - 0.2478649.

**E 9.3.4.**

a)-0.2472261, -0.2416451, -0.2404596, -0.2400968, -0.2399563, -0.2398928. b)-0.2393727, -0.2397994, -0.2398104, -0.2398115, -0.2398117, -0.2398117.

**E 9.4.1.**

$$a)I(h) = 4.41041 \cdot 10^{-1} - 8.49372 \cdot 10^{-12}h - 1.22104 \cdot 10^{-2}h^2 - 1.22376 \cdot 10^{-7}h^3 + 8.14294 \cdot 10^{-3}h^4$$

$$b)I(h) = 7.85398 \cdot 10^{-1} - 1.46294 \cdot 10^{-11}h - 4.16667 \cdot 10^{-2}h^2 - 2.16110 \cdot 10^{-7}h^3 + 4.65117 \cdot 10^{-6}h^4$$

$$c)I(h) = 1.58730 \cdot 10^{-3} - 9.68958 \cdot 10^{-10}h + 2.03315 \cdot 10^{-7}h^2 - 1.38695 \cdot 10^{-5}h^3 + 2.97262 \cdot 10^{-4}h^4$$

$$d)I(h) = 4.61917 \cdot 10^{-1} + 3.83229 \cdot 10^{-12}h + 2.52721 \cdot 10^{-2}h^2 + 5.48935 \cdot 10^{-8}h^3 + 5.25326 \cdot 10^{-4}h^4$$

**E 9.4.2.**

1.5707963	2.0943951		
1.8961189	2.0045598	1.9985707	
1.9742316	2.0002692	1.9999831	2.0000055

**E 9.4.3.**

0.7468337, 2.4606311, 1.6595275.

**E 9.4.5.**

$R(6,6) = -10.772065$ ,  $R(7,7) = 5.2677002$ ,  $R(8,8) = 6.1884951$ ,  $R(9,9) = 6.0554327$ ,  $R(10,10) = 6.0574643$ . O valor desta integral com oito dígitos corretos é aproximado por 6.0574613.

**E 9.5.1.**

$w_1 = 1/6$ ,  $w_2 = 2/3$ ,  $w_3 = 1/6$ . O esquema construído é o de Simpson e a ordem de exatidão é 3.

**E 9.5.2.**

3

**E 9.5.3.**

5

**E 9.5.4.**

$\int_0^1 f(x) dx \approx \frac{3}{2}f(1/3) - 2f(1/2) + \frac{3}{2}f(2/3)$  com ordem 3.

**E 9.5.5.**

5, 4, 3

**E 9.6.1.**

n	G-L	Exato	Erro Absoluto
2	0,2227		2,47E-01
3	0,4157	0,4701	5,44E-02
4	0,4437		2,64E-02
5	0,4616		8,47E-03

**E 9.7.1.**

n	b	c	d	e	f
2	2.205508	3.5733599	3.6191866	3.6185185	3.618146
4	2.5973554	3.6107456	3.6181465	3.6180970	3.6180970
6	2.7732372	3.6153069	3.6181044	3.6180970	3.6180970
8	2.880694	3.6166953	3.6180989	3.6180970	3.6180970

**Solução do item e:** Como

$$\cos(x) = 1 + \sum_{n=1}^{\infty} (-1)^n \frac{x^{2n}}{(2n)!}$$

temos

$$\frac{1 - \cos(x)}{\sqrt{x}} = - \sum_{n=1}^{\infty} (-1)^n \frac{x^{2n-1/2}}{(2n)!}, \quad x \geq 0$$

Logo, podemos integrar

$$\begin{aligned} I &= 4 + 2 \int_0^1 \frac{\cos(x) - 1}{\sqrt{|x|}} dx = 4 - 2 \sum_{n=1}^{\infty} (-1)^n \int_0^1 \frac{x^{2n-1/2}}{(2n)!} dx \\ &= 4 - 2 \sum_{n=1}^{\infty} (-1)^n \frac{1}{(2n)!(2n+1/2)} \end{aligned}$$

**Solução do item f)**

$$2 \int_0^1 \left( x^{-1/2} - \frac{x^{3/2}}{2} + \frac{x^{7/2}}{24} \right) dx = 2 \left( 2 - \frac{1}{5} + \frac{1}{54} \right) = \frac{977}{270}$$

$$2 \int_0^1 \frac{\cos(x) - P_4(x)}{\sqrt{x}} dx = \sqrt{2} \int_{-1}^1 \frac{\cos\left(\frac{1+u}{2}\right) - P_4\left(\frac{1+u}{2}\right)}{\sqrt{1+u}} du$$

**E 9.7.5.**

4.1138

**E 9.7.6.**

a) 19.2, 22.1, 23.3 b) 513.67K

**E 9.7.8.**

$$\int_{-1}^1 f(x) dx = f\left(-\frac{\sqrt{3}}{3}\right) + f\left(\frac{\sqrt{3}}{3}\right)$$

**E 9.7.9.** $w_1 = w_3 = 1$  e  $w_2 = 0$  com ordem 3.**E 10.2.1.**0,4496 com  $h = 0,1$  e 0,4660 com  $h = 0,01$ . A solução exata vale  $u(1) = \frac{1+2e^{-1}+e^{-2}}{4} = \left(\frac{1+e^{-1}}{2}\right)^2 \approx 0,4678$

**E 10.2.2.**

$u(2) \approx 0,430202$  e  $z(2) = 0,617294$  com  $h = 0,2$ ,  $u(2) \approx 0,435506$  e  $z(2) = 0,645776$  com  $h = 0,02$ ,  $u(2) \approx 0,435805$  e  $z(2) = 0,648638$  com  $h = 0,002$  e  $u(2) \approx 0,435832$  e  $z(2) = 0,648925$  com  $h = 0,0002$ .

**E 10.2.3.**

$u(2) \approx 1,161793$  com  $h = 0,1$ ,  $u(2) \approx 1,139573$  com  $h = 0,01$ ,  $u(2) \approx 1,137448$  com  $h = 0,001$ ,  $u(2) \approx 1,137237$  com  $h = 0,0001$ ,  $u(2) \approx 1,137216$  com  $h = 0,00001$

**E 10.6.1.**

$u(1) \approx 1,317078$  quando  $h = 0,1$  e  $u(1) \approx 1,317045$ .

**E 10.6.2.**

$t$	Exato	Euler	Euler melhorado	Erro Euler	Erro Euler melhorado
0.0	1.	1.	1.	0.	0.
0.1	0.826213	0.8	0.828	0.026213	0.001787
0.2	0.693094	0.656	0.695597	0.037094	0.002502
0.3	0.588333	0.547366	0.591057	0.040967	0.002724
0.4	0.504121	0.462669	0.506835	0.041453	0.002714
0.5	0.435267	0.394996	0.437861	0.040271	0.002594
0.6	0.378181	0.339894	0.380609	0.038287	0.002428
0.7	0.330305	0.294352	0.332551	0.035953	0.002246
0.8	0.289764	0.256252	0.291828	0.033512	0.002064
0.9	0.255154	0.224061	0.257043	0.031093	0.001889
1.0	0.225400	0.196634	0.227126	0.028766	0.001726

No Scilab, esta tabela pode ser produzida com o código:

```
deff('du=f(u)', 'du=-u-u^2')
sol_Euler=Euler(f,0,1,10,1)
sol_Euler_mod=Euler_mod(f,0,1,10,1)
deff('u=u_exata(t)', 'u=1/(2*exp(t)-1)')
t=[0.:1:i]
sol_exata=fval(t,u_exata)
tabela=[t sol_exata sol_Euler sol_Euler_mod abs(sol_exata-sol_Euler) abs(sol_exata-sol_Euler_mod)]
```

**E 10.19.1.**

Os valores exatos para os itens e e f são:  $\frac{1}{10} \ln\left(\frac{9}{4}\right)$  e  $\frac{1}{10} \ln(6)$

**E 10.19.2.**

O valor exato é  $\sqrt{\frac{g}{\alpha} [1 - e^{-200\alpha}]}$  em  $t = \frac{1}{\sqrt{g\alpha}} \tanh^{-1} \left( \sqrt{1 - e^{-200\alpha}} \right)$

**E 10.19.8.**

	0.5	1.0	1.5	2.0	2.5
Analítico	0.3032653	0.3678794	0.3346952	0.2706706	0.2052125
Euler	0.3315955	0.3969266	0.3563684	0.2844209	0.2128243
Euler modificado	0.3025634	0.3671929	0.3342207	0.2704083	0.2051058
Runge-Kutta Clássico	0.3032649	0.3678790	0.3346949	0.2706703	0.2052124
Adams-Bashforth ordem 4	0.3032421	0.3678319	0.3346486	0.2706329	0.2051848

	0.5	1.0	1.5	2.0	2.5
Euler	2.8D-02	2.9D-02	2.2D-02	1.4D-02	7.6D-03
Euler modificado	7.0D-04	6.9D-04	4.7D-04	2.6D-04	1.1D-04
Runge-Kutta Clássico	4.6D-07	4.7D-07	3.5D-07	2.2D-07	1.2D-07
Adams-Bashforth ordem 4	2.3D-05	4.8D-05	4.7D-05	3.8D-05	2.8D-05

	0.1	0.05	0.01	0.005	0.001
Euler	2.9D-02	5.6D-03	2.8D-03	5.5D-04	2.8D-04
Euler modificado	6.9D-04	2.5D-05	6.2D-06	2.5D-07	6.1D-08
Runge-Kutta Clássico	4.7D-07	6.9D-10	4.3D-11	6.8D-14	4.4D-15
Adams-Bashforth ordem 4	4.8D-05	9.0D-08	5.7D-09	9.2D-12	5.8D-13

**E 11.1.1.**

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 \\ 0 & -1 & 2 & -1 & 0 \\ 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \\ u_5 \end{bmatrix} = \begin{bmatrix} 5 \\ 2 \\ 2 \\ 2 \\ 10 \end{bmatrix}$$

Solução: [5, 9.25, 11.5, 11.75, 10]

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & -1 & 2 & -1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & -1 & 2 & -1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & -1 & 2 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & -1 & 2 & -1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & -1 & 2 & -1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & -1 & 2 & -1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ u_4 \\ u_5 \\ u_6 \\ u_7 \\ u_8 \\ u_9 \end{bmatrix} = \begin{bmatrix} 5 \\ 0.5 \\ 0.5 \\ 0.5 \\ 0.5 \\ 0.5 \\ 0.5 \\ 0.5 \\ 10 \end{bmatrix}$$

Solução: [5, 7.375, 9.25, 10.625, 11.5, 11.875, 11.75, 1.125, 10]

**E 11.1.2.** 120. 133.56 146.22 157.83 168.22 177.21 184.65 190.38 194.28 196.26 196.26 194.26 190.28 184.38 176.65 167.21  
156.22 143.83 130.22 115.56 100.

**E 11.1.3.** 391.13 391.13 390.24 388.29 385.12 380.56 374.44 366.61 356.95 345.38 331.82 316.27 298.73 279.27 257.99 234.99  
210.45 184.5 157.34 129.11 100.

**E 11.1.4.** 0., 6.57, 12.14, 16.73, 20.4, 23.24, 25.38, 26.93, 28, 28.7, 29.06, 29.15, 28.95, 28.46, 27.62, 26.36, 24.59, 22.18,  
19.02, 14.98, 10.

**E 11.1.5.**  $u(0) = 31.62$ ,  $u(1) = 31.50$ ,  $u(1.9) = 18.17$ .

**E 11.1.6.**  $u(1) = 1.900362$ ,  $u(2.5) = 1.943681$ ,  $u(4) = 1.456517$ .

# Referências Bibliográficas

- [1] Cecill and free software. <http://www.cecill.info>. Acessado em 30 de julho de 2015.
- [2] M. Baudin. Introduction to scilab. <http://forge.scilab.org/index.php/p/docintrotoscilab/>. Acessado em 30 de julho de 2015.
- [3] R.L. Burden and J.D. Faires. *Análise Numérica*. Cengage Learning, 8 edition, 2013.
- [4] J. P. Demailly. *Analyse Numérique et Équations Différentielles*. EDP Sciences, Grenoble, nouvelle Édition edition, 2006.
- [5] W Gautschi. Numerical analysis: An introduction birkhauser. *Barton, Mass, USA*, 1997.
- [6] Walter Gautschi and Gabriele Inglese. Lower bounds for the condition number of vandermonde matrices. *Numerische Mathematik*, 52(3):241–250, 1987/1988.
- [7] L.F. Guidi. Notas da disciplina cálculo numérico. [http://www.mat.ufrgs.br/~guidi/grad/MAT01169/calculo\\_numerico.pdf](http://www.mat.ufrgs.br/~guidi/grad/MAT01169/calculo_numerico.pdf). Acessado em julho de 2016.
- [8] E. Isaacson and H.B. Keller. *Analysis of numerical methods*. Dover, Ontário, 1994.
- [9] Arieh Iserles. *A first course in the numerical analysis of differential equations*. Cambridge university press, 2009.
- [10] W.H. Press. *Numerical Recipes 3rd Edition: The Art of Scientific Computing*. Cambridge University Press, 2007.
- [11] R. Rannacher. Einführung in die numerische mathematik (numerik 0). <http://numerik.uni-hd.de/~lehre/notes/num0/numerik0.pdf>. Acessado em 10.08.2014.

- [12] Todos os Colaboradores. Cálculo numérico - um livro colaborativo - versão com scilab. disponível em <https://www.ufrgs.br/numerico/livro/main.html>, Novembro 2016.

# Colaboradores

Aqui você encontra a lista de colaboradores do livro. Esta lista contém somente aqueles que explicitamente se manifestaram a favor de terem seus nomes registrados aqui. A lista completa de colaborações pode ser obtida no repositório GitHub do livro:

<https://github.com/livroscolaborativos/CalculoNumerico>

Além das colaborações via GitHub, o livro também recebe colaborações via discussões, sugestões e avisos deixados em nossa lista de emails:

[livro\\_colaborativo@googlegroups.com](mailto:livro_colaborativo@googlegroups.com)

Estas colaborações não estão listadas aqui, mas podem ser vistas no site do grupo de emails.

Caso encontre algum equívoco ou veja seu nome listado aqui por engano, por favor, entre em contato conosco por email:

[livroscolaborativos@gmail.com](mailto:livroscolaborativos@gmail.com)

ou via o repositório GitHub.

Tabela A.1: Lista de colaboradores

Nome	Afiliação	E-Mail	1ª Contribuição
Debora Lidia Gisch	-x-	-x-	#63



# Índice Remissivo

- ajuste
  - de uma reta, 175
  - derivação, 209
  - linear, 179
  - polinomial, 185
  - por mínimos quadrados, 174
- ajuste de curvas, 174
- algoritmo
  - de Thomas, 102
  - TDMA, 102
- aproximação
  - de funções, 151, 174
  - por polinômios, 159
- aproximações por diferenças finitas, 193
- aritmética
  - de máquina, 3
- arredondamento de números, 10
- autovalores, método da potência 128, 128
- cancelamento catastrófico, 24
- contração, 54
- critério de parada, 44
- derivação, 193
- diferenças divididas de Newton, 156
- diferenças finitas, 193
  - central, 196
  - ordem mais alta, 203
  - progressiva, 195
  - regressiva, 196
- eliminação gaussiana, 85
- equação
  - logística, 249
- equação diferencial
  - não autônoma, 250
- equações
  - de uma variável, 40
- erro
  - absoluto, 21
  - relativo, 21
- erros, 20
  - absoluto, 59
  - arredondamento, 199
  - de arredondamento, 12
- fórmula de diferenças finitas
  - central, 203
- fórmulas de diferenças finitas, 277
- função, 40
  - raiz de, 40
  - zero, 40
  - zero de, 40
- integração, 211
- integração numérica
  - método composto
    - de Simpson, 225
    - dos trapézios, 224
  - método de Romberg, 228
  - ordem de precisão, 232
  - regra de Simpson, 217, 218
  - regra do trapézio, 214
  - regras compostas, 222
  - regras de Newton-Cotes, 213
- integral, 211
- interpolação, 151
  - cúbica segmentada, 165

- derivação, 209
- linear segmentada, 163
- polinomial, 152
- iteração do ponto fixo, 40, 50
  - convergência, 58
  - estabilidade, 58
  - taxa de convergência, 55
- método
  - da bisseção, 43
  - da matrix tridiagonal, 102
  - de Euler, 247
    - ordem de precisão, 252
  - de separação de variáveis, 249
  - trapezoidal, 257
- Método da bisseção
  - taxa de convergência, 46
- método da bisseção, 40
- método das frações parciais, 249
- método das secantes, 40, 72
  - convergência, 74
- método de
  - Gauss-Seidel, 118
  - Jacobi, 116
  - Newton, 65
  - Newton-Raphson, 65
- método de diferenças finitas, 277
- Método de Jacobi
  - matriz de iteração, 122
  - vetor de iteração, 122
- método de Newton, 40
  - para sistemas, 136
- método de Newton-Raphson, 65
  - convergência, 67
- método dos mínimos quadrados, 174
- métodos iterativos
  - sistemas lineares, 115
  - convergência, 120
- malha uniforme, 278
- matrix
  - jacobiana, 135
- matriz
  - condicionamento, 109
  - diagonal dominante, 126
  - jacobiana, 147, 148
- matriz de
  - iteração, 120
- matriz de Vandermonde, 155
- medida
  - de erro, 21
  - de exatidão, 21
- mudança de base, 3
- número de condicionamento, 112
- norma
  - $L^\infty$ , 110
  - $L^p$ , 110
- norma de
  - matrizes, 111
  - vetores, 110
- passo da malha, 278
- polinômio interpolador, 153
- polinômios
  - de Lagrange, 158
- ponto fixo, 50
- porção áurea, 77
- problema de
  - ponto fixo, 50
- problema de valor de contorno, 277
- problema de valor inicial, 245
- problema discreto, 278
- Problemas de valores de contorno, 277
- quadratura numérica
  - Gauss-Legendre, 236
- representação
  - de números em máquina, 12
  - números inteiros, 12
- representação de números, 3
  - inteiros
    - bit de sinal, 13

- complemento de dois, [14](#)
  - sem sinal, [13](#)
- resíduo, [175](#)
- Scilab, [288](#)
  - elementos da linguagem, [290](#)
  - funções, [298](#)
  - funções e constantes, [291](#)
  - gráficos, [299](#)
  - instalação e execução, [288](#)
  - matrizes, [292](#)
  - operações matemáticas, [291](#)
  - operador :, [293](#)
  - operadores lógicos, [291](#)
  - ramificação e repetição, [296](#)
  - sobre, [288](#)
  - usando, [289](#)
- sequência de
  - Fibonacci, [77](#)
- simulação
  - computacional, [1](#)
  - numérica, [1](#)
- sistema de equações
  - não lineares, [133](#)
- sistema de numeração, [3](#)
- sistema linear, [84](#)
  - condicionamento, [109](#)
- sistema numérico
  - de ponto fixo, [15](#)
  - de ponto flutuante, [16](#)
  - notação normalizada, [8](#)
- sistemas
  - de equações diferenciais, [271](#)
- spline, [165](#)
  - fixado, [170](#)
  - natural, [167](#)
  - not-a-knot, [171](#)
  - periodico, [172](#)
- tamanho da malha, [278](#)
- teorema de
  - Bolzano, [40](#)
  - Teorema do
    - ponto fixo, [53](#)
  - teorema do
    - ponto fixo, [66](#)
  - teorema do valor intermediário, [40](#)
  - tolerância, [59](#)
  - vetor de
    - iteração, [120](#)